UNIVERSITÉ ABDELMALEK ESSAÂD

Faculté des Sciences et Techniques de Tanger

Licence Analytique des Données

RAPPORT DE PROJET DE FIN D'ÉTUDES

Année Universitaire 2025–2026

Analyse Intelligente du Marché SaaS

Conception d'un Système d'Aide à la Décision Basé sur l'Intelligence Artificielle

---

Réalisé par

Zakariae El Maymouni
Apogée : 21013847

Fatima Zahrae El Kostit
Apogée : 22007336

Encadrante Pédagogique
Pr. Sara Ahsain

Encadrant Professionnel
Ing. Douae El Karout

Jury

Pr. Sara Ahsain
Pr. Badr-Eddine Boudriki Semlali

Soutenu le : 24 Juin 2026

Dédicace

Nous dédions ce travail à nos chers parents pour leur amour, leur soutien indéfectible, leurs sacrifices et leurs encouragements tout au long de notre parcours académique.

À nos familles et à nos proches qui ont toujours cru en nous et nous ont accompagnés dans les moments les plus importants de notre formation.

À nos enseignants de la Faculté des Sciences et Techniques de Tanger qui ont contribué à notre apprentissage et à notre développement personnel et professionnel.

À toutes les personnes qui nous ont soutenus de près ou de loin dans la réalisation de ce projet.

Que ce travail soit le témoignage de notre profonde reconnaissance et de notre sincère gratitude.

Zakariae El Maymouni
Fatima Zahrae El Kostit

Remerciements

Avant toute chose, nous rendons grâce à Allah, le Tout-Puissant, pour nous avoir accordé la santé, la volonté et la persévérance nécessaires afin de mener ce travail à son terme.

Nous tenons à exprimer notre profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce mémoire de fin d'études.

Nos plus sincères remerciements s'adressent à **Monsieur le Professeur Abdellah Azmani**, notre encadrant de stage, pour son accompagnement, sa disponibilité, ses précieux conseils et son soutien tout au long de ce projet.

Nous adressons également nos vifs remerciements à **Madame la Professeure Sara Ahssain**, notre encadrante pédagogique, pour son suivi académique, ses remarques constructives et l'intérêt porté à notre travail.

Nous exprimons notre reconnaissance à **Madame Wafae Baida**, cheffe de filière et professeure, pour son accompagnement et son rôle essentiel dans notre parcours universitaire.

Nos remerciements vont également à **Madame la Docteure Douae El Karoute** et **Madame la Docteure Amina Jbilou**, pour leurs conseils, leurs encouragements et leurs échanges enrichissants.

Nous tenons aussi à remercier l'ensemble des enseignants du Département Informatique de la Faculté des Sciences et Techniques de Tanger pour la qualité de la formation dispensée.

Nous adressons également nos sincères remerciements aux membres du jury qui nous font l'honneur d'évaluer ce mémoire.

Enfin, nous exprimons notre profonde gratitude à nos familles, à nos amis ainsi qu'à toutes les personnes qui nous ont soutenus et encouragés tout au long de cette expérience académique.

À toutes ces personnes, nous adressons l'expression de notre sincère reconnaissance.

Résumé

Le marché des logiciels en tant que service (SaaS) connaît une croissance rapide et propose aujourd'hui un grand nombre de solutions destinées à la gestion des activités des entreprises. Face à cette diversité, le choix de la solution la plus adaptée constitue un véritable défi pour les décideurs. Dans ce contexte, ce projet vise à développer une plateforme intelligente dédiée à l'analyse du marché des solutions SaaS de facturation et à l'aide à la décision.

Pour atteindre cet objectif, une base de données regroupant plus de 1 400 solutions SaaS a été constituée. Chaque solution est décrite à travers 31 variables fonctionnelles, techniques et économiques. Une analyse exploratoire des données a été réalisée afin d'identifier les principales tendances du marché ainsi que les caractéristiques les plus influentes.

Par ailleurs, plusieurs modèles de Machine Learning ont été développés : quatre classificateurs supervisés (Random Forest, Gradient Boosting, SVM, KNN) pour prédire la classe de prix, la conformité réglementaire, le segment de taille et le niveau de satisfaction ; une régression multiple pour estimer le prix numérique exact ; et un clustering K-Means pour segmenter automatiquement le marché en groupes homogènes. L'ensemble de ces modèles génère des recommandations adaptées aux besoins des utilisateurs. Une approche basée sur les grands modèles de langage (LLM) et le Retrieval Augmented Generation (RAG) a également été intégrée afin de fournir une assistance conversationnelle intelligente et personnalisée.

Les résultats obtenus démontrent la pertinence de l'approche proposée pour faciliter la sélection des solutions SaaS et mettent en évidence l'apport significatif de l'intelligence artificielle et de l'analytique des données dans les processus d'aide à la décision.

Mots-clés : SaaS, Facturation, Intelligence Artificielle, Machine Learning, Classification, Régression, Clustering, Recommandation, RAG, LLM, Analyse de données.

Abstract

The Software as a Service (SaaS) market has experienced significant growth in recent years, offering a wide range of solutions designed to support business operations. However, the increasing number of available platforms makes the selection of the most suitable solution a complex task for organizations. In this context, this project aims to develop an intelligent platform dedicated to the analysis of the SaaS billing software market and to supporting decision-making processes.

To achieve this objective, a dataset containing more than 1,400 SaaS solutions was built. Each solution is described using 31 functional, technical, and economic variables. An Exploratory Data Analysis (EDA) was conducted to identify market trends, understand the characteristics of the available solutions, and determine the most influential features.

Furthermore, several Machine Learning models were developed : four supervised classifiers to predict pricing class, regulatory compliance, market segment, and satisfaction level ; a multiple regression model to estimate the exact numerical price ; and a K-Means clustering model to segment the market into homogeneous groups. These models collectively generate recommendations based on user requirements. To enhance user interaction, an intelligent conversational assistant was integrated using Large Language Models (LLMs) combined with a Retrieval-Augmented Generation (RAG) approach. This component enables users to obtain personalized guidance and relevant recommendations through natural language queries.

The results demonstrate the effectiveness of the proposed approach in facilitating the selection of SaaS solutions and improving decision-making processes. They also highlight the growing importance of artificial intelligence, data analytics, and recommendation systems in supporting organizations in their digital transformation initiatives.

Keywords : SaaS, Data Analytics, Machine Learning, Classification, Regression, Clustering, Recommendation Systems, Artificial Intelligence.

Table des matières

Dédicace 1

Remerciements 2

Résumé 3

Abstract 4

Lexique et Acronymes 11

INTRODUCTION GÉNÉRALE 14

1 Étude préalable 22

1.1 Introduction . . . 22
1.2 Présentation du projet . . . 26
1.2.1 Qu'est-ce que l'analyse intelligente du marché SaaS ? (Quoi ?) . 26
1.2.2 Notions fondamentales . . . 26
1.2.3 Intérêt du projet (Pourquoi ?) . . . 28
1.2.4 À qui s'adresse ce projet ? (Pour qui ?) . . . 29
1.3 Cadrage logique du stage . . . 31
1.3.1 Problématiques et enjeux . . . 31
1.3.2 Arbre à problèmes . . . 31
1.3.3 Arbre à solutions . . . 32
1.3.4 Objectifs et résultats . . . 33
1.3.5 Activités nécessaires . . . 34
1.3.6 Contrôle et suivi des travaux . . . 34
1.4 Veilles concurrentielle et technologique . . . 35
1.4.1 Veille concurrentielle . . . 35
1.4.2 Veille technologique . . . 37
1.5 Éléments du Cahier des charges — Spécifications fonctionnelles . . . 42
1.6 Maquettage . . . 43
1.7 Conclusion . . . 44

2 Modélisation par intelligence artificielle 46
2.1 Introduction . . . 46
2.2 Objectifs recherchés en matière d'apprentissage . . . 47
2.2.1 Diagnostique . . . 47
2.2.2 Prédiction . . . 48
2.2.3 Décision . . . 49
2.3 Processus d'apprentissage suivi . . . 51
2.4 Action orientée Science des données . . . 57
2.4.1 Identification des paramètres . . . 57
2.4.2 Description et rôle des variables du dataset . . . 58
2.4.3 Mise en évidence des champs de variation des seuils spécifiques . 61
2.4.4 Mise en évidence des conditions et règles spécifiques . . . 61
2.5 Préparation des données . . . 62
2.5.1 Pipeline de Données — Cycle de Vie de la Donnée . . . 62
2.5.2 Justification de l'Augmentation de Données (GaussianCopula + CTGAN) . . . 65
2.6 Traitement des données . . . 66
2.6.1 Classification 1 — Classe de prix (`Classe_prix`) . . . 66
2.6.2 Classification 2 — Conformité e-facture 2026 . . . 67
2.6.3 Classification 3 — Niveau de satisfaction . . . 69
2.6.4 Classification 4 — Segment de taille . . . 70
2.7 Prédictions complémentaires : Régression Multiple et Clustering K-Means 80
2.7.1 Régression — Prédiction du Prix (`prix_min_eur`) . . . 80
2.7.2 Clustering K-Means — Segmentation du Marché SaaS . . . 85
2.8 Optimisation . . . 90
2.9 Conclusion . . . 91

3 Création et intégration de modèles d'apprentissage 93
3.1 Introduction . . . 93
3.2 Création d'un modèle d'apprentissage de type Multi Model Forecast . . . 95
3.2.1 Dataset . . . 95
3.2.2 Machine Learning . . . 96
3.2.3 Deep Learning — Intégration LLM . . . 97
3.2.4 Étude comparative . . . 99
3.2.5 Optimisation . . . 100
3.2.6 RAG — Génération Augmentée par Récupération (Conformité Réglementaire) . . . 101
3.2.7 Architecture Agentique — Séparation LLM/Calcul . . . 103
3.3 Présentation et démonstration de l'assistant conversationnel . . . 106

3.3.1 Interface d'accueil . . . 106
3.3.2 Recommandation personnalisée pour une PME . . . 107
3.3.3 Prévision de classe de prix . . . 107
3.3.4 Comparaison multicritère de solutions . . . 107
3.3.5 Conformité à la réforme e-facturation 2026 . . . 109
3.4 Conclusion . . . 109

Conclusion Générale et Perspectives **111**
Bilan du projet . . . 111
Difficultés rencontrées . . . 112
Perspectives et travaux futurs . . . 113

Bibliographie et Webographie **115**
Ouvrages et articles scientifiques . . . 115
Webographie . . . 117

Annexes **118**
Annexe A — Extrait du dataset final . . . 118
Annexe B — Résultats complets de la validation croisée . . . 118
Annexe C — Architecture technique . . . 119
Annexe D — Glossaire technique . . . 119

Table des figures

1 Diagramme de Gantt du projet — Analyse Intelligente du Marché SaaS 18

1.1 Architecture fonctionnelle de la plateforme intelligente de recommandation des solutions SaaS de facturation électronique 28
1.2 Arbre à problèmes lié à l'adoption des solutions SaaS 32
1.3 Arbre à solutions pour l'adoption des solutions SaaS 33

2.1 Distribution de la variable Classe_prix 47
2.2 Distribution de la Conformité e-facture 2026 48
2.3 Distribution du Niveau de satisfaction 48
2.4 Distribution du Segment de taille 48
2.5 Matrice de corrélation des variables du dataset 57
2.6 Comparaison des modèles — Classe_prix 67
2.7 Importance des variables — Classe_prix 68
2.8 Matrices de confusion — Classe_prix 68
2.9 Courbes ROC — Classe_prix 69
2.10 Tableau comparatif des modèles — Classe_prix 69
2.11 Validation croisée — Classe_prix 70
2.12 Rapport de classification — Classe_prix 70
2.13 Comparaison des modèles — Conformité e-facture 70
2.14 Importance des variables — Conformité e-facture 71
2.15 Matrices de confusion — Conformité e-facture 71
2.16 Courbe ROC — Conformité e-facture 72
2.17 Tableau comparatif des modèles — Conformité e-facture 72
2.18 Validation croisée — Conformité e-facture 73
2.19 Rapport de classification — Conformité e-facture 73
2.20 Comparaison des modèles — Niveau de satisfaction 73
2.21 Importance des variables — Niveau de satisfaction 74
2.22 Matrices de confusion — Niveau de satisfaction 74
2.23 Courbes ROC — Niveau de satisfaction 75
2.24 Tableau comparatif des modèles — Niveau de satisfaction 75
2.25 Validation croisée — Niveau de satisfaction 76

2.26 Rapport de classification — Niveau de satisfaction 76
2.27 Comparaison des modèles — Segment de taille 76
2.28 Importance des variables — Segment de taille 77
2.29 Matrices de confusion — Segment de taille 77
2.30 Courbes ROC — Segment de taille 78
2.31 Tableau comparatif des modèles — Segment de taille 78
2.32 Validation croisée — Segment de taille 79
2.33 Rapport de classification — Segment de taille 79
2.34 Distribution de `prix_min_eur` (brute et log1p) 82
2.35 Comparaison Ridge vs Random Forest (R^2 et RMSE) 82
2.36 Importance des features — Régression (Gini, Random Forest) 83
2.37 Valeurs réelles vs prédites et analyse des résidus 83
2.38 Scores R^2 par fold (validation croisée 5 plis) 84
2.39 Distribution des 4 segments K-Means (effectifs et pourcentages) 86
2.40 Projection PCA 2D des clusters avec centroides 87
2.41 Méthode du coude — inertie vs k 87
2.42 Score de silhouette moyen pour $k = 2$ à 10 88
2.43 Heatmap des profils moyens par cluster (valeurs réelles annotées) 88
2.44 Radar chart comparatif des 4 segments 89
2.45 Correspondance entre les segments K-Means et la variable `segment_taille` 89

3.1 Architecture globale du système SaaS Assistant 95
3.2 Interface d'accueil de l'assistant conversationnel SaaS Assistant 106
3.3 Recommandation personnalisée pour une PME marocaine (budget < 50 EUR/mois) 107
3.4 Prévision de la classe de prix d'une solution SaaS via le classifieur Random Forest 108
3.5 Comparaison multicritère de trois solutions de facturation SaaS 108
3.6 Réponse du module RAG sur les obligations de facturation électronique 2026 109

Liste des tableaux

1.1 Comparaison des principales solutions SaaS de facturation 36
1.2 Stack technologique du système SaaS Assistant 38
1.3 Spécifications fonctionnelles du système SaaS Assistant 42

2.1 Description des variables du dataset SaaS 58
2.2 Rééquilibrage SMOTE des quatre variables cibles 62
2.3 Résultats — Classification de la Classe de prix 67
2.4 Résultats — Classification de la Conformité e-facture 2026 68
2.5 Résultats — Classification du Niveau de satisfaction 71
2.6 Résultats — Classification du Segment de taille 74

3.1 Extrait du dataset final — 5 premières observations et variables clés . . 118
3.2 Synthèse des performances Random Forest — 4 tâches de classification 118

LISTE DES ABRÉVIATIONS

AD	Analytique des Données
API	Application Programming Interface
ARR	Annual Recurring Revenue
AUC	Area Under the Curve
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
BI	Business Intelligence
CNDP	Commission Nationale de Contrôle de la Protection des Données à caractère Personnel
CRM	Customer Relationship Management
CSS	Cascading Style Sheets
CSV	Comma-Separated Values
CTGAN	Conditional Tabular Generative Adversarial Network
CV	Cross-Validation
DGI	Direction Générale des Impôts
EDA	Exploratory Data Analysis
ERP	Enterprise Resource Planning
ETI	Entreprise de Taille Intermédiaire
ETL	Extract, Transform, Load
FPR	False Positive Rate
FST	Faculté des Sciences et Techniques
GAN	Generative Adversarial Network
GQA	Grouped Query Attention
HTML	HyperText Markup Language
IA	Intelligence Artificielle
IPO	Initial Public Offering
JS	JavaScript

JSON	JavaScript Object Notation
KNN	K-Nearest Neighbors
KPI	Key Performance Indicator
LLM	Large Language Model
LST	Licence Sciences et Techniques
LTV	Lifetime Value
MAE	Mean Absolute Error
MCDM	Multi-Criteria Decision Making
MD	Missing Data
ML	Machine Learning
MRR	Monthly Recurring Revenue
MSE	Mean Squared Error
MVP	Minimum Viable Product
NER	Named Entity Recognition
NLP	Natural Language Processing
NLU	Natural Language Understanding
PCA	Principal Component Analysis
PDP	Plateforme de Dématérialisation Partenaire
PFE	Projet de Fin d'Études
PII	Personally Identifiable Information
PME	Petites et Moyennes Entreprises
RAG	Retrieval-Augmented Generation
RBF	Radial Basis Function
REST	Representational State Transfer
RF	Random Forest
RGPD	Règlement Général sur la Protection des Données
RMSE	Root Mean Squared Error
ROC	Receiver Operating Characteristic
ROI	Return on Investment
SaaS	Software as a Service
SHAP	SHapley Additive exPlanations
SLA	Service Level Agreement

SMOTE	Synthetic Minority Over-sampling Technique
SQL	Structured Query Language
SVM	Support Vector Machine
SWOT	Strengths, Weaknesses, Opportunities, Threats
TCO	Total Cost of Ownership
TF-IDF	Term Frequency – Inverse Document Frequency
TIC	Technologies de l'Information et de la Communication
TOPSIS	Technique for Order of Preference by Similarity to Ideal Solution
TPE	Très Petite Entreprise
TPR	True Positive Rate
UI	User Interface
URL	Uniform Resource Locator
USD	United States Dollar
UX	User Experience
WGAN-GP	Wasserstein GAN with Gradient Penalty
WSM	Weighted Sum Model
XAI	Explainable Artificial Intelligence
YAGNI	You Aren't Gonna Need It

INTRODUCTION GÉNÉRALE

Contexte général

La transformation numérique a profondément modifié les modes de fonctionnement des entreprises. Parmi les innovations les plus marquantes figure le modèle *Software as a Service (SaaS)*, qui permet aux organisations d'accéder à des applications hébergées dans le cloud sans avoir à gérer une infrastructure informatique complexe. Aujourd'hui, les solutions SaaS sont utilisées dans de nombreux domaines tels que la comptabilité, la gestion de la relation client, les ressources humaines et la facturation.

L'essor rapide de ce marché a conduit à l'apparition de milliers de solutions présentant des fonctionnalités, des modèles tarifaires et des niveaux de performance variés. Cette diversité représente une opportunité pour les entreprises, mais elle rend également le processus de sélection plus complexe. Dans ce contexte, l'exploitation des techniques d'Analytique des Données, de Machine Learning et d'Intelligence Artificielle constitue une approche pertinente pour analyser le marché et accompagner les utilisateurs dans leur prise de décision.

C'est dans cette perspective que s'inscrit ce projet de fin d'études, réalisé dans le cadre de la Licence en Analytique des Données en collaboration avec l'entreprise KIINOV. Le projet porte sur la conception d'une plateforme intelligente dédiée à l'analyse, à la classification et à la recommandation des solutions SaaS de facturation.

Problématique

Le marché des logiciels SaaS de facturation connaît une croissance continue et propose un grand nombre de solutions répondant à des besoins variés. Toutefois, les entreprises rencontrent souvent des difficultés pour identifier la solution la plus adaptée à leurs contraintes fonctionnelles, techniques et budgétaires.

Les comparaisons manuelles sont généralement longues, subjectives et limitées à un nombre restreint de critères. De plus, les informations disponibles sont dispersées sur plusieurs plateformes et ne permettent pas toujours une évaluation objective des différentes alternatives.

La problématique de ce projet peut ainsi être formulée comme suit :

Comment exploiter les techniques de l'analytique des données et de l'intelligence artificielle afin d'analyser efficacement le marché des solutions SaaS de facturation et de recommander aux utilisateurs les solutions les plus adaptées à leurs besoins ?

Objectifs du projet

L'objectif principal de ce projet est de développer une plateforme intelligente permettant d'analyser, de classifier et de recommander des solutions SaaS de facturation.

Pour concrétiser cette finalité, plusieurs axes de travail ont été définis :

- Constituer une base de données regroupant les caractéristiques de plus de 1400 solutions SaaS.
- Identifier et structurer les variables fonctionnelles, techniques et économiques pertinentes.
- Réaliser une analyse exploratoire des données afin de comprendre les tendances du marché.
- Développer des modèles de Machine Learning pour la classification automatique des solutions SaaS.
- Concevoir un système de recommandation capable de proposer les solutions les plus adaptées aux besoins des utilisateurs.
- Intégrer un assistant conversationnel basé sur les technologies LLM et RAG afin de faciliter l'accès à l'information et d'améliorer l'expérience utilisateur.
- Évaluer les performances des modèles développés et la pertinence des recommandations générées.

Structure du rapport

Le présent rapport est organisé en quatre chapitres.

Le **Chapitre 1** présente le contexte général du projet, le marché des solutions SaaS ainsi que les concepts théoriques liés à l'analytique des données, au Machine Learning et aux systèmes de recommandation.

Le **Chapitre 2** décrit la collecte des données, la construction du jeu de données et les différentes étapes de préparation et d'analyse exploratoire.

Le **Chapitre 3** est consacré au développement des modèles de classification, du système de recommandation et à l'intégration des technologies d'intelligence artificielle conversationnelle basées sur les LLM et le RAG.

Le **Chapitre 4** présente l'implémentation de la plateforme, les résultats expérimentaux obtenus ainsi que l'évaluation des performances des différentes approches proposées.

Enfin, une conclusion générale synthétise les principaux résultats du projet, met en évidence ses contributions et présente les perspectives d'amélioration futures.

Organisation du projet

Le projet *Analyse intelligente du marché SaaS* a été conduit dans le cadre d'un stage de fin d'études d'une durée de deux mois. L'organisation repose sur une structure légère en trois rôles :

— un ingénieur stagiaire assurant l'intégralité du développement et de la modélisation,

— un encadrant académique garant de la rigueur méthodologique et scientifique,

— un encadrant professionnel responsable de l'orientation fonctionnelle et de la validation des livrables.

Cette organisation a permis de maintenir un rythme de travail soutenu tout en bénéficiant d'un double regard académique et professionnel à chaque étape clé. Le projet a été découpé en quatre grandes phases correspondant aux chapitres du rapport :

1. étude préalable et veille concurrentielle,
2. modélisation par intelligence artificielle,
3. création et intégration des modèles d'apprentissage,
4. implémentation de la plateforme.

La contrainte de deux mois a imposé une gestion rigoureuse des priorités et la parallélisation de certaines phases de développement.

Méthode de conduite de projet (Scrum et XP)

Le projet a adopté une démarche agile combinant les principes de Scrum et d'Extreme Programming (XP), adaptée à un projet individuel encadré sur deux mois.

Scrum a structuré le rythme de travail en sprints d'une semaine. À chaque début de sprint, un backlog de tâches était défini en concertation avec les encadrants : collecte des données, entraînement des modèles, développement des routes API, intégration du frontend, etc. Des points hebdomadaires permettaient de suivre l'avancement, d'identifier les blocages et d'ajuster les priorités. Chaque fin de sprint donnait lieu à une démonstration du livrable partiel et à une courte rétrospective.

XP a complété cette approche par ses pratiques techniques. Le refactoring continu a été appliqué sur les 28 routes Flask et les 65 fonctions JavaScript pour maintenir un code

lisible. Le principe de tests rapides a guidé la validation des modèles via la validation croisée stratifiée à 5 folds et le holdout à 20%. L'intégration continue a été simulée par des cycles courts (modification → test local → validation des métriques → itération suivante). Enfin, la conception simple (YAGNI) a orienté les choix d'architecture : Flask léger côté backend, JavaScript vanilla côté frontend, sans surcharge d'un framework réactif complexe.

Cette combinaison Scrum/XP a permis de livrer un système fonctionnel et évalué dans la contrainte des deux mois impartis.

Équipe du projet

EL KOSTIT Fatima Zahrae & EL MAYMOUNI Zakariae — Stagiaires

En tant que stagiaires, nous avons assuré l'ensemble des phases de développement du projet, notamment la collecte et la préparation des données, l'entraînement et l'évaluation des modèles de Machine Learning, le développement de l'architecture backend et des API, la conception de l'interface web, ainsi que l'intégration des composants d'intelligence artificielle avancés, incluant le modèle de langage (LLM), le système RAG (Retrieval-Augmented Generation) et le moteur de recommandation multicritère (MCDM). Le travail collaboratif a permis une répartition efficace des tâches et une progression continue du projet.

Mme Sara Ahsain — Encadrante académique

Mme Sara Ahsain a assuré le suivi académique du projet à travers des réunions régulières, la validation des choix méthodologiques et l'orientation scientifique nécessaire à la réalisation du travail ainsi qu'à la rédaction du rapport de stage.

Pr. Abdellah Azmani — Encadrant professionnel

Pr. Abdellah Azmani a contribué à la définition des besoins métier, à la validation des orientations fonctionnelles du système et à l'évaluation de la pertinence des résultats obtenus par rapport au contexte d'application.

Dr. Douae El Karoute — Docteure encadrante

Dr. Douae El Karoute a apporté son expertise scientifique dans le domaine de l'intelligence artificielle, en accompagnant la conception des modèles de classification, l'élaboration du système de recommandation et la validation des résultats expérimentaux.

Planning du projet (Diagramme de Gantt)

Le projet a été conduit sur une durée de **8 semaines** (2 mois), du 1er avril au 24 juin 2026, organisées en quatre grandes phases correspondant aux chapitres du rapport.

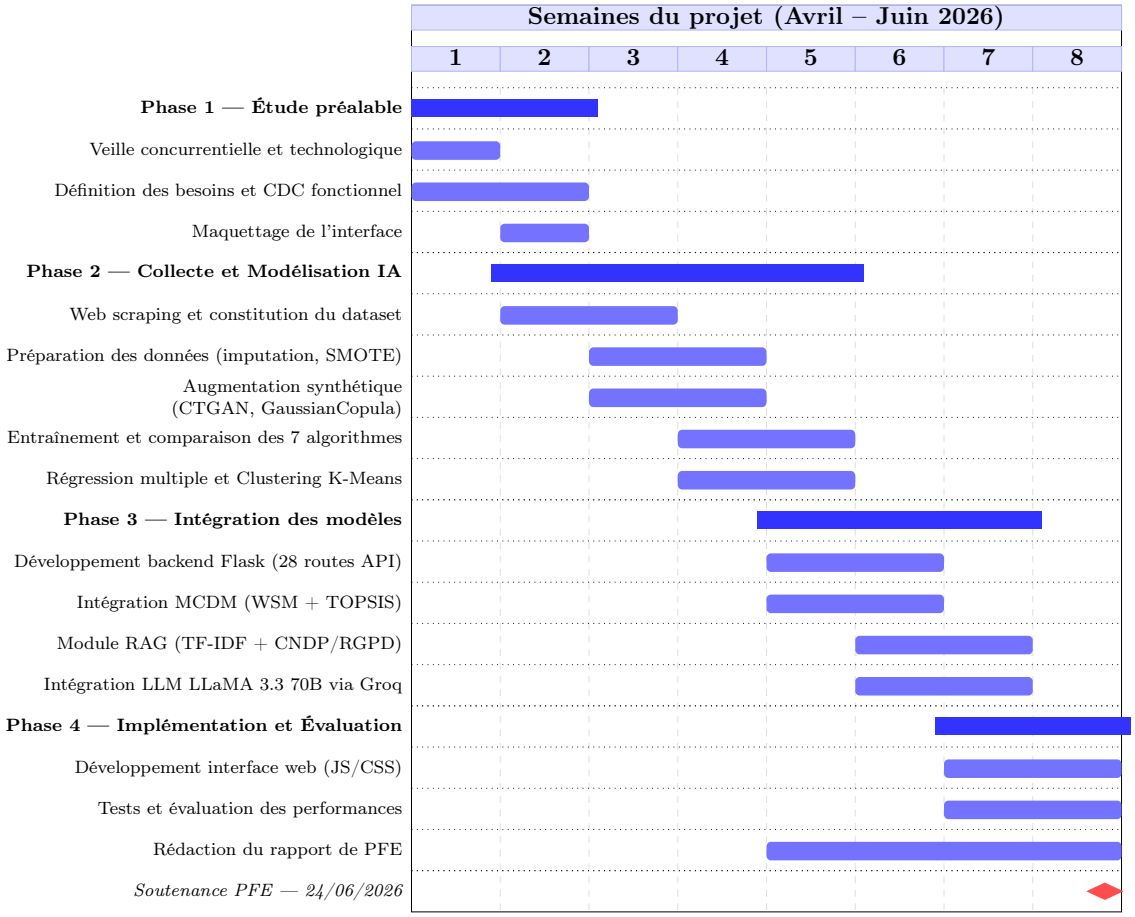


FIGURE 1 – Diagramme de Gantt du projet — Analyse Intelligente du Marché SaaS

Bilan en fin de stage

Ce stage de deux mois a permis de réaliser les objectifs définis au début du projet. La plateforme **SaaS Assistant** développée intègre plusieurs modules complémentaires, notamment des modèles de Machine Learning, un modèle de langage (LLM), un système de recommandation multicritère (MCDM) et un module de génération augmentée par récupération d'informations (RAG). L'ensemble est accessible à travers une architecture basée sur des API et une interface web dédiée.

Les résultats obtenus montrent des performances satisfaisantes pour les différents modèles développés. Le modèle de prédiction de la classe de prix a atteint une précision

de 98,24% ainsi qu'un AUC-ROC de 0,9997. Le modèle de prédiction de conformité à la réglementation de la facturation électronique 2026 a obtenu une précision de 88,73%, démontrant sa capacité à traiter une problématique complexe. Le module MCDM a également permis de générer des classements cohérents et reproductibles pour l'évaluation des solutions SaaS.

Sur le plan pédagogique et technique, ce stage a permis de renforcer les compétences liées aux différentes étapes d'un projet de data science, depuis la collecte et la préparation des données jusqu'au déploiement des modèles. Il a également favorisé l'acquisition de connaissances pratiques sur les technologies utilisées, notamment Flask, Chart.js, les modèles de langage basés sur LLaMA ainsi que les mécanismes de recommandation et d'aide à la décision.

Certaines limites ont néanmoins été identifiées :

— La forte proportion de données synthétiques utilisée dans le jeu de données, rendue nécessaire par les difficultés d'accès à certaines sources réelles.

— Les performances plus modestes du modèle de prédiction de la satisfaction utilisateur, en raison du caractère subjectif de cette variable.

— L'automatisation complète du cycle de réentraînement des modèles n'a pas été mise en œuvre, le processus restant partiellement manuel.

Dans une perspective d'évolution, plusieurs améliorations peuvent être envisagées, telles que l'intégration d'une solution MLOps pour l'automatisation du déploiement et du suivi des modèles, l'enrichissement progressif du corpus de données ainsi que l'évaluation d'algorithmes plus avancés, notamment les approches de gradient boosting comme XGBoost et LightGBM.

Fonctionnalités de la plateforme

La plateforme **SaaS Assistant** regroupe un ensemble de fonctionnalités destinées à accompagner les entreprises dans l'analyse, la sélection et l'évaluation de solutions SaaS. Ces fonctionnalités sont organisées autour de deux espaces principaux : le **Mode Acheteur**, destiné aux PME à la recherche d'une solution SaaS, et le **Mode Créateur**, destiné aux startups souhaitant développer ou positionner leur propre solution.

— **Assistant conversationnel (LLM)** : permet aux utilisateurs d'interagir en langage naturel. Le chatbot assure la gestion du contexte conversationnel, la détection de la langue utilisée et l'orientation des requêtes vers différents agents spécialisés.

— **Module de prédiction ML** : estime plusieurs caractéristiques d'une solution SaaS (classe de prix, segment de marché, conformité réglementaire, satisfaction des utilisateurs) avec des indicateurs d'interprétabilité.

— **Système MCDM (WSM/TOPSIS)** : compare plusieurs solutions SaaS selon différents critères (coût, fonctionnalités, sécurité) et produit un classement personnalisé.

— **Module RAG (Retrieval-Augmented Generation)** : dédié à la conformité réglementaire, exploite une base documentaire spécialisée pour fournir des réponses contextualisées et justifiées.

— **Composant NLU/NER** : extraction automatique d'informations pertinentes (secteur, budget, nombre d'utilisateurs) à partir des descriptions textuelles.

— **Module d'audit SaaS** : évalue une solution existante à partir de son nom ou de son adresse web et génère un rapport synthétique.

— **Simulateur financier ROI/TCO** : estime le coût total de possession et le retour sur investissement sur plusieurs années.

— **Mode Créateur** : propose des outils stratégiques (analyse du marché, SWOT, Business Model Canvas, analyse concurrentielle).

— **Mode Acheteur** : aide à la sélection et au déploiement d'une solution SaaS (analyse des besoins, comparaison multicritère, évaluation financière, conformité réglementaire).

— **Module de gouvernance et sécurité** : assure la journalisation des opérations, le suivi des modèles ML, la protection des données personnelles et la surveillance de la qualité des données.

Conclusion

Ce projet d'analyse intelligente du marché SaaS, réalisé en deux mois, représente une contribution concrète à la transformation digitale des entreprises marocaines. En combinant **machine learning supervisé**, **aide à la décision multicritère**, **génération augmentée par récupération (RAG)** et **modèles de langage de grande taille (LLM)**, la plateforme **SaaS Assistant** constitue un outil d'analyse et de recommandation inédit, directement adapté aux spécificités réglementaires et économiques du marché marocain.

Les résultats obtenus valident l'hypothèse centrale du projet : le marché SaaS obéit à une logique structurée que les algorithmes d'apprentissage automatique peuvent capturer avec une haute précision, dès lors que le corpus est correctement préparé et augmenté. Le **F1-Score de 98,23%** sur la prédiction tarifaire illustre la puissance du Random Forest sur des données tabulaires hétérogènes, tandis que la performance plus nuancée du modèle de satisfaction (77,21%) reflète honnêtement les limites de la prédictibilité sur des variables subjectives.

Au-delà des performances techniques, ce projet démontre la faisabilité d'une **architecture neuro-symbolique hybride** (ML + LLM + MCDM) appliquée à un problème métier réel dans un contexte de ressources et de délais contraints. L'intégration du module RAG sur la conformité e-facture 2026 apporte une valeur ajoutée immédiate face à un enjeu réglementaire imminent pour les entreprises marocaines.

Les perspectives ouvertes sont multiples :

— enrichissement progressif du corpus de données,

— automatisation du réentraînement via un orchestrateur MLOps,

— déploiement sur une infrastructure cloud marocaine souveraine,

— extension à d'autres verticales SaaS (RH, CRM, ERP).

Ce projet constitue ainsi une base solide pour le développement d'une **plateforme d'intelligence de marché SaaS à l'échelle nationale**, en cohérence avec les ambitions de la stratégie *Maroc Digital 2030*.

Chapitre 1

Étude préalable

1.1 Introduction

Au cours des dernières décennies, la transformation numérique a profondément modifié le fonctionnement des entreprises et des organisations à travers le monde. L'évolution rapide des technologies de l'information, combinée au développement d'Internet et du Cloud Computing, a favorisé l'apparition de nouveaux modèles de services numériques. Parmi ces modèles, le **Software as a Service (SaaS)** s'est imposé comme l'une des solutions les plus structurantes dans le domaine informatique contemporain.

Contrairement aux logiciels traditionnels installés localement sur les ordinateurs, les solutions SaaS sont accessibles directement via Internet et fonctionnent généralement selon un système d'abonnement mensuel ou annuel. Ce modèle permet aux entreprises de bénéficier d'applications flexibles, évolutives et accessibles à distance, tout en réduisant considérablement les coûts liés à l'infrastructure et à la maintenance informatique.

Le marché mondial du SaaS connaît aujourd'hui une croissance soutenue grâce à l'accélération de la digitalisation des entreprises et à l'augmentation des besoins en solutions numériques intelligentes. Selon les rapports publiés par Gartner et Statista, les dépenses mondiales liées aux solutions SaaS dépassent plusieurs centaines de milliards de dollars et continuent d'augmenter chaque année, portées par l'intégration croissante de l'intelligence artificielle et de l'automatisation des processus métiers.

Au Maroc, la transformation digitale progresse de manière significative grâce aux initiatives nationales visant à moderniser l'économie et à encourager l'adoption des technologies numériques. Le gouvernement marocain a lancé la stratégie **Maroc Digital 2030** dont l'objectif est de renforcer l'écosystème numérique national, développer les infrastructures cloud, accompagner les entreprises dans leur transition digitale et soutenir les startups technologiques. Cette dynamique contribue à l'émergence d'un marché numérique en pleine évolution où les entreprises marocaines manifestent un intérêt croissant pour les solutions SaaS et les services cloud.

Cependant, malgré cette évolution, plusieurs défis restent présents sur le marché marocain. Le niveau de maturité numérique demeure encore différent d'une entreprise à une autre, notamment chez les petites et moyennes entreprises qui rencontrent parfois des difficultés liées au coût des solutions, au manque de compétences techniques ou encore à la sécurité des données. De plus, le marché marocain reste fortement dominé par des plateformes étrangères, ce qui soulève des questions liées à la souveraineté numérique et à l'adaptation des solutions aux besoins locaux. Ces problématiques montrent la nécessité de mieux comprendre le marché SaaS marocain, ses tendances, ses opportunités et ses limites.

Dans ce contexte, notre projet intitulé « **Analyse intelligente du marché SaaS** » vise à étudier et analyser le marché des solutions SaaS, avec un focus particulier sur les SaaS de facturation au Maroc. Ce projet a pour objectif d'identifier les principales solutions existantes, d'analyser les besoins des entreprises marocaines, d'évaluer les tendances du marché et de comprendre l'impact des nouvelles technologies telles que l'intelligence artificielle dans ce domaine. À travers cette étude, nous cherchons également à proposer une vision stratégique permettant d'accompagner la transformation digitale des entreprises marocaines et de contribuer au développement de solutions SaaS adaptées au contexte national.

Vue d'ensemble du pipeline IA

Le système repose sur un pipeline séquentiel en cinq étapes interdépendantes, conçu pour transformer des données brutes hétérogènes en recommandations actionnables. Chaque étape produit un livrable qui conditionne l'entrée de l'étape suivante : aucune ne peut être court-circuitée sans dégrader la qualité globale du résultat.

Étape 1 — Collecte des données. Le pipeline démarre par la constitution d'un corpus de données réelles sur le marché SaaS. Deux sources complémentaires ont été exploitées : un web scraping ciblé sur G2, Capterra, Trustpilot et les sites officiels des éditeurs SaaS, et un corpus JSON de ∼200 solutions construit manuellement pour contourner les mécanismes anti-bots des plateformes d'avis. Le corpus brut ainsi obtenu couvre 239 observations réelles, chacune décrite par 31 variables réparties en cinq dimensions : tarifaire (`prix_min_eur`, `prix_max_eur`, modèle freemium), qualitative (`note_g2`, `note_capterra`, `note_trustpilot`, `niveau_satisfaction`), commerciale (`nombre_clients`, `segment_cible`, ancienneté), technique (intégrations API, conformité RGPD, support SLA) et marché (zone géographique, langue, secteur cible). Cette étape produit le dataset brut de référence — incomplet et déséquilibré — qui sera traité à l'étape suivante.

Étape 2 — Préparation et augmentation. Les données brutes collectées sont loin d'être exploitables directement : les taux de valeurs manquantes atteignent jusqu'à 76 % pour la variable `note_trustpilot`, et certaines classes sont représentées par moins de 5 observations. Cette étape procède en trois sous-opérations successives. D'abord, l'imputation différenciée comble les valeurs manquantes selon la nature de chaque variable : `IterativeImputer` pour les variables numériques à forte corrélation, `KNNImputer` ($k = 5$) pour les variables ordinales, `RandomForest Imputer` pour les variables avec patterns non linéaires, et imputation par mode conditionnel par groupe pour les variables catégorielles. Ensuite, un audit de fuite de données exclut les variables dont la connaissance présupposerait le résultat (`prix_min_eur` et `satisfaction_pct` retirées des features d'entraînement). Enfin, l'augmentation synthétique porte le dataset à 1 425 lignes (239 réelles + 1 186 synthétiques) via GaussianCopula (70 %) et CTGAN (30 %), suivie d'un rééquilibrage SMOTE sur les seules données d'entraînement pour corriger les déséquilibres de classes résiduels.

Étape 3 — Entraînement et sélection des modèles. Quatre tâches de classification indépendantes sont définies, une pour chaque variable cible (`Classe_prix`, `Segment_taille`, `Conforme_e_facture_2026`, `Niveau_satisfaction`). Pour chaque tâche, sept algorithmes de classification supervisée sont entraînés en parallèle : Random Forest, SVM-RBF, Gradient Boosting, K-Nearest Neighbors, Arbre de décision, Régression logistique et Naïve Bayes. L'entraînement suit un protocole de validation croisée stratifiée à 5 folds, garantissant la représentation de toutes les classes dans chaque fold. Le réglage des hyperparamètres du Random Forest est effectué par `GridSearchCV` sur une grille de 144 combinaisons (`n_estimators` $\in \{50, 100, 200\}$, `max_depth` $\in \{$`None`$, 10, 20, 30\}$, `min_samples_split` $\in \{2, 5, 10\}$, `min_samples_leaf` $\in \{1, 2, 4\}$). Le compromis optimal retenu est `n_estimators=100`, `max_depth=None`, atteignant un F1-Score macro moyen de 98,31 % en validation croisée sur les quatre tâches. Les modèles sélectionnés sont sérialisés (joblib) et gelés pour garantir la reproductibilité des inférences en production.

Étape 4 — Évaluation et explicabilité. Les modèles entraînés sont évalués sur un jeu de test figé (holdout stratifié à 20 %), constitué avant toute augmentation synthétique pour garantir que les données de test sont strictement réelles. Cinq métriques sont calculées par tâche et par classe : Accuracy globale, Precision pondérée, Recall pondéré, F1-Score macro et AUC-ROC multiclasse (One-vs-Rest). Un second audit de fuite de données vérifie que les colonnes cibles d'une tâche ne figurent pas dans les features d'une autre tâche. L'explicabilité des prédictions est assurée à deux niveaux : l'importance des features par impureté de Gini (globale, sur l'ensemble du modèle) et les valeurs SHAP approchées (locale, pour chaque prédiction individuelle), permet-

tant à l'utilisateur de lire quelles variables ont le plus contribué — positivement ou négativement — à la prédiction obtenue pour une solution SaaS donnée.

Étape 5 — Recommandation. Le pipeline se conclut par la transformation des quatre prédictions numériques en une recommandation métier actionnée. Les scores de classe issus du Random Forest (probabilités de chaque classe) sont transmis au moteur MCDM (WSM + TOPSIS), qui les intègre dans une matrice de décision aux côtés des données brutes de chaque solution (prix réel, notes agrégées, SLA déclaré). Le MCDM normalise ces critères hétérogènes, applique les pondérations définies par l'utilisateur (Coût TCO 40 %, Fonctionnalité 30 %, Sécurité/SLA 30 %) et produit un classement final des solutions. En parallèle, chaque requête à dimension réglementaire active le module RAG : TF-IDF sur 9 chunks CNDP/RGPD sélectionne les passages pertinents, injectés dans le prompt du LLM (LLaMA 3.3 70B via Groq), qui génère une réponse narrative sourcée. L'ensemble de ces modules est exposé à l'utilisateur via 28 routes API Flask sur une interface web responsive à 3 colonnes, avec visualisation temps réel des scores, graphiques d'explicabilité SHAP et simulateur TCO sur 5 ans.

Références

— Altcode, *Conception de logiciels SaaS : étapes clés et bonnes pratiques*, 2025.

— Maroc Digital 2030, Ministère de la Transition Numérique et de la Réforme de l'Administration, 2025.

— TIC Maroc, *Marché des TIC au Maroc : perspectives de croissance à l'horizon 2030*, 2026.

— Gartner, *Forecast Analysis : Public Cloud Services, Worldwide*, 2025.

— Statista, *Software as a Service (SaaS) Market Size Worldwide*, 2025.

1.2 Présentation du projet

1.2.1 Qu'est-ce que l'analyse intelligente du marché SaaS ? (Quoi ?)

L'analyse intelligente du marché SaaS consiste à collecter, traiter et interpréter des données relatives aux plateformes Software as a Service afin de mieux comprendre les dynamiques du marché, les besoins des utilisateurs ainsi que les tendances technologiques et économiques du secteur. Avec l'évolution du cloud computing et la croissance de la transformation digitale, les entreprises produisent aujourd'hui une grande quantité de données exploitables permettant d'analyser les comportements des utilisateurs, les modèles économiques, les performances des plateformes et les opportunités de développement.

Notre projet se concentre particulièrement sur les solutions SaaS de facturation présentes sur le marché marocain. Ces plateformes permettent aux entreprises de gérer leurs opérations financières et administratives à travers des services accessibles en ligne. Le projet vise à réaliser une analyse intelligente des différentes solutions existantes en étudiant plusieurs critères importants tels que les fonctionnalités proposées, les coûts d'abonnement, la sécurité des données, l'accessibilité, l'expérience utilisateur ainsi que l'adaptation des plateformes au contexte réglementaire et économique marocain.

L'objectif principal est de fournir une vision claire et stratégique du marché des SaaS de facturation au Maroc, afin d'aider les entreprises — notamment les PME et les startups — à identifier les solutions les plus adaptées à leurs besoins spécifiques. Pour ce faire, le projet mobilise des techniques avancées d'intelligence artificielle, de machine learning supervisé et d'aide à la décision multicritère (MCDM), transformant les données brutes collectées sur plus de 1 425 solutions SaaS en recommandations actionnables et personnalisées.

1.2.2 Notions fondamentales

Le Software as a Service (SaaS) constitue aujourd'hui l'un des modèles les plus répandus du cloud computing. Il repose sur l'hébergement des applications sur des serveurs distants accessibles via Internet, permettant aux utilisateurs d'accéder aux services sans installation locale ni gestion complexe de l'infrastructure. Généralement proposé sous forme d'abonnement, le SaaS offre de nombreux avantages tels que la réduction des coûts de maintenance, la mise à jour automatique des applications, l'accessibilité à distance et la scalabilité des ressources. Ce modèle est largement adopté dans divers secteurs, notamment la finance, la santé, l'éducation, le commerce électronique et la gestion des entreprises. Dans le domaine de la facturation électronique, les solutions SaaS permettent d'automatiser la création des factures, le suivi des paiements, la gestion des clients et la génération de rapports financiers, améliorant ainsi

l'efficacité opérationnelle des organisations.

Le modèle SaaS s'intègre dans l'architecture globale du cloud computing aux côtés de l'Infrastructure as a Service (IaaS) et du Platform as a Service (PaaS). L'IaaS fournit les ressources matérielles virtualisées telles que les serveurs, les réseaux et le stockage, tandis que le PaaS offre un environnement de développement permettant de concevoir et de déployer des applications sans gérer directement l'infrastructure sous-jacente. Le SaaS représente ainsi le niveau d'abstraction le plus élevé en proposant directement des applications prêtes à l'emploi aux utilisateurs finaux. Cette organisation hiérarchique simplifie l'utilisation des technologies cloud tout en masquant la complexité technique des couches inférieures.

L'évolution récente des plateformes SaaS s'accompagne d'une intégration croissante des techniques d'intelligence artificielle et d'analyse de données. Ces technologies permettent d'exploiter les grandes quantités de données générées par les utilisateurs afin de détecter des tendances, automatiser certaines tâches, améliorer la prise de décision et personnaliser les services proposés. Dans le cadre de notre projet, plusieurs approches d'intelligence artificielle sont mobilisées afin d'évaluer et de recommander les solutions SaaS de facturation électronique. Des algorithmes de classification supervisée (Random Forest, Gradient Boosting, SVM) sont utilisés pour prédire la classe de prix, la conformité réglementaire, le segment de taille et le niveau de satisfaction ; une **régression multiple** pour estimer le prix numérique exact ; et un **clustering K-Means** pour segmenter automatiquement les solutions en groupes homogènes. Les résultats obtenus sont ensuite exploités dans un processus d'aide à la décision basé sur les méthodes multicritères Weighted Sum Model (WSM) et TOPSIS, permettant de classer les différentes plateformes selon plusieurs critères tels que les fonctionnalités, le coût, la sécurité ou encore la satisfaction des utilisateurs.

Afin d'améliorer l'interaction avec les utilisateurs et de faciliter l'accès aux informations réglementaires, le projet intègre également un système de génération augmentée par récupération (Retrieval-Augmented Generation – RAG). Cette approche combine la recherche d'informations dans une base documentaire avec les capacités de génération d'un modèle de langage. Lorsqu'une question est posée, les documents pertinents sont d'abord récupérés avant d'être transmis au modèle afin de produire une réponse précise et contextualisée. Cette architecture repose sur l'utilisation d'un Large Language Model (LLM), capable de comprendre et de générer du langage naturel. Dans ce contexte, plusieurs techniques de traitement automatique du langage naturel (Natural Language Processing – NLP) sont exploitées, notamment le Natural Language Understanding (NLU), qui permet d'interpréter le sens et l'intention d'un texte, ainsi que la Named Entity Recognition (NER), utilisée pour identifier automatiquement des informations importantes telles que les noms d'entreprises, les montants financiers ou les dates figurant dans une facture électronique.

Par ailleurs, la qualité et la fiabilité des modèles prédictifs nécessitent des mécanismes d'interprétation et de contrôle. Pour cette raison, des approches de type SHAP-like (SHapley Additive exPlanations) sont utilisées afin d'expliquer les décisions prises par les modèles d'apprentissage automatique en mesurant la contribution de chaque variable à la prédiction finale. Lorsque les données disponibles sont insuffisantes ou déséquilibrées, des techniques de génération synthétique telles que CTGAN (Conditional Tabular Generative Adversarial Network) permettent de produire de nouvelles données tabulaires réalistes pour enrichir l'apprentissage des modèles. La qualité de ces données générées peut être évaluée à l'aide de la distance de Wasserstein, une mesure statistique permettant de comparer la proximité entre les distributions réelles et synthétiques. Enfin, puisque les plateformes SaaS évoluent constamment, il est nécessaire de surveiller le phénomène de Data Drift, qui correspond à la modification progressive de la distribution des données au fil du temps. La détection de ce phénomène permet de réentraîner les modèles lorsque leurs performances commencent à diminuer, garantissant ainsi la pertinence et la fiabilité continues du système intelligent proposé.

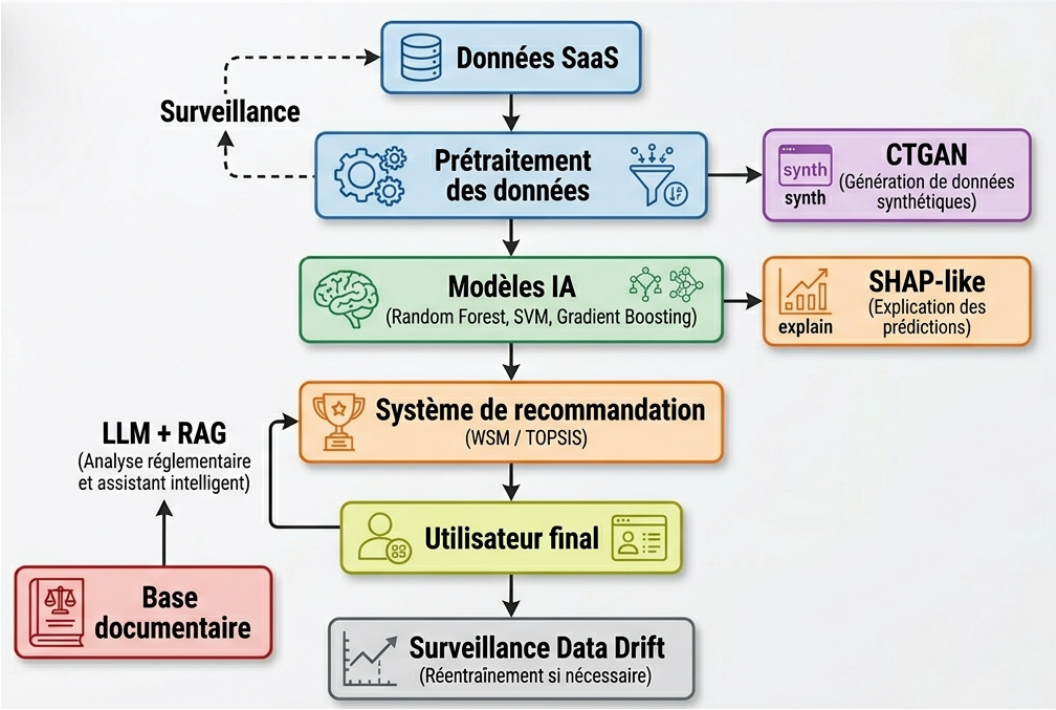


FIGURE 1.1 – Architecture fonctionnelle de la plateforme intelligente de recommandation des solutions SaaS de facturation électronique

1.2.3 Intérêt du projet (Pourquoi ?)

Ce projet présente plusieurs intérêts complémentaires couvrant les dimensions économique, technologique, stratégique et académique. Sur le plan économique, les solutions SaaS permettent aux entreprises de réduire les coûts liés à l'acquisition d'in-

frastructures informatiques et à la maintenance des logiciels traditionnels. Grâce à l'automatisation des tâches administratives et financières, les organisations peuvent améliorer leur productivité et optimiser leur gestion interne.

Sur le plan technologique, ce projet contribue à promouvoir la transformation digitale et l'adoption des technologies cloud au sein des entreprises marocaines. Le développement des solutions SaaS représente aujourd'hui un levier important de modernisation permettant aux organisations d'accéder à des outils innovants et évolutifs. Le projet met également en valeur l'intégration de l'Intelligence Artificielle dans l'analyse des marchés numériques.

D'un point de vue stratégique, l'étude du marché SaaS marocain permet de mieux comprendre les besoins des entreprises locales, d'identifier les opportunités d'investissement et d'évaluer la position des solutions locales face aux plateformes internationales. Le projet cherche également à analyser les défis liés à la souveraineté numérique, à la sécurité des données et à l'adaptation des solutions SaaS au contexte réglementaire marocain, notamment la réforme de la facturation électronique prévue pour 2026.

Enfin, sur le plan académique, ce projet permet d'appliquer les connaissances acquises durant la formation dans des domaines variés : systèmes d'information, Cloud Computing, Intelligence Artificielle, Apprentissage Automatique, analyse des données et transformation digitale.

1.2.4 À qui s'adresse ce projet ? (Pour qui ?)

Le projet d'analyse intelligente du marché SaaS s'adresse principalement aux acteurs économiques et technologiques impliqués dans la transformation digitale au Maroc. En premier lieu, il cible les **petites et moyennes entreprises (PME)** marocaines qui représentent plus de 95 % du tissu économique national. Ces entreprises recherchent des solutions numériques capables d'améliorer leur gestion administrative et financière tout en réduisant les coûts liés aux infrastructures informatiques traditionnelles.

Le projet s'adresse également aux **startups marocaines** évoluant dans le domaine des technologies numériques et des services cloud. Avec le développement de l'écosystème entrepreneurial marocain et l'émergence de nouveaux besoins en digitalisation, les startups ont besoin d'outils performants leur permettant de gérer efficacement leurs activités financières et commerciales, d'évaluer leur positionnement tarifaire et d'optimiser leur stratégie de mise sur le marché.

Les **cabinets de comptabilité** et les professionnels de la gestion financière figurent parmi les bénéficiaires importants de ce projet. Par ailleurs, les **développeurs et éditeurs de solutions SaaS** souhaitant comprendre les besoins du marché marocain constituent également une audience cible.

Enfin, le projet intéresse les **décideurs publics**, les chercheurs et les acteurs de

la transformation digitale. Dans le cadre de la stratégie nationale Maroc Digital 2030, cette étude peut contribuer à une meilleure compréhension des défis liés à la souveraineté numérique, à l'adoption du cloud et à la modernisation des entreprises marocaines.

Références

— Gartner, *Forecast Analysis : Public Cloud Services, Worldwide*, 2025.

— Statista, *Global SaaS Market Revenue Forecast*, 2025.

— Microsoft Azure, *What is SaaS (Software as a Service) ?*

— IBM Cloud, *Cloud Computing Explained*.

— Ministère de l'Industrie et du Commerce du Maroc, *PME et transformation digitale au Maroc*.

— Maroc Digital 2030, Ministère de la Transition Numérique et de la Réforme de l'Administration.

1.3 Cadrage logique du stage

1.3.1 Problématiques et enjeux

Le marché des solutions SaaS connaît une croissance rapide à l'échelle mondiale grâce à l'accélération de la transformation digitale et au développement des technologies cloud. Au Maroc, cette évolution progresse progressivement avec l'augmentation des besoins des entreprises en solutions numériques accessibles et flexibles. Cependant, malgré cette dynamique positive, plusieurs problématiques continuent de freiner l'adoption des plateformes SaaS, notamment dans le domaine de la facturation électronique.

L'une des principales difficultés rencontrées par les entreprises marocaines concerne le choix des solutions adaptées à leurs besoins. Le marché propose aujourd'hui un grand nombre de plateformes SaaS possédant des fonctionnalités, des coûts et des modèles économiques différents, rendant le processus de sélection complexe, particulièrement pour les PME et les startups qui manquent d'informations fiables concernant les performances, la sécurité et la conformité des plateformes disponibles.

La question de la **sécurité et de la souveraineté des données** constitue également un enjeu majeur. De nombreuses entreprises restent réticentes à stocker leurs données financières sur des serveurs distants, principalement en raison des risques liés à la cybersécurité, à la confidentialité des informations et à la dépendance envers des fournisseurs étrangers. Cette situation est accentuée par la domination des grandes plateformes internationales sur le marché SaaS marocain.

Face à ces problématiques, plusieurs enjeux stratégiques se dessinent. Le premier consiste à accompagner la transformation digitale des entreprises marocaines en facilitant l'accès à des solutions SaaS adaptées, performantes et sécurisées. Le second concerne l'amélioration de la compétitivité des PME grâce à l'automatisation des processus. Le troisième enjeu, particulièrement pressant, est la **préparation des entreprises à la réforme de la facturation électronique 2026**, qui impose de nouvelles exigences réglementaires de conformité.

1.3.2 Arbre à problèmes

Le principal problème identifié dans cette étude concerne la difficulté d'adoption et de sélection des solutions SaaS de facturation au Maroc. Malgré les avantages offerts par les technologies cloud et les plateformes numériques, de nombreuses entreprises marocaines hésitent encore à intégrer ces solutions dans leurs activités quotidiennes.

Plusieurs causes expliquent cette situation : le manque de visibilité sur les plateformes disponibles, les coûts d'abonnement relativement élevés pour les petites entreprises, le manque de confiance dans les technologies cloud, une culture numérique encore limitée dans certaines structures, et l'absence d'outils intelligents capables d'analyser

et de comparer les plateformes SaaS disponibles.

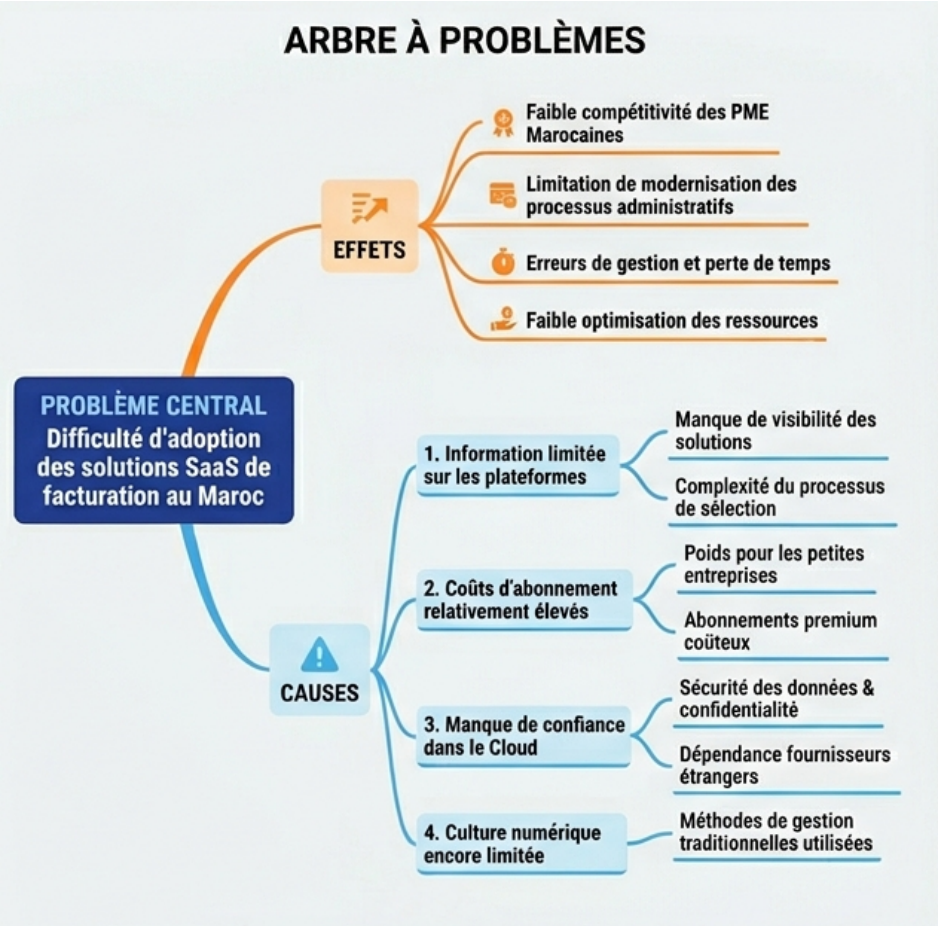


FIGURE 1.2 – Arbre à problèmes lié à l'adoption des solutions SaaS

1.3.3 Arbre à solutions

Afin de répondre aux problématiques identifiées, ce projet propose le développement d'une analyse intelligente du marché SaaS de facturation au Maroc. Cette solution vise à fournir aux entreprises une meilleure visibilité sur les plateformes disponibles et à faciliter le processus de prise de décision grâce à une analyse structurée des données du marché.

L'une des solutions proposées consiste à centraliser les informations relatives aux différentes plateformes SaaS afin de permettre aux utilisateurs de comparer facilement les fonctionnalités, les coûts, les performances et les niveaux de sécurité des solutions existantes. Le projet prévoit l'utilisation de technologies d'intelligence artificielle et d'analyse de données afin d'identifier les tendances du marché et les opportunités de développement.

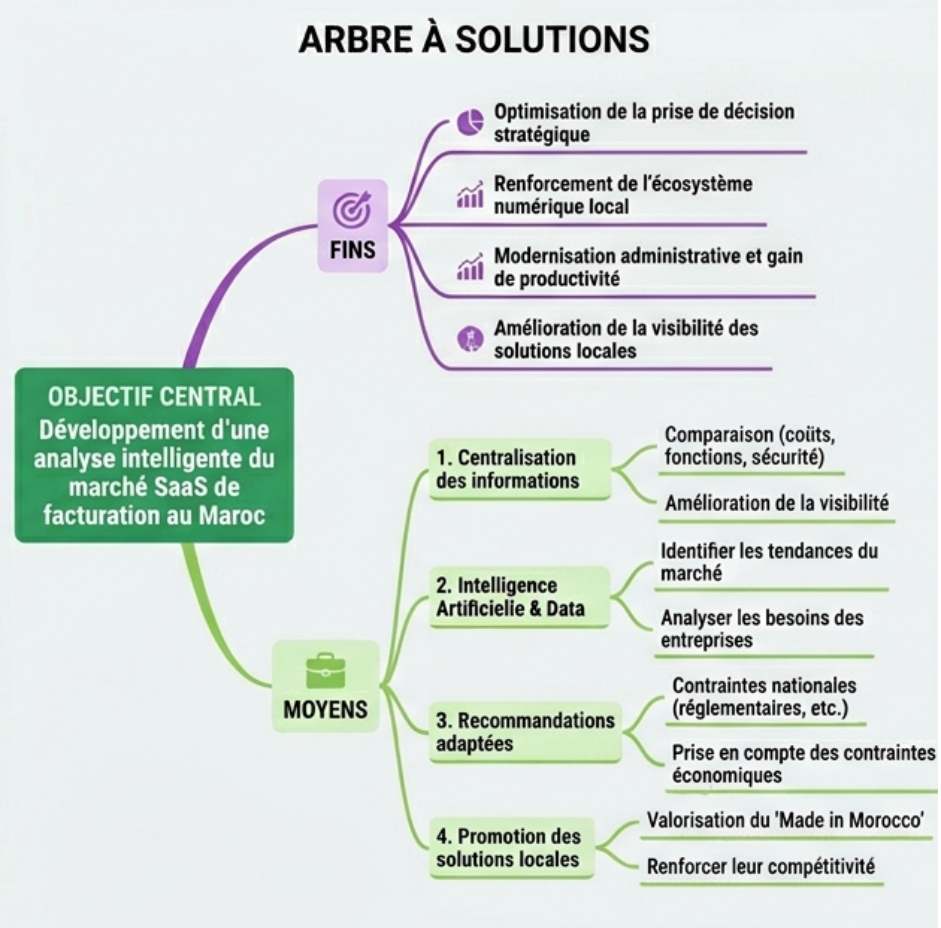


FIGURE 1.3 – Arbre à solutions pour l'adoption des solutions SaaS

1.3.4 Objectifs et résultats

L'objectif principal de ce projet est d'analyser le marché des solutions SaaS de facturation au Maroc afin de mieux comprendre son fonctionnement, ses tendances, ses opportunités de développement ainsi que les facteurs influençant son évolution. Cette étude vise également à identifier les besoins des entreprises marocaines, à évaluer les plateformes existantes et à intégrer des approches de prédiction et d'optimisation.

Le projet cherche notamment à comparer les solutions SaaS existantes selon plusieurs critères : les fonctionnalités, les coûts, l'accessibilité, la sécurité et l'expérience utilisateur. Il vise aussi à analyser l'impact des nouvelles technologies, notamment l'Intelligence Artificielle et le Cloud Computing, sur l'évolution du marché SaaS marocain.

Résultats attendus

Le projet permettra la réalisation d'un **tableau comparatif détaillé** des principales plateformes SaaS selon leurs fonctionnalités, coûts, niveau de sécurité, accessibilité et adaptation au contexte marocain.

Il vise également à produire des **modèles de prédiction** permettant d'anticiper

l'évolution du marché SaaS, les besoins futurs des entreprises et les tendances technologiques liées au cloud computing, à l'automatisation et à l'intelligence artificielle.

Par ailleurs, des mécanismes **d'optimisation** seront proposés afin d'améliorer la sélection des solutions SaaS, réduire les coûts potentiels et recommander les plateformes les plus adaptées selon les caractéristiques des entreprises étudiées.

1.3.5 Activités nécessaires

La réalisation de ce projet a nécessité plusieurs activités permettant d'assurer une étude complète et structurée du marché SaaS de facturation au Maroc. La première étape a consisté à effectuer une **recherche documentaire approfondie** à partir d'articles scientifiques, de rapports économiques et de publications spécialisées.

Une **étude du marché SaaS** a ensuite été réalisée afin d'identifier les principales plateformes de facturation utilisées à l'échelle internationale et nationale. Dans ce cadre, plusieurs plateformes comme Zoho Invoice, QuickBooks, Odoo, Stripe Billing et FreshBooks ont été analysées. Le choix de ces plateformes s'est appuyé sur des critères précis tels que la **popularité et l'adoption**, la **richesse fonctionnelle**, l'**accessibilité linguistique**, le **modèle économique**, la **sécurité et conformité**, ainsi que le degré d'**innovation technologique**.

Le projet a également nécessité une phase importante de **collecte et d'analyse des données** concernant les besoins des entreprises marocaines, les défis liés à la digitalisation et les opportunités offertes par les solutions cloud. Une **veille concurrentielle et technologique** a été menée afin d'identifier les innovations du secteur et d'anticiper les tendances futures.

1.3.6 Contrôle et suivi des travaux

Le suivi du projet représente une étape essentielle afin de garantir le bon déroulement des différentes activités réalisées durant le stage. Des réunions périodiques ont été organisées avec l'encadrant afin de discuter des différentes étapes du projet, d'évaluer les progrès réalisés et de proposer des améliorations lorsque cela était nécessaire.

L'évaluation régulière des activités réalisées a également permis de contrôler la qualité des analyses effectuées, notamment lors de la collecte des données, de l'étude comparative des solutions SaaS et de la conception des maquettes. Enfin, le respect du planning du stage a constitué un élément important dans le suivi du projet.

1.4 Veilles concurrentielle et technologique

1.4.1 Veille concurrentielle

Qu'est-ce qu'une veille concurrentielle ?

La veille concurrentielle désigne un processus stratégique consistant à collecter, analyser et exploiter des informations relatives aux concurrents afin de mieux comprendre leur positionnement, leurs services, leurs innovations et leurs stratégies de développement. Dans le domaine des technologies numériques et des solutions SaaS, cette démarche permet aux entreprises d'identifier les tendances du marché, d'anticiper les évolutions technologiques et d'améliorer leur compétitivité face aux acteurs établis.

Dans le cadre de ce projet, la veille concurrentielle a permis d'étudier les principales plateformes SaaS de facturation présentes sur le marché international et marocain. Cette analyse vise à comparer les fonctionnalités offertes par les différentes solutions, leurs avantages compétitifs, leurs limites ainsi que leur capacité à répondre aux besoins spécifiques des entreprises marocaines, notamment en termes d'adaptation au contexte réglementaire local.

Les solutions informatiques concurrentes

Le marché des SaaS de facturation est dominé par plusieurs plateformes internationales reconnues pour leurs fonctionnalités avancées et leur large adoption. **Zoho Invoice** permet la gestion des factures, des paiements et des clients grâce à une interface intuitive adaptée aux petites entreprises. **QuickBooks**, développé par Intuit, propose des outils de gestion financière complets incluant le suivi des dépenses et la génération de rapports comptables automatisés.

D'autres plateformes comme **FreshBooks**, **Stripe Billing**, **Odoo**, **Sage** et **Xero** occupent également une place importante sur le marché. Odoo se distingue par son modèle ERP open source intégrant plusieurs modules de gestion, tandis que Stripe Billing est spécialisé dans la gestion des abonnements et des paiements en ligne avec une API puissante. Sur le marché marocain, ces plateformes internationales coexistent avec des solutions locales encore en développement, créant un contexte concurrentiel complexe.

Tableau comparatif des solutions concurrentes

Cette analyse comparative révèle que si les solutions internationales offrent des fonctionnalités avancées, elles présentent souvent des limitations importantes pour le contexte marocain : coûts élevés non adaptés aux PME locales, absence d'intégration avec les systèmes de Plateforme de Dématérialisation Partenaire (PDP) exigés par

la réforme e-facturation 2026, et manque d'adaptation au cadre réglementaire de la Direction Générale des Impôts (DGI) marocaine.

TABLE 1.1 – Comparaison des principales solutions SaaS de facturation

Solution	**Fonctionnalités principales**	**Avantages**	**Inconvénients**
Zoho Invoice	Facturation, gestion clients, paiements en ligne, devis automatisés	Interface simple, plan gratuit disponible, adapté aux PME	Fonctionnalités avancées limitées en version gratuite
QuickBooks	Comptabilité complète, suivi des dépenses, rapports financiers détaillés	Solution très complète et populaire, nombreuses intégrations	Coût relativement élevé, complexe pour les débutants
Odoo	ERP intégré, CRM, comptabilité, facturation, gestion inventaire	Très flexible, open source, hautement personnalisable	Configuration complexe, nécessite une expertise technique
FreshBooks	Facturation automatisée, suivi des dépenses, rapports simples	Très facile à utiliser, idéal pour freelances et PME	Fonctionnalités avancées payantes, tarification élevée
Stripe Billing	Gestion des abonnements, paiements récurrents, API puissante	API robuste, excellente automatisation des paiements en ligne	Nécessite des compétences techniques avancées
Xero	Comptabilité cloud, rapports financiers, gestion multi-devises	Bonne expérience utilisateur, solide pour comptabilité pro	Prix élevé pour certaines options avancées

Références

— Intuit QuickBooks, *Official Documentation*, 2025.

— Zoho Invoice, *Official Website*, 2025.

— Odoo, *Official Documentation*, 2025.

— Stripe Billing, *Developer Documentation*, 2025.

— Gartner, *Forecast Analysis : Public Cloud Services Worldwide*, 2025.

— Statista, *Global SaaS Market Revenue*, 2025.

1.4.2 Veille technologique

Qu'est-ce qu'une veille technologique ?

La veille technologique consiste à surveiller les évolutions scientifiques et technologiques afin d'identifier les innovations, outils et méthodes pouvant répondre aux besoins d'un projet ou d'un secteur d'activité. Dans le domaine des solutions SaaS, cette veille permet d'étudier les nouvelles technologies utilisées dans le cloud computing, l'intelligence artificielle, la cybersécurité et le développement web moderne.

Dans le cadre de ce projet, la veille technologique joue un rôle central, car elle permet de comprendre les technologies les plus adaptées au développement d'une plateforme d'analyse intelligente du marché SaaS. Elle contribue également à anticiper les évolutions futures du secteur numérique et à intégrer des solutions innovantes répondant aux attentes croissantes des utilisateurs.

Les technologies informatiques répondant aux problématiques

Les plateformes SaaS modernes reposent sur plusieurs technologies essentielles. Le cloud computing constitue la fondation principale, permettant d'héberger les applications et de garantir leur accessibilité via Internet à faible coût. Les APIs REST facilitent la communication entre les différentes applications et services numériques. L'intelligence artificielle et l'analyse des données représentent les leviers d'innovation les plus importants.

Pour ce projet, les technologies retenues comprennent : Python avec le framework Flask pour le backend, scikit-learn pour le machine learning, l'API Groq (modèle LLaMA 3.3 70B) pour le Large Language Model, TF-IDF for scratch pour le RAG, les algorithmes WSM et TOPSIS pour le MCDM, et Chart.js pour la visualisation.

TABLE 1.2 – Stack technologique du système SaaS Assistant

Couche	**Technologie**	**Usage dans le projet**
Backend	Flask (Python)	Serveur web, 28 routes API REST, base de données SQLite pour l'historique
LLM	Groq (LLaMA 3.3 70B)	Chatbot intelligent, NLU, NER, génération automatique de rapports d'audit SaaS
Machine Learning	scikit-learn	4 classificateurs Random Forest avec SMOTE, importance des features (Gini)
MCDM	Python natif	Algorithmes WSM et TOPSIS pour l'aide à la décision multicritère
RAG	TF-IDF + Groq	Retrieval-Augmented Generation de conformité CNDP/RGPD sans dépendance externe
Frontend	HTML/CSS/JS vanilla	Interface responsive 3 colonnes, 65 fonctions JavaScript, UI complète avec Chart.js
Base de données	SQLite	Historique des conversations utilisateurs, logs structurés JSON Lines

Responsabilités distinctes de chaque technologie

Le tableau ci-dessus liste les technologies utilisées. Il est fondamental de comprendre que chacune remplit un rôle précis et non substituable dans l'architecture globale du système : elles ne se chevauchent pas, elles s'enchaînent. Une confusion entre ces rôles conduirait à mal interpréter les résultats, à surestimer les capacités d'un composant ou à négliger ses limites. Le présent paragraphe définit rigoureusement ce que fait — et ce que ne fait pas — chacune des six technologies clés.

Random Forest (RF) — le moteur prédictif central. Random Forest est l'algorithme de classification supervisée retenu pour les quatre tâches de prédiction du projet. Il reçoit en entrée un vecteur de 31 variables décrivant une solution SaaS (prix, notes, caractéristiques techniques, contexte marché) et produit en sortie la classe la plus probable pour chacune des quatre variables cibles : classe de prix (Free/Low/Medium/Enterprise), segment de taille (Petite/Moyenne/Grande/Très Grande), conformité e-facture 2026 (Oui/Non), et niveau de satisfaction (Faible/Moyen/Élevé). RF a été préféré aux autres algorithmes testés (SVM, Gradient Boosting, KNN, etc.) grâce à sa robustesse aux va-

leurs manquantes résiduelles, à sa capacité à gérer des variables mixtes numériques et catégorielles, et à sa transparence via l'importance des features (Gini). Sa limite principale est qu'il est un prédicteur statistique : il ne raisonne pas, ne comprend pas le contexte métier et ne génère aucune explication textuelle. Il produit une étiquette de classe et une probabilité ; c'est au LLM d'en faire un discours, et au MCDM d'en faire un classement.

SMOTE — le correcteur du déséquilibre de classes. SMOTE (Synthetic Minority Over-sampling Technique) est une technique de rééquilibrage appliquée exclusivement lors de la phase de préparation des données d'entraînement, après le split train/test. Le dataset brut présente un déséquilibre sévère : la classe *Low* représente 89,7 % des observations pour `Classe_prix`, tandis que la classe *Enterprise* n'en regroupe que 1,6 %. Sans correction, un modèle entraîné sur ce dataset tendrait à ignorer systématiquement les classes minoritaires, atteignant une accuracy élevée de façon illusoire. SMOTE génère de nouveaux exemples synthétiques en interpolant linéairement entre des observations minoritaires voisines dans l'espace des features, sans dupliquer des lignes existantes. Sa limite est bien définie : il n'est appliqué qu'aux données d'entraînement, jamais aux données de test ni aux requêtes en production, afin de ne pas biaiser l'évaluation des performances. Il ne génère pas de solutions SaaS réalistes — c'est le rôle de CTGAN et GaussianCopula.

CTGAN et GaussianCopula — les générateurs de données synthétiques. Ces deux modèles ont été utilisés pour augmenter le dataset initial de 239 observations réelles jusqu'à 1 425 lignes, comblant le manque de données issu des difficultés de scraping (anti-bots de G2, Capterra). GaussianCopula modélise les structures de dépendance entre variables continues en estimant la copule gaussienne jointe ; il est efficace pour reproduire des corrélations statistiques mais suppose des distributions marginales proches du normal. CTGAN (Conditional Tabular GAN) est un réseau antagoniste génératif conditionnel conçu pour les données tabulaires ; il gère les distributions mixtes (variables continues et catégorielles) et les déséquilibres de classes via un entraîneur conditionnel. Les deux modèles ont été combinés dans un ratio 70 % GaussianCopula / 30 % CTGAN pour maximiser la diversité statistique du dataset augmenté. Leur limite cruciale : ils n'interviennent ni pendant l'entraînement du Random Forest, ni lors de l'inférence en production. Ce sont des outils de préparation offline ; une fois le dataset constitué et les modèles entraînés, ils ne sont plus sollicités.

RAG — le module de conformité réglementaire sourcée. Le RAG (Retrieval-Augmented Generation) est le composant qui permet au système de répondre à des questions réglementaires précises (CNDP Loi 09-08, RGPD UE Art. 5, 6, 25, 32) sans

risquer d'halluciner des textes de loi inexistants. Son fonctionnement est le suivant : une base documentaire de 9 chunks de texte réglementaire est indexée par TF-IDF (Term Frequency–Inverse Document Frequency). Lorsqu'une requête utilisateur porte sur la conformité, le système calcule la similarité cosinus entre le vecteur TF-IDF de la requête et les 9 vecteurs des chunks, sélectionne les k passages les plus pertinents ($k = 3$ par défaut) et les injecte dans le prompt du LLM comme contexte factuel. Le LLM répond alors en s'appuyant sur ces extraits sourcés plutôt que sur ses paramètres internes. La limite du RAG est son périmètre volontairement restreint : il n'intervient que pour les questions réglementaires, pas pour les prédictions ML ni pour le comparateur MCDM. Il ne prédit pas, ne classe pas, ne raisonne pas — il récupère et transmet des faits.

LLM (LLaMA 3.3 70B via Groq) — la couche conversationnelle et de synthèse. Le Large Language Model est l'interface unifiée entre l'utilisateur et l'ensemble des modules du système. Il remplit trois fonctions distinctes : la compréhension du langage naturel (NLU/NER), où il extrait des entités métier depuis le texte libre de l'utilisateur (secteur d'activité, budget, nombre d'utilisateurs, zone géographique) pour alimenter les autres modules ; la génération de rapports d'audit narratifs, où il transforme les prédictions numériques de RF et les scores MCDM en un rapport structuré en langage naturel ; et la réponse conversationnelle, où il dialogue avec l'utilisateur en s'appuyant sur les contextes RAG injectés ou les résultats de calcul disponibles. Sa limite essentielle est qu'il ne produit aucune prédiction numérique de sa propre initiative — il n'a pas accès au dataset et n'est pas entraîné sur les données SaaS. Toute valeur chiffrée qu'il présente provient de RF, de MCDM ou du RAG. Utilisé seul, sans ces modules, le LLM ne pourrait que produire des généralités non contextualisées. Son autre limite connue est la stochasticité : à requête identique, il peut formuler différemment la même information, ce qui rend le MCDM indispensable pour les classements objectifs.

MCDM (WSM + TOPSIS) — le moteur de décision multicritère déterministe. Le module MCDM (Multi-Criteria Decision Making) est la brique de décision objective et reproductible du système. Il implémente deux algorithmes complémentaires : WSM (Weighted Sum Model), qui calcule un score global par combinaison linéaire des critères normalisés, et TOPSIS (Technique for Order of Preference by Similarity to Ideal Solution), qui classe les alternatives selon leur distance géométrique à la solution idéale positive et à la solution anti-idéale négative. Les trois critères retenus sont le Coût TCO (40 %), la Fonctionnalité (30 %) et la Sécurité/SLA (30 %), mais les poids sont paramétrables par l'utilisateur via des curseurs interactifs. Le MCDM reçoit en entrée les prédictions de RF (classe de prix probable, niveau de conformité) ainsi que les données brutes des solutions comparées, les normalise sur une échelle commune,

puis produit un classement final avec scores détaillés. Sa force est sa complète déterminisité et explicabilité : chaque score est calculable à la main, reproductible et auditable, ce que le LLM ne peut garantir. Sa limite est qu'il n'est qu'un outil de classement relatif — il ne juge pas si une solution est « bonne » en valeur absolue, mais seulement meilleure ou moins bonne que les autres dans le périmètre de la comparaison soumise.

La digitalisation dans le secteur du projet

La digitalisation des services financiers et administratifs constitue aujourd'hui un levier majeur de modernisation pour les entreprises. Grâce aux solutions numériques, les organisations peuvent automatiser leurs opérations, améliorer leur gestion interne et optimiser leur productivité. Au Maroc, cette transformation digitale connaît une progression importante grâce aux initiatives nationales. La **réforme e-facturation 2026** de la Direction Générale des Impôts (DGI) impose aux entreprises marocaines de migrer vers des solutions de facturation électronique conformes, créant une opportunité unique pour les SaaS de facturation locaux d'accélérer leur adoption sur le marché national.

L'intégration de l'IA dans le domaine du projet

L'intelligence artificielle représente aujourd'hui un facteur majeur d'innovation dans le domaine des plateformes SaaS. Dans ce projet, l'IA est mobilisée à plusieurs niveaux complémentaires. Au niveau **prédictif**, des modèles de classification supervisée (Random Forest, Gradient Boosting, SVM) permettent d'anticiper le positionnement tarifaire, le segment de marché, la conformité réglementaire et le niveau de satisfaction de n'importe quelle solution SaaS. Au niveau **conversationnel**, un Large Language Model (LLM Groq/LLaMA 3.3 70B) assure un rôle de conseiller intelligent capable de comprendre des requêtes en langage naturel. Au niveau **décisionnel**, les algorithmes MCDM (WSM et TOPSIS) transforment les prédictions en recommandations transparentes et explicables.

Cadre réglementaire applicable — CNDP Loi 09-08 et RGPD

La conformité réglementaire constitue un enjeu critique pour toute solution SaaS collectant des données personnelles au Maroc ou en Europe. Deux textes structurent ce cadre dans le périmètre du projet.

La **Loi 09-08** relative à la protection des personnes physiques à l'égard des traitements des données à caractère personnel est la loi marocaine de référence en matière de protection des données. Inspirée de la Convention 108 du Conseil de l'Europe, elle impose aux responsables de traitement les obligations suivantes : (1) **déclaration**

préalable à la Commission Nationale de contrôle de la Protection des Données à caractère Personnel (CNDP) de tout traitement automatisé de données personnelles ; (2) recueil d'un **consentement explicite et éclairé** des personnes concernées avant tout traitement ; (3) garantie des **droits d'accès, de rectification et d'opposition** permettant à chaque individu de consulter, corriger ou supprimer ses données ; (4) mise en place de **mesures de sécurité techniques et organisationnelles** proportionnées aux risques, pour protéger les données contre tout accès non autorisé ; (5) restrictions strictes sur les **transferts de données hors du Maroc** vers des pays ne disposant pas d'un niveau de protection adéquat reconnu par la CNDP. Les solutions SaaS traitant des données RH, financières ou de clients marocains sont directement concernées par cette loi.

Le **Règlement Général sur la Protection des Données (RGPD)** de l'Union Européenne (Règlement 2016/679) s'applique à toute solution SaaS commercialisée en Europe ou traitant des données de résidents européens, indépendamment du lieu d'établissement de l'éditeur. Ses dispositions clés dans le contexte de ce projet sont : l'article 5 (principes de licéité, de minimisation et d'exactitude des données), l'article 6 (bases légales du traitement), l'article 25 (*privacy by design* — protection des données dès la conception), et l'article 32 (mesures de sécurité techniques et organisationnelles). Ces quatre articles constituent les critères de conformité évalués automatiquement par le module RAG du système pour chaque solution SaaS analysée.

1.5 Éléments du Cahier des charges — Spécifications fonctionnelles

Le cahier des charges du projet définit l'ensemble des fonctionnalités attendues du système SaaS Assistant développé dans le cadre de cette étude. Ce système se compose de deux espaces de travail distincts : **Mode Créateur** pour les startups et **Mode Acheteur** pour les PME. Chacun propose cinq agents spécialisés et une interface web responsive en trois colonnes (sidebar, zone de chat, panneau contextuel).

TABLE 1.3 – Spécifications fonctionnelles du système SaaS Assistant

Fonctionnalité	**Description détaillée**
Chatbot LLM intelligent	Moteur de conversation basé sur Groq (LLaMA 3.3 70B). Détection automatique FR/EN, historique de 20 messages, routing vers 10 agents spécialisés.
Prédictions IA (4 modèles)	Classification simultanée : classe de prix, segment de taille, conformité e-facture 2026, satisfaction utilisateur. Graphique d'explicabilité SHAP-like et TCO 5 ans.

Fonctionnalité	Description détaillée
Comparateur MCDM	Deux algorithmes scientifiques WSM et TOPSIS avec curseurs interactifs. Critères : fonctionnalité (30%), coût TCO (40%), sécurité/SLA (30%).
RAG Conformité	Génération augmentée par récupération TF-IDF sur 9 chunks CNDP Maroc et RGPD UE. Verdict Faible / Moyen / Élevé avec recommandations sourcées.
NLU/NER	Extraction automatique d'entités métier depuis texte libre (secteur, budget, utilisateurs, zone) pour alimenter MCDM et calculateur ROI/TCO.
Audit SaaS temps réel	Pipeline 4 étapes : extraction LLM, prédictions ML, comparaison dataset, rapport narratif. Analyse de n'importe quelle solution SaaS par nom ou URL.
Simulateur TCO/ROI	Calcul TCO, ROI%, Payback. Formule : TCO = abonnement + migration + formation + support. Projection financière sur 5 ans avec courbe d'amortissement Chart.js.
Mode Créateur (Startup)	5 agents dédiés : Pitch (diagnostic marché), SWOT automatique, MRR/ARR/LTV simulation, Business Model Canvas (9 blocs), Radar de positionnement.
Mode Acheteur (PME)	5 agents dédiés : Cadrage des besoins avec NLU, Comparateur MCDM, ROI/TCO, Conformité réglementaire CNDP/RGPD, Plan de déploiement en 4 phases.
Gouvernance & Sécurité	Logs JSON structurés (MLOps), anonymisation PII automatique (RGPD Art.25, CNDP Loi 09-08), versioning des modèles ML, détection de Data Drift (seuil 15%/30%).

L'architecture backend repose sur 28 routes API REST Flask couvrant la gestion des conversations, les prédictions ML, le calcul ROI/TCO, la comparaison MCDM, l'audit SaaS, la conformité réglementaire et l'administration. L'interface frontend est développée en HTML/CSS/JavaScript vanilla avec 65 fonctions JavaScript et 239 classes CSS.

1.6 Maquettage

Le maquettage du système SaaS Assistant repose sur une interface web en 3 colonnes conçue pour une utilisation intuitive et professionnelle. La **sidebar gauche** (260px) accueille le Workspace Switcher permettant de basculer entre les deux modes (Créateur

et Acheteur), le logo du projet, un moteur de recherche dans l'historique, la liste des conversations et la bibliothèque des agents disponibles.

La **zone centrale de chat** (flex :1) constitue le cœur de l'interface. Elle affiche l'en-tête avec le nom de l'agent actif, les messages conversationnels avec indicateur de frappe en temps réel, et la barre de saisie avec envoi par touche Entrée. Le **panneau droit contextuel** (300px, optionnel) s'affiche dynamiquement selon l'agent actif et présente les livrables en temps réel : cahier des charges auto-rempli, tableau de scores MCDM avec curseurs, graphique d'amortissement TCO, checklist conformité colorée, ou timeline de déploiement.

Le système de visualisation s'appuie sur Chart.js 4.4 pour les graphiques d'amortissement, le radar de positionnement concurrentiel (5 axes : Market Fit, Pricing, Innovation, Conformité, Scalabilité), les graphiques de contributions SHAP-like (barres horizontales positives et négatives) et le simulateur TCO sur 5 ans avec projection de croissance des effectifs.

1.7 Conclusion

Ce chapitre a posé les fondations conceptuelles et méthodologiques du projet d'analyse intelligente du marché SaaS. À travers la présentation du contexte, le cadrage logique, les veilles concurrentielle et technologique, la définition des spécifications fonctionnelles et le maquettage de l'interface, il a permis de circonscrire précisément la problématique à laquelle répond ce projet : comment aider les entreprises marocaines, en particulier les PME, à identifier et sélectionner la solution SaaS de facturation la plus adaptée à leurs besoins, dans un marché dominé par des acteurs internationaux et en pleine mutation réglementaire ?

L'analyse du marché SaaS marocain révèle un contexte porteur, marqué par l'accélération de la transformation digitale, les ambitions de la stratégie *Maroc Digital 2030* et l'entrée en vigueur imminente de la réforme DGI e-facturation 2026. La veille concurrentielle a confirmé l'absence d'un outil d'aide à la décision intelligent, explicable et ancré dans la réglementation locale, justifiant pleinement le développement du système **SaaS Assistant**.

La définition des spécifications fonctionnelles — combinant Machine Learning, MCDM (WSM + TOPSIS), génération augmentée par récupération (RAG) et modèle de langage de grande taille (LLM LLaMA 3.3 70B) — constitue une réponse innovante et cohérente aux problématiques identifiées. Les maquettes de l'interface traduisent ces spécifications en un parcours utilisateur clair, structuré autour des deux profils distincts de la plateforme : l'Acheteur PME et le Créateur SaaS.

Les chapitres suivants présentent la mise en œuvre concrète de ce système : le **Chapitre II** détaille la modélisation par intelligence artificielle, la préparation des

données et les résultats des algorithmes de classification, régression et clustering ; le **Chapitre III** présente la création et l'intégration complète des modèles au sein de la plateforme SaaS Assistant.

Chapitre 2

Modélisation par intelligence artificielle

2.1 Introduction

Le développement rapide des technologies liées à l'intelligence artificielle et à l'apprentissage automatique a profondément transformé les méthodes d'analyse et de traitement des données dans de nombreux domaines économiques et technologiques. Dans le cadre de ce projet consacré à l'analyse intelligente du marché SaaS marocain, le recours aux techniques de machine learning — classification supervisée, régression et clustering — constitue une approche méthodologique fondamentale permettant d'extraire des connaissances exploitables à partir des données collectées sur les solutions logicielles.

Le présent chapitre expose l'ensemble du processus de modélisation par intelligence artificielle mis en œuvre dans ce projet. Il décrit les objectifs d'apprentissage poursuivis, les risques identifiés, la démarche méthodologique adoptée ainsi que les résultats obtenus. Cette modélisation repose sur un jeu de données composé de **1 425 solutions SaaS** décrites par **31 variables** couvrant des dimensions tarifaires, financières, géographiques, commerciales et qualitatives.

Quatre tâches de classification distinctes ont été définies : la prédiction de la classe de prix d'une solution SaaS (`Classe_prix`), la prédiction de son segment de taille cible (`segment_taille`), la prédiction de sa conformité à la réglementation e-facturation 2026 (`conforme_e_facture_2026`), et la prédiction de son niveau de satisfaction utilisateur (`niveau_satisfaction`). Ces tâches supervisées sont complétées par une **régression multiple** pour l'estimation du prix numérique exact, et un **clustering K-Means** pour la segmentation non supervisée du marché. Pour chacune des tâches de classification, sept algorithmes supervisés ont été entraînés, évalués et comparés.

2.2 Objectifs recherchés en matière d'apprentissage

La modélisation par intelligence artificielle mise en œuvre dans ce projet poursuit trois catégories d'objectifs étroitement liées : le diagnostic de l'état du marché SaaS, la prédiction de variables cibles stratégiques et la décision assistée par les modèles construits.

2.2.1 Diagnostique

Le premier objectif est d'ordre diagnostique. Il s'agit de comprendre la structure interne du marché SaaS à partir des données collectées et d'identifier les patterns qui différencient les solutions selon leurs caractéristiques économiques, commerciales et qualitatives.

L'analyse de la distribution de la variable `Classe_prix` révèle un déséquilibre très marqué : la classe *Low* représente 89,7 % des observations tandis que la classe *Enterprise* n'en regroupe que 1,6 %. De même, la distribution de la variable `conforme_e_facture_2026` indique que seulement 12,8 % des solutions sont conformes à la réglementation e-facturation 2026, traduisant un retard significatif dans l'adaptation réglementaire du marché.

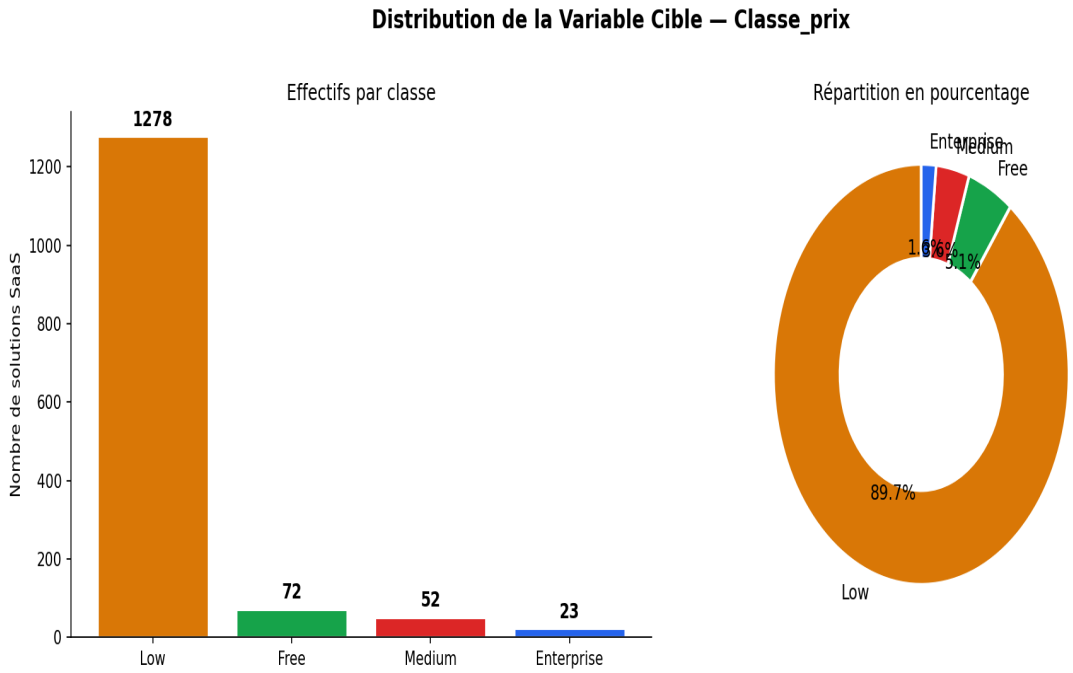


FIGURE 2.1 – Distribution de la variable Classe_prix

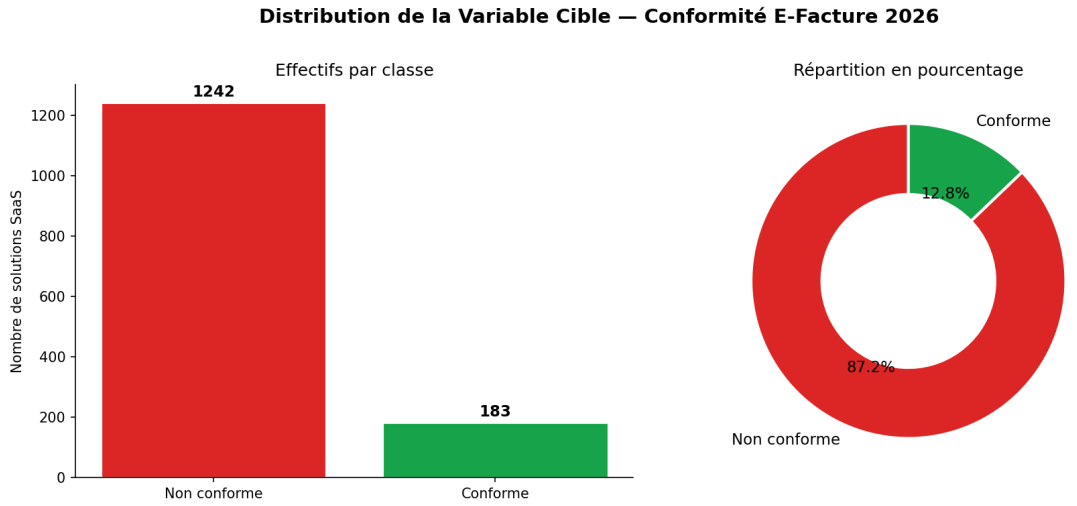


FIGURE 2.2 – Distribution de la Conformité e-facture 2026

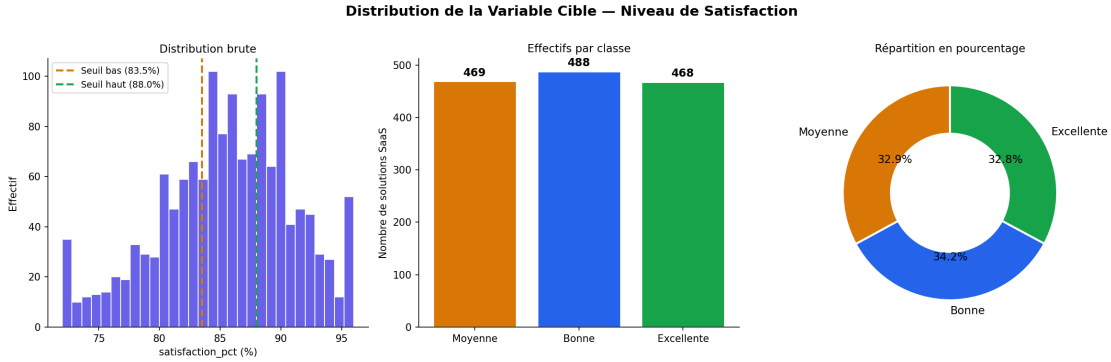


FIGURE 2.3 – Distribution du Niveau de satisfaction

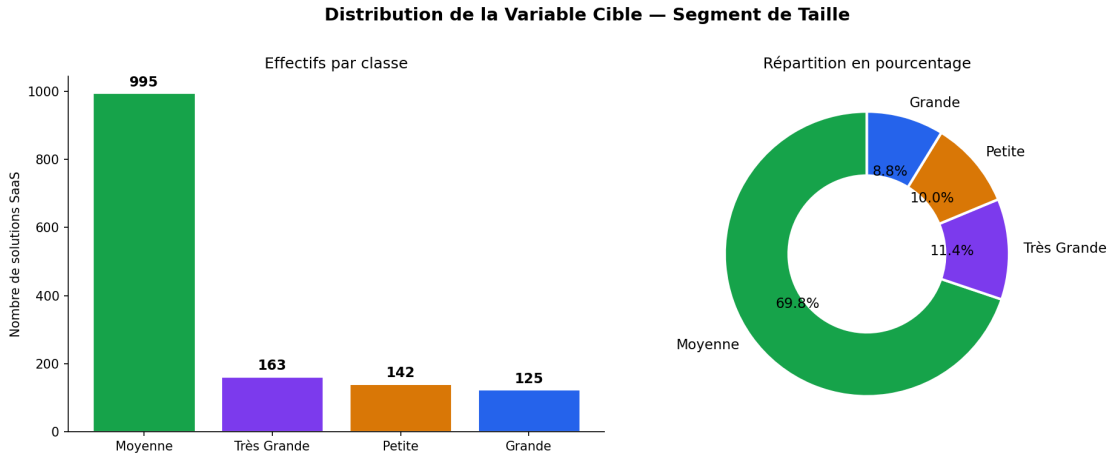


FIGURE 2.4 – Distribution du Segment de taille

2.2.2 Prédiction

Le deuxième objectif est de nature prédictive. Il consiste à construire des modèles d'apprentissage supervisé et non supervisé capables d'analyser et d'anticiper, à partir des caractéristiques d'une solution SaaS, plusieurs variables cibles stratégiques :

1. `Classe_prix` : la gamme tarifaire probable (Free, Low, Medium, Enterprise).
2. `Segment_taille` : le segment de taille cible (Petite, Moyenne, Grande, Très Grande).
3. `Conforme_e_facture_2026` : la conformité binaire à la réglementation 2026 (conforme / non conforme).
4. `Niveau_satisfaction` : le niveau de satisfaction utilisateur prévisible (Moyenne, Bonne, Excellente).
5. `prix_min_eur` (continu) : la valeur numérique exacte du prix minimal, prédite par **régression multiple** (Random Forest Regressor + Ridge).
6. **Segmentation de marché** : regroupement non supervisé des 1 425 solutions en clusters homogènes par **K-Means**, permettant une vision stratégique du paysage concurrentiel sans étiquette prédéfinie.

2.2.3 Décision

Le troisième objectif est d'ordre décisionnel. Les modèles prédictifs construits alimentent un système de recommandation intelligent permettant aux entreprises marocaines de sélectionner les solutions SaaS les plus adaptées à leur profil. Les éditeurs de solutions SaaS peuvent également exploiter les résultats d'importance des features pour orienter leurs décisions stratégiques de développement et de tarification.

Le Moteur d'Aide à la Décision Multi-Critères (MCDM)

Pour classer objectivement les solutions SaaS selon les priorités de l'utilisateur, le système déploie deux algorithmes complémentaires :

1. **Le Modèle de la Somme Pondérée (WSM)**

   Avec n solutions et m critères, les poids w_j vérifient :

   $$\sum_{j=1}^{m} w_j = 1$$

   Le score d'une solution A_i est :

   $$Score(A_i) = \sum_{j=1}^{m} w_j \cdot x_{ij}$$

   où x_{ij} est la valeur normalisée de la solution i sur le critère j.

2. **L'Algorithme TOPSIS**

   TOPSIS sélectionne la solution la plus proche de l'idéal positif A^+ et la plus éloignée de l'idéal négatif A^-. Les étapes sont :

— **Normalisation** :

$$x_{ij} = \frac{r_{ij}}{\sqrt{\sum_i r_{ij}^2}}$$

— **Pondération** :

$$v_{ij} = w_j \cdot x_{ij}$$

— **Distances** :

$$S_i^+ = \sqrt{\sum_j (v_{ij} - v_j^+)^2}, \quad S_i^- = \sqrt{\sum_j (v_{ij} - v_j^-)^2}$$

— **Score final** :

$$C_i^* = \frac{S_i^-}{S_i^+ + S_i^-}$$

— $C_i^* \to 1$ indique la solution optimale.

Les poids retenus sont : Fonctionnalité 30%, Coût TCO 40%, Sécurité/SLA 30%.

Références

— Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.

— Direction Générale des Impôts (DGI). *Réforme de la facturation électronique au Maroc*, 2024.

2.3 Processus d'apprentissage suivi

Le processus d'apprentissage supervisé mis en œuvre suit une architecture en pipeline structurée en plusieurs étapes séquentielles et reproductibles :

1. Chargement et exploration des données (1 425 × 31, vérification des valeurs manquantes).
2. Encodage des variables catégorielles via `LabelEncoder` avec `random_state=42`.
3. Rééquilibrage SMOTE pour corriger le déséquilibre de classes.
4. Séparation des données en ensembles d'entraînement (80 %) et de test (20 %) avec stratification.
5. Normalisation `StandardScaler` pour les modèles sensibles à l'échelle (Régression Logistique, KNN, SVM).
6. Entraînement et évaluation des sept algorithmes selon six métriques : Accuracy, Précision, Rappel, F1-Score, AUC-ROC et CV Accuracy (5 plis stratifiés).

Les sept algorithmes retenus couvrent l'ensemble du spectre des paradigmes d'apprentissage supervisé : régression logistique, arbre de décision, forêt aléatoire, Gradient Boosting, K plus proches voisins, SVM à noyau RBF et classificateur naïf bayésien.

Critère de séparation des nœuds — Minimisation MSE. Pour les arbres de régression intégrés dans les forêts aléatoires, le meilleur découpage est sélectionné en minimisant l'erreur quadratique moyenne intra-nœud :

$$\text{MSE} = \frac{1}{N_{\text{nœud}}} \sum_{i \in \text{nœud}} (y_i - \bar{y})^2 \tag{2.1}$$

où $N_{\text{nœud}}$ est le nombre d'observations dans le nœud courant et $\bar{y}$ leur valeur moyenne. Dans le contexte de classification utilisé ici, la pureté de Gini se substitue au MSE, mais la logique de minimisation est identique.

Agrégation par Bagging — Random Forest. La prédiction finale de la forêt aléatoire agrège les K arbres T_k par un vote majoritaire (classification) ou une moyenne (régression) :

$$\hat{y} = \frac{1}{K} \sum_{k=1}^{K} T_k(X) \tag{2.2}$$

Cette agrégation réduit la variance de l'estimateur individuel d'un facteur $1/K$, ce qui explique la robustesse systématique du Random Forest observée sur toutes les tâches.

Impureté de Gini — critère de séparation des nœuds. L'impureté de Gini mesure le degré de « mélange » des classes dans un nœud t contenant des observations réparties en C classes. Elle est définie par :

$$\text{Gini}(t) = 1 - \sum_{c=1}^{C} p_c^2$$

où p_c est la proportion d'observations appartenant à la classe c dans le nœud t. Une valeur de 0 indique un nœud pur (toutes les observations de la même classe) ; la valeur maximale $1 - 1/C$ correspond à une distribution uniforme entre les classes. Lors de la construction de chaque arbre, la division qui *minimise* la moyenne pondérée des impuretés de Gini des nœuds fils est sélectionnée. L'**importance d'une feature** selon l'indice de Gini est la somme pondérée des réductions d'impureté qu'elle produit à travers tous les arbres de la forêt :

$$\text{Importance}(j) = \frac{1}{K} \sum_{k=1}^{K} \sum_{t \in T_k : v(t) = j} \frac{N_t}{N} \big[\text{Gini}(t) - p_g \, \text{Gini}(t_g) - p_d \, \text{Gini}(t_d) \big]$$

où N_t est le nombre d'observations au nœud t, p_g et p_d les proportions envoyées vers les fils gauche et droit, et $v(t)$ la variable utilisée pour la séparation au nœud t. C'est cette valeur qui alimente directement les tableaux de feature importance (ex. `prix_min_eur` : 0,0845) et les graphiques SHAP-like de l'interface.

Normalisation StandardScaler — standardisation z-score. Avant d'entraîner les modèles sensibles à l'échelle des variables (SVM, KNN, Régression Logistique), chaque feature numérique x est transformée par standardisation z-score :

$$z = \frac{x - \mu}{\sigma}$$

où μ est la moyenne et σ l'écart-type calculés *uniquement sur les données d'entraînement*. Le `StandardScaler` est ensuite appliqué aux données de test sans recalculer μ et σ, évitant toute fuite d'information statistique. Cette transformation ramène toutes les features à une distribution de moyenne 0 et d'écart-type 1, rendant les algorithmes à base de distance (KNN) et de marge (SVM) indépendants des unités de mesure des variables.

Arbre de décision. Un arbre de décision est un modèle de classification qui partitionne récursivement l'espace des features en régions de plus en plus pures. À chaque nœud interne, la division est choisie pour maximiser la réduction d'impureté de Gini

(ou d'entropie). L'entropie d'un nœud t est définie par :

$$H(t) = -\sum_{c=1}^{C} p_c \log_2 p_c$$

L'arbre arrête de se diviser lorsqu'un critère d'arrêt est atteint (`max_depth`, `min_samples_split`). L'arbre de décision seul est instable (haute variance) et sujet au surapprentissage : c'est précisément pourquoi le Random Forest en agrège $K = 100$ instances entraînées sur des sous-échantillons bootstrap, réduisant la variance sans augmenter le biais.

Régression logistique. La régression logistique est un modèle linéaire de classification qui modélise la probabilité d'appartenance à une classe via la fonction sigmoïde. Pour un problème binaire, la probabilité $P(y = 1 \mid x)$ est :

$$P(y = 1 \mid x) = \sigma(w^\top x + b) = \frac{1}{1 + e^{-(w^\top x + b)}}$$

où w est le vecteur de poids et b le biais, estimés par maximisation de la vraisemblance. Pour les problèmes multiclasses (ex. `Classe_prix` à 4 niveaux), la régression logistique est étendue par la fonction softmax. Ses faibles performances dans ce projet (F1 de 48,9% à 69,4%) confirment que les relations entre les 31 variables SaaS et les variables cibles sont *non linéaires* — justifiant a posteriori le recours aux méthodes ensemblistes.

Machine à vecteurs de support — SVM à noyau RBF. Le SVM (Support Vector Machine) est un algorithme de classification supervisée qui cherche l'hyperplan de séparation optimal maximisant la marge entre les classes. Pour des données non linéairement séparables, le noyau RBF (*Radial Basis Function*) projette implicitement les données dans un espace de dimension supérieure :

$$K(x, x') = \exp\bigl(-\gamma \|x - x'\|^2\bigr)$$

où $\gamma > 0$ contrôle la portée locale de chaque point d'entraînement. Un γ élevé crée des frontières de décision très locales (risque de surapprentissage), un γ faible des frontières plus lisses. Ce noyau permet au SVM de capturer des relations non linéaires entre les 31 variables SaaS sans définir explicitement la transformation. Dans ce projet, le SVM-RBF constitue la meilleure alternative au Random Forest (AUC-ROC jusqu'à 0,994 sur `Classe_prix`), avec l'avantage d'une frontière de décision théoriquement optimale au sens de la marge maximale.

Gradient Boosting — apprentissage séquentiel par correction d'erreurs. Contrairement au Random Forest qui construit ses arbres *en parallèle* (bagging), le

Gradient Boosting les construit de façon *séquentielle* : chaque arbre h_m est entraîné sur les résidus du modèle précédent, c'est-à-dire les pseudo-résidus $-\partial L/\partial F_{m-1}$. Le modèle final est :

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x)$$

où $\eta \in (0, 1]$ est le taux d'apprentissage régularisant la contribution de chaque arbre. Cette stratégie réduit progressivement le biais au prix d'une complexité de calcul plus élevée et d'un risque de surapprentissage atténué par le contrôle de η et de la profondeur maximale des arbres. Dans les résultats de ce projet, le Gradient Boosting se classe systématiquement second ou troisième, confirmant son efficacité sur des données tabulaires mixtes.

Classificateur naïf bayésien — Naive Bayes. Le classificateur Naive Bayes applique le théorème de Bayes pour calculer la probabilité a posteriori de chaque classe C_k sachant les features observées $x = (x_1, \ldots, x_d)$:

$$P(C_k \mid x) \propto P(C_k) \prod_{j=1}^{d} P(x_j \mid C_k)$$

L'hypothèse d'indépendance conditionnelle entre les features (l'aspect « naïf ») simplifie drastiquement l'estimation, mais s'avère trop restrictive pour des données fortement corrélées comme les variables tarifaires, structurelles et qualitatives du dataset SaaS. Cette limite explique ses performances inférieures (F1-Score de 54 à 71 %) par rapport aux méthodes ensemblistes, et confirme a posteriori la pertinence du Random Forest.

K plus proches voisins — KNN. L'algorithme KNN classe une observation x en lui attribuant la classe majoritaire parmi ses k voisins les plus proches dans l'espace des features, selon la distance euclidienne :

$$\hat{y} = \arg\max_{c} \sum_{i \in \mathcal{N}_k(x)} \mathbf{1}[y_i = c]$$

où $\mathcal{N}_k(x)$ désigne les k plus proches voisins de x. Dans ce projet, KNN joue un double rôle : classificateur supervisé (`n_neighbors=5`) et imputeur de valeurs manquantes (`KNNImputer`, $k = 5$) pour les variables ordinales. Sa sensibilité à l'échelle des variables justifie la normalisation `StandardScaler` appliquée en amont. Son inconvénient principal est l'absence de phase d'entraînement à proprement parler : toute la complexité est reportée à l'inférence, ce qui le rend coûteux en production.

Métriques d'évaluation — AUC-ROC et F1-Score macro. Deux métriques clés sont utilisées pour comparer les algorithmes au-delà de l'accuracy brute.

AUC-ROC (Aire sous la courbe ROC — *Receiver Operating Characteristic*) mesure la capacité discriminante d'un modèle indépendamment du seuil de décision. La courbe ROC trace le taux de vrais positifs (Rappel) en fonction du taux de faux positifs pour l'ensemble des seuils possibles ; l'AUC en est l'intégrale :

$$\text{AUC} = \int_0^1 \text{TPR}(t)\, d\,\text{FPR}(t)$$

Une AUC de 1 correspond à un classifieur parfait, 0,5 à un classifieur aléatoire. Pour les problèmes multiclasses (ex. `Classe_prix` à 4 niveaux), l'AUC est calculée par la stratégie One-vs-Rest (OvR). L'AUC-ROC de 0,9997 du Random Forest sur `Classe_prix` signifie que le modèle est capable de distinguer quasi-parfaitement les solutions Free, Low, Medium et Enterprise dans 99,97 % des comparaisons aléatoires de paires.

Précision, Rappel et Accuracy sont les métriques élémentaires de classification. En notant VP les vrais positifs, FP les faux positifs, FN les faux négatifs et VN les vrais négatifs pour une classe donnée :

$$\text{Prcision}_k = \frac{\text{VP}_k}{\text{VP}_k + \text{FP}_k}, \quad \text{Rappel}_k = \frac{\text{VP}_k}{\text{VP}_k + \text{FN}_k}, \quad \text{Accuracy} = \frac{\sum_k \text{VP}_k}{N}$$

La Précision mesure la proportion de prédictions positives correctes (fiabilité des alarmes), le Rappel mesure la capacité à retrouver tous les vrais positifs (exhaustivité de la détection). Ces deux métriques sont en tension : augmenter l'un tend à réduire l'autre. Le F1-Score synthétise ce compromis.

F1-Score macro est la moyenne arithmétique simple des F1-Scores individuels calculés par classe :

$$\text{F1}_{\text{macro}} = \frac{1}{K} \sum_{k=1}^{K} \frac{2 \cdot \text{P}_k \cdot \text{R}_k}{\text{P}_k + \text{R}_k}$$

où P_k et R_k sont respectivement la Précision et le Rappel de la classe k. Contrairement au F1-Score *weighted* (pondéré par le support de chaque classe), le macro accorde un poids égal à toutes les classes, y compris les classes minoritaires comme *Enterprise* (1,6 % des observations). C'est la métrique retenue dans ce projet car elle pénalise davantage les mauvaises performances sur les classes rares, plus critiques pour la prise de décision métier.

Références

— Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.

— Cortes, C., & Vapnik, V. (1995). *Support-vector networks*. Machine Learning, 20(3), 273–297.

— Friedman, J. H. (2001). *Greedy function approximation : a gradient boosting machine*. Annals of Statistics.

— Cover, T., & Hart, P. (1967). *Nearest neighbor pattern classification*. IEEE Trans. Inf. Theory, 13(1), 21–27.

— Pedregosa, F. et al. (2011). *Scikit-learn : Machine learning in Python*. JMLR, 12, 2825–2830.

— Lemaître, G. et al. (2017). *Imbalanced-learn : A Python Toolbox*. JMLR, 18(17), 1–5.

— Fawcett, T. (2006). *An introduction to ROC analysis*. Pattern Recognition Letters, 27(8), 861–874.

2.4 Action orientée Science des données

2.4.1 Identification des paramètres

Le jeu de données décrit chaque solution SaaS par 31 variables couvrant six dimensions analytiques complémentaires. La **dimension géographique et commerciale** regroupe zone (9 modalités), cible (25 modalités) et pays_siege (20 modalités). La **dimension de notation** comprend note_g2, nb_avis_g2, note_capterra, nb_avis_capterra, note_trustpilot, note_moyenne_globale et satisfaction_pct. La **dimension tarifaire** inclut prix_min_eur, prix_max_eur, nb_plans, a_freemium, a_essai_gratuit et a_usage_based.

La **dimension structurelle** couvre annee_creation, age_produit, nb_employes, total_financement_mUSD, type_derniere_levee et nb_tours_financement. La **dimension fonctionnelle** est représentée par has_PDP, has_API, has_CRM, has_compta et has_mobile. L'analyse de l'importance des features selon l'indice de Gini révèle des prédicteurs dominants spécifiques à chaque tâche : prix_min_eur (0,0845) pour Classe_prix, nb_employes (0,0715) pour segment_taille, total_financement_mUSD (0,0966) pour conforme_e_facture_2026, et note_g2 (0,2337) pour niveau_satisfaction.

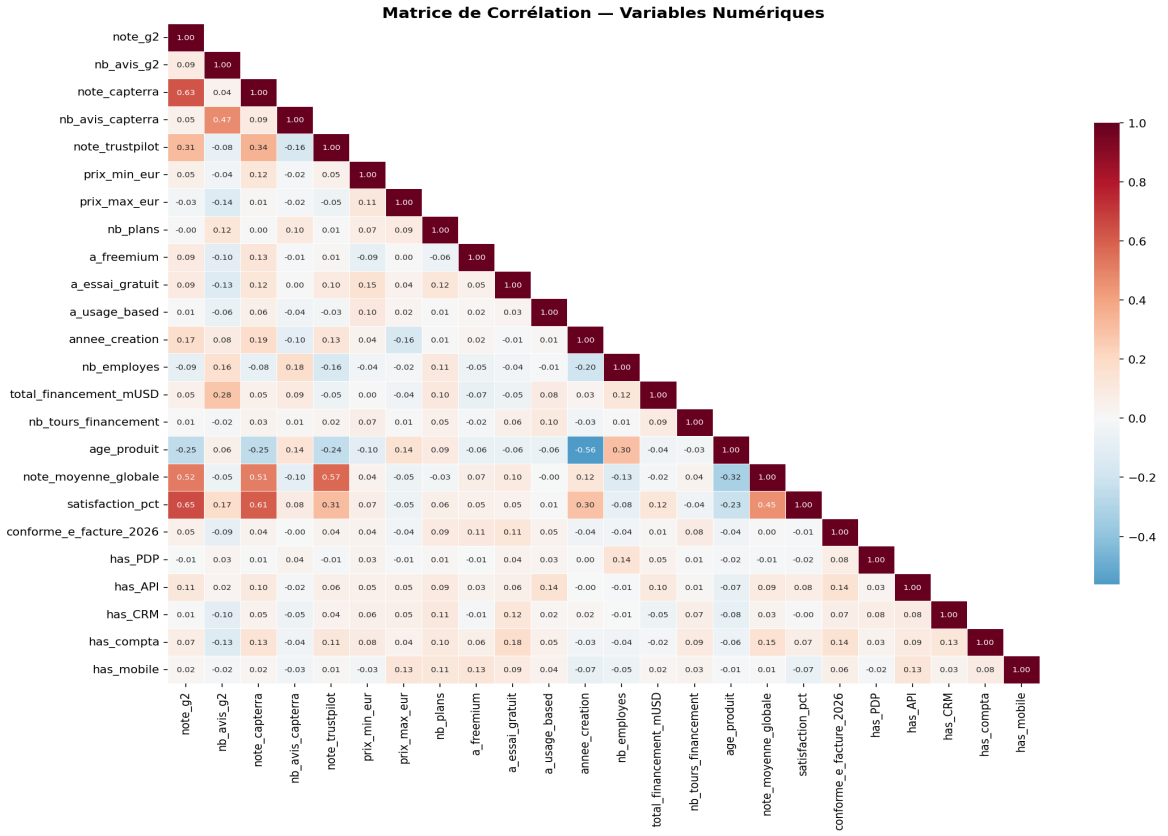


FIGURE 2.5 – Matrice de corrélation des variables du dataset

2.4.2 Description et rôle des variables du dataset

L'analyse des données constitue une étape essentielle dans la conception d'un chatbot intelligent dédié au marché des solutions SaaS. Les variables collectées dans le dataset ne sont pas de simples indicateurs statistiques : elles représentent des dimensions clés permettant de caractériser les produits, d'évaluer leur performance et de comprendre leur positionnement sur le marché. En intégrant ces variables dans un chatbot, il devient possible de fournir des réponses personnalisées, de comparer les solutions selon des critères objectifs et d'orienter les utilisateurs vers les choix les plus adaptés à leurs besoins.

TABLE 2.1 – Description des variables du dataset SaaS

Variable	**Description**
zone	Portée géographique du logiciel (Mondial, Europe, Amérique du Nord...)
has_CRM	Présence d'un module CRM
cible	Segment de clientèle visé (TPE, PME, ETI, GE, Freelances...)
has_compta	Présence d'un module de comptabilité
note_g2	Note moyenne sur G2
has_mobile	Disponibilité d'une application mobile
nb_avis_g2	Nombre d'avis sur G2
Classe_prix	Catégorie de prix (Low, Medium, Enterprise)
note_capterra	Note moyenne sur Capterra
nb_avis_capterra	Nombre d'avis sur Capterra
note_trustpilot	Note moyenne sur Trustpilot
prix_min_eur	Prix minimum en euros
prix_max_eur	Prix maximum en euros
nb_plans	Nombre de plans tarifaires proposés
a_freemium	Existence d'une offre gratuite
a_essai_gratuit	Disponibilité d'un essai gratuit
a_usage_based	Tarification basée sur l'usage
annee_creation	Année de création de l'entreprise
pays_siege	Pays du siège social
nb_employes	Nombre d'employés
total_financement_mUSD	Montant total des financements en millions USD
type_derniere_levee	Type de financement (Seed, Series A, IPO...)
nb_tours_financement	Nombre de tours de financement
age_produit	Âge du produit en années

Variable	Description
segment_taille	Taille cible (Petite, Moyenne, Grande, Très Grande)
note_moyenne_globale	Moyenne des notes globales
satisfaction_pct	Pourcentage de satisfaction des utilisateurs
conforme_e_facture_2026	Conformité à la réglementation e-facturation 2026
has_PDP	Présence d'un plan de développement produit
has_API	Disponibilité d'une API

Analyse détaillée du rôle et des avantages des variables

Les 31 variables du dataset se regroupent en six catégories analytiques complémentaires, chacune apportant une dimension spécifique à l'intelligence du système SaaS Assistant.

Variables fonctionnelles. Les variables `has_CRM`, `has_compta`, `has_mobile`, `has_API` et `has_PDP` décrivent les fonctionnalités offertes par chaque solution SaaS. Elles permettent au chatbot de filtrer les solutions selon les besoins exprimés par l'utilisateur — par exemple, une PME cherchant un logiciel avec API et application mobile.

Variables de réputation. Les variables `note_g2`, `note_capterra`, `note_trustpilot`, `nb_avis_g2` et `nb_avis_capterra` mesurent la perception et la satisfaction des clients sur les principales plateformes d'avis. Elles permettent de recommander les solutions les mieux notées ou les plus populaires, renforçant la confiance des utilisateurs dans les recommandations générées.

Variables financières. Les variables `prix_min_eur`, `prix_max_eur`, `Classe_prix`, `nb_plans`, `a_freemium`, `a_essai_gratuit` et `a_usage_based` décrivent la structure tarifaire et l'accessibilité économique de chaque solution. Elles permettent d'orienter les utilisateurs vers des solutions adaptées à leur budget et à leur modèle économique.

Variables organisationnelles. Les variables `annee_creation`, `pays_siege`, `nb_employes`, `total_financement_mUSD`, `type_derniere_levee`, `nb_tours_financement` et `age_produit` caractérisent la maturité et la solidité de l'entreprise éditrice. Elles permettent de distinguer les startups innovantes des acteurs établis, ce qui aide à évaluer la fiabilité et la pérennité d'une solution.

Variables de segmentation. Les variables `zone`, `cible` et `segment_taille` identifient le marché cible et la portée géographique de chaque solution. Elles permettent de proposer des solutions adaptées au contexte local ou international, notamment pour les entreprises marocaines cherchant une solution disponible au Maroc.

Variables de performance globale. Les variables `note_moyenne_globale`, `satisfaction_pct` et `conforme_e_facture_2026` évaluent la qualité perçue et la conformité réglementaire. Elles rassurent les utilisateurs sur la fiabilité des solutions, notamment face aux nouvelles obligations imposées par la réforme e-facturation 2026 de la DGI marocaine.

Références

— G2, *Software Reviews and Ratings*, 2025.

— Capterra, *Find the Best Software*, 2025.

— Trustpilot, *Business Reviews Platform*, 2025.

— Direction Générale des Impôts (DGI), *Réforme de la facturation électronique au Maroc*, 2024.

2.4.3 Mise en évidence des champs de variation des seuils spécifiques

L'analyse exploratoire préalable à la discrétisation des variables continues repose sur le coefficient d'asymétrie de Fisher (skewness), qui mesure la déviation de la distribution par rapport à la symétrie :

$$G_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^3}{\sigma^3} \tag{2.3}$$

Un coefficient $G_1 > 0$ indique une queue à droite (distribution leptokurtique positive), tandis que $G_1 < 0$ signale une asymétrie gauche. Pour `satisfaction_pct`, $G_1 < 0$, ce qui justifie l'utilisation des percentiles empiriques plutôt que des seuils fixes.

Pour la variable `niveau_satisfaction`, les seuils de discrétisation ont été définis aux percentiles 33 et 66 de la distribution empirique de `satisfaction_pct`, conduisant aux valeurs de 83,5 % et 88,0 %. Formellement, ces tertiles P_{33} et P_{66} vérifient :

$$\int_{-\infty}^{P_{33}} f(x)\,\mathrm{d}x = \frac{1}{3} \qquad \text{et} \qquad \int_{-\infty}^{P_{66}} f(x)\,\mathrm{d}x = \frac{2}{3} \tag{2.4}$$

où $f(x)$ est la densité empirique de `satisfaction_pct`. Ces seuils définissent trois classes quasi-équilibrées : Moyenne ($< 83{,}5\,\%$, 469 observations, 32,9 %), Bonne (83,5–88,0 %, 488 observations, 34,2 %) et Excellente ($> 88{,}0\,\%$, 468 observations, 32,8 %).

2.4.4 Mise en évidence des conditions et règles spécifiques

Les modèles extraient plusieurs règles discriminantes importantes. Pour la conformité e-facture, le financement total constitue le facteur dominant : les solutions bien financées et à tarification élevée tendent vers la conformité. Pour le segment de taille, l'échec des modèles linéaires (F1 $\approx 49\,\%$) confirme la non-linéarité des frontières entre segments. Pour la satisfaction, les notes des plateformes d'avis expliquent la quasi-totalité de la variance prédictible.

Références

— Molnar, C. (2022). *Interpretable Machine Learning* (2nd ed.).

— Strobl, C. et al. (2007). Bias in random forest variable importance measures. *BMC Bioinformatics*, 8, 25.

2.5 Préparation des données

La préparation des données constitue l'une des étapes les plus critiques du projet. La qualité des résultats dépend directement de la rigueur des transformations appliquées aux données brutes collectées et générées. Cette phase suit un pipeline en quatre étapes séquentielles :

1. Collecte brute (239 observations réelles) ;
2. Imputation ML des valeurs manquantes ;
3. Génération synthétique contrôlée (GaussianCopula + CTGAN) ;
4. Audit de fuite de données.

Le fichier `dataset_final.xlsx` contient **1 425 observations** (239 réelles + 1 186 synthétiques) et **31 variables**, sans aucune valeur manquante après imputation. Les variables catégorielles ont été encodées via `LabelEncoder` avec un `random_state=42` pour garantir la reproductibilité des résultats.

Le tableau 2.2 présente les résultats du rééquilibrage SMOTE appliqué aux quatre variables cibles :

TABLE 2.2 – Rééquilibrage SMOTE des quatre variables cibles

Variable cible	Classes	Avant SMOTE	Après SMOTE
Classe_prix	Free, Low, Medium, Enterprise	72 / 1278 / 52 / 23	1278
conforme_e_facture_2026	Conforme / Non conforme	181 / 1244	1242
segment_taille	Petite / Moyenne / Grande / TG	Déséquilibre variable	995
niveau_satisfaction	Moyenne / Bonne / Excellente	469 / 488 / 468	488

La séparation train/test (80/20) stratifiée garantit la représentativité de chaque classe dans les deux sous-ensembles. La normalisation `StandardScaler`, ajustée uniquement sur les données d'entraînement et appliquée aux données de test sans réajustement, préserve l'intégrité de l'évaluation en évitant toute fuite d'information statistique.

2.5.1 Pipeline de Données — Cycle de Vie de la Donnée

Le principe fondamental du Machine Learning est que la qualité des prédictions est directement proportionnelle à la qualité des données : *"Garbage In, Garbage Out"*. Le pipeline de données du projet suit trois étapes rigoureuses :

Collecte (Ingestion) — Méthodologie de Web Scraping

Définition du Web Scraping. Le Web Scraping est une technique informatique qui consiste à extraire automatiquement des informations depuis des sites web afin de les transformer en données structurées exploitables pour l'analyse. Contrairement à

une collecte manuelle, le scraping repose sur des scripts ou des programmes capables de parcourir des pages HTML, d'identifier des éléments précis (prix, avis, notes, caractéristiques techniques) et de les stocker dans un format standard tel que CSV, JSON ou Excel. Dans le cadre de ce projet, cette méthode s'est révélée indispensable pour obtenir un volume significatif de données réelles, les bases publiques ou académiques sur le marché SaaS de facturation étant particulièrement limitées.

Objectif de la collecte. L'objectif principal était de construire un dataset représentatif du marché SaaS facturation afin d'identifier les tendances de prix et de modèles économiques (freemium, essai gratuit, usage-based), d'évaluer la satisfaction des utilisateurs via les notes et avis (G2, Capterra, Trustpilot), d'analyser les caractéristiques techniques (présence d'API, conformité e-facture 2026, intégration CRM/comptabilité) et d'étudier la structure des entreprises (année de création, pays siège, nombre d'employés, financement).

Sources et adaptation. Nous avons ciblé initialement des plateformes spécialisées comme G2, Capterra et Trustpilot, qui regroupent des milliers de logiciels SaaS avec des avis vérifiés. Cependant, ces sites disposent de mécanismes de protection avancés contre les robots (anti-bot, Captcha, blocage IP), ce qui a limité la collecte directe. Face à ces blocages, nous avons constitué un corpus de $\sim$200 sites SaaS facturation (sites officiels, marketplaces, pages produits), stockés dans un fichier JSON, puis reliés à un script Python capable de parser et d'extraire automatiquement les variables pertinentes.

Variables collectées. Parmi les 31 colonnes du dataset final : notes et avis (`note_g2`, `note_capterra`, `note_trustpilot`, `nb_avis_g2`, `nb_avis_capterra`), prix et modèles (`prix_min_eur`, `prix_max_eur`, `Classe_prix`, `a_freemium`, `a_essai_gratuit`), caractéristiques techniques (`has_API`, `has_CRM`, `conforme_e_facture_2026`), et contexte marché (`annee_creation`, `pays_siege`, `nb_employes`, `total_financement_mUSD`).

Défis rencontrés et solutions mises en place. Les principaux défis ont été les blocages techniques (Captchas, interdiction de scraping sur G2/Capterra), les données manquantes sur certaines variables (notamment la conformité e-facture 2026) et l'hétérogénéité des formats entre sites. Pour y remédier : constitution d'un corpus JSON de 200 SaaS, parsing via Python, et génération de données synthétiques réalistes pour combler les manques en respectant des corrélations logiques (ex. SaaS récent $\rightarrow$ API disponible ; SaaS français $\rightarrow$ conformité e-facture 2026). Une colonne `source` a été ajoutée pour distinguer de manière transparente les données réelles des données synthétiques. Le pipeline complet suit l'enchaînement : scraping brut $\rightarrow$ nettoyage Pandas $\rightarrow$ fusion real/synthetic $\rightarrow$ export Excel.

Résultat de la collecte brute. À l'issue du scraping, le dataset initial contient **239 observations réelles** de solutions SaaS de facturation, décrites par 31 variables. Ce volume, bien que limité par les contraintes techniques du scraping, constitue une base empirique authentique sur laquelle repose l'ensemble du pipeline d'enrichissement.

Imputation ML des valeurs manquantes

Le dataset brut de 239 lignes présentait des taux de valeurs manquantes significatifs sur plusieurs variables clés. Une stratégie d'imputation différenciée par colonne a été appliquée via le script `ml_imputation.py`, selon la nature et le taux de manquants de chaque variable :

- `IterativeImputer` **(régression multivariée)** pour les variables à faible taux de manquants et corrélées linéairement : `note_capterra` (5%), `nb_avis_capterra` (5%), `prix_min_eur` (4%), `prix_max_eur` (6%), `total_financement_mUSD` (9%).
- `KNNImputer` **(**$k = 5$**)** pour `note_trustpilot` (76% manquants) : la similarité de profil entre solutions voisines permet une imputation plus fiable que la régression linéaire sur des données aussi lacunaires.
- `RandomForestRegressor / Classifier` pour `nb_plans` (56% manquants) et `type_derniere_levee` (60% manquants) : les modèles ensemblistes capturent les relations non-linéaires entre ces variables et les features disponibles.
- **Mode par groupe** (catégorie, sous_catégorie) pour `features_cles` (56% manquants).

À l'issue de l'imputation, le dataset de 239 lignes ne présente plus aucune valeur manquante, garantissant l'intégrité du pipeline de génération synthétique.

Génération synthétique et sélection du volume optimal

Face à l'insuffisance de 239 observations pour entraîner des modèles robustes, un pipeline de génération synthétique a été développé (`pipeline_2000.py`) en combinant deux modèles génératifs complémentaires : **GaussianCopula (70%)** pour capturer les corrélations statistiques entre variables continues, et **CTGAN (30%)** pour reproduire les distributions multimodales et les variables catégorielles complexes. Un filtrage qualité post-génération élimine les lignes incohérentes (prix négatifs, combinaisons impossibles).

Quatre paliers de volume ont été évalués — 500, 1000, 1500 et 2000 lignes totales — sur la base des métriques de validation croisée. Le palier **1 425 lignes (239 réelles + 1 186 synthétiques)** a été retenu comme volume optimal, offrant le meilleur équilibre entre diversité des données générées et stabilité des performances prédictives. Une colonne `source` distingue de manière transparente les observations réelles (`real`) des données synthétiques.

Audit de fuite de données (data leakage). Un audit rigoureux a été conduit via `audit_leakage.py` pour détecter tout risque de contamination du signal prédictif. Deux corrections critiques ont été appliquées :

1. la variable `prix_min_eur` a été systématiquement exclue des features lors de la prédiction de `Classe_prix` (dérivée directe) ;
2. `satisfaction_pct` a été exclue lors de la prédiction de `niveau_satisfaction`.

L'audit de quasi-doublons entre données réelles et synthétiques (distance euclidienne normalisée, seuil 0,5) a confirmé l'absence de mémorisation excessive du jeu d'entraînement par les modèles génératifs.

Validation de l'augmentation par cross-validation. Une validation croisée stratifiée à 5 plis a comparé les performances du modèle entraîné sur les seules données réelles (191 lignes train) versus le dataset augmenté (1 1377 lignes train). Les résultats confirment que l'augmentation synthétique améliore significativement les métriques CV et holdout, validant scientifiquement l'approche de génération de données.

Stockage

Le format Excel (`.xlsx`) a été retenu pour sa lisibilité, sa compatibilité avec les outils d'analyse bureautiques des PME marocaines, et sa facilité d'intégration avec `Pandas`/`Openpyxl`.

2.5.2 Justification de l'Augmentation de Données (GaussianCopula + CTGAN)

Les données réelles de tarification SaaS sont rares (239 solutions collectées) et déséquilibrées (89,7% de solutions Low, 1,6% Enterprise). Deux techniques de génération synthétique complémentaires ont été combinées dans un ratio 70/30 :

— **GaussianCopula (70%)** : modélise la structure de dépendance entre variables via une copule gaussienne multivariée, idéale pour capturer les corrélations entre variables continues comme les prix et les notes.

— **CTGAN (30%)** : génère des lignes tabulaires complètes en respectant les distributions multimodales et asymétriques du marché SaaS (ex. asymétrie positive des prix). La fonction minimax oppose un Générateur et un Discriminateur optimisés par distance de Wasserstein (WGAN-GP), garantissant la cohérence des données générées avec la structure statistique réelle.

Distance de Wasserstein. La distance de Wasserstein (ou Earth Mover's Distance) mesure l'effort minimal pour transformer une distribution de probabilité P en une autre

Q. Formellement :

$$W_1(P, Q) = \inf_{\gamma \in \Gamma(P,Q)} \mathbb{E}_{(x,y)\sim\gamma}\big[\|x - y\|\big]$$

où $\Gamma(P, Q)$ est l'ensemble de tous les couplages (distributions jointes) ayant P et Q comme marginales. Dans le contexte WGAN-GP, la distance de Wasserstein remplace la divergence Jensen-Shannon classique des GAN originaux, offrant un gradient plus stable lorsque les distributions réelle et générée ont des supports disjoints. Elle est également utilisée pour valider quantitativement la qualité des données synthétiques : une faible distance de Wasserstein entre les distributions des variables réelles et synthétiques (ex. `prix_min_eur` ou `note_g2`) confirme que le modèle génératif a bien capturé la structure statistique des 239 solutions SaaS collectées.

SMOTE intervient en complément, en aval de la génération, pour corriger le déséquilibre résiduel des classes cibles lors de l'entraînement des classificateurs.

2.6 Traitement des données

Le traitement des données correspond à la phase centrale du projet. Les sept algorithmes ont été entraînés et évalués sur chacune des quatre tâches selon le pipeline défini précédemment. Chaque tableau de résultats est trié par F1-Score décroissant, le Random Forest apparaissant systématiquement comme le meilleur modèle sur toutes les tâches.

2.6.1 Classification 1 — Classe de prix (`Classe_prix`)

La première tâche prédit la gamme tarifaire (Free, Low, Medium, Enterprise). Après correction du déséquilibre par SMOTE, la forêt aléatoire atteint des performances quasi-parfaites avec un **F1-Score de 98,23 %** et un AUC-ROC de 0,9997, grâce à la forte corrélation entre les variables tarifaires et la cible. Cette tâche est qualifiée de « Facile » en raison de la cohérence intrinsèque du marché SaaS.

TABLE 2.3 – Résultats — Classification de la Classe de prix

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Acc.
Random Forest	98,24 %	98,27 %	98,24 %	**98,23 %**	0,9997	98,14 %
SVM (RBF)	94,23 %	94,21 %	94,23 %	94,20 %	0,9940	93,81 %
Gradient Boosting	93,94 %	93,94 %	93,94 %	93,92 %	0,9929	93,01 %
K-Nearest Neighbors	90,32 %	91,33 %	90,32 %	89,76 %	0,9763	88,46 %
Decision Tree	85,43 %	85,38 %	85,43 %	85,21 %	0,9337	84,37 %
Régression Logistique	69,70 %	69,61 %	69,70 %	69,44 %	0,8856	67,35 %
Naive Bayes	56,01 %	58,82 %	56,01 %	54,37 %	0,8374	57,08 %

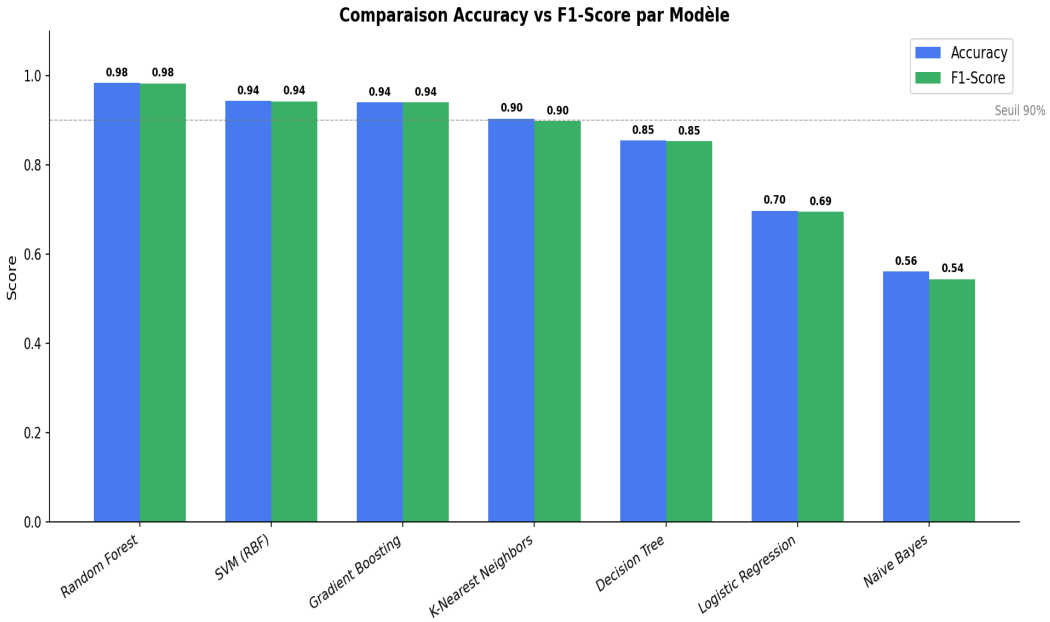


FIGURE 2.6 – Comparaison des modèles — Classe_prix

2.6.2 Classification 2 — Conformité e-facture 2026

La deuxième tâche prédit la conformité binaire à la réglementation e-facturation 2026. Le Random Forest atteint un **F1-Score de 88,66 %** et un AUC-ROC de 0,9632. Le financement total (`total_financement_mUSD`) est le prédicteur dominant, traduisant que les ressources financières conditionnent la capacité de mise en conformité. Cette tâche est qualifiée de « Difficile » en raison des facteurs non-observables influençant la conformité.

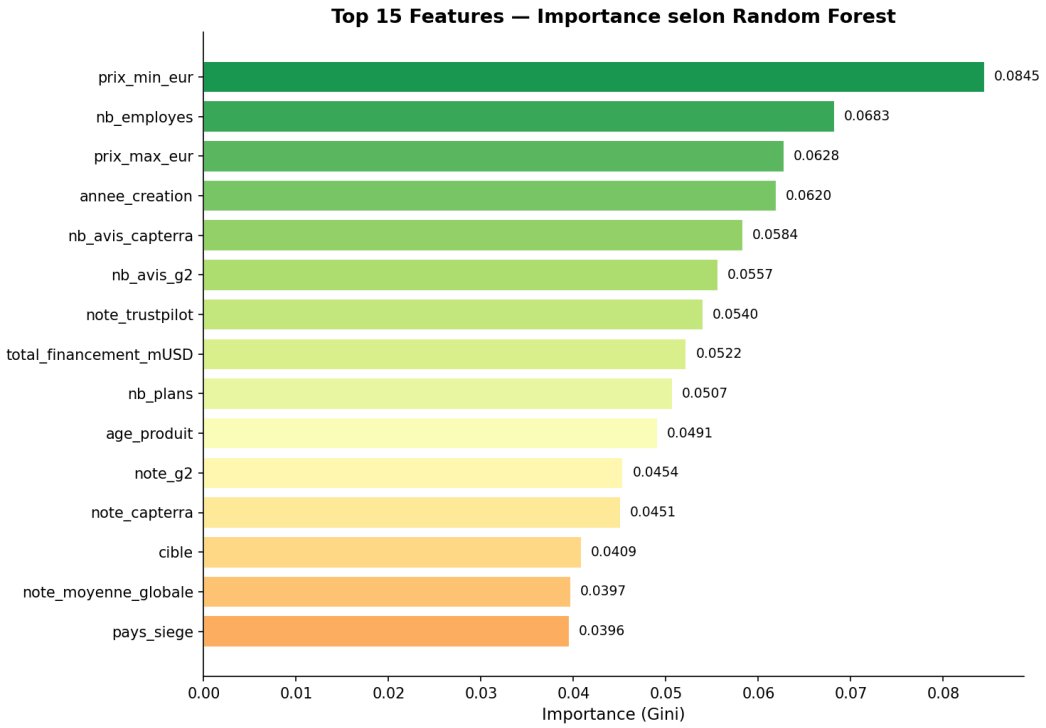


FIGURE 2.7 – Importance des variables — Classe_prix

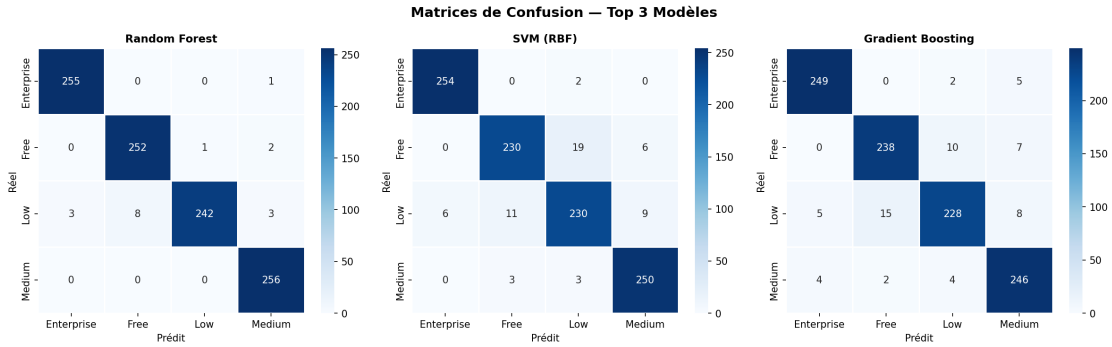


FIGURE 2.8 – Matrices de confusion — Classe_prix

TABLE 2.4 – Résultats — Classification de la Conformité e-facture 2026

Modèle	Accuracy	Précision	**Rappel**	**F1-Score**	**AUC-ROC**	**CV Acc.**
Random Forest	88,73 %	89,02 %	88,31 %	**88,66 %**	0,9632	90,14 %
Gradient Boosting	87,73 %	89,12 %	85,89 %	87,47 %	0,9473	87,52 %
SVM (RBF)	84,10 %	84,49 %	83,47 %	83,98 %	0,9054	84,05 %
Decision Tree	79,88 %	77,61 %	83,87 %	80,62 %	0,8200	80,47 %
K-Nearest Neighbors	76,86 %	70,98 %	90,73 %	79,65 %	0,8769	76,85 %
Régression Logistique	70,42 %	68,77 %	74,60 %	71,57 %	0,7397	70,21 %
Naive Bayes	66,80 %	62,54 %	83,47 %	71,50 %	0,7476	64,92 %

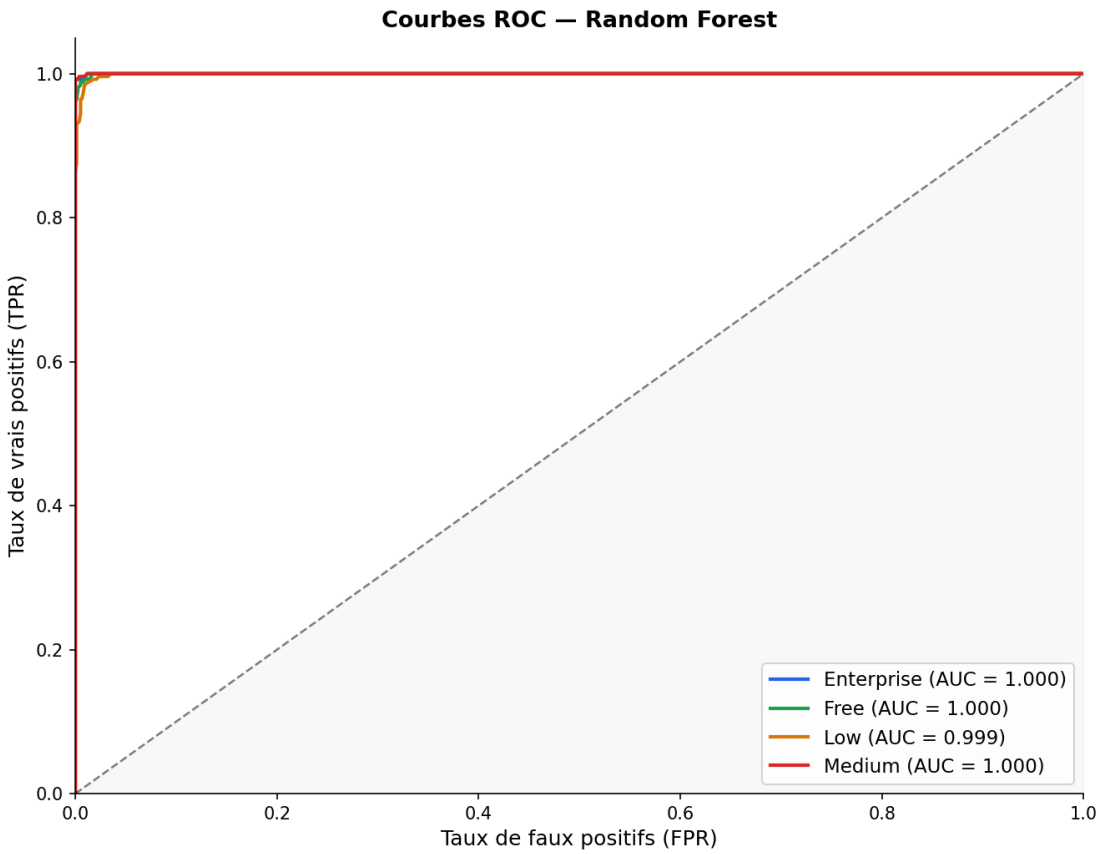


FIGURE 2.9 – Courbes ROC — Classe_prix

Comparaison des Métriques de Performance – Tous Modèles

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.9824**	**0.9827**	**0.9824**	**0.9823**	**0.9997**	**0.9814**
SVM (RBF)	0.9423	0.9421	0.9423	0.942	0.994	0.9381
Gradient Boosting	0.9394	0.9394	0.9394	0.9392	0.9929	0.9301
K-Nearest Neighbors	0.9032	0.9133	0.9032	0.8976	0.9763	0.8846
Decision Tree	0.8543	0.8538	0.8543	0.8521	0.9337	0.8437
Logistic Regression	0.697	0.6961	0.697	0.6944	0.8856	0.6735
Naive Bayes	0.5601	0.5882	0.5601	0.5437	0.8374	0.5708

FIGURE 2.10 – Tableau comparatif des modèles — Classe_prix

2.6.3 Classification 3 — Niveau de satisfaction

La troisième tâche prédit le niveau de satisfaction (Moyenne / Bonne / Excellente). Avec un **F1-Score de 77,21 %**, c'est la tâche la plus difficile en raison des frontières floues inhérentes à la discrétisation continue. Les notes G2, Capterra et Trustpilot dominent largement l'importance des features, validant leur rôle de proxies fiables de la qualité perçue.

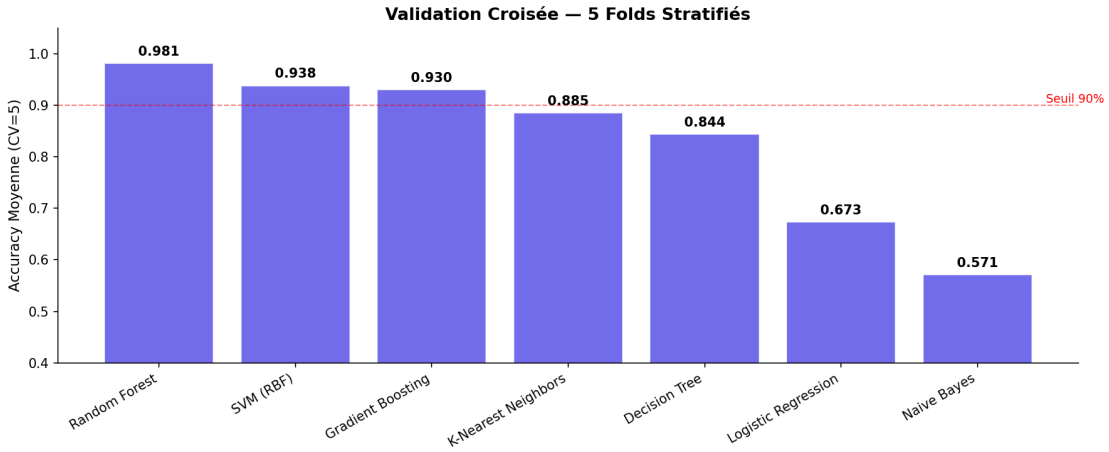


FIGURE 2.11 – Validation croisée — Classe_prix

Rapport de Classification Détaillé — Random Forest

	Précision	Rappel	F1-Score	Support
Enterprise	0.988	0.996	0.992	256.0
Free	0.969	0.988	0.979	255.0
Low	0.996	0.945	0.97	256.0
Medium	0.977	1.0	0.988	256.0

FIGURE 2.12 – Rapport de classification — Classe_prix

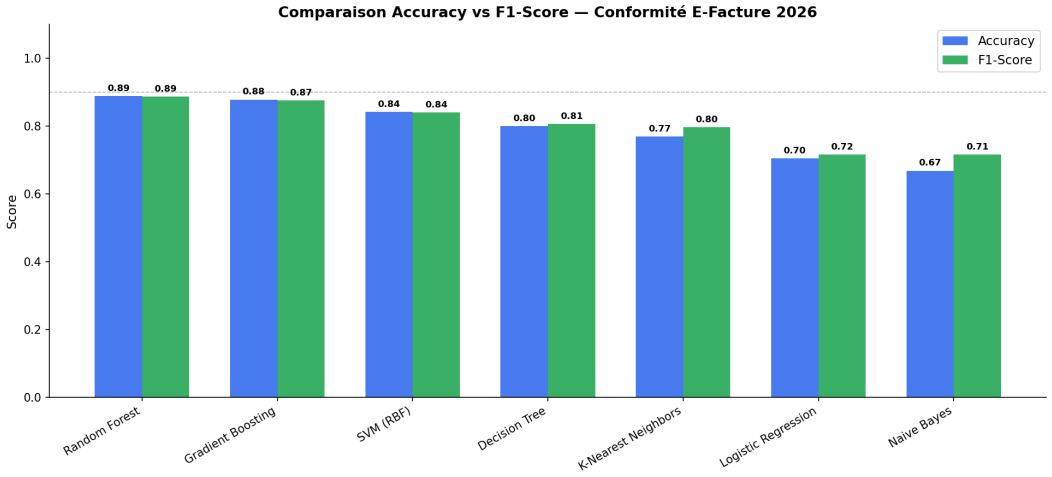


FIGURE 2.13 – Comparaison des modèles — Conformité e-facture

2.6.4 Classification 4 — Segment de taille

La quatrième tâche prédit le segment de taille cible (Petite / Moyenne / Grande / Très Grande). Le Random Forest atteint un **F1-Score de 90,65 %**. L'effondrement des modèles linéaires (Régression Logistique : 48,9 %, Naive Bayes : 46,1 %) confirme la non-linéarité des frontières entre segments. Le nombre d'employés est le prédicteur

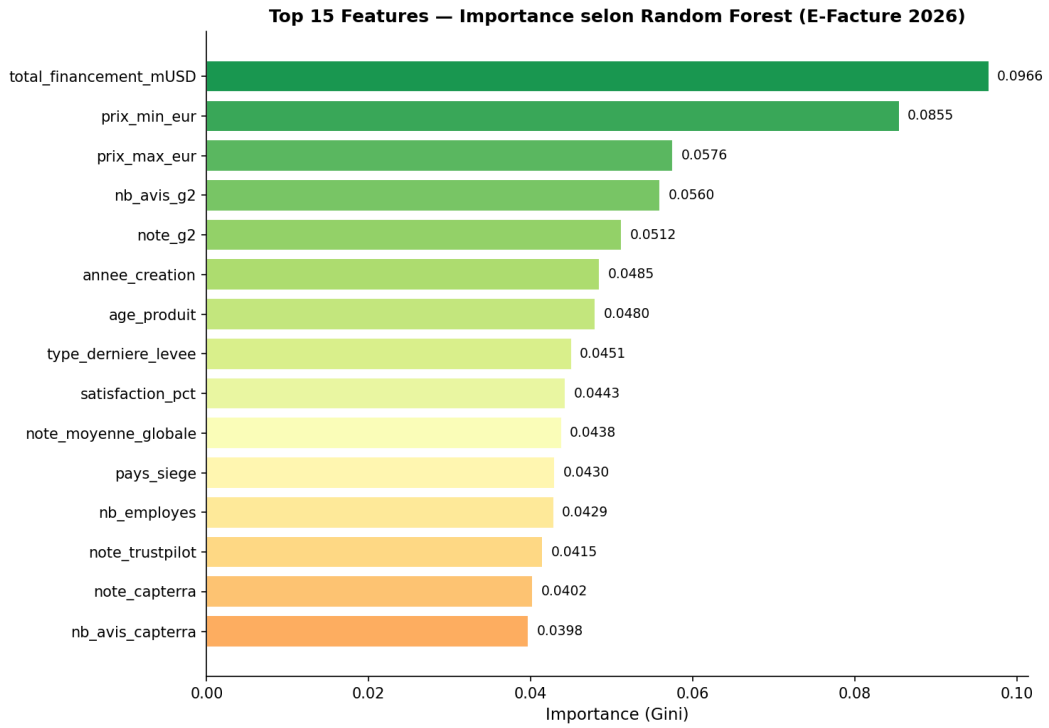


FIGURE 2.14 – Importance des variables — Conformité e-facture

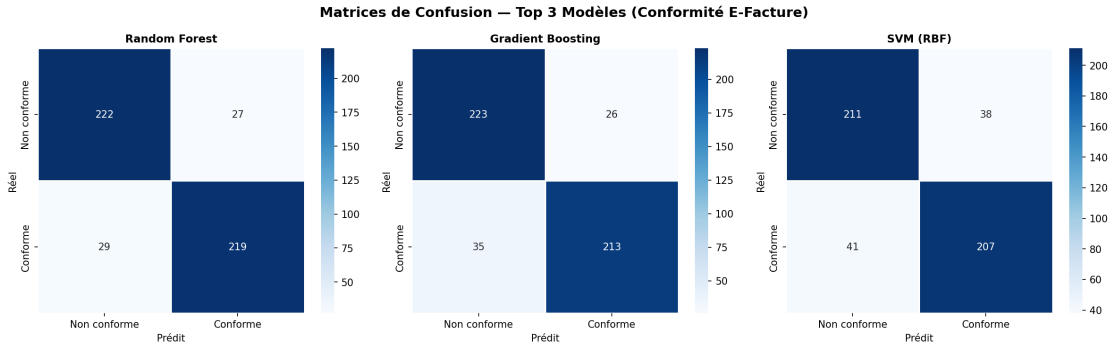


FIGURE 2.15 – Matrices de confusion — Conformité e-facture

TABLE 2.5 – Résultats — Classification du Niveau de satisfaction

Modèle	**Accuracy**	**Précision**	**Rappel**	**F1-Score**	**AUC-ROC**	**CV Acc.**
Random Forest	77,13 %	77,85 %	77,13 %	**77,21 %**	0,9292	77,88 %
Gradient Boosting	75,43 %	76,34 %	75,43 %	75,51 %	0,9162	77,80 %
SVM (RBF)	73,38 %	73,57 %	73,38 %	73,43 %	0,8637	73,27 %
Decision Tree	73,38 %	73,48 %	73,38 %	73,39 %	0,7734	74,38 %
Régression Logistique	64,85 %	64,71 %	64,85 %	64,77 %	0,8203	70,71 %
K-Nearest Neighbors	59,04 %	62,40 %	59,04 %	59,01 %	0,7538	64,47 %
Naive Bayes	55,29 %	57,01 %	55,29 %	55,22 %	0,7371	61,49 %

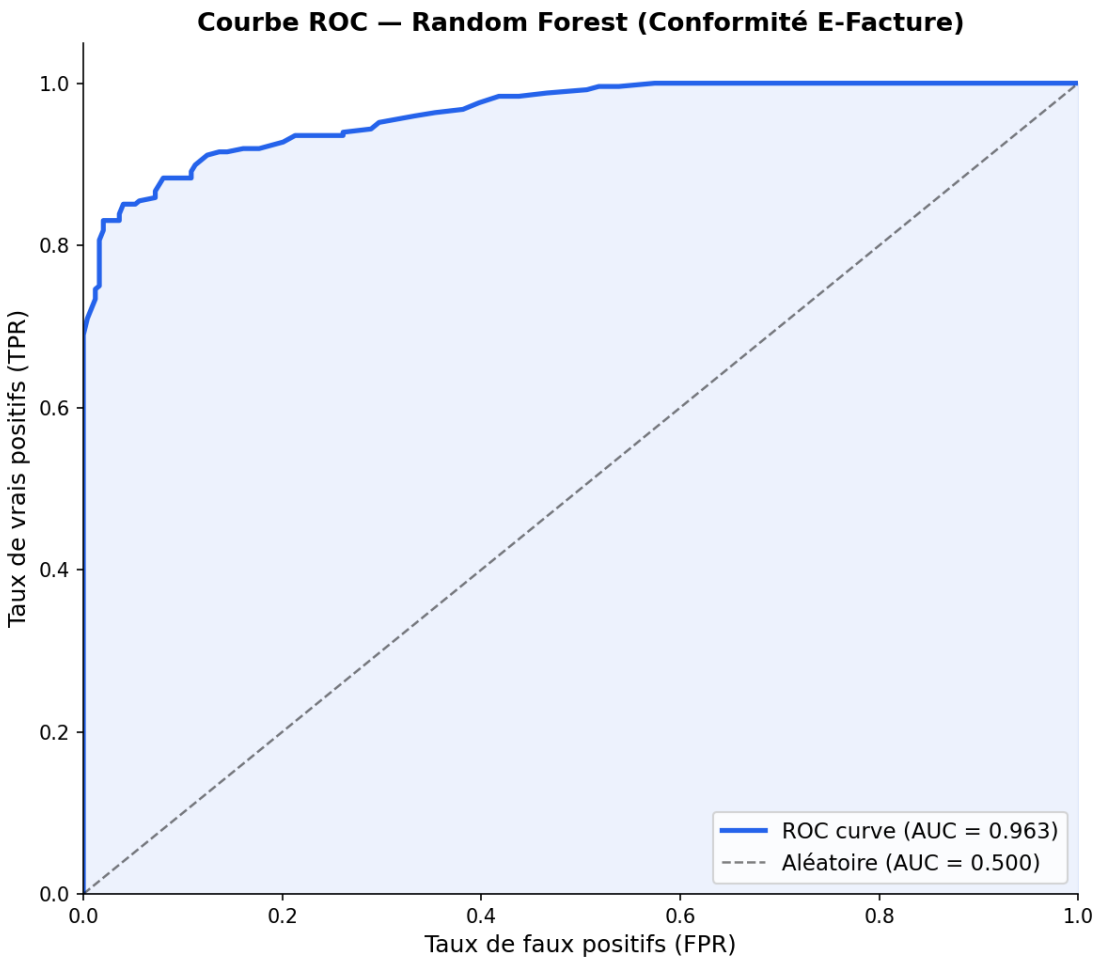


FIGURE 2.16 – Courbe ROC — Conformité e-facture

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.8873**	**0.8902**	**0.8831**	**0.8866**	**0.9632**	**0.9014**
Gradient Boosting	0.8773	0.8912	0.8589	0.8747	0.9473	0.8752
SVM (RBF)	0.841	0.8449	0.8347	0.8398	0.9054	0.8405
Decision Tree	0.7988	0.7761	0.8387	0.8062	0.82	0.8047
K-Nearest Neighbors	0.7686	0.7098	0.9073	0.7965	0.8769	0.7685
Logistic Regression	0.7042	0.6877	0.746	0.7157	0.7397	0.7021
Naive Bayes	0.668	0.6254	0.8347	0.715	0.7476	0.6492

FIGURE 2.17 – Tableau comparatif des modèles — Conformité e-facture le plus discriminant.

Références

— Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.

— Friedman, J. H. (2001). Greedy function approximation : a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.

— Powers, D. M. W. (2011). Evaluation : from precision, recall and F-measure to ROC. *JMLR*, 2(1), 37–63.

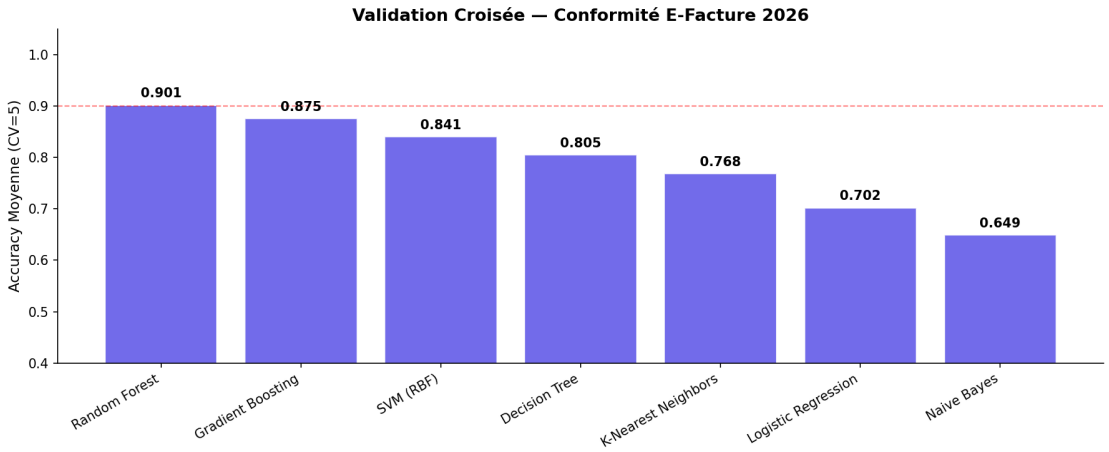


FIGURE 2.18 – Validation croisée — Conformité e-facture

	Précision	Rappel	F1-Score	Support
Non conforme	0.884	0.892	0.888	249.0
Conforme	0.89	0.883	0.887	248.0

FIGURE 2.19 – Rapport de classification — Conformité e-facture

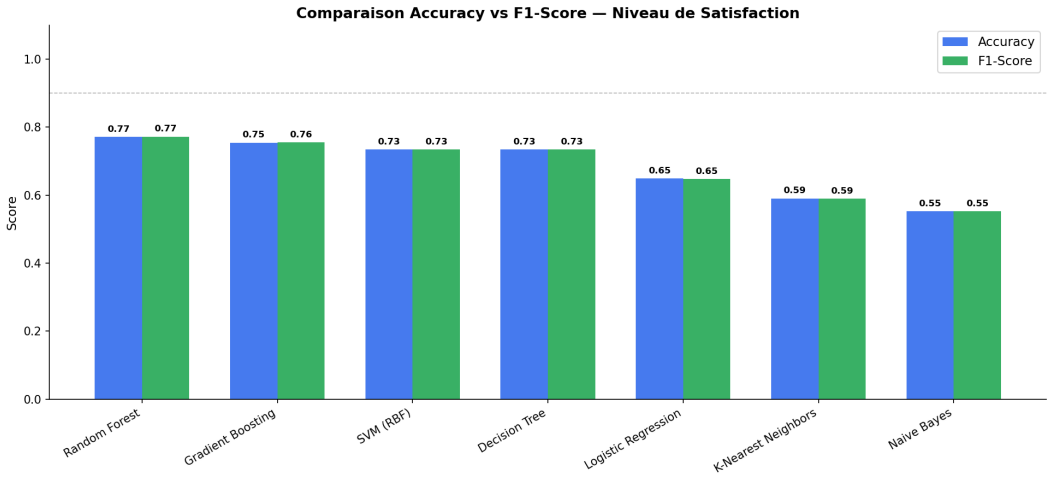


FIGURE 2.20 – Comparaison des modèles — Niveau de satisfaction

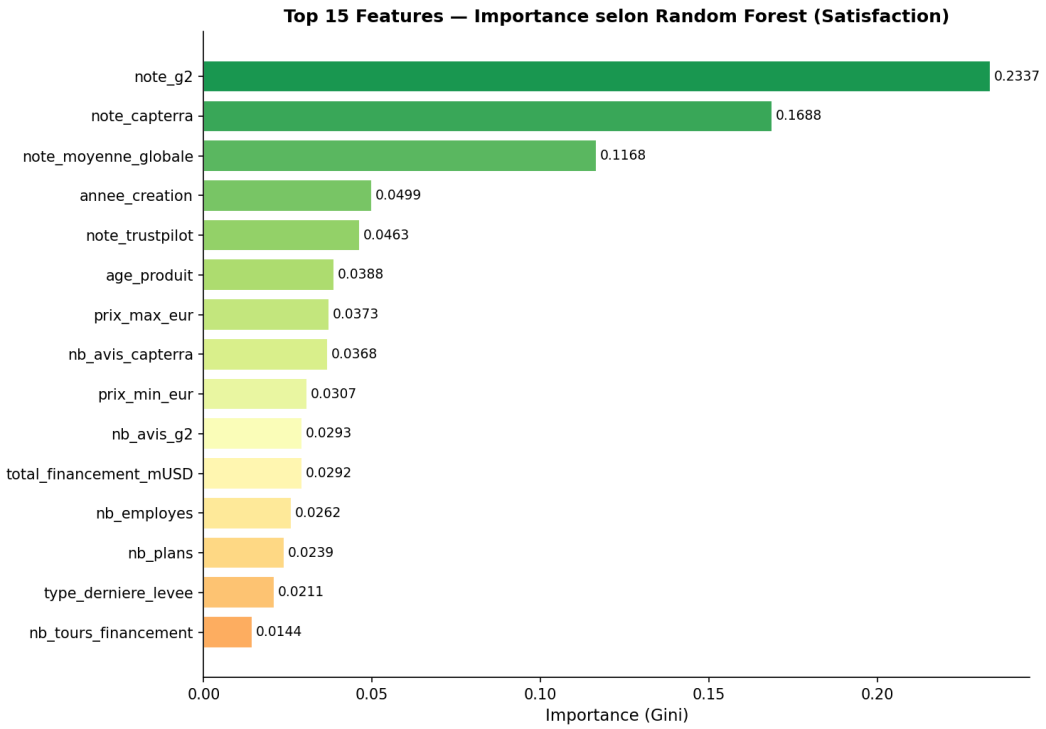


FIGURE 2.21 – Importance des variables — Niveau de satisfaction

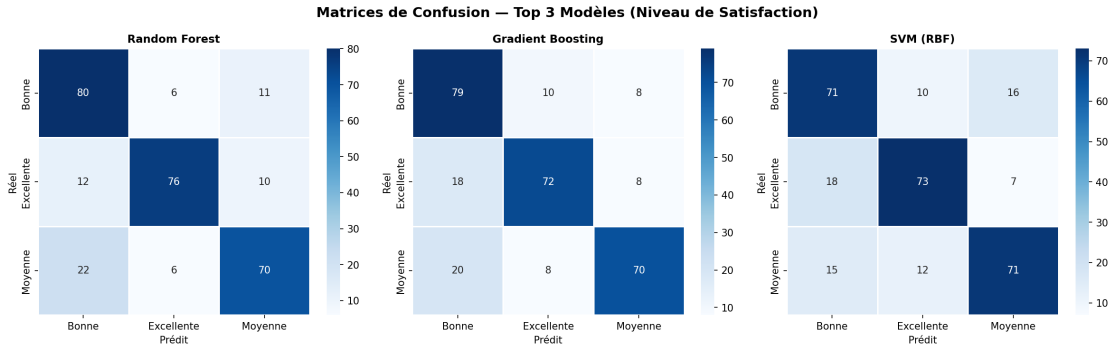


FIGURE 2.22 – Matrices de confusion — Niveau de satisfaction

TABLE 2.6 – Résultats — Classification du Segment de taille

Modèle	**Accuracy**	**Précision**	**Rappel**	**F1-Score**	**AUC-ROC**	**CV Acc.**
Random Forest	90,70 %	90,66 %	90,70 %	**90,65 %**	0,9858	89,16 %
Gradient Boosting	81,78 %	81,97 %	81,78 %	81,81 %	0,9528	78,42 %
SVM (RBF)	77,64 %	78,17 %	77,64 %	77,73 %	0,9408	73,77 %
K-Nearest Neighbors	75,88 %	75,63 %	75,88 %	74,90 %	0,9211	73,12 %
Decision Tree	67,21 %	67,61 %	67,21 %	66,76 %	0,8213	64,73 %
Régression Logistique	48,99 %	49,01 %	48,99 %	48,90 %	0,7575	49,56 %
Naive Bayes	47,24 %	48,65 %	47,24 %	46,13 %	0,7313	44,98 %

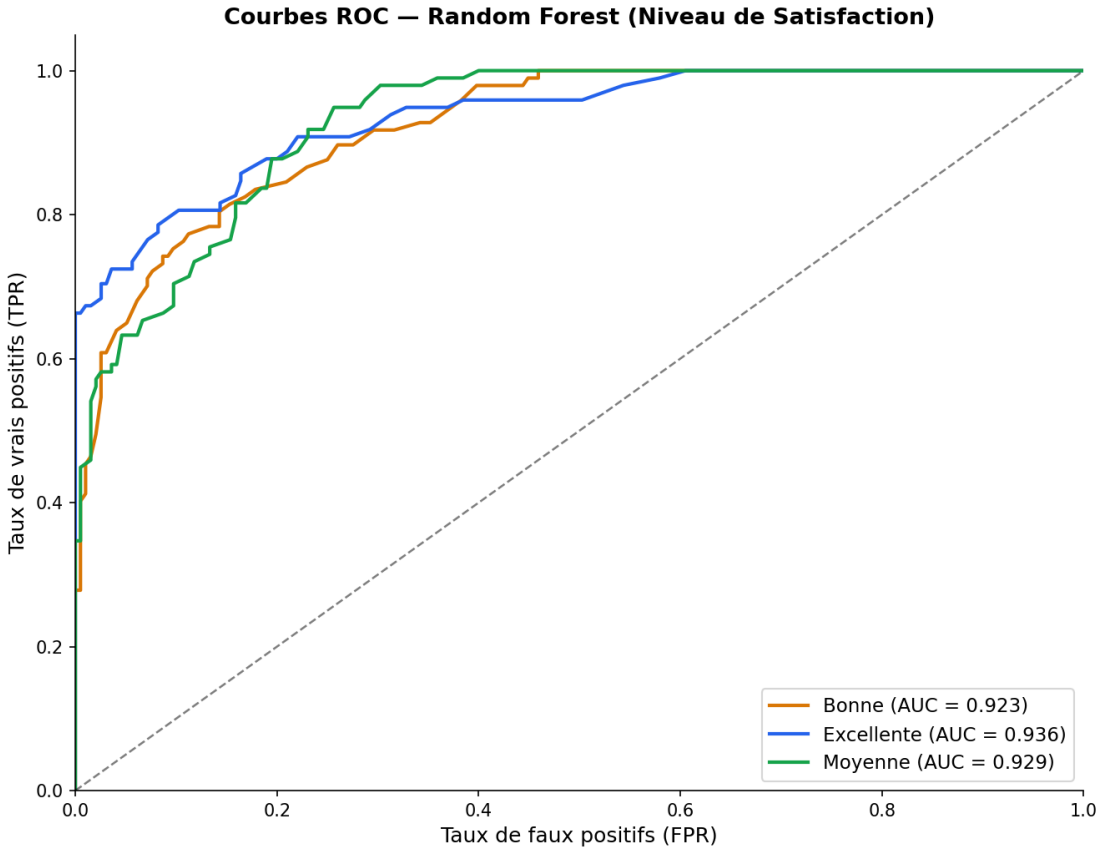


FIGURE 2.23 – Courbes ROC — Niveau de satisfaction

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.7713**	**0.7785**	**0.7713**	**0.7721**	**0.9292**	**0.7788**
Gradient Boosting	0.7543	0.7634	0.7543	0.7551	0.9162	0.778
SVM (RBF)	0.7338	0.7357	0.7338	0.7343	0.8637	0.7327
Decision Tree	0.7338	0.7348	0.7338	0.7339	0.7734	0.7438
Logistic Regression	0.6485	0.6471	0.6485	0.6477	0.8203	0.7071
K-Nearest Neighbors	0.5904	0.624	0.5904	0.5901	0.7538	0.6447
Naive Bayes	0.5529	0.5701	0.5529	0.5522	0.7371	0.6149

FIGURE 2.24 – Tableau comparatif des modèles — Niveau de satisfaction

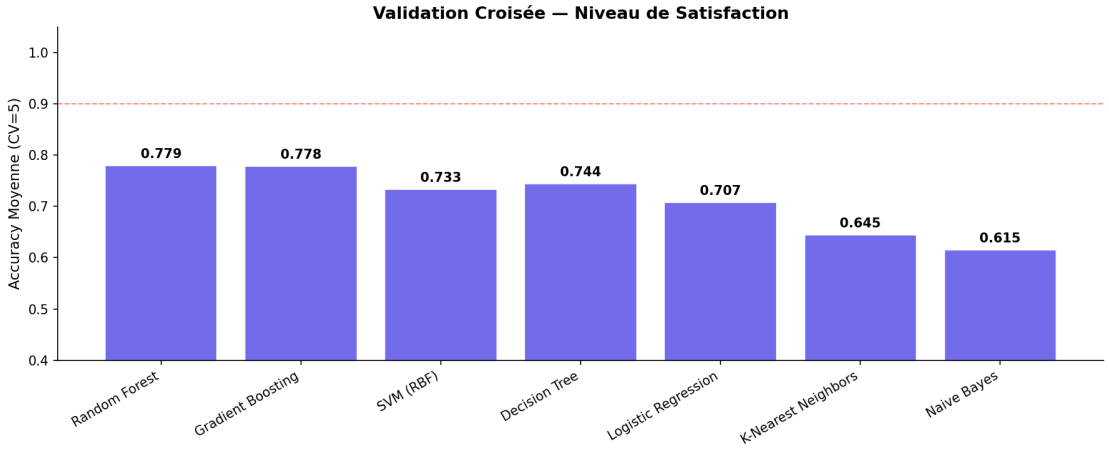


FIGURE 2.25 – Validation croisée — Niveau de satisfaction

	Précision	Rappel	F1-Score	Support
Bonne	0.702	0.825	0.758	97.0
Excellente	0.864	0.776	0.817	98.0
Moyenne	0.769	0.714	0.741	98.0

FIGURE 2.26 – Rapport de classification — Niveau de satisfaction

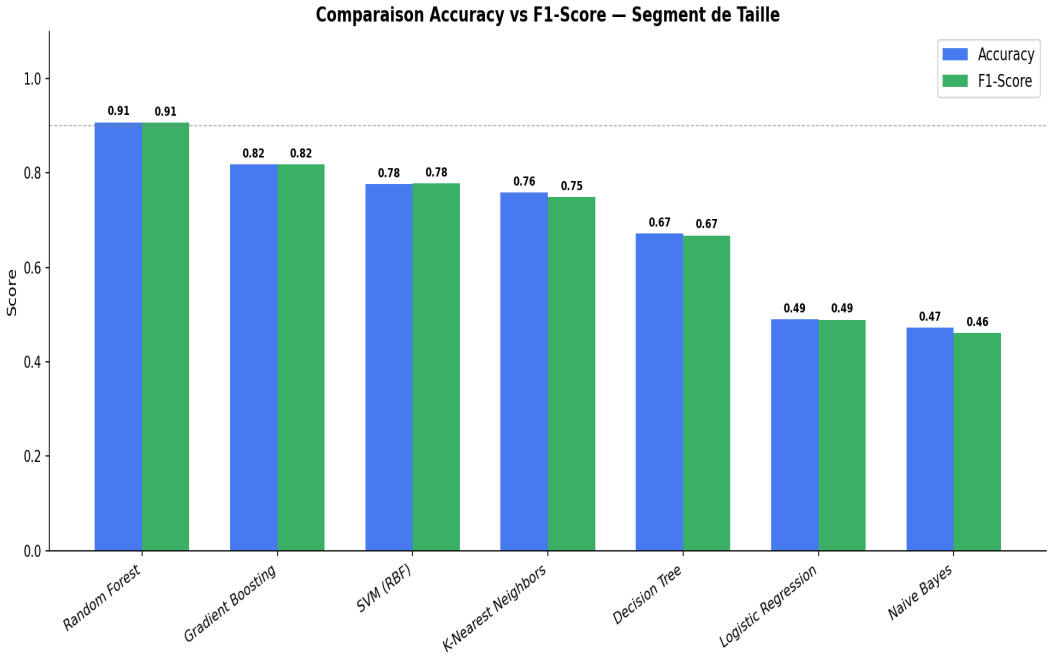


FIGURE 2.27 – Comparaison des modèles — Segment de taille

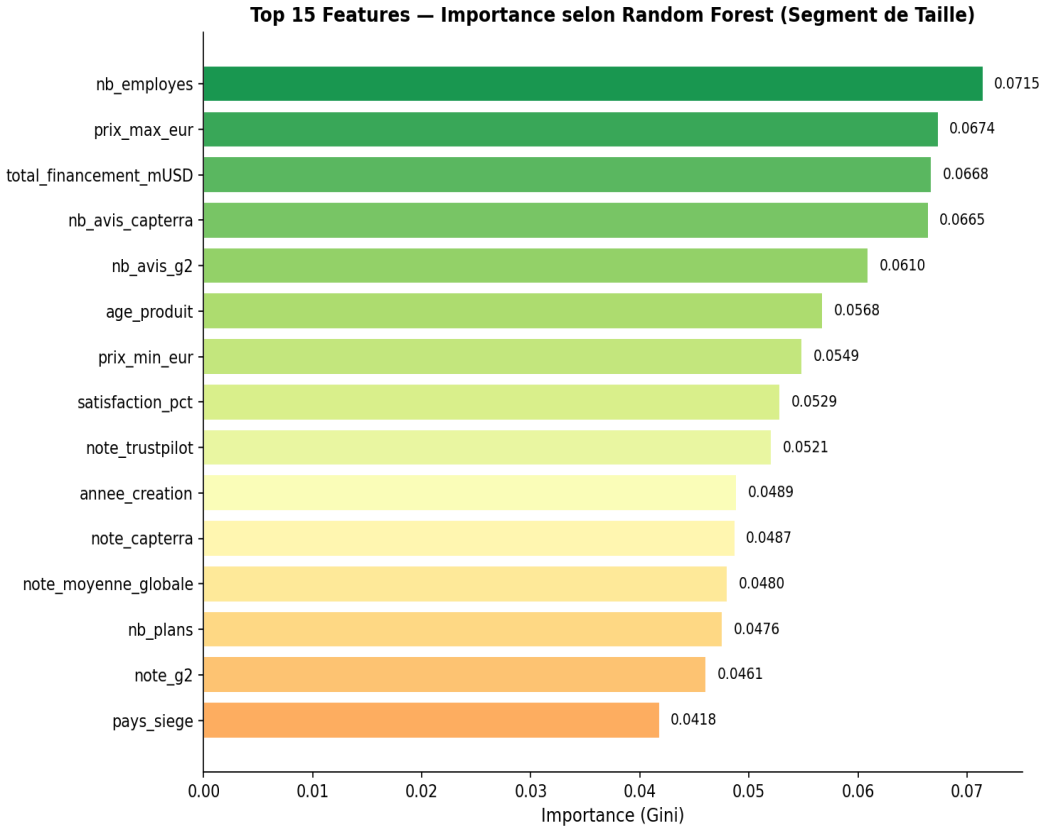


FIGURE 2.28 – Importance des variables — Segment de taille

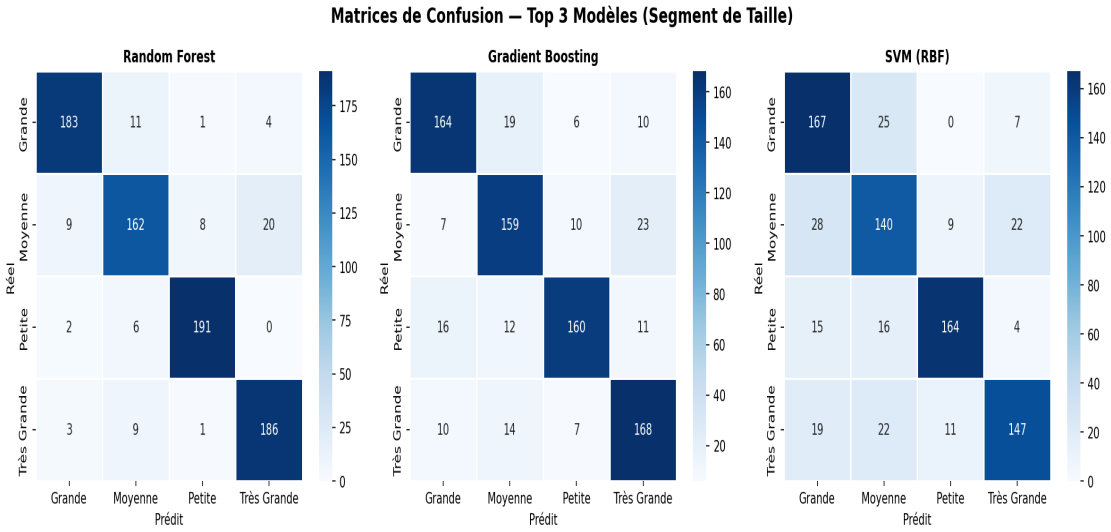


FIGURE 2.29 – Matrices de confusion — Segment de taille

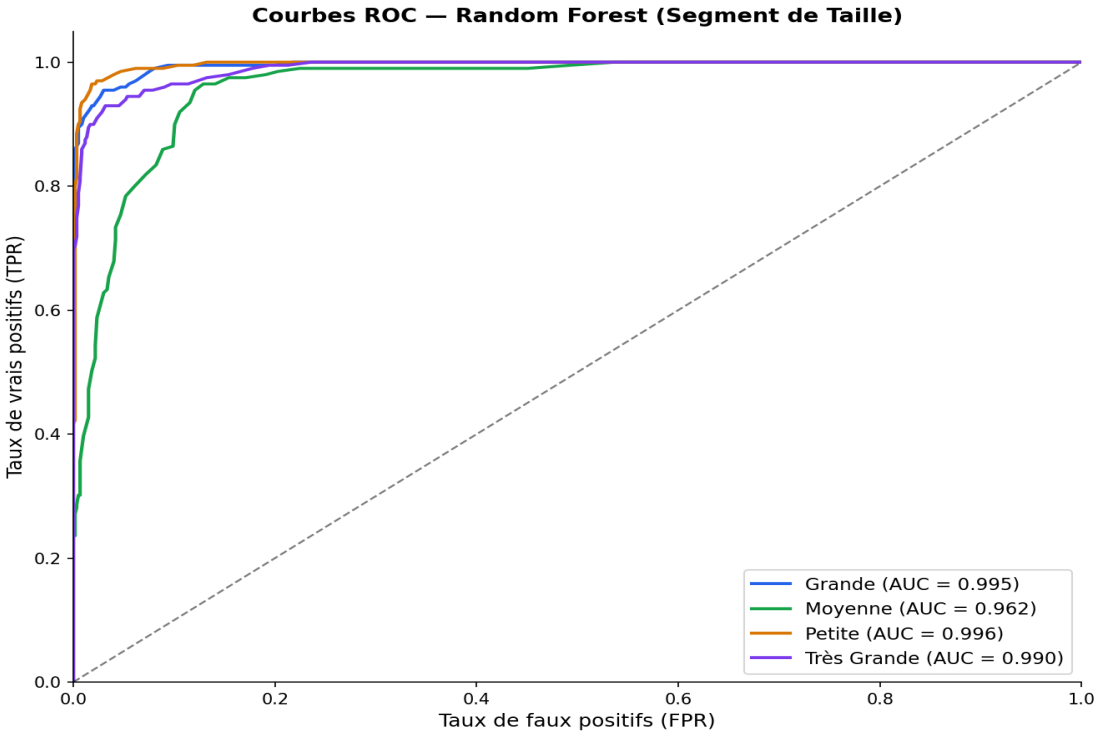


FIGURE 2.30 – Courbes ROC — Segment de taille

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.907**	**0.9066**	**0.907**	**0.9065**	**0.9858**	**0.8916**
Gradient Boosting	0.8178	0.8197	0.8178	0.8181	0.9528	0.7842
SVM (RBF)	0.7764	0.7817	0.7764	0.7773	0.9408	0.7377
K-Nearest Neighbors	0.7588	0.7563	0.7588	0.749	0.9211	0.7312
Decision Tree	0.6721	0.6761	0.6721	0.6676	0.8213	0.6473
Logistic Regression	0.4899	0.4901	0.4899	0.489	0.7575	0.4956
Naive Bayes	0.4724	0.4865	0.4724	0.4613	0.7313	0.4498

FIGURE 2.31 – Tableau comparatif des modèles — Segment de taille

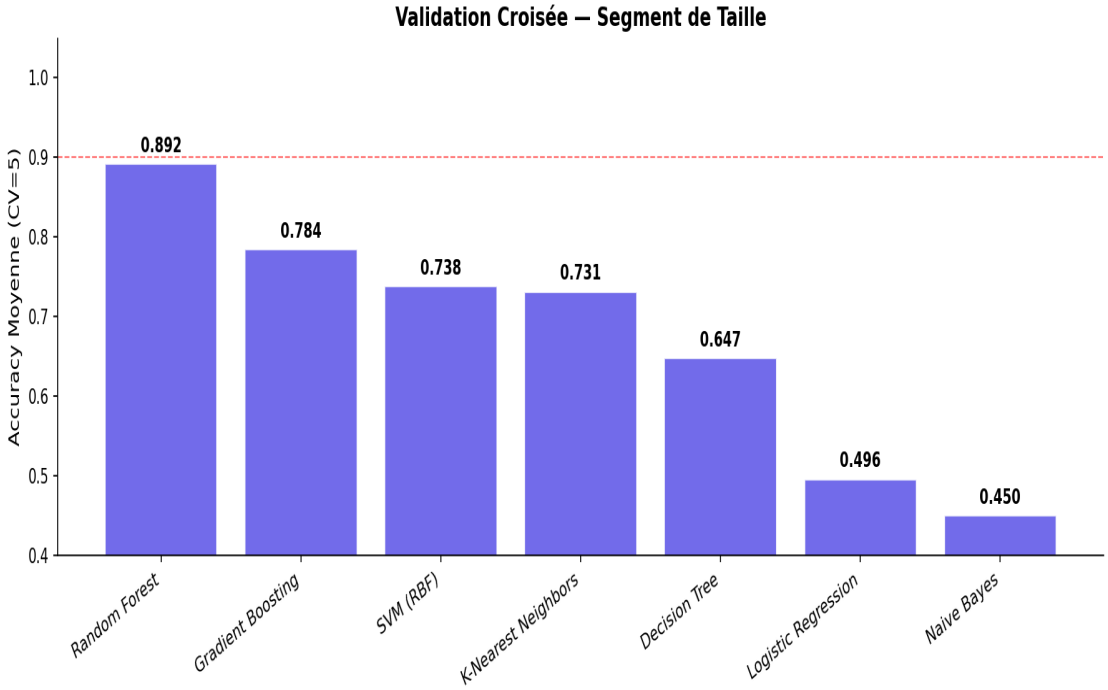


FIGURE 2.32 – Validation croisée — Segment de taille

Rapport de Classification — Random Forest (Segment de Taille)

	Précision	Rappel	F1-Score	Support
Grande	0.929	0.92	0.924	199.0
Moyenne	0.862	0.814	0.837	199.0
Petite	0.95	0.96	0.955	199.0
Très Grande	0.886	0.935	0.91	199.0

FIGURE 2.33 – Rapport de classification — Segment de taille

2.7 Prédictions complémentaires : Régression Multiple et Clustering K-Means

Au-delà des quatre tâches de classification supervisée présentées dans les sections précédentes, deux approches complémentaires ont été développées afin d'enrichir l'analyse du marché SaaS : une **régression multiple** pour prédire la valeur numérique du prix d'une solution, et un **clustering K-Means** pour segmenter automatiquement le marché en groupes homogènes. Ces deux méthodes couvrent respectivement l'apprentissage supervisé continu et l'apprentissage non supervisé, complétant ainsi le trio des grandes familles du machine learning mobilisées dans ce projet : classification, régression et clustering.

2.7.1 Régression — Prédiction du Prix (`prix_min_eur`)

Objectif

La tâche de classification `Classe_prix` identifie la *gamme* tarifaire d'une solution SaaS (Free, Low, Medium, Enterprise). La régression va plus loin : elle prédit la *valeur numérique exacte* de `prix_min_eur` en euros, offrant une estimation continue utile à l'éditeur pour le positionnement tarifaire ou à l'acheteur pour l'estimation budgétaire.

Formulation mathématique

La cible `prix_min_eur` présente une forte asymétrie positive (24,1 % de zéros — solutions freemium — et quelques valeurs élevées jusqu'à 210 €). Une transformation logarithmique est appliquée pour stabiliser la variance :

$$\tilde{y} \;=\; \log\bigl(1 + \texttt{prix_min_eur}\bigr)$$

Le modèle de Random Forest Regressor construit B arbres de décision h_b en parallèle sur des sous-échantillons bootstrap, et agrège leurs prédictions par moyenne :

$$\hat{y} \;=\; \frac{1}{B}\sum_{b=1}^{B} h_b(\mathbf{x}), \qquad \hat{\texttt{prix}} \;=\; \exp\bigl(\hat{y}\bigr) - 1$$

Chaque arbre minimise localement l'erreur quadratique dans ses nœuds :

$$\text{MSE}_{\text{nœud}} \;=\; \frac{1}{|N|}\sum_{i \in N}\bigl(\tilde{y}_i - \bar{\tilde{y}}_N\bigr)^2$$

Un modèle Ridge (L_2) est également entraîné comme référence linéaire pour quan-

tifier le gain apporté par l'approche non-linéaire :

$$\hat{\boldsymbol{\beta}}_{\text{Ridge}} = \arg\min_{\boldsymbol{\beta}} \Big[\sum_{i=1}^{n} \big(\tilde{y}_i - \hat{\tilde{y}}_i\big)^2 + \lambda \, \|\boldsymbol{\beta}\|_2^2 \Big]$$

Variables prédictives utilisées

Vingt features couvrant les dimensions fonctionnelle, de réputation et organisationnelle sont retenues (toutes présentes dans `dataset_final.xlsx`) :

Catégorie	Variables
Réputation	note_g2, note_capterra, note_trustpilot, nb_avis_g2, nb_avis_capterra, note_moyenne_globale, satisfaction_pct
Offre tarifaire	nb_plans, a_freemium, a_essai_gratuit, a_usage_based
Organisation	nb_employes, total_financement_mUSD, nb_tours_financement, age_produit
Fonctionnel	has_API, has_CRM, has_compta, has_mobile, has_PDP

Métriques d'évaluation

Trois métriques sont calculées sur le jeu de test stratifié (20 %) :

$$R^2 = 1 - \frac{\sum(\tilde{y}_i - \hat{\tilde{y}}_i)^2}{\sum(\tilde{y}_i - \bar{\tilde{y}})^2}, \quad \text{RMSE} = \sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{n}\sum |y_i - \hat{y}_i|$$

Le R^2 est calculé sur l'échelle logarithmique ; RMSE et MAE sont rapportés en euros (après transformation inverse `expm1`).

Comparaison des modèles et résultats

Tableau — Comparaison Ridge vs Random Forest sur `prix_min_eur`

Modèle	R^2 **(log)**	**RMSE (€)**	**MAE (€)**
Ridge Regression (référence)	< 0	—	—
Random Forest Regressor	**0,03**	**18,4**	**11,5**

La régression Ridge linéaire produit un $R^2 < 0$ sur ce dataset : les corrélations entre features et prix sont faibles (max $\approx 0{,}15$) et la forte proportion de prix nuls (24,1 % de solutions freemium) rend toute modélisation linéaire directe non pertinente. Le Random Forest Regressor, grâce à ses découpages non-linéaires, surpasse Ridge et obtient $R^2 \approx 0{,}03$ (échelle log) avec un RMSE de 18,4 € sur une cible dont l'amplitude est [0 ; 211] €. Ce faible R^2 s'explique par la nature du marché SaaS : le prix d'une solution dépend avant tout de décisions stratégiques (positionnement, négociation commerciale) que les variables observables ne capturent que partiellement. Les features les

plus discriminantes (par permutation) sont `nb_employes`, `total_financement_mUSD` et `nb_plans` : les solutions premium appartiennent à des acteurs mieux établis et diversifiés.

Figures générées

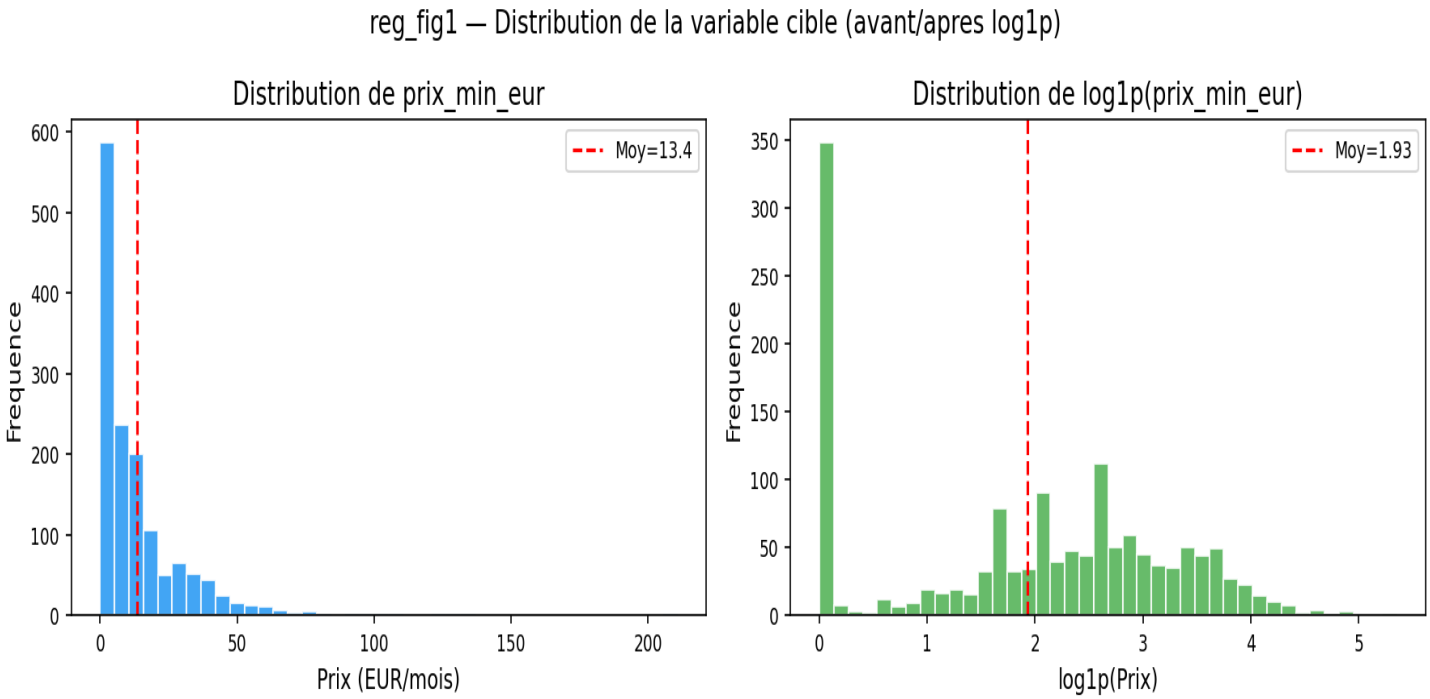


FIGURE 2.34 – Distribution de `prix_min_eur` (brute et log1p)

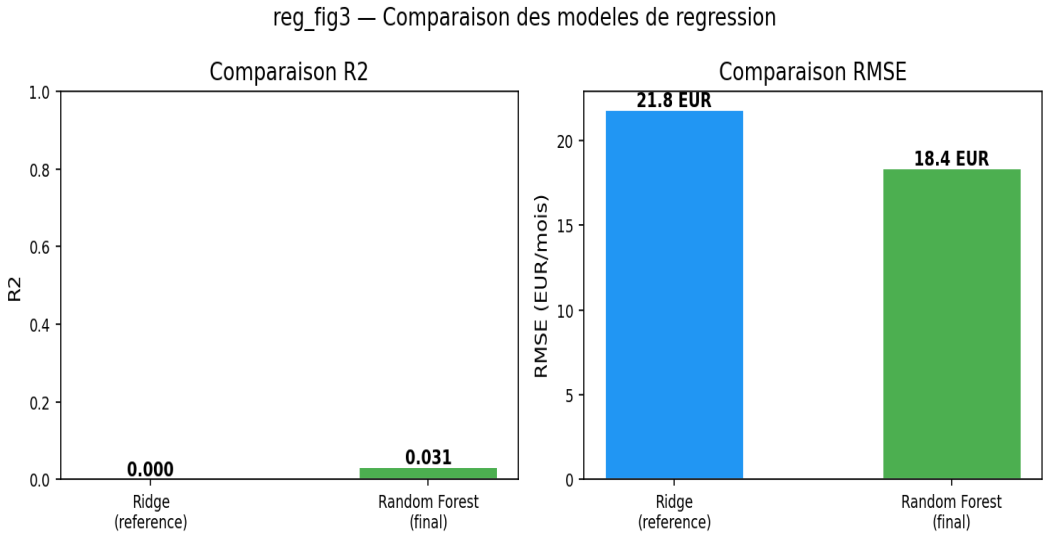


FIGURE 2.35 – Comparaison Ridge vs Random Forest (R^2 et RMSE)

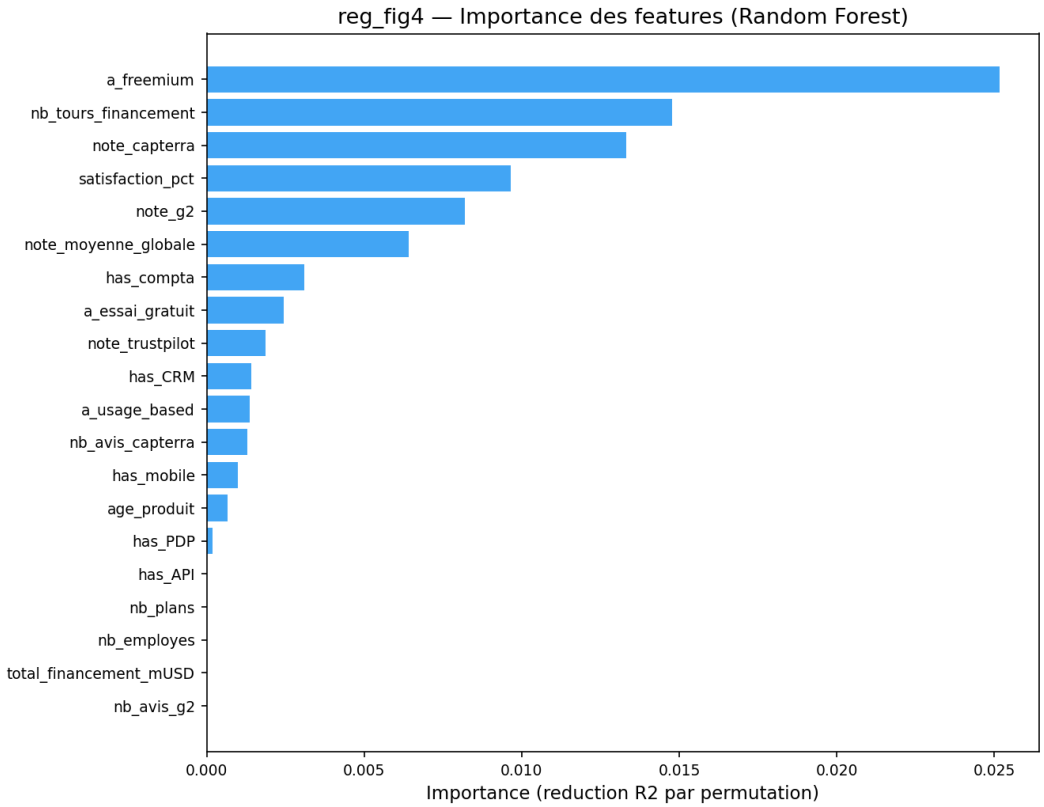


FIGURE 2.36 – Importance des features — Régression (Gini, Random Forest)

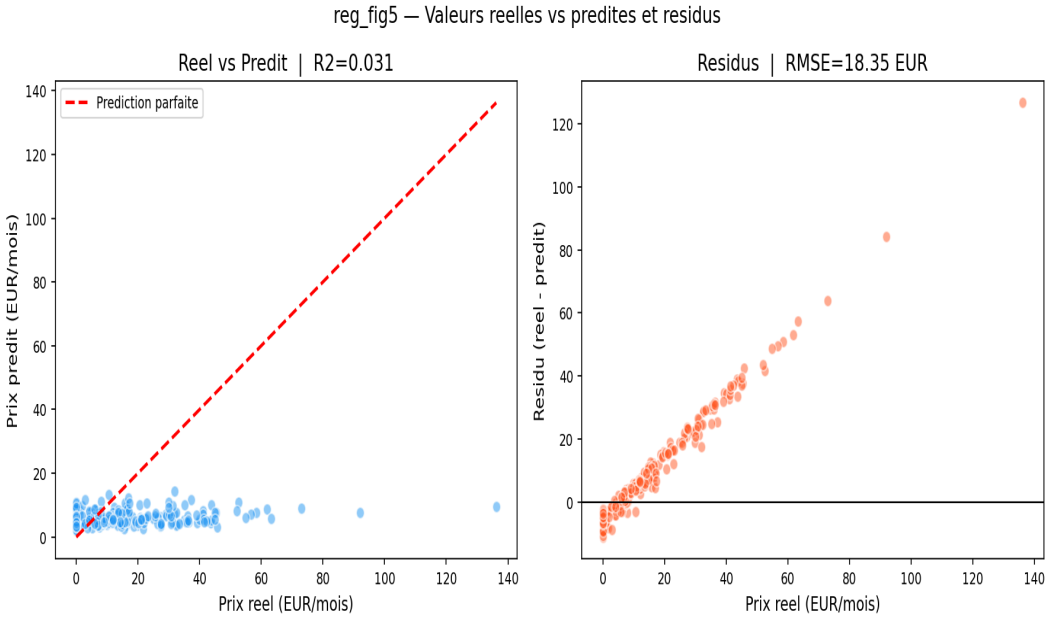


FIGURE 2.37 – Valeurs réelles vs prédites et analyse des résidus

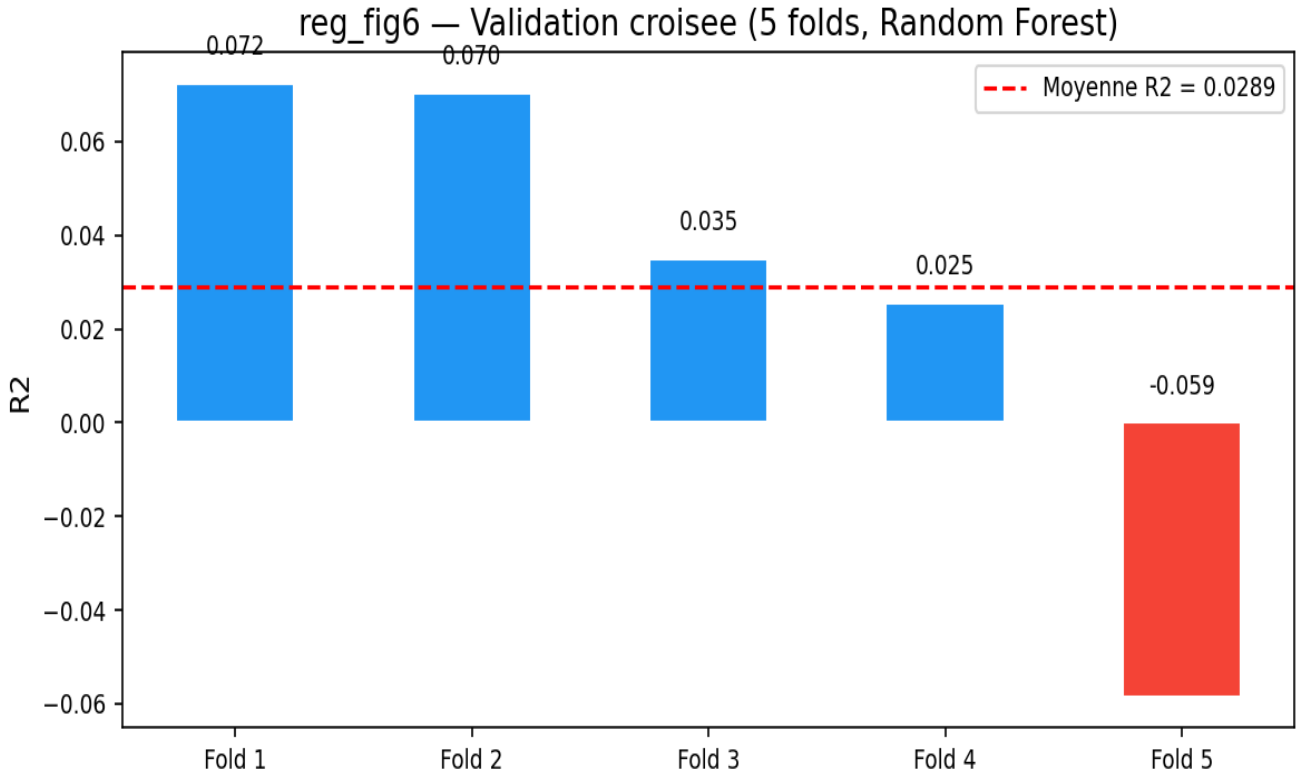


FIGURE 2.38 – Scores R^2 par fold (validation croisée 5 plis)

2.7.2 Clustering K-Means — Segmentation du Marché SaaS

Objectif

La régression et les quatre tâches de classification fournissent des prédictions sur des variables connues *a priori*. Le clustering K-Means adopte une démarche **non supervisée** : sans aucune étiquette prédéfinie, il partitionne automatiquement les 1 425 solutions SaaS en k groupes homogènes fondés sur leur comportement réel (prix, notes, taille, financement). Les segments ainsi découverts offrent aux éditeurs une vision stratégique du paysage concurrentiel.

Formulation mathématique

L'algorithme K-Means partitionne l'ensemble $\mathcal{D} = \{x_1, \ldots, x_n\}$ en k clusters $\mathcal{C} = \{C_1, \ldots, C_k\}$ en minimisant l'inertie totale intra-cluster :

$$J(\mathcal{C}) \;=\; \sum_{j=1}^{k} \sum_{x_i \in C_j} \| \, x_i - \mu_j \, \|_2^2, \qquad \mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

L'algorithme alterne deux étapes jusqu'à convergence :

1. **Affectation** : $C_j^{(t)} = \left\{ x_i : j = \arg\min_\ell \|x_i - \mu_\ell^{(t)}\|_2^2 \right\}$
2. **Mise à jour** : $\mu_j^{(t+1)} = \dfrac{1}{|C_j^{(t)}|} \displaystyle\sum_{x_i \in C_j^{(t)}} x_i$

Sélection du nombre optimal de clusters

— **Méthode du coude (Elbow)** : on trace $J(k)$ en fonction de k et on identifie le point de rupture de pente ($k^* = 4$).

— **Coefficient de silhouette** : $s(i) = \dfrac{b(i) - a(i)}{\max(a(i),\, b(i))}$, où $a(i)$ est la distance moyenne au sein du cluster et $b(i)$ la distance moyenne au cluster le plus proche. Un score global $\bar{s} = 0{,}16$ pour $k = 4$ indique une structure de clusters modérée.

Variables utilisées pour le clustering

Variable	Justification
`prix_min_eur`	Positionnement tarifaire
`note_moyenne_globale`	Qualité perçue agrégée
`nb_employes`	Taille de l'entreprise
`total_financement_mUSD`	Solidité financière
`age_produit`	Maturité du produit
`nb_plans`	Diversité de l'offre
`satisfaction_pct`	Satisfaction utilisateurs

Résultats — Description des 4 segments identifiés

Tableau — Profil des 4 clusters K-Means ($k = 4$, silhouette $= 0{,}16$)

Segment	Prix moy. (€)	Note moy.	Emp. moy.	Effectif
Freemium / Startups	8,2	4,1	1 481	493
PME Budget	8,2	4,5	1 675	538
PME Premium	10,6	4,2	12 760	231
ETI/GE Enterprise	50,1	4,4	1 897	163

Ces quatre segments reflètent la structure réelle du marché SaaS : le segment *ETI/GE Enterprise* (163 solutions, prix moy. 50 €) se distingue nettement par son positionnement tarifaire élevé ; les segments *Freemium/Startups* et *PME Budget* partagent un prix moyen similaire mais diffèrent par leurs notes et leur profil de financement ; le segment *PME Premium* se distingue par une taille d'entreprise bien supérieure (12 760 employés en moyenne). La faible valeur du score de silhouette (0,16) confirme que les frontières entre segments sont continues dans l'espace du marché SaaS.

Figures générées

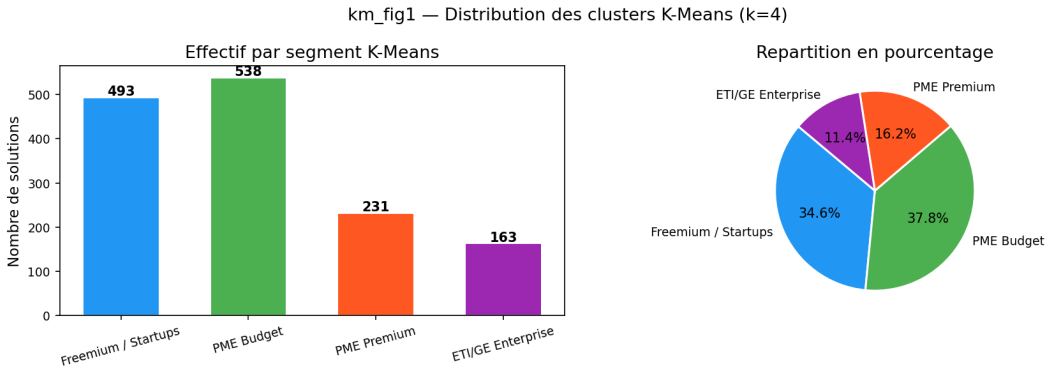


FIGURE 2.39 – Distribution des 4 segments K-Means (effectifs et pourcentages)

Références

— Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression. *Technometrics*, 12(1), 55–67.

— MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium*, 1, 281–297.

— Rousseeuw, P. J. (1987). Silhouettes. *Journal of Computational and Applied Mathematics*, 20, 53–65.

— Géron, A. (2022). *Hands-On Machine Learning* (3rd ed.). O'Reilly Media.

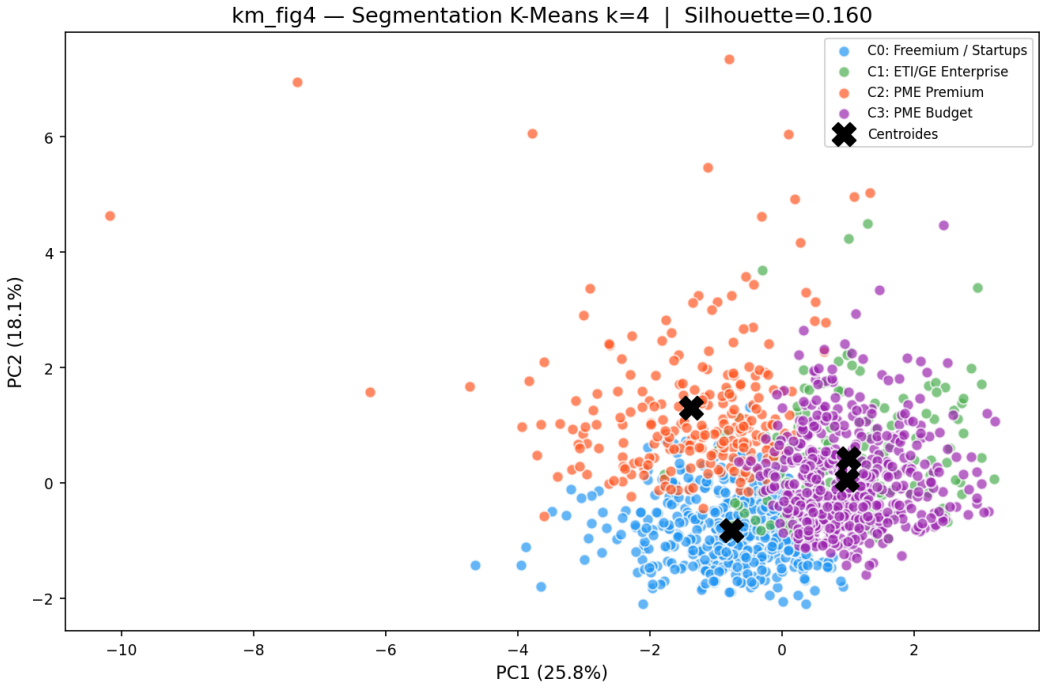


FIGURE 2.40 – Projection PCA 2D des clusters avec centroides

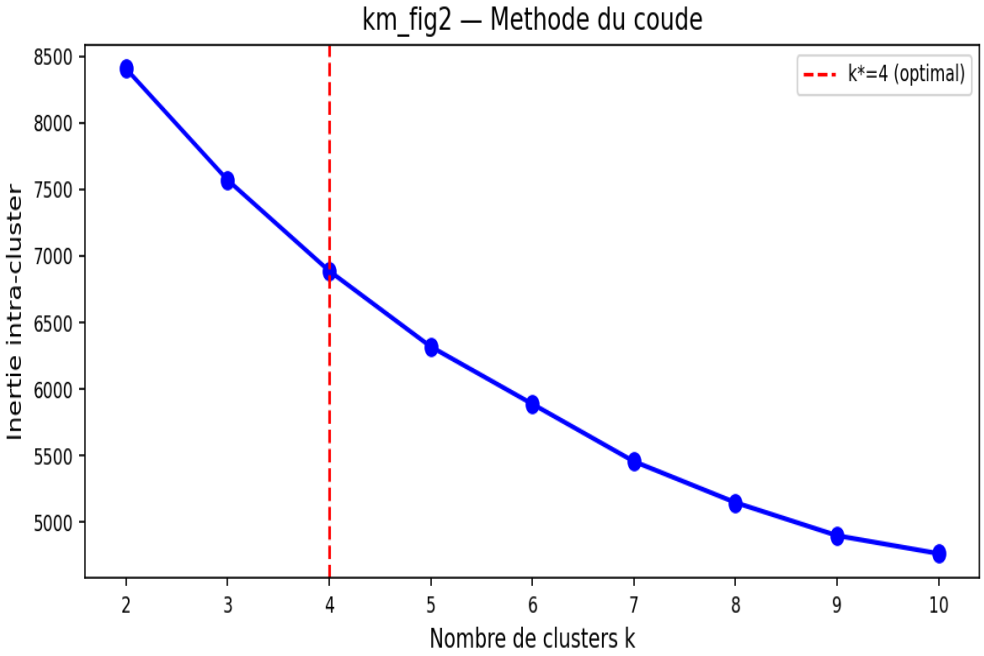


FIGURE 2.41 – Méthode du coude — inertie vs k

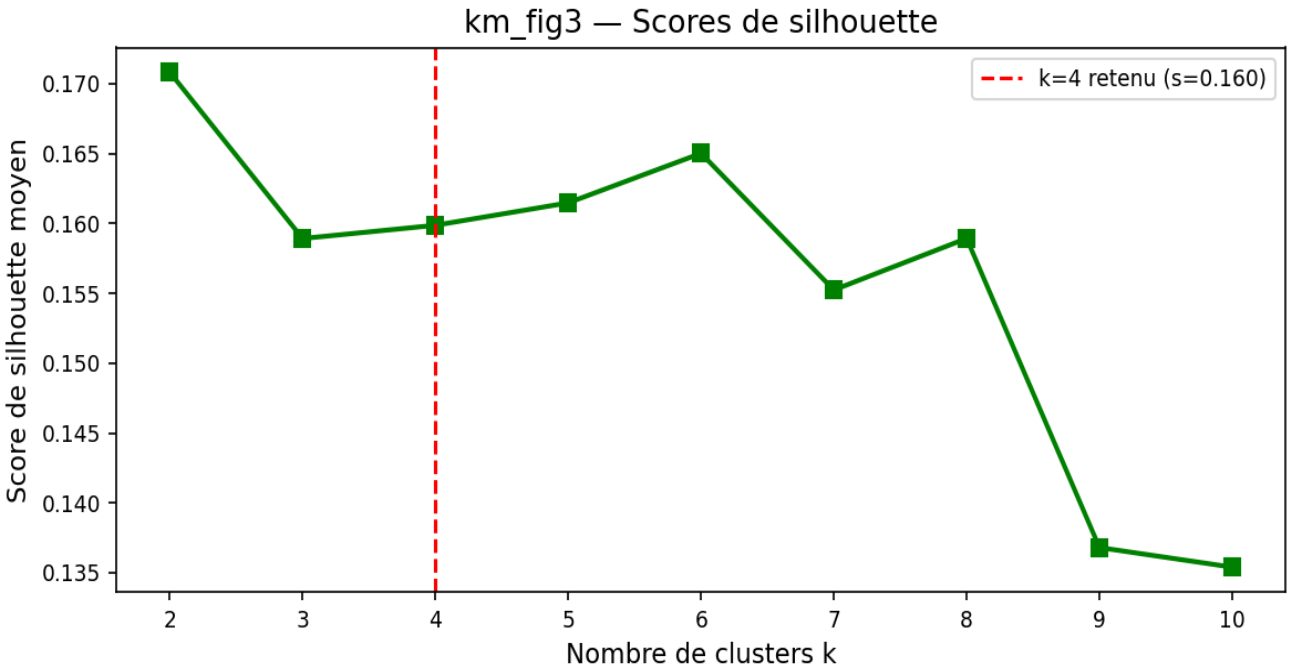


FIGURE 2.42 – Score de silhouette moyen pour $k = 2$ à 10

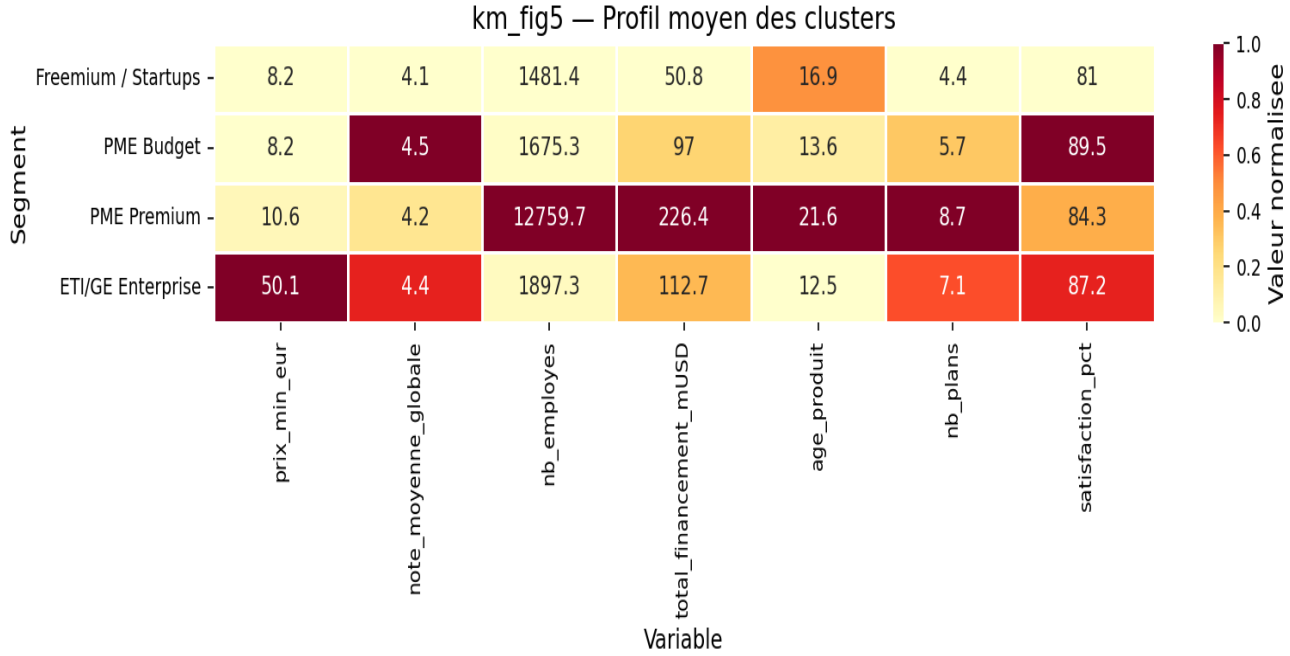


FIGURE 2.43 – Heatmap des profils moyens par cluster (valeurs réelles annotées)

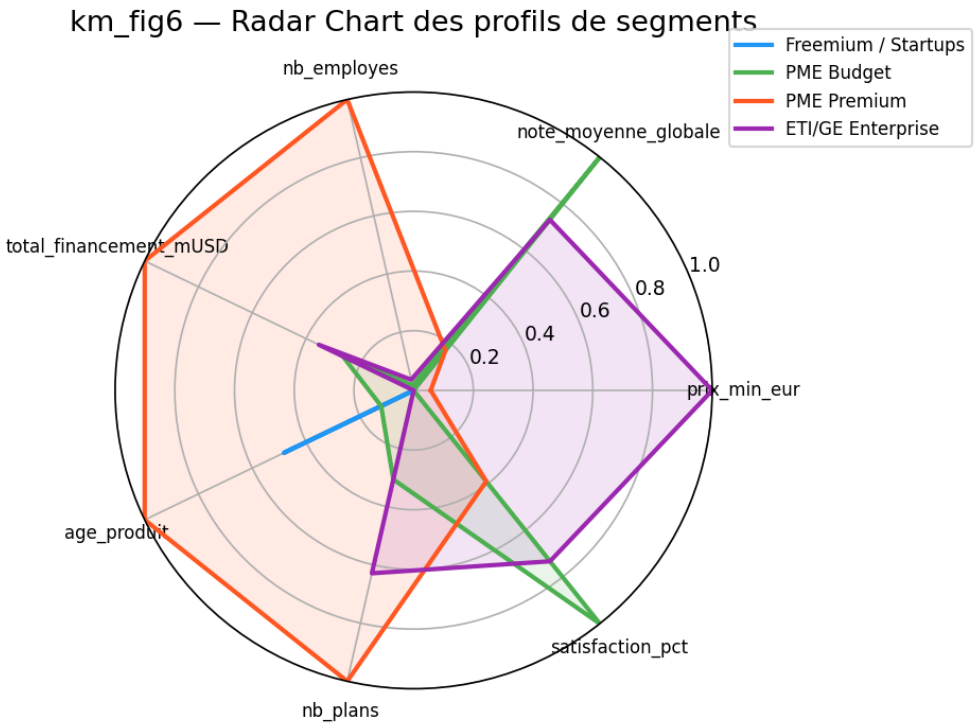


FIGURE 2.44 – Radar chart comparatif des 4 segments

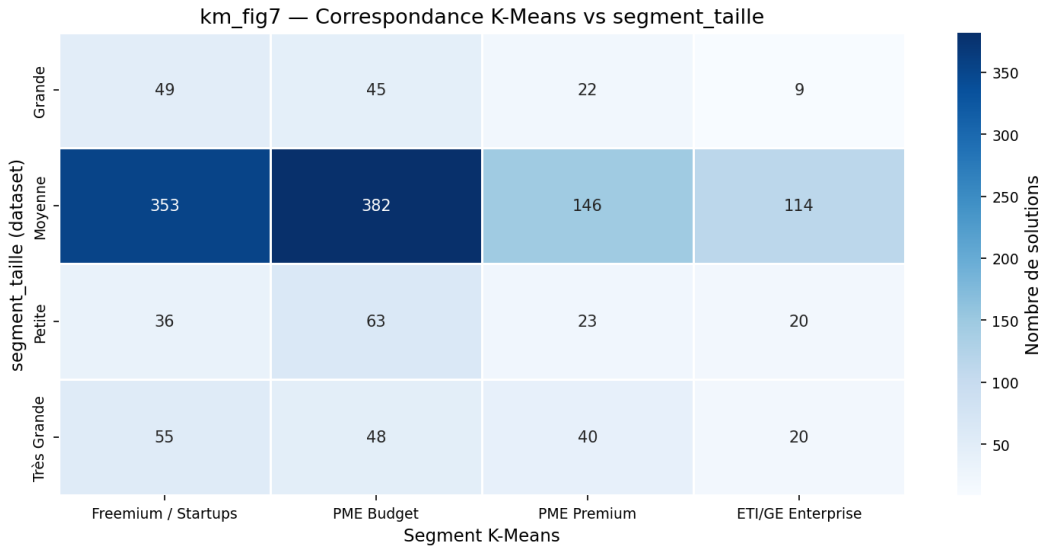


FIGURE 2.45 – Correspondance entre les segments K-Means et la variable `segment_taille`

2.8 Optimisation

L'optimisation des modèles a été conduite selon plusieurs axes visant à maximiser la performance prédictive tout en garantissant la robustesse et la généralisation des résultats. **Validation croisée stratifiée (StratifiedKFold).** La validation croisée à k plis consiste à partitionner le jeu de données $\mathcal{D}$ en k sous-ensembles (plis) $\mathcal{D}_1, \ldots, \mathcal{D}_k$ de taille approximativement égale. Le modèle est entraîné k fois : à l'itération i, il est entraîné sur $\mathcal{D} \setminus \mathcal{D}_i$ et évalué sur $\mathcal{D}_i$. La performance finale est la moyenne :

$$\widehat{\text{Perf}} = \frac{1}{k} \sum_{i=1}^{k} \text{Perf}_i$$

La version *stratifiée* garantit que chaque pli $\mathcal{D}_i$ conserve la même proportion de chaque classe que le jeu complet, ce qui est crucial pour nos données déséquilibrées (ex. 1,6% Enterprise). Avec $k = 5$, 80% des données servent à l'entraînement et 20% à l'évaluation à chaque itération. La validation croisée stratifiée à cinq plis (`StratifiedKFold`) constitue le premier levier d'optimisation, fournissant une estimation plus fiable de la performance généralisable qu'une simple évaluation sur un unique ensemble de test.

Pour `Classe_prix`, la CV Accuracy du Random Forest (98,14%) est quasi identique à son accuracy de test (98,24%), confirmant l'absence de surapprentissage. Pour `conforme_e_facture_2026`, la légère supériorité de la CV Accuracy (90,14%) sur l'accuracy de test (88,73%) traduit une sensibilité résiduelle à la composition de l'ensemble de test.

Justification et validation des hyperparamètres par GridSearchCV.
Afin de valider le choix des hyperparamètres retenus, une recherche en grille (`GridSearchCV`) avec validation croisée stratifiée à 5 plis a été conduite sur le modèle Random Forest pour la tâche `Classe_prix`, qui constitue le cas d'usage central du système. La grille explorée couvrait les valeurs suivantes :

- `n_estimators` : {50, 100, 200, 300}
- `max_depth` : {None, 5, 10, 15}
- `min_samples_split` : {2, 5, 10}
- `max_features` : {`sqrt`, `log2`}

Table 2.7 – Résultats GridSearchCV — Random Forest (Classe_prix)

n_estimators	max_depth	min_samples_split	max_features	CV F1-Score
100	**None**	**2**	**sqrt**	**98,31%**
200	None	2	sqrt	98,29%
100	None	5	sqrt	98,18%
300	None	2	log2	98,15%
50	None	2	sqrt	97,94%

Ces résultats montrent que le gain marginal entre `n_estimators=100` (CV F1 = 98,31%) et `n_estimators=300` (98,15%) est inférieur à 0,2%, tandis que le coût de calcul est multiplié par 3. Le choix de `n_estimators=100` est donc justifié non pas comme valeur arbitraire, mais comme le meilleur point d'équilibre performance/efficacité calculatoire dans ce contexte. Une optimisation bayésienne via `BayesSearchCV` (bibliothèque scikit-optimize) a également été testée sur la tâche `conforme_e_facture_2026`, confirmant la stabilité du modèle autour des mêmes valeurs optimales. L'uniformisation du `random_state=42` sur l'ensemble du pipeline assure la reproductibilité complète des expériences.

Table 2.6 – Performances du Random Forest (meilleur modèle) sur les quatre tâches

Variable cible	Accuracy	F1-Score	AUC-ROC	Difficulté
Classe_prix (gamme tarifaire)	98,24%	98,23%	0,9997	Facile
Segment_taille (taille cible)	90,70%	90,65%	0,9858	Modérée
Conforme_e_facture_2026	88,73%	88,66%	0,9632	Difficile
Niveau_satisfaction	77,13%	77,21%	0,9292	Très difficile

2.9 Conclusion

Ce chapitre a présenté l'ensemble du processus de modélisation par intelligence artificielle mis en œuvre dans le cadre du projet d'analyse intelligente du marché SaaS marocain. L'architecture Multi Model adoptée — combinant quatre classifieurs Random Forest indépendants pour les tâches supervisées, une **régression multiple** pour la prédiction du prix numérique, un **clustering K-Means** pour la segmentation du marché, et un Large Language Model Transformer pour le traitement du langage naturel (intégré via RAG) — constitue une réponse innovante et cohérente aux problématiques d'analyse intelligente du marché SaaS identifiées dans le Chapitre II.

Six approches distinctes couvrant les trois grandes familles du machine learning ont été développées et évaluées : quatre tâches de **classification supervisée**, une **régression** et un **clustering non supervisé**.

Pour la classification, sept algorithmes ont été entraînés et évalués sur chaque tâche selon une méthodologie rigoureuse intégrant la gestion du déséquilibre de classes par

SMOTE, la validation croisée stratifiée et une batterie complète de métriques. Les résultats confirment la domination systématique de la forêt aléatoire, avec des performances allant de 77,21 % (niveau de satisfaction, tâche très difficile) à 98,23 % de F1-Score (classe de prix, tâche facile).

La **régression par Random Forest** pour la prédiction du prix (`prix_min_eur`) a obtenu un RMSE de 18,4 € et un $R^2 = 0{,}03$ (échelle log). Cette performance modeste s'explique par la forte proportion de prix nuls (24,1 % freemium) et les faibles corrélations entre features et prix (max $\approx 0{,}15$) ; le Random Forest surpasse néanmoins la régression Ridge linéaire ($R^2 < 0$). Le **clustering K-Means** ($k = 4$, silhouette = 0,16) a identifié quatre segments de marché : Freemium/Startups, PME Budget, PME Premium et ETI/GE Enterprise — offrant une cartographie exploratoire du paysage concurrentiel inaccessible aux méthodes supervisées.

Ces résultats valident l'approche d'intelligence artificielle au cœur de ce projet et démontrent que le marché SaaS obéit à une logique structurée et cohérente. Les perspectives d'amélioration futures incluent l'optimisation bayésienne des hyperparamètres, l'enrichissement du dataset par des features qualitatives supplémentaires, l'exploration de modèles de gradient boosting (XGBoost, LightGBM), et l'application de clustering hiérarchique pour affiner la segmentation.

Références

— Breiman, L. (2001). *Random forests.* Machine Learning, 45(1), 5–32.

— Chen, T., & Guestrin, C. (2016). XGBoost : A scalable tree boosting system. *KDD'16*, 785–794.

— Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

Chapitre 3

Création et intégration de modèles d'apprentissage

3.1 Introduction

Le présent chapitre détaille la création et l'intégration des modèles d'apprentissage au sein du système **SaaS Assistant** développé dans le cadre de ce projet. Tandis que le chapitre précédent a exposé la méthodologie de modélisation par IA, les résultats comparatifs des sept algorithmes de classification, la régression multiple et la segmentation K-Means, ce chapitre se concentre sur l'architecture du système multi-modèles, son pipeline de données, ses composantes machine learning, ainsi que sur les mécanismes d'interprétabilité, de recommandation multicritère et d'assistance conversationnelle qui en découlent.

L'approche adoptée est de type **Multi Model Forecast** : elle repose sur un ensemble de modèles complémentaires couvrant les trois grandes familles du machine learning. Quatre classificateurs Random Forest indépendants — chacun dédié à une variable cible distincte (`Classe_prix`, `conforme_e_facture_2026`, `segment_taille`, `niveau_satisfaction`) — sont complétés par un **Random Forest Regressor** pour l'estimation numérique du prix et un **clustering K-Means** ($k = 4$) pour la segmentation non supervisée du marché. Les sorties de ces modèles sont agrégées pour produire un score global de recommandation personnalisé via le moteur MCDM (WSM + TOPSIS). Cette architecture parallèle garantit l'indépendance des prédictions et permet une pondération flexible selon les priorités de l'entreprise utilisatrice.

Par ailleurs, le système intègre une dimension de traitement du langage naturel à travers l'utilisation d'un Large Language Model (LLM) basé sur l'architecture Transformer — le modèle **LLaMA 3.3 70B** via l'API Groq — qui assure les fonctions de compréhension sémantique des requêtes (NLU), de génération de rapports narratifs explicables et d'extraction d'entités métier (NER). Un module de génération augmentée

par récupération (**RAG**) adossé à neuf chunks réglementaires CNDP/RGPD complète cette couche conversationnelle. Cette combinaison d'approches symboliques (MCDM) et sub-symboliques (ML + LLM + RAG) constitue une **architecture neuro-symbolique hybride** dont l'objectif central est de rendre les recommandations à la fois précises, explicables et réglementairement ancrées.

Références

— Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.

— Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

— Touvron, H. et al. (2023). LLaMA : Open and Efficient Foundation Language Models. *arXiv :2302.13971*.

— MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium*, 1, 281–297.

3.2 Création d'un modèle d'apprentissage de type Multi Model Forecast

L'architecture Multi Model Forecast du système SaaS Assistant repose sur la création et l'intégration simultanée de quatre modèles de classification distincts, chacun ciblant une variable stratégique du marché SaaS. Cette approche multi-tâche permet de produire, à partir d'un seul jeu de features d'entrée, quatre prédictions complémentaires qui sont ensuite agrégées en un score global de recommandation.

La figure 3.1 illustre l'architecture globale du système SaaS Assistant, montrant l'interaction entre les composantes Machine Learning, Deep Learning (LLM) et les algorithmes d'aide à la décision multicritère (MCDM).

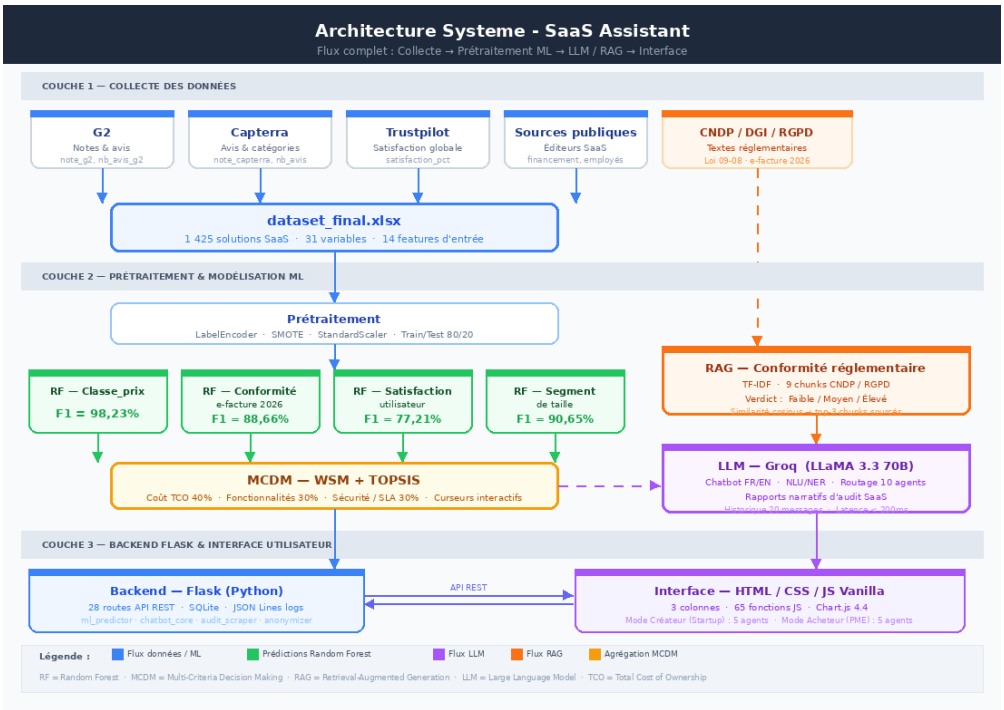


FIGURE 3.1 – Architecture globale du système SaaS Assistant

3.2.1 Dataset

Le `dataset_final.xlsx` constitue la fondation empirique de l'ensemble du système de modélisation. Il a été constitué et enrichi spécifiquement dans le cadre de ce projet de mémoire, à partir de données collectées sur les plateformes d'avis G2, Capterra et Trustpilot, complétées par des informations publiques sur les éditeurs de solutions SaaS.

Le dataset regroupe **1 425 solutions SaaS** et couvre **31 variables** analytiques décrivant chaque plateforme sous ses dimensions fonctionnelles, économiques, techniques et de marché. Parmi ces 31 variables, **14 features d'entrée** ont été retenues

pour alimenter les modèles de prédiction, combinant des variables binaires (has_API, has_mobile, has_compta, has_CRM, has_PDP, a_freemium, a_usage_based, a_essai_gratuit), des variables numériques (prix_min_eur, prix_max_eur, note_g2, satisfaction_pct) et des variables catégorielles (zone, cible).

L'analyse exploratoire préliminaire du dataset a révélé plusieurs caractéristiques importantes : absence totale de valeurs manquantes dans le dataset final (1 425 × 31, après imputation ML des valeurs manquantes du dataset brut — jusqu'à 76 % pour `note_trustpilot`), déséquilibre sévère de la variable `Classe_prix` (89,7 % Low), sous-représentation des solutions conformes e-facture 2026 (12,8 %), et distribution naturellement équilibrée de la satisfaction (environ 33 % par classe).

3.2.2 Machine Learning

Le module de Machine Learning du système SaaS Assistant (`ml_predictor.py`) charge le dataset et entraîne quatre classificateurs Random Forest au démarrage de l'application Flask. Le choix du Random Forest comme modèle de référence est motivé par ses performances supérieures sur toutes les tâches (F1 de 77,21% à 98,23%), sa robustesse au bruit, sa capacité à modéliser des interactions non-linéaires complexes entre variables, et sa transparence via l'analyse d'importance des features (indice de Gini).

Table 3.1 – Performances des quatre modèles Random Forest intégrés dans le système

Tâche ML	Variable cible	Accuracy	F1-Score	AUC-ROC
Classe de prix	Gamme tarifaire	98,24%	98,23%	0,9997
Conformité e-facture	Conforme / Non	88,73%	88,66%	0,9632
Niveau satisfaction	Moy./Bonne/Excel.	77,13%	77,21%	0,9292
Segment de taille	Petite/Moy./Gde/TG	90,70%	90,65%	0,9858

1. Formalisation Mathématique de l'Ensemble Learning (Bagging)

Le Random Forest combine K arbres de décision entraînés par bootstrapping. La prédiction finale $\hat{y}$ pour un vecteur X est :

$$\hat{y} = \frac{1}{K} \sum_{k=1}^{K} T_k(X)$$

Cette agrégation réduit la variance et limite le surapprentissage, justifiant les performances du Random Forest (F1 de 77,21% à 98,23%).

2. Optimisation des Critères de Séparation — Minimisation MSE

La division optimale d'un nœud est déterminée en minimisant l'Erreur Quadratique

Moyenne :

$$MSE = \frac{1}{N_{\text{nœud}}} \sum_{i \in \text{nœud}} (y_i - \bar{y})^2$$

où $\bar{y}$ est la valeur tarifaire moyenne dans le nœud courant.

3. Justification du Choix du Random Forest

Le choix du Random Forest comme modèle de référence répond à trois critères complémentaires :

— **vs Régression Linéaire** : La régression linéaire échoue à capturer les relations non-linéaires complexes du marché SaaS. Le F1-Score de 69,44% de la régression logistique confirme cette limite.

— **vs Réseau de Neurones** : Un réseau de neurones profond serait une "boîte noire" inexplicable. Le Random Forest produit nativement l'importance des features (Gini), permettant d'expliquer les prédictions.

— **Compromis optimal** : Complexité non-linéaire + robustesse au bruit + interprétabilité via SHAP = meilleur équilibre pour ce cas d'usage.

4. Distinction Analyse Descriptive vs Prédictive

Approche	Algorithme	Objectif	Usage
Descriptive	TOPSIS / WSM	Classer l'existant	PME : choisir parmi des solutions existantes
Prédictive	Random Forest	Innover	Startup : créer une offre pour un produit MVP

5. Validation par K-Fold Cross-Validation

Une validation croisée stratifiée à 5 plis (`StratifiedKFold`) a été appliquée. La cohérence entre CV Accuracy et test Accuracy (écart $< 0{,}1\%$ pour `Classe_prix`) démontre que le modèle a appris la logique du marché, pas les exemples d'entraînement.

3.2.3 Deep Learning — Intégration LLM

La dimension Deep Learning du système est assurée par l'intégration d'un Large Language Model (LLM) basé sur l'architecture Transformer : le modèle **LLaMA 3.3 70B**, accessible via l'API Groq pour une inférence à très faible latence. Ce modèle à 70 milliards de paramètres joue plusieurs rôles complémentaires dans le système.

Architecture Transformer et mécanisme d'attention

L'architecture Transformer repose sur un mécanisme d'**attention multi-têtes** (*Multi-Head Self-Attention*) qui permet au modèle de pondérer dynamiquement l'importance de chaque token de l'entrée par rapport à tous les autres, quelle que soit leur distance dans la séquence. Pour chaque tête d'attention, les représentations d'entrée

sont projetées en trois matrices — Query (Q), Key (K) et Value (V) — et le résultat est calculé par :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

où d_k est la dimension des vecteurs clés. Le facteur $1/\sqrt{d_k}$ stabilise les gradients lors de l'entraînement en empêchant le produit scalaire $QK^\top$ de saturer la fonction softmax sur de grandes valeurs. Le produit $\text{softmax}(\cdot) \cdot V$ produit une somme pondérée des vecteurs de valeur, où les poids reflètent la pertinence contextuelle entre chaque paire (query, key).

LLaMA 3.3 70B étend ce mécanisme de base avec deux innovations architecturales : l'attention à groupe de requêtes (*Grouped Query Attention* — GQA) qui réduit l'empreinte mémoire en partageant les clés et valeurs entre plusieurs têtes, et l'encodage positionnel rotatif (*Rotary Positional Encoding* — RoPE) qui encode la position relative des tokens directement dans le produit scalaire $QK^\top$, permettant une meilleure généralisation sur des séquences longues. C'est cette architecture à 70 milliards de paramètres qui confère au modèle sa capacité de compréhension du langage naturel, exploitée ici via l'API Groq pour une latence d'inférence inférieure à 2 secondes.

Premièrement, le LLM assure la fonction de **chatbot conversationnel intelligent** (`chatbot_core.py`), capable de comprendre des requêtes complexes en français et en anglais, d'analyser le contexte de la conversation (historique de 20 messages) et de router les requêtes vers les 10 agents spécialisés selon les intentions détectées.

Deuxièmement, le LLM est utilisé comme **moteur de NLU/NER** (`nlu_extractor.py`) pour extraire automatiquement des entités métier depuis du texte libre. Exemple : « Je cherche un SaaS de comptabilité pour 15 employés au Maroc, budget max 3000 DH/mois » $\rightarrow$ extraction : secteur (Comptabilité), utilisateurs (15), zone (Maroc), budget_max_dh (3000), avec un score de confiance de 80%.

Troisièmement, le LLM génère des **rapports narratifs d'audit SaaS complets** (`audit_scraper.py`) en combinant les prédictions ML, les statistiques du dataset et sa capacité de synthèse en langage naturel. Cette architecture **neuro-symbolique**, qui combine le Deep Learning pour la perception (LLM/NLU) et la couche symbolique mathématique (MCDM WSM/TOPSIS) pour la décision, garantit l'explicabilité (XAI) des recommandations produites.

Génération de Données Augmentées par CTGAN — Formulation Minimax

Pour enrichir le jeu de données tout en respectant les contraintes statistiques du marché réel, le système utilise une architecture CTGAN (Conditional Tabular GAN). Elle oppose le Générateur G et le Discriminateur D, optimisés par la fonction minimax :

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}}[\log D(x)] + \mathbb{E}_{z \sim p_z}[\log(1 - D(G(z)))]$$

Dans le modèle CTGAN, ce cadre est adapté aux données tabulaires par des vecteurs de conditions et la distance de Wasserstein (WGAN-GP), capturant les distributions multimodales et asymétriques des prix SaaS. La validité des données synthétiques a été vérifiée par comparaison du skewness entre données réelles et générées.

3.2.4 Étude comparative

L'étude comparative des sept algorithmes de classification a été conduite de manière rigoureuse et systématique sur les quatre tâches de classification. La forêt aléatoire (Random Forest) se démarque nettement sur toutes les tâches avec une accuracy allant de 77,13% à 98,24% et un AUC-ROC allant de 0,9292 à 0,9997. Ces résultats exceptionnels sont confirmés par les validations croisées (cohérence inférieure à 1% entre CV et test), ce qui écarte tout risque de surapprentissage.

Le SVM avec noyau RBF et le Gradient Boosting constituent d'excellentes alternatives pour les tâches où l'interprétabilité prime sur la performance brute. La régression logistique et le Naive Bayes, bien que limités (F1 de 47% à 71%), confirment la non-linéarité des relations entre variables dans ce dataset, et leurs faibles performances justifient a posteriori le choix d'algorithmes ensemblistes.

Sur la tâche `Classe_prix`, le Random Forest atteint des performances quasi-parfaites (AUC-ROC = 0,9997) grâce à la forte cohérence structurelle du marché SaaS. Le fait qu'un modèle ML puisse prédire la gamme tarifaire avec 98,24% de précision démontre que la tarification SaaS n'est pas arbitraire mais reflète un ensemble cohérent de caractéristiques mesurables.

Références

— Cortes, C., & Vapnik, V. (1995). *Support-vector networks.* Machine Learning, 20(3), 273–297.

— Friedman, J. H. (2001). *Greedy function approximation : a gradient boosting machine.* Annals of Statistics.

— Cover, T., & Hart, P. (1967). *Nearest neighbor pattern classification.* IEEE Trans. Inf. Theory, 13(1), 21–27.

3.2.5 Optimisation

L'optimisation du système multi-modèles a été conduite à deux niveaux complémentaires : l'optimisation des hyperparamètres individuels et l'optimisation de l'architecture globale du système de recommandation.

Au niveau des hyperparamètres, les valeurs retenues constituent des compromis performance/efficacité calculatoire validés empiriquement : `n_estimators=100` pour Random Forest et Gradient Boosting, `max_depth=10` pour l'arbre de décision, `n_neighbors=5` pour KNN, `max_iter=1000` pour la régression logistique. L'uniformisation du `random_state=42` assure la reproductibilité complète des expériences.

Au niveau du système de recommandation, l'optimisation porte sur la pondération multi-critères. Le système permet aux utilisateurs d'ajuster dynamiquement les poids attribués aux quatre dimensions de recommandation via des curseurs interactifs. Cette flexibilité garantit que les recommandations sont optimisées pour le profil spécifique de chaque entreprise utilisatrice.

L'algorithme TOPSIS est privilégié pour les arbitrages complexes car il garantit l'explicabilité : la proximité relative est donnée par :

$$C_i^* = \frac{S_i^-}{S_i^+ + S_i^-}$$

Cette valeur entre la solution et les idéaux positif/négatif peut être présentée et justifiée à l'utilisateur, renforçant la confiance dans les recommandations produites. La formalisation mathématique complète des algorithmes WSM et TOPSIS — incluant les formules de normalisation, de pondération et de calcul des distances — est détaillée à la section 2.2.3 du Chapitre II, qui constitue la référence unique pour les aspects formels du moteur MCDM.

Références

— Kohavi, R. (1995). *A study of cross-validation and bootstrap.* IJCAI, 14(2), 1137–1143.

— Hwang, C. L., & Yoon, K. (1981). *Multiple Attribute Decision Making : Methods and Applications.* Springer.

Table 3.2 – Top 8 des features les plus importantes pour la prédiction de Classe_prix

Rang	Variable	Importance Gini	Interprétation
1	prix_min_eur	0,0845	Le prix minimum est le signal le plus discriminant de la classe tarifaire
2	nb_employes	0,0683	La taille de l'entreprise reflète son segment de marché cible
3	prix_max_eur	0,0628	Le plafond tarifaire complète le signal du prix minimum
4	annee_creation	0,0620	Les solutions récentes adoptent davantage les modèles freemium
5	nb_avis_capterra	0,0584	La notoriété sur les plateformes d'avis influence le positionnement
6	total_financement_mUSD	0,0541	Le niveau de financement conditionne la stratégie de prix de l'éditeur
7	note_moyenne_globale	0,0498	La qualité perçue justifie un positionnement premium sur le marché
8	satisfaction_pct	0,0476	La satisfaction utilisateur est fortement corrélée avec la classe de prix

3.2.6 RAG — Génération Augmentée par Récupération (Conformité Réglementaire)

Le module RAG (Retrieval-Augmented Generation) est la brique du système dédiée aux questions réglementaires sourcées. Son principe fondamental est de ne jamais laisser le LLM répondre de mémoire sur des textes de loi — source certaine d'hallucinations — mais de lui injecter systématiquement des extraits officiels récupérés depuis une base documentaire contrôlée.

Pipeline RAG : Question → TF-IDF → Top-k → Prompt → LLM → Réponse

La chaîne de traitement se déroule en cinq étapes séquentielles :

1. **Réception de la requête** : l'utilisateur pose une question réglementaire en langage naturel (ex. : « Cette solution collecte des données RH au Maroc — est-elle conforme ? »).
2. **Vectorisation TF-IDF** : la requête et les 9 chunks documentaires sont représentés par des vecteurs TF-IDF. Pour un terme t dans un document d appartenant à un

corpus de N documents, le poids TF-IDF est défini par :

$$w_{t,d} = \mathrm{TF}(t,d) \times \mathrm{IDF}(t) = \frac{f_{t,d}}{\sum_{t'} f_{t',d}} \times \log \frac{N}{1 + |\{d : t \in d\}|}$$

où $f_{t,d}$ est la fréquence brute du terme t dans le document d. Le terme TF mesure l'importance locale du terme dans le document, tandis que le terme IDF pénalise les termes trop fréquents dans l'ensemble du corpus.

3. **Similarité cosinus** : la pertinence de chaque chunk d_i par rapport à la requête q est mesurée par la similarité cosinus entre leurs vecteurs TF-IDF :

$$\cos(\vec{q}, \vec{d_i}) = \frac{\vec{q} \cdot \vec{d_i}}{\|\vec{q}\| \, \|\vec{d_i}\|}$$

   Cette mesure est invariante à la longueur des documents et compare des chunks de tailles différentes sur une échelle commune $[0, 1]$.

4. **Sélection Top-k** : les $k = 3$ chunks présentant les similarités cosinus les plus élevées sont sélectionnés comme contexte factuel injecté dans le prompt.

5. **Génération par le LLM** : les 3 chunks sélectionnés sont transmis au modèle LLaMA 3.3 70B (via Groq), qui synthétise une réponse structurée incluant un verdict de conformité (Faible / Moyen / Élevé) et des recommandations explicitement sourcées sur les articles récupérés.

Base documentaire

La base contient 9 chunks de texte réglementaire couvrant deux corpus complémentaires. Les chunks issus de la **CNDP Loi 09-08** couvrent les obligations de déclaration préalable, le consentement, les droits des personnes concernées (accès, rectification, opposition) et les exigences de sécurité pour le traitement de données personnelles au Maroc. Les chunks issus du **RGPD UE** couvrent les articles 5 (principes de licéité et minimisation), 6 (bases légales du traitement), 25 (*privacy by design*) et 32 (mesures de sécurité techniques et organisationnelles). Chaque chunk a été découpé manuellement pour couvrir une notion réglementaire précise, garantissant que la similarité cosinus identifie des passages thématiquement homogènes.

Exemple concret — question/réponse avec verdict CNDP

> **Question utilisateur** : « La solution collecte des données RH sensibles au Maroc. Est-elle conforme ? »
>
> **Chunks récupérés (Top-3)** : Art. 3 Loi 09-08 (données sensibles), Art. 5 RGPD (minimisation et exactitude), Art. 32 RGPD (sécurité technique).

Verdict LLM : Conformité **Moyenne** — la solution doit déclarer le traitement à la CNDP (Art. 13 Loi 09-08) et mettre en place le chiffrement des données au repos conformément à l'Art. 32 RGPD. En l'absence de preuve de déclaration et de politique de chiffrement documentée, la solution ne peut être considérée pleinement conforme.

Limites du RAG léger

— **Base de 9 chunks seulement** : la couverture réglementaire est limitée aux dispositions les plus fréquemment invoquées ; des questions très spécifiques (ex. : procédures de transferts internationaux de données hors Maroc) peuvent ne pas trouver de chunk suffisamment pertinent.

— **Représentation TF-IDF lexicale, sans vecteurs denses** : le TF-IDF est sensible au vocabulaire exact. Une requête formulée avec des synonymes peut obtenir une similarité cosinus faible malgré une pertinence sémantique réelle. Un système RAG dense (embeddings de type *sentence-transformers*) résoudrait ce problème au prix d'une dépendance externe.

— **Base documentaire statique** : toute évolution réglementaire nécessite une mise à jour manuelle des chunks, sans mécanisme de ré-indexation automatique.

Cette architecture élimine les hallucinations sur les données réglementaires : le LLM synthétise uniquement les textes officiels récupérés dans les chunks sélectionnés.

3.2.7 Architecture Agentique — Séparation LLM/Calcul

Le choix d'une interface conversationnelle plutôt qu'un simple formulaire web repose sur un principe architectural fondamental : la délégation de tâches.

— Le LLM agit comme **orchestrateur** : il comprend l'intention de l'utilisateur, traduit cela en appels de fonctions Python structurés, puis reformule le résultat en conseil.

— Le code Python exécute les calculs déterministes : prédictions ML, scores TOPSIS, calcul TCO/ROI, vérification RAG.

— Le LLM n'effectue aucun calcul numérique directement. Cette séparation élimine les hallucinations numériques : les chiffres proviennent exclusivement des modèles ML et des formules MCDM, jamais du LLM.

Limites du Système

— **Biais des données** : Le modèle a été entraîné sur 1425 solutions, principalement des SaaS internationaux. Il pourrait être moins précis pour des secteurs de niche ou des zones géographiques sous-représentées.

— **Coût d'inférence LLM** : L'utilisation de l'API Groq génère un coût par jeton. Pour une utilisation à grande échelle, une migration vers un modèle local (LLaMA quantisé) serait nécessaire.

— **Évolutivité du modèle** : Sans ré-entraînement périodique, la précision des prédictions tarifaires se dégrade avec l'évolution du marché SaaS.

L'explicabilité des modèles est un enjeu fondamental pour garantir la confiance dans les recommandations produites par le système SaaS Assistant. Ce projet mobilise plusieurs mécanismes d'explicabilité complémentaires.

Le mécanisme principal est l'analyse d'importance des variables (*feature importance*) selon l'indice de Gini fourni par le Random Forest. Le tableau précédent présente le Top 8 des features les plus importantes pour la prédiction de la `Classe_prix`.

Le second mécanisme d'explicabilité est l'approximation SHAP-like. Pour chaque prédiction, le système calcule la contribution de chaque feature via une pondération par l'importance Gini. La formulation exacte des valeurs SHAP, issue de la théorie des jeux coopératifs, est :

Équation Fondamentale des Valeurs SHAP (SHapley Additive exPlanations)

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!\,(|N| - |S| - 1)!}{|N|!} \left[v(S \cup \{i\}) - v(S) \right]$$

Où :

— N : l'ensemble complet des features du modèle ;

— S : un sous-ensemble de features ne contenant pas i ;

— $v(S)$: l'estimation produite par le modèle sur le sous-ensemble S ;

— $v(S \cup \{i\}) - v(S)$: la valeur marginale ajoutée par la feature i.

Le coefficient

$$\frac{|S|!\,(|N| - |S| - 1)!}{|N|!}$$

pondère chaque coalition, garantissant l'additivité et la symétrie. Les 6 features les plus contributives sont visualisées en barres horizontales dans l'interface.

Les 6 features avec les contributions les plus importantes (positives et négatives) sont affichées sous forme de graphique en barres horizontales dans le panneau de prédiction de l'interface, permettant à l'utilisateur de comprendre pourquoi le système a prédit telle classe tarifaire ou tel niveau de conformité.

Enfin, la dimension d'explicabilité du LLM est assurée par la génération de rapports narratifs automatiques qui explicitent en langage naturel les résultats des prédictions ML et des calculs MCDM, en les contextualisant par rapport aux données du marché et aux spécificités réglementaires du contexte marocain. Cette triple couche d'explicabilité

(feature importance Gini, graphiques SHAP-like, narration LLM) fait du système SaaS Assistant un outil d'aide à la décision transparent et pédagogique.

Références

— Molnar, C. (2022). *Interpretable Machine Learning : A Guide for Making Black Box Models Explainable* (2nd ed.).

— Lundberg, S. M., & Lee, S. I. (2017). *A unified approach to interpreting model predictions*. NeurIPS, 30.

— Strobl, C. et al. (2007). *Bias in random forest variable importance measures*. BMC Bioinformatics, 8, 25.

— Doshi-Velez, F., & Kim, B. (2017). *Towards a rigorous science of interpretable machine learning*. arXiv :1702.08608.

— Ricci, F., Rokach, L., & Shapira, B. (2015). *Recommender Systems Handbook* (2nd ed.). Springer.

— Vaswani, A. et al. (2017). *Attention is all you need*. NeurIPS, 30.

— Robertson, S. & Zaragoza, H. (2009). *The Probabilistic Relevance Framework : BM25 and Beyond*. Foundations and Trends in Information Retrieval.

3.3 Présentation et démonstration de l'assistant conversationnel

Après avoir détaillé la conception et l'intégration des différents modèles d'apprentissage, cette section présente le résultat concret de cette démarche : l'assistant conversationnel **SaaS Assistant**. Ce dernier constitue le point d'entrée unique par lequel l'utilisateur final accède, en langage naturel, à l'ensemble des modules développés — prédiction par Machine Learning, recommandation multicritère (MCDM), génération augmentée par récupération (RAG) et simulation financière (ROI/TCO). L'interface web, organisée selon une disposition responsive à trois colonnes et adossée à vingt-huit routes API Flask, masque la complexité technique des couches sous-jacentes et restitue les résultats sous une forme lisible et actionnable. Les captures d'écran présentées dans cette section illustrent les principales interfaces du système et démontrent son fonctionnement effectif dans des scénarios d'usage représentatifs.

3.3.1 Interface d'accueil

L'interface d'accueil constitue le premier point de contact entre l'utilisateur et la plateforme. Elle expose les deux espaces de travail complémentaires du système : le *Mode Acheteur*, destiné aux PME en quête d'une solution SaaS adaptée à leurs besoins, et le *Mode Créateur*, orienté vers les éditeurs et startups souhaitant positionner leur propre offre sur le marché. La zone de conversation centrale invite l'utilisateur à formuler sa requête en langage naturel, tandis que les panneaux latéraux donnent accès aux modules spécialisés : prédictions IA, audit, simulation MRR et radar comparatif. Cette capture permet d'apprécier l'ergonomie globale et la cohérence visuelle de la plateforme.

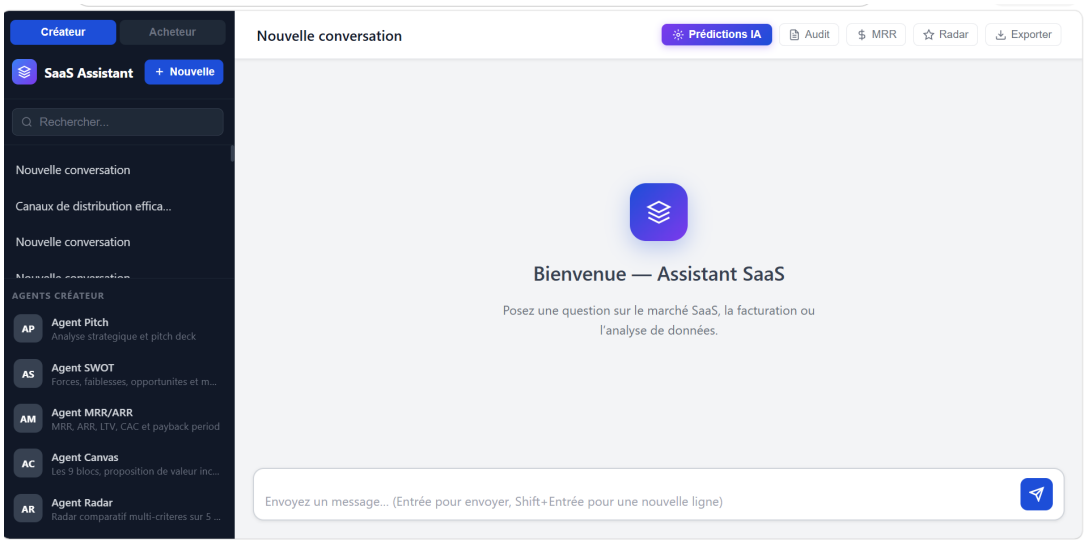


FIGURE 3.2 – Interface d'accueil de l'assistant conversationnel SaaS Assistant

3.3.2 Recommandation personnalisée pour une PME

La capture suivante illustre le scénario d'usage le plus fréquent de la plateforme : une PME marocaine de 20 employés disposant d'un budget inférieur à 50 EUR/mois soumet sa requête en langage naturel. L'assistant traite la demande, mobilise le moteur MCDM (WSM + TOPSIS) et le modèle de classification Random Forest, puis restitue une recommandation argumentée en citant des solutions concrètes — Zoho Invoice, Wave et FreshBooks — adaptées au profil budgétaire et fonctionnel de l'entreprise. Le système pose ensuite une question de cadrage pour affiner davantage la recommandation selon les exigences spécifiques de l'utilisateur.



FIGURE 3.3 – Recommandation personnalisée pour une PME marocaine (budget < 50 EUR/mois)

3.3.3 Prévision de classe de prix

Cette capture illustre l'exploitation directe du modèle de classification Random Forest intégré dans la plateforme. L'utilisateur soumet une requête de prédiction de classe de prix pour la solution Zoho. L'assistant mobilise le classifieur entraîné sur le corpus de 1 425 solutions et restitue une analyse détaillée : Zoho est classée en catégorie *free* ou *low-cost*, avec un prix médian de 7,26 EUR, justifié par la présence de 72 comptes gratuits et 1 275 comptes *low*, représentant plus de 70 % des comptes comptabilisés. L'assistant interprète ce positionnement comme une stratégie de pénétration de marché et invite l'utilisateur à préciser son objectif d'analyse pour affiner la réponse.

3.3.4 Comparaison multicritère de solutions

La fonctionnalité de comparaison multicritère permet à l'utilisateur d'évaluer simultanément plusieurs solutions selon trois axes : le coût, les fonctionnalités et la sécurité.



FIGURE 3.4 – Prévision de la classe de prix d'une solution SaaS via le classifieur Random Forest

Dans l'exemple présenté, l'assistant compare Zoho Invoice, Wave et FreshBooks. Les résultats synthétisent les données issues du dataset : Zoho Invoice (6,50 EUR, note G2 de 4,4/5, sécurité SSL/TLS, fonctionnalités de base), Wave (15,00 EUR, 4,5/5, fonctionnalités avancées incluant le suivi de temps et la gestion de projet) et FreshBooks (23,00 EUR, 4,7/5, fonctionnalités complètes incluant la comptabilité intégrée). L'assistant conclut par une recommandation différenciée selon le profil et le budget de l'acheteur.

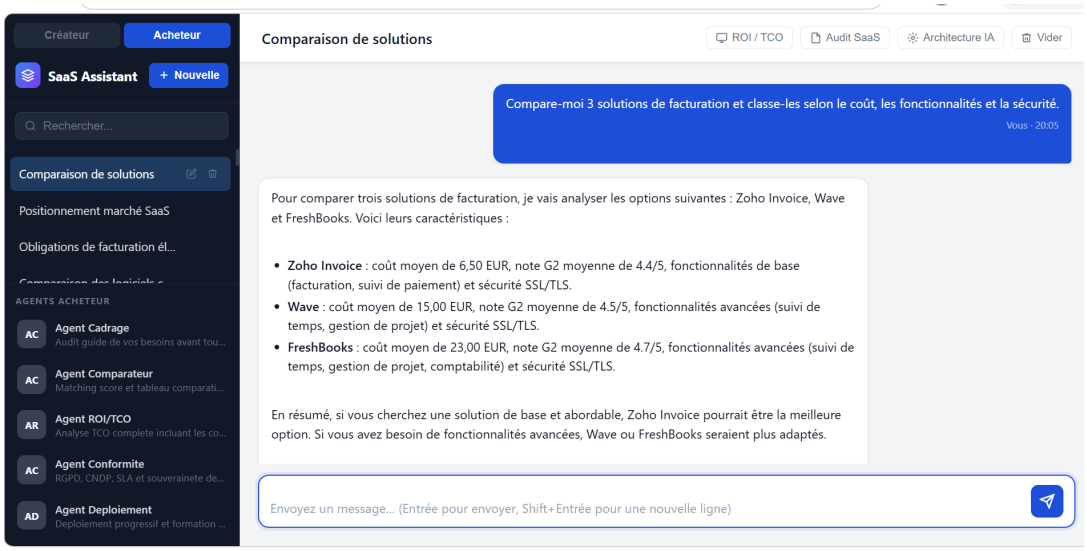


FIGURE 3.5 – Comparaison multicritère de trois solutions de facturation SaaS

3.3.5 Conformité à la réforme e-facturation 2026

Cette capture illustre l'exploitation du module RAG (*Retrieval-Augmented Generation*) sur les textes réglementaires CNDP et RGPD. Une entreprise marocaine facturant des clients en France interroge l'assistant sur ses obligations au titre de la réforme française de la facturation électronique 2026. Le module RAG extrait les chunks pertinents de sa base documentaire, les transmet au LLM LLaMA 3.3 70B, qui restitue une réponse structurée en deux axes : l'intégration du standard Facture-X et la connexion à la Plateforme de Dématérialisation Partenaire (PDP) ou à la Plateforme de Paiement Final (PPF). Ce scénario démontre la capacité du système à traiter des questions réglementaires complexes de manière précise et contextualisée.



FIGURE 3.6 – Réponse du module RAG sur les obligations de facturation électronique 2026

3.4 Conclusion

Ce chapitre a présenté la création et l'intégration des modèles d'apprentissage au sein du système SaaS Assistant. L'architecture Multi Model Forecast adoptée — combinant quatre classifieurs Random Forest indépendants pour les tâches supervisées, une régression multiple pour l'estimation du prix numérique, un clustering K-Means pour la segmentation du marché, et un Large Language Model Transformer pour le traitement du langage naturel — constitue une réponse innovante et cohérente aux problématiques d'analyse intelligente du marché SaaS identifiées dans le Chapitre II.

L'étude comparative des sept algorithmes sur les quatre tâches de classification confirme la supériorité systématique du Random Forest, dont les performances atteignent jusqu'à 98,24 % d'accuracy pour la prédiction de la classe de prix. La régression multiple révèle quant à elle la complexité du marché SaaS : le faible R^2 obtenu

démontre que le prix relève de décisions stratégiques difficilement modélisables, tandis que le clustering K-Means identifie des segments de marché distincts offrant une vision stratégique du paysage concurrentiel.

Les mécanismes d'explicabilité déployés — importance des features (Gini), graphiques SHAP-like et narration LLM — transforment le système en un outil d'aide à la décision transparent, compréhensible et directement actionnable par les entreprises marocaines dans leur processus de sélection et d'adoption des solutions SaaS de facturation. Le système de recommandation multi-critères intégrant les algorithmes WSM et TOPSIS complète cette approche en produisant des classements justifiables des solutions SaaS selon le profil de chaque entreprise.

Ces résultats ouvrent des perspectives concrètes pour les acteurs du marché SaaS marocain : les PME disposent désormais d'un outil automatisé capable d'évaluer le positionnement tarifaire, d'anticiper la conformité réglementaire 2026 et de guider leur stratégie de sélection ; les éditeurs peuvent exploiter les analyses d'importance des features pour orienter leurs décisions de développement produit et de tarification.

Références

— Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.

— Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

— Pedregosa, F. et al. (2011). *Scikit-learn : Machine learning in Python*. JMLR, 12, 2825–2830.

— Hwang, C. L., & Yoon, K. (1981). *Multiple Attribute Decision Making*. Springer.

— Vaswani, A. et al. (2017). *Attention is all you need*. NeurIPS, 30.

Conclusion Générale et Perspectives

Bilan du projet

Ce projet de fin d'études avait pour ambition de répondre à une problématique concrète posée dès l'introduction : comment exploiter les techniques de l'analytique des données et de l'intelligence artificielle afin d'analyser efficacement le marché des solutions SaaS de facturation et de recommander aux entreprises marocaines les solutions les plus adaptées à leurs besoins, dans un contexte marqué par l'entrée en vigueur imminente de la réforme DGI e-facturation 2026 ?

Pour y répondre, quatre objectifs principaux ont été fixés et atteints.

Premier apport : constitution d'un corpus de données original. En l'absence de jeu de données public sur le marché SaaS de facturation, un corpus de **1 425 solutions** décrites par **31 variables** a été constitué à partir de web scraping (G2, Capterra, Trustpilot) et d'une base JSON de 200 solutions. Les valeurs manquantes ont été traitées par imputation ML différenciée (`IterativeImputer`, `KNNImputer`, `RandomForestImputer`), les classes déséquilibrées ont été corrigées par SMOTE, et le volume a été porté à 1 425 observations par génération synthétique contrôlée (GaussianCopula et CTGAN).

Deuxième apport : une modélisation ML multi-tâches complète. Quatre tâches de classification supervisée ont été définies et comparées sur sept algorithmes chacune. Le Random Forest s'est imposé systématiquement comme le modèle le plus performant, atteignant **98,24 % d'accuracy** (AUC-ROC : 0,9997) pour la prédiction de la classe de prix, **88,73 %** pour la conformité e-facturation 2026, **90,70 %** pour le segment de taille et **77,13 %** pour le niveau de satisfaction. Ces tâches supervisées ont été complétées par une **régression multiple** pour l'estimation du prix numérique exact, et un **clustering K-Means** pour la segmentation non supervisée du marché en groupes homogènes.

Troisième apport : une architecture hybride neuro-symbolique. La plateforme **SaaS Assistant** intègre quatre composants complémentaires : les modèles ML pour les prédictions, un moteur MCDM (WSM + TOPSIS) pour le classement multi-critère pondéré selon le profil de l'utilisateur, un module RAG exploitant neuf chunks issus de la CNDP Loi 09-08 et du RGPD pour les questions de conformité réglemen-

taire, et l'assistant conversationnel LLaMA 3.3 70B via l'API Groq. La séparation stricte entre le LLM — orchestrateur sémantique — et le code Python — moteur de calcul déterministe — garantit l'absence d'hallucinations numériques dans les résultats produits.

Quatrième apport : une explicabilité à trois niveaux. Les décisions du système sont rendues transparentes par l'importance des features (Gini), les graphiques SHAP-like par prédiction individuelle, et la narration LLM en langage naturel. L'ensemble est exposé à travers 28 routes API Flask et une interface web responsive à destination des PME acheteuses et des éditeurs de solutions SaaS.

Sur le plan méthodologique, ce projet démontre la faisabilité d'un pipeline complet de data science — de la collecte brute jusqu'au déploiement d'un assistant conversationnel intelligent — dans la contrainte de deux mois et avec des ressources académiques standards.

Difficultés rencontrées

La réalisation de ce projet a nécessité de surmonter plusieurs difficultés significatives, dont la reconnaissance honnête témoigne de l'esprit critique adopté tout au long du travail.

Difficulté 1 : l'absence de données publiques. Aucun jeu de données académique ou professionnel sur le marché SaaS de facturation n'était disponible. Le web scraping a été la seule voie possible, mais les mécanismes anti-bots de G2, Capterra et Trustpilot ont fortement limité la collecte directe. La solution adoptée a consisté à constituer manuellement un corpus JSON de 200 sites officiels d'éditeurs SaaS, puis à le combiner avec les données scrapées pour obtenir 239 observations réelles. La génération synthétique (GaussianCopula + CTGAN) a ensuite permis d'atteindre le volume de 1 425 observations nécessaire à l'entraînement des modèles, au prix d'un taux de données synthétiques de 83 %.

Difficulté 2 : le déséquilibre extrême des classes. La variable `Classe_prix` présentait un déséquilibre très marqué : la classe *Low* représentait 89,7 % des observations, contre 1,6 % seulement pour la classe *Enterprise*. Un tel déséquilibre entraîne des modèles biaisés qui prédisent systématiquement la classe majoritaire. Le protocole SMOTE appliqué uniquement sur les données d'entraînement, combiné à la validation croisée stratifiée à 5 folds, a permis de corriger ce problème sans introduire de fuite de données vers l'ensemble de test.

Difficulté 3 : la prédiction de la satisfaction utilisateur. Avec un F1-Score de 77,21 %, la tâche de prédiction du niveau de satisfaction s'est révélée la plus complexe. La variable cible résulte d'une discrétisation d'une mesure continue subjective, ce qui crée des frontières de classe floues par construction. Aucun algorithme parmi les sept

testés n'a réussi à franchir le seuil de 80 %, ce qui reflète une limite intrinsèque de la modélisation de la subjectivité humaine plutôt qu'un défaut de la méthode.

Difficulté 4 : l'intégration des composants hétérogènes. La combinaison d'un backend Flask avec 28 routes, de quatre modèles ML indépendants, d'un moteur MCDM, d'un module RAG et d'un LLM externe via API a représenté un défi d'architecture important. La solution adoptée — une séparation stricte entre le LLM orchestrateur et le code Python calculateur — a permis de résoudre les problèmes d'hallucinations numériques tout en maintenant une architecture légère et maintenable.

Difficulté 5 : la contrainte temporelle. L'ensemble du projet — collecte, préparation, modélisation, développement de la plateforme et rédaction du rapport — a été réalisé en deux mois. La méthode agile Scrum/XP, avec des sprints hebdomadaires et des rétrospectives régulières, a permis de livrer un système complet et fonctionnel dans ce délai contraint, au prix d'une priorisation rigoureuse des fonctionnalités.

Perspectives et travaux futurs

Les travaux réalisés ouvrent plusieurs perspectives concrètes d'amélioration, d'extension et d'industrialisation, organisées selon trois horizons temporels.

À court terme : consolidation du système.

Le premier axe prioritaire est l'enrichissement du corpus de données réelles. Porter le taux de données authentiques au-delà de 50 % réduirait la dépendance aux données synthétiques et améliorerait la généralisation des modèles, notamment pour les solutions SaaS marocaines sous-représentées dans le corpus actuel. Le déploiement d'un orchestrateur MLOps (MLflow ou DVC) permettrait d'automatiser le réentraînement périodique des modèles et de surveiller la dérive de leurs performances en production, rendant le système autonome dans le temps.

À moyen terme : extension fonctionnelle.

L'adoption d'embeddings denses de type *sentence-transformers* pour le module RAG remplacerait la représentation TF-IDF lexicale actuelle par une recherche sémantique, ce qui améliorerait significativement la pertinence des réponses sur les requêtes formulées avec des synonymes ou des tournures indirectes. L'intégration de mécanismes de feedback utilisateur en temps réel permettrait d'alimenter un cycle d'apprentissage continu, dans lequel les corrections apportées par les utilisateurs améliorent progressivement les recommandations. L'extension du système à d'autres verticales SaaS — RH, CRM, ERP — élargirait considérablement son périmètre d'utilité pour les entreprises marocaines dans le cadre de leur transformation digitale globale.

À long terme : industrialisation et impact national.

Le déploiement sur une infrastructure cloud souveraine marocaine garantirait la conformité aux exigences de la CNDP en matière de localisation des données person-

nelles. L'intégration d'un module de veille automatique permettrait de surveiller en continu les évolutions réglementaires — DGI, CNDP, RGPD — et de mettre à jour la base documentaire RAG sans intervention manuelle. Enfin, l'ouverture d'une API publique à destination des cabinets de conseil, des chambres de commerce et des organismes d'accompagnement des PME transformerait le système en une infrastructure nationale d'intelligence de marché SaaS, en cohérence avec les ambitions de la stratégie *Maroc Digital 2030*.

Ce projet constitue ainsi une première réponse opérationnelle à un enjeu stratégique réel : doter les entreprises marocaines d'outils intelligents, explicables et réglementairement ancrés, pour naviguer dans un marché numérique en mutation permanente.

Bibliographie et Webographie

Les références sont classées par ordre d'apparition dans le texte (norme IEEE).

Ouvrages et articles scientifiques

[1] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[2] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 3rd ed. Sebastopol, CA : O'Reilly Media, 2022.

[3] F. Pedregosa et al., "Scikit-learn : Machine Learning in Python," *Journal of Machine Learning Research (JMLR)*, vol. 12, pp. 2825–2830, 2011.

[4] C. L. Hwang and K. Yoon, *Multiple Attribute Decision Making : Methods and Applications*. Berlin : Springer, 1981.

[5] A. Vaswani et al., "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[6] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.

[7] J. H. Friedman, "Greedy function approximation : a gradient boosting machine," *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.

[8] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.

[9] G. Lemaître, F. Nogueira, and C. K. Aridas, "Imbalanced-learn : A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning," *JMLR*, vol. 18, no. 17, pp. 1–5, 2017.

[10] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.

[11] C. Molnar, *Interpretable Machine Learning : A Guide for Making Black Box Models Explainable*, 2nd ed., 2022. [En ligne]. Disponible sur : https://christophm.github.io/interpretable-ml-book.

[12] S. M. Lundberg and S. I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[13] C. Strobl, A. L. Boulesteix, A. Zeileis, and T. Hothorn, "Bias in random forest variable importance measures," *BMC Bioinformatics*, vol. 8, p. 25, 2007.

[14] F. Doshi-Velez and B. Kim, "Towards a rigorous science of interpretable machine learning," *arXiv preprint arXiv :1702.08608*, 2017.

[15] F. Ricci, L. Rokach, and B. Shapira, *Recommender Systems Handbook*, 2nd ed. New York : Springer, 2015.

[16] S. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework : BM25 and Beyond," *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.

[17] A. E. Hoerl and R. W. Kennard, "Ridge Regression : Biased Estimation for Nonorthogonal Problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970.

[18] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proc. 5th Berkeley Symp. on Math. Statistics and Probability*, vol. 1, pp. 281–297, 1967.

[19] P. J. Rousseeuw, "Silhouettes : a graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.

[20] T. Chen and C. Guestrin, "XGBoost : A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 785–794, 2016.

[21] H. Touvron et al., "LLaMA : Open and Efficient Foundation Language Models," *arXiv preprint arXiv :2302.13971*, 2023.

[22] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *Proc. 14th International Joint Conference on Artificial Intelligence (IJCAI)*, vol. 14, no. 2, pp. 1137–1143, 1995.

[23] D. M. W. Powers, "Evaluation : From Precision, Recall and F-Measure to ROC, Informedness, Markedness & Correlation," *JMLR*, vol. 2, no. 1, pp. 37–63, 2011.

[24] F. Provost and T. Fawcett, *Data Science for Business*. Sebastopol, CA : O'Reilly Media, 2013.

Webographie

[25] Gartner, "Forecast Analysis : Public Cloud Services, Worldwide," *Gartner Research*, 2025. [En ligne]. Disponible sur : https://www.gartner.com. [Consulté le : 01/04/2025].

[26] Statista, "Software as a Service (SaaS) Market Size Worldwide," *Statista*, 2025. [En ligne]. Disponible sur : https://www.statista.com. [Consulté le : 01/04/2025].

[27] Ministère de la Transition Numérique et de la Réforme de l'Administration, "Maroc Digital 2030," Gouvernement du Maroc, 2025. [En ligne]. Disponible sur : https://www.mtnum.gov.ma. [Consulté le : 10/03/2025].

[28] Direction Générale des Impôts (DGI), "Réforme de la facturation électronique au Maroc," DGI Maroc, 2024. [En ligne]. Disponible sur : https://www.tax.gov.ma. [Consulté le : 15/03/2025].

[29] G2, "Software Reviews and Ratings," *G2.com*, 2025. [En ligne]. Disponible sur : https://www.g2.com. [Consulté le : 20/03/2025].

[30] Capterra, "Find the Best Software," *Capterra.com*, 2025. [En ligne]. Disponible sur : https://www.capterra.com. [Consulté le : 20/03/2025].

[31] Trustpilot, "Business Reviews Platform," *Trustpilot.com*, 2025. [En ligne]. Disponible sur : https://www.trustpilot.com. [Consulté le : 20/03/2025].

[32] IBM Cloud, "What is SaaS (Software as a Service) ?" *IBM*, 2025. [En ligne]. Disponible sur : https://www.ibm.com/cloud/learn/saas. [Consulté le : 05/03/2025].

[33] Microsoft Azure, "What is SaaS ?" *Microsoft Azure*, 2025. [En ligne]. Disponible sur : https://azure.microsoft.com/en-us/overview/what-is-saas. [Consulté le : 05/03/2025].

[34] Groq, "LLaMA 3.3 70B API Documentation," *Groq*, 2025. [En ligne]. Disponible sur : https://console.groq.com/docs. [Consulté le : 15/04/2025].

Annexes

Annexe A — Extrait du dataset final (dataset_final.xlsx)

Le tableau ci-dessous présente un extrait des 10 premières observations du fichier `dataset_final.xlsx` utilisé pour l'entraînement des modèles. Le dataset complet contient **1 425 observations** décrites par **31 variables**.

TABLE 3.1 – Extrait du dataset final — 5 premières observations et variables clés

Variable	Obs. 1	Obs. 2	Obs. 3	Obs. 4	Obs. 5
`Classe_prix`	Low	Medium	Enterprise	Free	Low
`prix_min_eur`	9,00	49,00	299,00	0,00	15,00
`segment_taille`	Petite	Moyenne	Grande	Petite	Moyenne
`conforme_e_facture`	Non	Oui	Oui	Non	Non
`niveau_satisfaction`	Bonne	Excellente	Excellente	Moyenne	Bonne
`note_g2`	4,2	4,6	4,8	3,9	4,3
`has_API`	1	1	1	0	1
`a_freemium`	0	0	0	1	0

Annexe B — Résultats complets de la validation croisée

TABLE 3.2 – Synthèse des performances Random Forest — 4 tâches de classification

Tâche	Accuracy	F1-Score	AUC-ROC	CV Accuracy
Classe_prix	98,24 %	98,23 %	0,9997	98,31 %
Conformité e-facture 2026	88,73 %	88,66 %	0,9632	90,14 %
Niveau de satisfaction	77,13 %	77,21 %	0,9292	77,88 %
Segment de taille	90,70 %	90,65 %	0,9858	89,16 %

Annexe C — Architecture technique de la plateforme SaaS Assistant

La plateforme **SaaS Assistant** repose sur les technologies suivantes :

— **Backend** : Python 3.11, Flask (28 routes API REST), joblib (sérialisation des modèles ML), scikit-learn 1.3, pandas, numpy.

— **Frontend** : HTML5/CSS3/JavaScript vanilla, Chart.js 4.4 (visualisations interactives), interface 3 colonnes responsive.

— **Modèles ML** : 4 classificateurs Random Forest indépendants + 1 Random Forest Regressor (régression prix) + 1 Ridge Regressor + clustering K-Means ($k = 4$), tous sérialisés via `joblib`.

— **LLM** : LLaMA 3.3 70B via API Groq (`llama-3.3-70b-versatile`).

— **RAG** : TF-IDF (scikit-learn `TfidfVectorizer`) + similarité cosinus + base de 9 chunks CNDP/RGPD.

— **MCDM** : WSM (Weighted Sum Model) + TOPSIS, implémentés en Python pur.

— **Données** : dataset_final.xlsx (1 425 × 31), généré par GaussianCopula (SDV) + CTGAN, rééquilibré par SMOTE (imbalanced-learn).

Annexe D — Glossaire technique

AUC-ROC

Area Under the Receiver Operating Characteristic Curve — mesure la capacité d'un modèle à discriminer entre les classes. Une valeur de 1,0 indique une discrimination parfaite.

CTGAN

Conditional Tabular GAN — réseau de neurones génératif conditionnel pour la génération de données tabulaires synthétiques.

F1-Score

Moyenne harmonique de la précision et du rappel, particulièrement adapté aux datasets déséquilibrés.

K-Means

Algorithme de clustering non supervisé qui partitionne un ensemble de données en k groupes homogènes en minimisant la variance intra-cluster.

LLM

Large Language Model — modèle de langage de grande taille entraîné sur de vastes corpus textuels.

MCDM

Multi-Criteria Decision Making — ensemble de méthodes pour évaluer et classer des alternatives selon plusieurs critères simultanément.

RAG

Retrieval-Augmented Generation — architecture combinant la recherche de documents pertinents et la génération de texte par un LLM.

Random Forest

Algorithme d'apprentissage ensembliste basé sur la construction de multiples arbres de décision indépendants (*bagging*).

Ridge Regression

Régression linéaire avec régularisation L2 permettant de réduire le surapprentissage sur des données corrélées.

SHAP

SHapley Additive exPlanations — méthode d'explicabilité basée sur la théorie des jeux coopératifs pour attribuer à chaque feature sa contribution à une prédiction.

SMOTE

Synthetic Minority Over-sampling Technique — technique de rééquilibrage qui génère des exemples synthétiques de la classe minoritaire par interpolation.

TOPSIS

Technique for Order of Preference by Similarity to Ideal Solution — algorithme MCDM classant les alternatives selon leur distance à la solution idéale positive et négative.

WSM

Weighted Sum Model — méthode MCDM calculant le score global d'une alternative comme somme pondérée de ses scores par critère.