UNIVERSITÉ ABDELMALEK ESSAÂDI

Faculté des Sciences et Techniques de Tanger

Licence Analytique des Données

RAPPORT DE PROJET DE FIN D'ÉTUDES

Année universitaire 2025 – 2026

Intitulé du projet :

Analyse Intelligente du Marché SaaS

Conception d'un Système d'Aide à la Décision Basé sur l'Intelligence Artificielle

Réalisé par :

Zakariae El Maymouni Fatima Zahrae El Kostit

Numéro d'apogée : 21013847 · 22007336

Encadrant Pédagogique	Encadrant Professionnel
Pr. Sara Ahsain	Mme. Douae El Karoute
FST de Tanger	*KIINOV*

Soutenu devant le jury composé de :

Pr. Badr-Eddine Boudriki Semlali	Président du jury	FST de Tanger
Pr. Sara Ahsain	Encadrante interne	FST de Tanger
Ing. Douae El Karoute	Encadrante externe	KIINOV

Soutenu le : 24 / 06 / 2026

Dédicace

Nous dédions ce travail à nos chers parents pour leur amour, leur soutien indéfectible, leurs sacrifices et leurs encouragements tout au long de notre parcours académique.

À nos familles et à nos proches qui ont toujours cru en nous et nous ont accompagnés dans les moments les plus importants de notre formation.

À nos enseignants de la Faculté des Sciences et Techniques de Tanger qui ont contribué à notre apprentissage et à notre développement personnel et professionnel.

À toutes les personnes qui nous ont soutenus de près ou de loin dans la réalisation de ce projet.

Que ce travail soit le témoignage de notre profonde reconnaissance et de notre sincère gratitude.

Zakariae El Maymouni
Fatima Zahrae El Kostit

Remerciements

Avant tout, nous remercions Allah, le Tout-Puissant, de nous avoir accordé la santé, la force et la persévérance nécessaires pour mener à bien ce travail.

Nous adressons nos sincères remerciements à **Madame la Professeure Sara Ahssain**, notre encadrante pédagogique, pour son accompagnement, sa disponibilité et ses précieux conseils tout au long de ce projet.

Nous remercions également **Madame l'Ingénieure Douae El Karoute**, notre encadrante professionnelle au sein de l'entreprise d'accueil, pour son suivi, son soutien et les connaissances qu'elle nous a transmises durant notre stage.

Nos remerciements vont aussi à **Monsieur le Professeur Abdellah Azmani** pour ses orientations et son accompagnement, ainsi qu'à **Madame la Professeure Wafae Baida**, cheffe de filière, pour son soutien et son engagement au service des étudiants.

Nous remercions également **Madame Amina Jbilou, doctorante**, pour ses encouragements et l'intérêt porté à notre travail.

Nous exprimons notre gratitude à l'ensemble des enseignants du **Département Informatique de la Faculté des Sciences et Techniques de Tanger** pour la qualité de la formation dispensée.

Nos remerciements s'adressent également aux membres du jury qui nous font l'honneur d'évaluer ce mémoire.

Enfin, nous remercions nos familles, nos proches et nos amis pour leur soutien et leurs encouragements tout au long de cette expérience.

À toutes les personnes ayant contribué à la réussite de ce travail, nous adressons nos sincères remerciements.

Résumé

Le marché des logiciels en tant que service (SaaS) connaît une croissance rapide et propose aujourd'hui un grand nombre de solutions destinées à la gestion des activités des entreprises. Face à cette diversité, le choix de la solution la plus adaptée constitue un véritable défi pour les décideurs. Dans ce contexte, ce projet vise à développer une plateforme intelligente dédiée à l'analyse du marché des solutions SaaS de facturation et à l'aide à la décision.

Pour atteindre cet objectif, une base de données regroupant plus de 1 400 solutions SaaS a été constituée. Chaque solution est décrite à travers 31 variables fonctionnelles, techniques et économiques. Une analyse exploratoire des données a été réalisée afin d'identifier les principales tendances du marché ainsi que les caractéristiques les plus influentes.

Par ailleurs, plusieurs modèles de Machine Learning ont été développés : quatre classificateurs supervisés (Random Forest, Gradient Boosting, SVM, KNN) pour prédire la classe de prix, la conformité réglementaire, le segment de taille et le niveau de satisfaction ; une régression multiple pour estimer le prix numérique exact ; et un clustering K-Means pour segmenter automatiquement le marché en groupes homogènes. L'ensemble de ces modèles génère des recommandations adaptées aux besoins des utilisateurs. Une approche basée sur les grands modèles de langage (LLM) et le Retrieval Augmented Generation (RAG) a également été intégrée afin de fournir une assistance conversationnelle intelligente et personnalisée.

Les résultats obtenus démontrent la pertinence de l'approche proposée pour faciliter la sélection des solutions SaaS et mettent en évidence l'apport significatif de l'intelligence artificielle et de l'analytique des données dans les processus d'aide à la décision.

Mots-clés : SaaS, Facturation, Intelligence Artificielle, Machine Learning, Classification, Régression, Clustering, Recommandation, RAG, LLM, Analyse de données.

Abstract

The Software as a Service (SaaS) market has experienced significant growth in recent years, offering a wide range of solutions designed to support business operations. However, the increasing number of available platforms makes the selection of the most suitable solution a complex task for organizations. In this context, this project aims to develop an intelligent platform dedicated to the analysis of the SaaS billing software market and to supporting decision-making processes.

To achieve this objective, a dataset containing more than 1,400 SaaS solutions was built. Each solution is described using 31 functional, technical, and economic variables. An Exploratory Data Analysis (EDA) was conducted to identify market trends, understand the characteristics of the available solutions, and determine the most influential features.

Furthermore, several Machine Learning models were developed : four supervised classifiers to predict pricing class, regulatory compliance, market segment, and satisfaction level ; a multiple regression model to estimate the exact numerical price ; and a K-Means clustering model to segment the market into homogeneous groups. These models collectively generate recommendations based on user requirements. To enhance user interaction, an intelligent conversational assistant was integrated using Large Language Models (LLMs) combined with a Retrieval-Augmented Generation (RAG) approach. This component enables users to obtain personalized guidance and relevant recommendations through natural language queries.

The results demonstrate the effectiveness of the proposed approach in facilitating the selection of SaaS solutions and improving decision-making processes. They also highlight the growing importance of artificial intelligence, data analytics, and recommendation systems in supporting organizations in their digital transformation initiatives.

Keywords : SaaS, Data Analytics, Machine Learning, Classification, Regression, Clustering, Recommendation Systems, Artificial Intelligence.

Table des matières

Dédicace 1

Remerciements 2

Résumé 3

Abstract 4

Lexique et Acronymes 11

INTRODUCTION GÉNÉRALE 12

0.1 Présentation de l'entreprise d'accueil . . . 12

0.1.1 Fiche d'identité et positionnement sectoriel . . . 12

0.1.2 Département d'accueil et organisation du travail . . . 12

0.1.3 Contexte de la mission dans la stratégie de l'entreprise . . . 13

1 Étude préalable 18

1.1 Introduction . . . 18

1.2 Présentation du projet . . . 19

1.2.1 Qu'est-ce que l'analyse intelligente du marché SaaS ? (Quoi ?) . 19

1.2.2 Notions fondamentales . . . 19

1.2.3 Intérêt du projet (Pourquoi ?) . . . 20

1.2.4 À qui s'adresse ce projet ? (Pour qui ?) . . . 20

1.2.5 Problématiques et enjeux . . . 21

1.2.6 Arbre à problèmes . . . 21

1.2.7 Arbre à solutions . . . 22

1.2.8 Objectifs et résultats . . . 23

1.2.9 Activités nécessaires . . . 24

1.2.10 Contrôle et suivi des travaux . . . 24

1.3 Veilles concurrentielle et technologique . . . 24

1.3.1 Veille concurrentielle . . . 24

1.3.2 Veille technologique . . . 26

1.4 Éléments du Cahier des charges — Spécifications fonctionnelles 28
1.5 Maquettage 30
1.6 Conclusion 30

2 Modélisation par intelligence artificielle 31
2.1 Introduction 31
2.2 Objectifs recherchés en matière d'apprentissage 32
2.2.1 Diagnostique 32
2.2.2 Prédiction 33
2.2.3 Décision 34
2.3 Action orientée Science des données 35
2.3.1 Identification des paramètres 35
2.3.2 Description et rôle des variables du dataset 36
2.3.3 Mise en évidence des champs de variation 39
2.3.4 Mise en évidence des règles spécifiques 39
2.4 Préparation des données 39
2.4.1 Pipeline de Données 40
2.4.2 Justification de l'Augmentation de Données 41
2.5 Traitement des données 42
2.5.1 Classification 1 — Classe de prix (`Classe_prix`) 42
2.5.2 Classification 2 — Conformité e-facture 2026 43
2.5.3 Classification 3 — Niveau de satisfaction 44
2.5.4 Classification 4 — Segment de taille 45
2.6 Prédictions complémentaires : Régression Multiple et Clustering K-Means 56
2.6.1 Régression — Prédiction du Prix (`prix_min_eur`) 56
2.6.2 Clustering K-Means — Segmentation du Marché SaaS 58
2.7 Optimisation 62
2.8 Conclusion 65

3 Création et intégration de modèles d'apprentissage 66
3.1 Introduction 66
3.2 Création d'un modèle Multi Model Forecast 66
3.2.1 Dataset 67
3.2.2 Machine Learning 67
3.2.3 Deep Learning — Intégration LLM 68
3.2.4 Optimisation 69
3.2.5 RAG — Génération Augmentée par Récupération 70
3.2.6 Architecture Agentique — Séparation LLM/Calcul 70
3.2.7 Explicabilité des modèles 71
3.3 Présentation et démonstration de l'assistant conversationnel 72

3.3.1 Interface d'accueil 72
3.3.2 Recommandation personnalisée pour une PME 72
3.3.3 Prévision de classe de prix 73
3.3.4 Comparaison multicritère de solutions 73
3.3.5 Exploitation du module RAG 73
3.4 Conclusion 74

Conclusion Générale et Perspectives **76**
Bilan du projet 76
Difficultés rencontrées 77

Bibliographie et Webographie **78**
Ouvrages et articles scientifiques 78
Webographie 78

Annexes **80**
Annexe A — Extrait du dataset final 80
Annexe B — Validation croisée 80
Annexe C — Architecture technique 80
Annexe D — Glossaire technique 81

Table des figures

1 Diagramme de Gantt du projet — Analyse Intelligente du Marché SaaS 16

1.1 Architecture fonctionnelle de la plateforme intelligente de recommandation des solutions SaaS de facturation électronique 20
1.2 Arbre à problèmes lié à l'adoption des solutions SaaS 22
1.3 Arbre à solutions pour l'adoption des solutions SaaS 23

2.1 Distribution de la variable Classe_prix 32
2.2 Distribution de la Conformité e-facture 2026 33
2.3 Distribution du Niveau de satisfaction 33
2.4 Distribution du Segment de taille 33
2.5 Matrice de corrélation des variables du dataset 36
2.6 Comparaison des modèles — Classe_prix 42
2.7 Importance des variables — Classe_prix 43
2.8 Matrices de confusion — Classe_prix 43
2.9 Courbes ROC — Classe_prix 44
2.10 Tableau comparatif des modèles — Classe_prix 44
2.11 Validation croisée — Classe_prix 45
2.12 Rapport de classification — Classe_prix 45
2.13 Comparaison des modèles — Conformité e-facture 46
2.14 Importance des variables — Conformité e-facture 46
2.15 Matrices de confusion — Conformité e-facture 47
2.16 Courbe ROC — Conformité e-facture 47
2.17 Tableau comparatif des modèles — Conformité e-facture 48
2.18 Validation croisée — Conformité e-facture 48
2.19 Rapport de classification — Conformité e-facture 48
2.20 Comparaison des modèles — Niveau de satisfaction 49
2.21 Importance des variables — Niveau de satisfaction 50
2.22 Matrices de confusion — Niveau de satisfaction 50
2.23 Courbes ROC — Niveau de satisfaction 51
2.24 Tableau comparatif des modèles — Niveau de satisfaction 51
2.25 Validation croisée — Niveau de satisfaction 52

2.26 Rapport de classification — Niveau de satisfaction 52
2.27 Comparaison des modèles — Segment de taille 52
2.28 Importance des variables — Segment de taille 53
2.29 Matrices de confusion — Segment de taille 53
2.30 Courbes ROC — Segment de taille 54
2.31 Tableau comparatif des modèles — Segment de taille 54
2.32 Validation croisée — Segment de taille 55
2.33 Rapport de classification — Segment de taille 55
2.34 Distribution de `prix_min_eur` (brute et log1p) 58
2.35 Comparaison Ridge vs Random Forest (R^2 et RMSE) 58
2.36 Importance des features — Régression (Gini, Random Forest) 59
2.37 Valeurs réelles vs prédites et analyse des résidus 59
2.38 Scores R^2 par fold (validation croisée 5 plis) 60
2.39 Distribution des 4 segments K-Means (effectifs et pourcentages) 61
2.40 Projection PCA 2D des clusters avec centroides 61
2.41 Méthode du coude — inertie vs k 62
2.42 Score de silhouette moyen pour $k = 2$ à 10 62
2.43 Heatmap des profils moyens par cluster (valeurs réelles annotées) 62
2.44 Radar chart comparatif des 4 segments 63
2.45 Correspondance entre les segments K-Means et la variable `segment_taille` 63

3.1 Architecture globale du système SaaS Assistant 67
3.2 Interface d'accueil de l'assistant conversationnel SaaS Assistant 72
3.3 Recommandation personnalisée pour une PME marocaine (budget < 50 EUR/mois) 73
3.4 Prévision de la classe de prix d'une solution SaaS via le classifieur Random Forest 74
3.5 Comparaison multicritère de trois solutions de facturation SaaS 74
3.6 Réponse du module RAG sur les obligations de facturation électronique 2026 75

Liste des tableaux

1.1 Comparaison des principales solutions SaaS de facturation 26
1.2 Stack technologique du système SaaS Assistant 27
1.3 Spécifications fonctionnelles du système SaaS Assistant 29

2.1 Description des variables du dataset SaaS 37
2.2 Rééquilibrage SMOTE des variables cibles 39
2.3 Résultats — Classification de la Classe de prix 42
2.4 Résultats — Classification de la Conformité e-facture 2026 45
2.5 Résultats — Classification du Niveau de satisfaction 49
2.6 Résultats — Classification du Segment de taille 49

3.1 Extrait du dataset final (variables clés) 80
3.2 Performances Random Forest sur 4 tâches 80

LISTE DES ABRÉVIATIONS

AD Analytique des Données

API Application Programming Interface

BI Business Intelligence

CRM Customer Relationship Management

CSV Comma-Separated Values

CTGAN Conditional Tabular Generative Adversarial Network

IA Intelligence Artificielle

ML Machine Learning

MCDM Multi-Criteria Decision Making

PDP Plateforme de Dématérialisation Partenaire

PFE Projet de Fin d'Études

PME Petites et Moyennes Entreprises

RAG Retrieval-Augmented Generation

RF Random Forest

RGPD Règlement Général sur la Protection des Données

SaaS Software as a Service

SMOTE Synthetic Minority Over-sampling Technique

SQL Structured Query Language

SVM Support Vector Machine

TOPSIS Technique for Order of Preference by Similarity to Ideal Solution

UX User Experience

INTRODUCTION GÉNÉRALE

Contexte général

La transformation numérique a profondément changé le fonctionnement des entreprises. Parmi les innovations majeures figure le modèle *Software as a Service (SaaS)*, qui permet d'accéder à des applications hébergées dans le cloud sans infrastructure complexe. Les solutions SaaS couvrent aujourd'hui divers domaines tels que la comptabilité, la relation client, les ressources humaines et la facturation.

La diversité des milliers de solutions disponibles rend le choix difficile. Dans ce contexte, l'usage de l'Analytique des Données, du Machine Learning et de l'Intelligence Artificielle constitue une approche pertinente pour analyser le marché et guider la décision.

Ce projet de fin d'études, réalisé en collaboration avec l'entreprise KIINOV, vise à concevoir une plateforme intelligente dédiée à l'analyse, la classification et la recommandation des solutions SaaS de facturation.

0.1 Présentation de l'entreprise d'accueil

0.1.1 Fiche d'identité et positionnement sectoriel

Notre projet s'est déroulé au sein de **KIINOV**, une entreprise marocaine spécialisée dans les **NTIC** et l'ingénierie des systèmes. Configurée en **SARL** au capital de 10 000 DHS, son siège est basé à Tanger. KIINOV se positionne aujourd'hui comme un **acteur de la transformation digitale**, intégrant l'**IA** et le **Big Data**.

0.1.2 Département d'accueil et organisation du travail

Nous avons été intégrés au **Pôle Data Science**, sous la supervision du Chef de projet Data. La collaboration avec l'équipe Ingénierie a permis de concevoir l'architecture de collecte (ETL) et de structurer une **base de connaissances robuste** pour alimenter le système de classification et de recommandation des solutions SaaS.

0.1.3 Contexte de la mission dans la stratégie de l'entreprise

Ce projet s'inscrit dans la stratégie de KIINOV visant à renforcer son expertise en **analyse intelligente des marchés numériques**. L'objectif était de développer une solution centralisée pour analyser les offres SaaS de facturation et générer des recommandations adaptées, notamment dans le cadre de la réforme de la **facturation électronique 2026**. Le défi principal concernait l'hétérogénéité des données. Le pipeline mis en place permet de **nettoyer, consolider et enrichir** ces flux afin d'extraire des indicateurs exploitables. La solution développée améliore la **réactivité commerciale** et optimise les choix d'investissement, grâce à une **interface conversationnelle** facilitant l'accès aux analyses.

Problématique

Le marché des logiciels SaaS de facturation connaît une croissance rapide et propose une grande diversité de solutions. Les entreprises peinent toutefois à identifier celle qui correspond le mieux à leurs contraintes fonctionnelles, techniques et budgétaires.

Les comparaisons manuelles restent longues, subjectives et limitées, tandis que les informations sont dispersées sur plusieurs plateformes, rendant l'évaluation objective difficile.

La problématique de ce projet peut ainsi être formulée comme suit :

> **Comment utiliser l'analytique des données et l'intelligence artificielle pour analyser le marché des solutions SaaS de facturation et recommander celles les plus adaptées aux besoins des utilisateurs ?**

Objectifs du projet

L'objectif principal est de développer une **plateforme intelligente** d'analyse, de classification et de recommandation des solutions SaaS de facturation.

Les objectifs spécifiques sont :

- Constituer une base de données de plus de 1400 solutions SaaS.
- Structurer les variables fonctionnelles, techniques et économiques pertinentes.
- Réaliser une analyse exploratoire pour dégager les tendances du marché.
- Développer des modèles de **Machine Learning** pour classifier automatiquement les solutions.
- Concevoir un système de recommandation adapté aux besoins des utilisateurs.
- Intégrer un assistant conversationnel basé sur les technologies **LLM** et **RAG**.

— Évaluer les performances des modèles et la pertinence des recommandations.

Structure du rapport

Le rapport est organisé en quatre chapitres :

— **Chapitre 1** : Contexte général, marché SaaS et concepts liés à l'analytique des données, au Machine Learning et aux systèmes de recommandation.

— **Chapitre 2** : Collecte, construction et préparation du jeu de données, avec analyse exploratoire.

— **Chapitre 3** : Développement des modèles de classification, du système de recommandation et intégration des technologies **LLM** et **RAG**.

— **Chapitre 4** : Implémentation de la plateforme, résultats expérimentaux et évaluation des performances.

Enfin, une conclusion générale synthétise les résultats, souligne les contributions et propose des perspectives d'amélioration.

Organisation du projet

Le projet *Analyse intelligente du marché SaaS* a été réalisé dans le cadre d'un stage de fin d'études de deux mois. L'organisation reposait sur trois rôles principaux :

— un ingénieur stagiaire chargé du développement et de la modélisation,

— un encadrant académique garant de la rigueur scientifique,

— un encadrant professionnel responsable de l'orientation fonctionnelle et de la validation.

Cette structure a permis de combiner un suivi académique et professionnel à chaque étape. Le projet a été découpé en quatre phases :

1. étude préalable et veille concurrentielle,
2. modélisation par intelligence artificielle,
3. création et intégration des modèles,
4. implémentation de la plateforme.

La contrainte de deux mois a imposé une gestion stricte des priorités et la parallélisation de certaines tâches.

Méthode de conduite de projet (Scrum et XP)

Le projet a suivi une démarche agile combinant **Scrum** et **Extreme Programming (XP)** sur deux mois.

Scrum a organisé le travail en sprints hebdomadaires avec backlog défini, points de suivi, démonstrations et rétrospectives. XP a renforcé l'approche par des pratiques techniques : refactoring continu (28 routes Flask, 65 fonctions JS), tests rapides (validation croisée 5 folds, holdout 20%), cycles courts d'intégration et conception simple (Flask léger, JavaScript vanilla).

Cette combinaison a permis de livrer un système fonctionnel et évalué dans les délais impartis.

Équipe du projet

EL KOSTIT Fatima Zahrae & EL MAYMOUNI Zakariae — Stagiaires Nous avons assuré les principales phases du projet : collecte et préparation des données, entraînement et évaluation des modèles de Machine Learning, développement du backend et des API, conception de l'interface web et intégration des composants IA (LLM, RAG, MCDM).

Mme Sara Ahsain — Encadrante académique Responsable du suivi scientifique et méthodologique, elle a validé les choix et accompagné la rédaction du rapport.

Dr. Douae El Karoute — Encadrante professionnelle Elle a orienté le projet sur le plan fonctionnel, apporté son expertise en intelligence artificielle et validé les résultats expérimentaux.

Planning du projet (Diagramme de Gantt)

Le projet a été conduit sur une durée de **8 semaines** (2 mois), du 1er avril au 24 juin 2026, organisées en quatre grandes phases correspondant aux chapitres du rapport.



FIGURE 0.1 – Diagramme de Gantt du projet — Analyse Intelligente du Marché SaaS

Bilan en fin de stage

Ce stage de deux mois a permis d'atteindre les objectifs fixés. La plateforme **SaaS Assistant** intègre des modèles de **Machine Learning**, un **LLM**, un système **MCDM** et un module **RAG**, accessibles via une architecture API et une interface web.

Les résultats sont satisfaisants : précision de 98,24% et AUC-ROC de 0,9997 pour la prédiction tarifaire, 88,73% pour la conformité réglementaire, et classements cohérents générés par le MCDM. Le stage a renforcé nos compétences en data science et technologies (Flask, Chart.js, LLaMA, systèmes de recommandation).

Limites identifiées :

— recours important aux données synthétiques,

— performances modestes sur la satisfaction utilisateur,

— absence d'automatisation complète du réentraînement.

Des améliorations sont envisageables : intégration d'une solution **MLOps**, enrichissement du corpus et exploration d'algorithmes avancés (XGBoost, LightGBM).

Fonctionnalités de la plateforme

La plateforme propose deux espaces : **Mode Acheteur** (PME) et **Mode Créateur** (startups). Parmi les fonctionnalités principales :

— **Assistant conversationnel (LLM)** multilingue,

— **Module ML** de prédiction (prix, conformité, satisfaction),

— **Système MCDM** (WSM/TOPSIS),

— **Module RAG** pour la conformité réglementaire,

— **Audit SaaS** et **simulateur financier ROI/TCO**,

— outils stratégiques pour le **Mode Créateur**,

— **gouvernance et sécurité** des données et modèles.

Conclusion

Ce projet démontre la faisabilité d'une **architecture hybride neuro-symbolique** (ML + LLM + MCDM) appliquée au marché SaaS marocain. Les performances valident l'approche (F1-Score 98,23% sur la prédiction tarifaire, 77,21% sur la satisfaction). L'intégration du module RAG apporte une valeur immédiate face à la réforme de la **facturation électronique 2026**.

Perspectives :

— enrichissement du corpus,

— automatisation via **MLOps**,

— déploiement sur cloud souverain,

— extension à d'autres verticales SaaS (RH, CRM, ERP).

Ce projet constitue une base solide pour une **plateforme nationale d'intelligence de marché SaaS**, en cohérence avec la stratégie *Maroc Digital 2030*.

Chapitre 1

Étude préalable

1.1 Introduction

La transformation numérique a profondément modifié le fonctionnement des entreprises. Parmi les nouveaux modèles, le **Software as a Service (SaaS)** s'est imposé comme une solution flexible et économique, accessible via Internet et basée sur un système d'abonnement.

Le marché mondial du SaaS connaît une croissance soutenue, portée par la digitalisation et l'intégration de l'IA. Au Maroc, la stratégie **Maroc Digital 2030** favorise l'adoption des technologies numériques, mais des défis persistent : coûts élevés, manque de compétences, sécurité des données et domination des plateformes étrangères. Ces enjeux soulignent la nécessité d'analyser le marché SaaS marocain et d'adapter les solutions aux besoins locaux.

Dans ce contexte, notre projet « **Analyse intelligente du marché SaaS** » vise à étudier les solutions de facturation, identifier les besoins des entreprises, évaluer les tendances et proposer une vision stratégique adaptée au marché national.

Vue d'ensemble du pipeline IA

Le pipeline comporte cinq étapes séquentielles :

1. **Collecte des données** : web scraping (G2, Capterra, Trustpilot) et corpus JSON manuel (239 observations, 31 variables).
2. **Préparation et augmentation** : imputation des valeurs manquantes, audit de fuite, génération synthétique (GaussianCopula, CTGAN) et rééquilibrage SMOTE.
3. **Entraînement et sélection** : classification sur 4 tâches avec 7 algorithmes (Random Forest, SVM, etc.), validation croisée 5 folds, F1-Score moyen 98,31%.
4. **Évaluation et explicabilité** : test holdout 20%, métriques (Accuracy, Recall, F1, AUC-ROC), importance des features (Gini, SHAP).

5. **Recommandation** : intégration des prédictions dans un moteur MCDM(WSM/TOPSIS), pondérations définies par l'utilisateur, module **RAG** pour conformité réglementaire, exposition via API Flask et interface web interactive.

1.2 Présentation du projet

1.2.1 Qu'est-ce que l'analyse intelligente du marché SaaS ? (Quoi ?)

L'analyse intelligente du marché SaaS consiste à collecter et interpréter des données sur les plateformes **Software as a Service** afin de comprendre les dynamiques du marché, les besoins des utilisateurs et les tendances technologiques. Avec l'essor du cloud computing, ces données permettent d'évaluer les comportements, modèles économiques et opportunités de développement.

Notre projet se concentre sur les solutions de **facturation SaaS** au Maroc, en étudiant des critères tels que fonctionnalités, coûts, sécurité, accessibilité, expérience utilisateur et conformité réglementaire.

L'objectif est de fournir une vision claire et stratégique du marché marocain pour aider les PME et startups à identifier les solutions adaptées. Pour cela, le projet mobilise des techniques avancées d'**IA**, de **Machine Learning supervisé** et d'**aide multicritère (MCDM)**, transformant un corpus de plus de 1 425 solutions en recommandations personnalisées.

1.2.2 Notions fondamentales

Le **Software as a Service (SaaS)** est un modèle majeur du cloud computing : les applications sont hébergées sur des serveurs distants et accessibles par abonnement, offrant flexibilité, scalabilité et réduction des coûts. Il est largement utilisé dans la finance, la santé, l'éducation, le commerce et la facturation électronique.

Le SaaS s'inscrit dans une hiérarchie avec l'**IaaS** (infrastructure virtualisée) et le **PaaS** (environnement de développement). Il représente le niveau d'abstraction le plus élevé, simplifiant l'usage des technologies cloud.

L'évolution des plateformes SaaS intègre désormais l'**IA** et l'analytique des données : détection de tendances, automatisation et personnalisation des services. Dans notre projet, des modèles supervisés (Random Forest, Gradient Boosting, SVM), une **régression multiple** et un **clustering K-Means** sont mobilisés pour prédire prix, conformité et satisfaction, puis exploités via des méthodes multicritères (**WSM**, **TOPSIS**) pour recommander les solutions.

Un module **RAG** couplé à un **LLM** facilite l'accès aux informations réglementaires, enrichi par des techniques de **NLP** comme le **NLU** et la **NER**. L'explicabilité est assurée par des méthodes **SHAP-like**, tandis que des données synthétiques générées

par **CTGAN** sont évaluées via la distance de **Wasserstein**. Enfin, la détection du **Data Drift** garantit la pertinence continue des modèles.

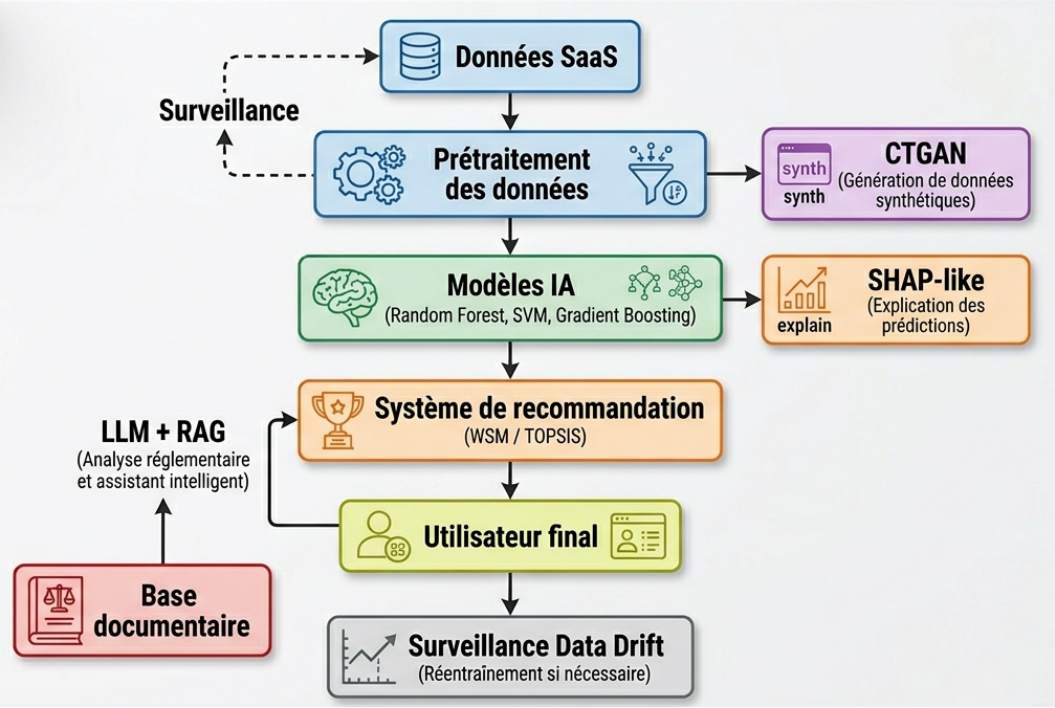


FIGURE 1.1 – Architecture fonctionnelle de la plateforme intelligente de recommandation des solutions SaaS de facturation électronique

1.2.3 Intérêt du projet (Pourquoi ?)

Ce projet présente des intérêts multiples :

— **Économique** : réduction des coûts d'infrastructure et de maintenance, automatisation des tâches administratives et financières, amélioration de la productivité.

— **Technologique** : promotion de la transformation digitale et adoption des solutions cloud, intégration de l'**IA** dans l'analyse des marchés numériques.

— **Stratégique** : compréhension des besoins des entreprises marocaines, identification des opportunités d'investissement, analyse des enjeux de souveraineté numérique et de conformité à la réforme de la **facturation électronique 2026**.

— **Académique** : application des connaissances en systèmes d'information, cloud computing, intelligence artificielle, apprentissage automatique et analyse des données.

1.2.4 À qui s'adresse ce projet ? (Pour qui ?)

Ce projet cible plusieurs acteurs de la transformation digitale au Maroc :

— **PME marocaines** : représentant plus de 95 % du tissu économique, elles recherchent des solutions numériques pour optimiser leur gestion et réduire les coûts.

— **Startups technologiques** : besoin d'outils performants pour gérer leurs activités, évaluer leur positionnement et affiner leur stratégie de mise sur le marché.

— **Cabinets de comptabilité et professionnels financiers** : bénéficient d'outils adaptés pour la gestion et l'audit.

— **Développeurs et éditeurs SaaS** : compréhension des besoins locaux et adaptation des solutions.

— **Décideurs publics et chercheurs** : contribution à la stratégie **Maroc Digital 2030**, en lien avec souveraineté numérique et modernisation des entreprises.

1.2.5 Problématiques et enjeux

Le marché des solutions SaaS connaît une expansion mondiale soutenue, portée par la transformation digitale et l'essor des technologies cloud. Au Maroc, cette dynamique s'accompagne d'un intérêt croissant des entreprises pour les solutions numériques, mais demeure freinée par plusieurs obstacles, notamment dans le domaine de la facturation électronique.

La complexité du choix des plateformes adaptées constitue une difficulté majeure : la diversité des offres, leurs coûts et modèles économiques rendent la sélection particulièrement délicate pour les PME et startups, souvent dépourvues d'informations fiables sur la performance, la sécurité et la conformité des solutions. Par ailleurs, la question de la **sécurité et de la souveraineté des données** reste centrale, les entreprises manifestant une réticence à externaliser leurs données financières sur des serveurs distants, dominés par des acteurs internationaux.

Dans ce contexte, trois enjeux stratégiques se dessinent : (i) accompagner la transformation digitale des entreprises marocaines par des solutions SaaS adaptées et sécurisées, (ii) renforcer la compétitivité des PME grâce à l'automatisation des processus, (iii) préparer les organisations à la réforme imminente de la **facturation électronique 2026**, qui impose de nouvelles exigences réglementaires.

1.2.6 Arbre à problèmes

Le principal problème identifié dans cette étude réside dans la difficulté d'adoption et de sélection des solutions **SaaS de facturation** au Maroc. Bien que les technologies cloud offrent des avantages indéniables en termes de flexibilité et de réduction des coûts, de nombreuses entreprises hésitent encore à les intégrer dans leurs pratiques quotidiennes. Cette réticence s'explique par plusieurs facteurs : manque de visibilité

sur les plateformes disponibles, coûts d'abonnement jugés élevés pour les petites structures, déficit de confiance envers le cloud, faible maturité numérique dans certaines organisations, ainsi que l'absence d'outils intelligents permettant une analyse et une comparaison rigoureuse des solutions existantes.

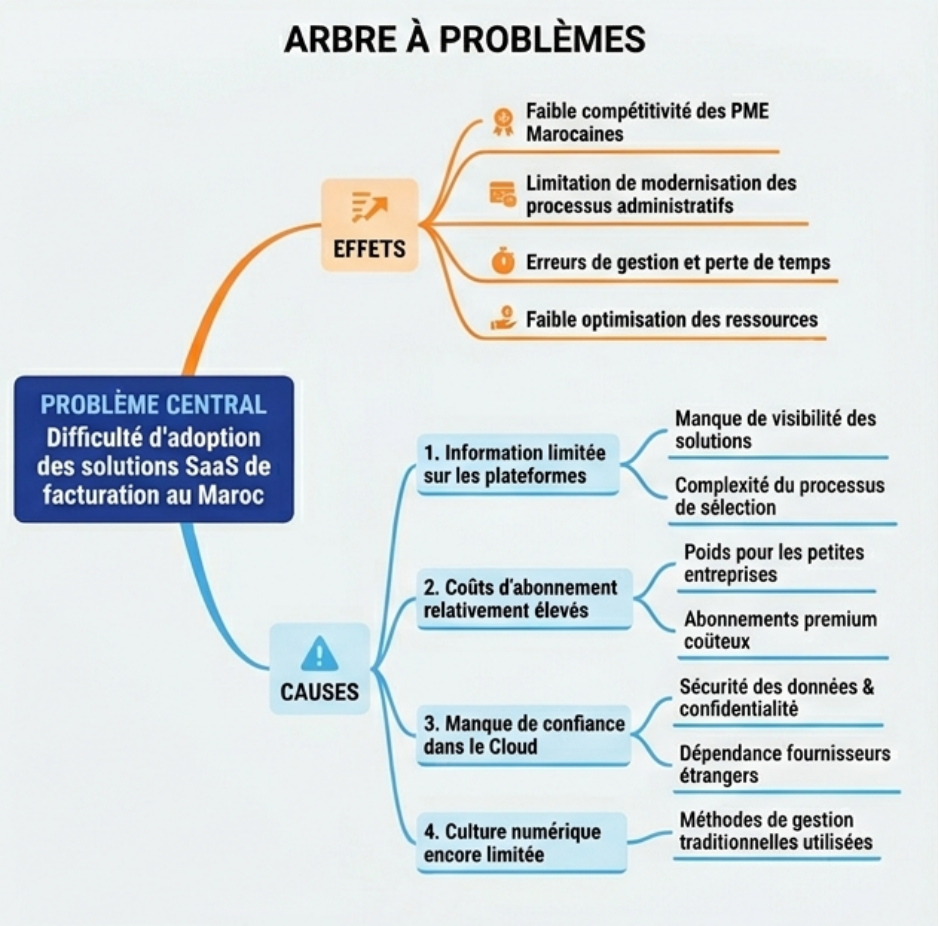


FIGURE 1.2 – Arbre à problèmes lié à l'adoption des solutions SaaS

1.2.7 Arbre à solutions

Afin de répondre aux problématiques identifiées, ce projet propose une **analyse intelligente du marché SaaS de facturation au Maroc**. L'objectif est d'offrir aux entreprises une meilleure visibilité sur les plateformes disponibles et de faciliter la prise de décision grâce à une centralisation des informations et une comparaison structurée des fonctionnalités, coûts, performances et sécurité. En mobilisant des techniques avancées d'**IA** et d'**analyse de données**, le projet vise à identifier les tendances du marché, mettre en évidence les opportunités de développement et accompagner la transformation digitale des entreprises marocaines dans un contexte réglementaire en évolution.

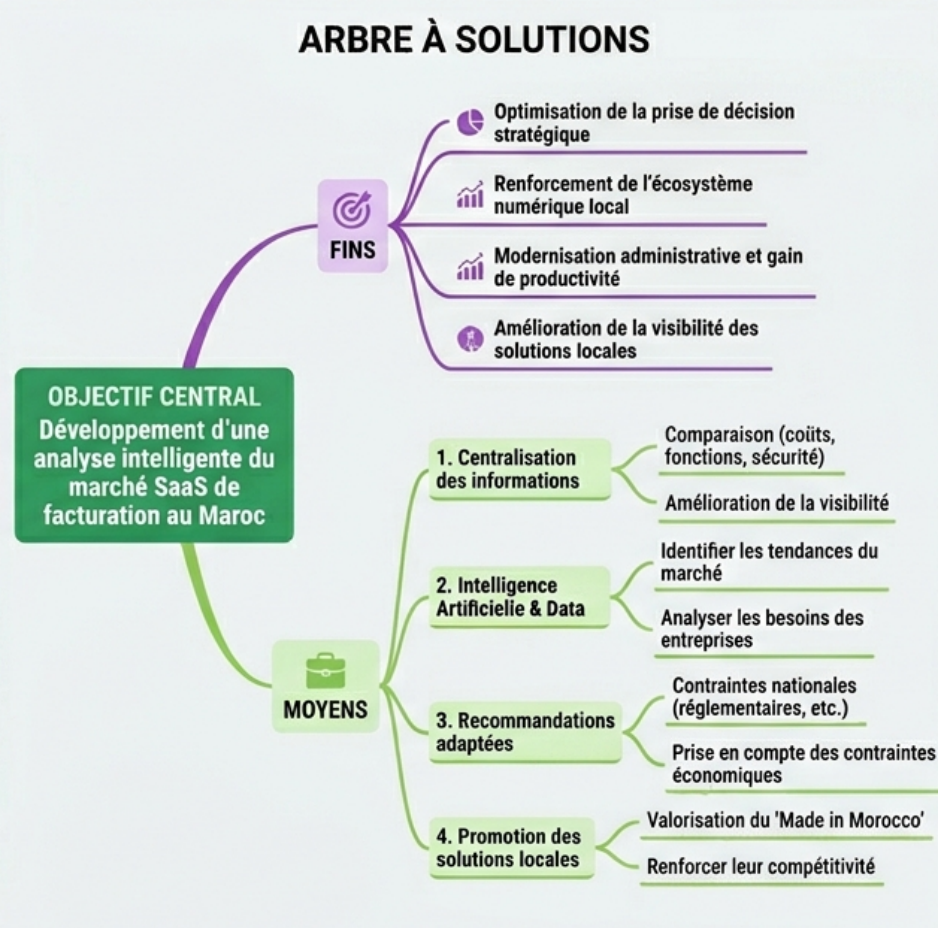


FIGURE 1.3 – Arbre à solutions pour l'adoption des solutions SaaS

1.2.8 Objectifs et résultats

L'objectif principal de ce projet est d'analyser le marché des solutions **SaaS de facturation au Maroc** afin de comprendre son fonctionnement, ses tendances et ses opportunités, tout en identifiant les besoins des entreprises locales et en intégrant des approches de prédiction et d'optimisation.

Le projet vise à comparer les plateformes existantes selon plusieurs critères (fonctionnalités, coûts, accessibilité, sécurité, expérience utilisateur) et à étudier l'impact des nouvelles technologies, notamment l'**IA** et le **Cloud Computing**, sur l'évolution du marché.

Résultats attendus

Les résultats attendus incluent :

— un **tableau comparatif détaillé** des principales plateformes SaaS adaptées au contexte marocain,

— des **modèles de prédiction** pour anticiper l'évolution du marché et les besoins futurs,

— des mécanismes d'**optimisation** pour améliorer la sélection des solutions, réduire les coûts et recommander les plateformes les plus pertinentes.

1.2.9 Activités nécessaires

La réalisation du projet a mobilisé plusieurs activités essentielles. Une **recherche documentaire approfondie** a été menée à partir d'articles scientifiques, rapports économiques et publications spécialisées. Une **étude du marché SaaS** a ensuite permis d'identifier et d'analyser des plateformes de facturation internationales et nationales (Zoho Invoice, QuickBooks, Odoo, Stripe Billing, FreshBooks), selon des critères précis : popularité, richesse fonctionnelle, accessibilité linguistique, modèle économique, sécurité et innovation. Le projet a également impliqué une **collecte et analyse de données** sur les besoins des entreprises marocaines, complétée par une **veille concurrentielle et technologique** pour anticiper les tendances futures.

1.2.10 Contrôle et suivi des travaux

Le suivi du projet a assuré le bon déroulement des activités grâce à des réunions périodiques avec l'encadrant, permettant d'évaluer les progrès et d'apporter des ajustements. Une **évaluation régulière** a garanti la qualité des analyses (collecte des données, étude comparative, conception des maquettes). Enfin, le respect du **planning du stage** a constitué un élément clé pour maintenir la cohérence et l'efficacité du projet.

1.3 Veilles concurrentielle et technologique

1.3.1 Veille concurrentielle

La veille concurrentielle est un processus stratégique de collecte et d'analyse des informations sur les concurrents afin de comprendre leur positionnement, leurs services et leurs innovations. Dans le domaine des solutions **SaaS de facturation**, elle permet d'identifier les tendances du marché, d'anticiper les évolutions technologiques et d'améliorer la compétitivité des entreprises.

Dans ce projet, l'étude a porté sur les principales plateformes internationales et nationales. **Zoho Invoice** et **QuickBooks** offrent des outils complets de gestion financière adaptés aux petites structures. **FreshBooks**, **Stripe Billing**, **Odoo**, **Sage** et **Xero** occupent également une place importante : Odoo se distingue par son modèle ERP open source, tandis que Stripe Billing est spécialisé dans la gestion des abonnements et paiements en ligne.

Cette analyse révèle que, malgré leurs fonctionnalités avancées, ces solutions présentent des limites pour le contexte marocain : coûts élevés pour les PME, absence d'intégration avec les **Plateformes de Dématérialisation Partenaires (PDP)** exigées par la réforme de la **facturation électronique 2026**, et inadéquation avec le cadre réglementaire de la **DGI**.

Tableau comparatif des solutions concurrentes

Cette analyse comparative montre que, malgré leurs fonctionnalités avancées, les solutions internationales présentent des limites majeures dans le contexte marocain : **coûts élevés** peu adaptés aux PME locales, **absence d'intégration avec les Plateformes de Dématérialisation Partenaires (PDP)** exigées par la réforme de la facturation électronique 2026, et **inadéquation avec le cadre réglementaire** de la Direction Générale des Impôts (DGI).

TABLE 1.1 – Comparaison des principales solutions SaaS de facturation

Solution	**Fonctionnalités principales**	**Avantages**	**Inconvénients**
Zoho Invoice	Facturation, gestion clients, paiements en ligne, devis automatisés	Interface simple, plan gratuit disponible, adapté aux PME	Fonctionnalités avancées limitées en version gratuite
QuickBooks	Comptabilité complète, suivi des dépenses, rapports financiers détaillés	Solution très complète et populaire, nombreuses intégrations	Coût relativement élevé, complexe pour les débutants
Odoo	ERP intégré, CRM, comptabilité, facturation, gestion inventaire	Très flexible, open source, hautement personnalisable	Configuration complexe, nécessite une expertise technique
FreshBooks	Facturation automatisée, suivi des dépenses, rapports simples	Très facile à utiliser, idéal pour freelances et PME	Fonctionnalités avancées payantes, tarification élevée
Stripe Billing	Gestion des abonnements, paiements récurrents, API puissante	API robuste, excellente automatisation des paiements en ligne	Nécessite des compétences techniques avancées
Xero	Comptabilité cloud, rapports financiers, gestion multi-devises	Bonne expérience utilisateur, solide pour comptabilité pro	Prix élevé pour certaines options avancées

1.3.2 Veille technologique

La veille technologique consiste à surveiller les évolutions scientifiques et numériques afin d'identifier les innovations utiles aux projets SaaS. Elle permet d'anticiper les tendances du cloud computing, de l'intelligence artificielle, de la cybersécurité et du développement web, et d'intégrer des solutions adaptées aux besoins des utilisateurs.

Dans ce projet, elle a guidé le choix des technologies clés : **Flask/Python** pour le backend, **scikit-learn** pour le machine learning, **Groq (LLaMA 3.3 70B)** pour le

LLM, **TF-IDF** pour le RAG, **WSM** et **TOPSIS** pour le MCDM, ainsi que **Chart.js** pour la visualisation.

TABLE 1.2 – Stack technologique du système SaaS Assistant

Couche	**Technologie**	**Usage**
Backend	Flask (Python)	API REST, gestion des données
LLM	Groq (LLaMA 3.3 70B)	Chatbot intelligent, génération de texte
Machine Learning	scikit-learn	Classification et analyse prédictive
MCDM	Python natif	Décision multicritère (WSM, TOPSIS)
RAG	TF-IDF + Groq	Recherche augmentée, conformité RGPD
Frontend	HTML/CSS/JS + Chart.js	Interface web et visualisations
Base de données	SQLite	Stockage historique et logs

Responsabilités distinctes de chaque technologie

Chaque technologie du système joue un rôle spécifique et complémentaire, sans chevauchement.

Random Forest (RF) Algorithme central de classification supervisée, utilisé pour prédire les quatre variables cibles (prix, segment, conformité e-facture, satisfaction). Avantage : robustesse et transparence via importance des features. Limite : produit uniquement des étiquettes probabilistes, sans raisonnement métier.

SMOTE Technique de rééquilibrage appliquée aux données d'entraînement pour corriger le déséquilibre des classes. Avantage : évite la domination des classes majoritaires. Limite : n'est jamais appliqué aux données de test ni en production.

CTGAN et GaussianCopula Générateurs de données synthétiques pour augmenter le dataset initial. Avantage : diversité statistique et meilleure représentativité. Limite : utilisés uniquement en phase de préparation offline, pas en production.

RAG Module de conformité réglementaire basé sur TF-IDF. Avantage : réponses sourcées et fiables aux questions CNDP/RGPD. Limite : périmètre restreint aux aspects réglementaires, sans prédiction ni classement.

LLM (LLaMA 3.3 70B) Couche conversationnelle et de synthèse. Avantage : compréhension du langage naturel, génération de rapports narratifs, dialogue utilisateur. Limite : ne produit aucune prédiction numérique, dépend des modules RF/MCDM/RAG.

MCDM (WSM + TOPSIS) Moteur de décision multicritère. Avantage : classement objectif et explicable des solutions SaaS. Limite : outil de comparaison relative, ne juge pas la valeur absolue d'une solution.

La digitalisation dans le secteur du projet

La digitalisation des services financiers et administratifs constitue un levier majeur de modernisation. Au Maroc, cette dynamique est renforcée par la **réforme e-facturation 2026** de la DGI, qui impose aux entreprises de migrer vers des solutions de facturation électronique conformes, offrant ainsi une opportunité stratégique aux SaaS locaux.

L'intégration de l'IA dans le domaine du projet

L'intelligence artificielle est mobilisée à trois niveaux : **prédictif** (Random Forest, SVM, Gradient Boosting pour anticiper prix, segment, conformité et satisfaction), **conversationnel** (LLM Groq/LLaMA 3.3 70B pour comprendre et dialoguer en langage naturel), et **décisionnel** (MCDM WSM/TOPSIS pour transformer les prédictions en recommandations explicables).

Cadre réglementaire applicable — CNDP Loi 09-08 et RGPD

La **Loi 09-08** au Maroc impose déclaration préalable à la CNDP, consentement explicite, droits d'accès/rectification/opposition, mesures de sécurité adaptées et restrictions sur les transferts de données hors du pays. Le **RGPD** européen (articles 5, 6, 25, 32) fixe les principes de licéité, bases légales, privacy by design et exigences de sécurité. Ces critères sont automatiquement évalués par le module RAG pour chaque solution SaaS.

1.4 Éléments du Cahier des charges — Spécifications fonctionnelles

Le cahier des charges du projet définit l'ensemble des fonctionnalités attendues du système SaaS Assistant développé dans le cadre de cette étude. Ce système se compose de deux espaces de travail distincts : **Mode Créateur** pour les startups et **Mode**

Acheteur pour les PME. Chacun propose cinq agents spécialisés et une interface web responsive en trois colonnes (sidebar, zone de chat, panneau contextuel).

TABLE 1.3 – Spécifications fonctionnelles du système SaaS Assistant

Fonctionnalité	**Description détaillée**
Chatbot LLM intelligent	Moteur de conversation basé sur Groq (LLaMA 3.3 70B). Détection automatique FR/EN, historique de 20 messages, routing vers 10 agents spécialisés.
Prédictions IA (4 modèles)	Classification simultanée : classe de prix, segment de taille, conformité e-facture 2026, satisfaction utilisateur. Graphique d'explicabilité SHAP-like et TCO 5 ans.
Comparateur MCDM	Deux algorithmes scientifiques WSM et TOPSIS avec curseurs interactifs. Critères : fonctionnalité (30%), coût TCO (40%), sécurité/SLA (30%).
RAG Conformité	Génération augmentée par récupération TF-IDF sur 9 chunks CNDP Maroc et RGPD UE. Verdict Faible / Moyen / Élevé avec recommandations sourcées.
NLU/NER	Extraction automatique d'entités métier depuis texte libre (secteur, budget, utilisateurs, zone) pour alimenter MCDM et calculateur ROI/TCO.
Audit SaaS temps réel	Pipeline 4 étapes : extraction LLM, prédictions ML, comparaison dataset, rapport narratif. Analyse de n'importe quelle solution SaaS par nom ou URL.
Simulateur TCO/ROI	Calcul TCO, ROI%, Payback. Formule : TCO = abonnement + migration + formation + support. Projection financière sur 5 ans avec courbe d'amortissement Chart.js.
Mode Créateur (Startup)	5 agents dédiés : Pitch (diagnostic marché), SWOT automatique, MRR/ARR/LTV simulation, Business Model Canvas (9 blocs), Radar de positionnement.
Mode Acheteur (PME)	5 agents dédiés : Cadrage des besoins avec NLU, Comparateur MCDM, ROI/TCO, Conformité réglementaire CNDP/RGPD, Plan de déploiement en 4 phases.
Gouvernance & Sécurité	Logs JSON structurés (MLOps), anonymisation PII automatique (RGPD Art.25, CNDP Loi 09-08), versioning des modèles ML, détection de Data Drift (seuil 15%/30%).

L'architecture backend repose sur 28 routes API REST Flask couvrant la gestion des

conversations, les prédictions ML, le calcul ROI/TCO, la comparaison MCDM, l'audit SaaS, la conformité réglementaire et l'administration. L'interface frontend est développée en HTML/CSS/JavaScript vanilla avec 65 fonctions JavaScript et 239 classes CSS.

1.5 Maquettage

Le maquettage du **SaaS Assistant** repose sur une interface web en trois colonnes : - **Sidebar gauche** : Workspace Switcher (Créateur/Acheteur), logo, moteur de recherche, historique des conversations et bibliothèque des agents. - **Zone centrale de chat** : cœur de l'interface avec en-tête, messages, indicateur de frappe et barre de saisie. - **Panneau contextuel droit** : livrables dynamiques (cahier des charges, tableau MCDM, graphique TCO, checklist conformité, timeline).

La visualisation utilise **Chart.js** pour les graphiques d'amortissement, radar concurrentiel, contributions SHAP-like et simulateur TCO sur 5 ans.

1.6 Conclusion

Ce chapitre a défini les bases conceptuelles et méthodologiques du projet : contexte, veilles, spécifications fonctionnelles et maquettage. L'objectif est d'aider les **PME marocaines** à choisir une solution SaaS de facturation adaptée, dans un marché dominé par des acteurs internationaux et marqué par la réforme **DGI e-facturation 2026**.

La veille concurrentielle confirme l'absence d'un outil d'aide à la décision intelligent et conforme au cadre local, justifiant le développement du **SaaS Assistant**. Les spécifications (ML, MCDM, RAG, LLM) offrent une réponse innovante et explicable, traduite dans une interface claire pour les deux profils : Acheteur PME et Créateur SaaS.

Les chapitres suivants détaillent la mise en œuvre : - **Chapitre II** : modélisation IA, préparation des données et résultats des algorithmes. - **Chapitre III** : intégration complète des modèles dans la plateforme SaaS Assistant.

Chapitre 2

Modélisation par intelligence artificielle

2.1 Introduction

Le développement rapide des technologies liées à l'intelligence artificielle et à l'apprentissage automatique a profondément transformé les méthodes d'analyse et de traitement des données dans de nombreux domaines économiques et technologiques. Dans le cadre de ce projet consacré à l'analyse intelligente du marché SaaS marocain, le recours aux techniques de machine learning — classification supervisée, régression et clustering — constitue une approche méthodologique fondamentale permettant d'extraire des connaissances exploitables à partir des données collectées sur les solutions logicielles.

Le présent chapitre expose l'ensemble du processus de modélisation par intelligence artificielle mis en œuvre dans ce projet. Il décrit les objectifs d'apprentissage poursuivis, les risques identifiés, la démarche méthodologique adoptée ainsi que les résultats obtenus. Cette modélisation repose sur un jeu de données composé de **1 425 solutions SaaS** décrites par **31 variables** couvrant des dimensions tarifaires, financières, géographiques, commerciales et qualitatives.

Quatre tâches de classification distinctes ont été définies : la prédiction de la classe de prix d'une solution SaaS (`Classe_prix`), la prédiction de son segment de taille cible (`segment_taille`), la prédiction de sa conformité à la réglementation e-facturation 2026 (`conforme_e_facture_2026`), et la prédiction de son niveau de satisfaction utilisateur (`niveau_satisfaction`). Ces tâches supervisées sont complétées par une **régression multiple** pour l'estimation du prix numérique exact, et un **clustering K-Means** pour la segmentation non supervisée du marché. Pour chacune des tâches de classification, sept algorithmes supervisés ont été entraînés, évalués et comparés.

2.2 Objectifs recherchés en matière d'apprentissage

La modélisation par intelligence artificielle mise en œuvre dans ce projet poursuit trois catégories d'objectifs étroitement liées : le diagnostic de l'état du marché SaaS, la prédiction de variables cibles stratégiques et la décision assistée par les modèles construits.

2.2.1 Diagnostique

Le premier objectif est d'ordre diagnostique. Il s'agit de comprendre la structure interne du marché SaaS à partir des données collectées et d'identifier les patterns qui différencient les solutions selon leurs caractéristiques économiques, commerciales et qualitatives.

L'analyse de la distribution de la variable `Classe_prix` révèle un déséquilibre très marqué : la classe *Low* représente 89,7 % des observations tandis que la classe *Enterprise* n'en regroupe que 1,6 %. De même, la distribution de la variable `conforme_e_facture_2026` indique que seulement 12,8 % des solutions sont conformes à la réglementation e-facturation 2026, traduisant un retard significatif dans l'adaptation réglementaire du marché.

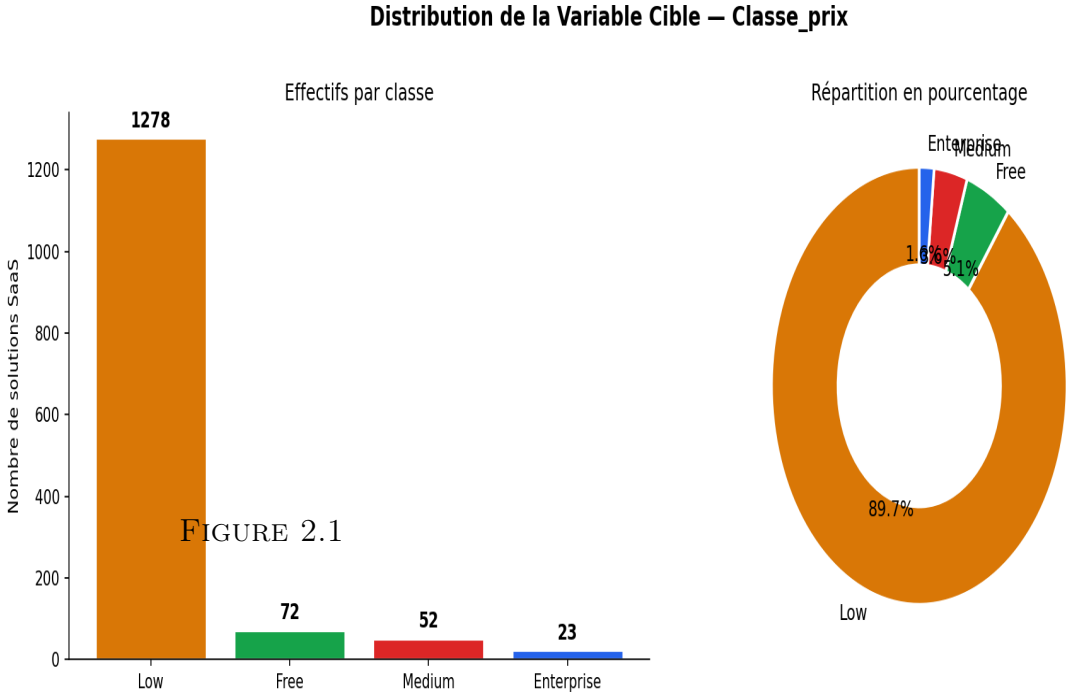


FIGURE 2.1

– Distribution de la variable Classe_prix

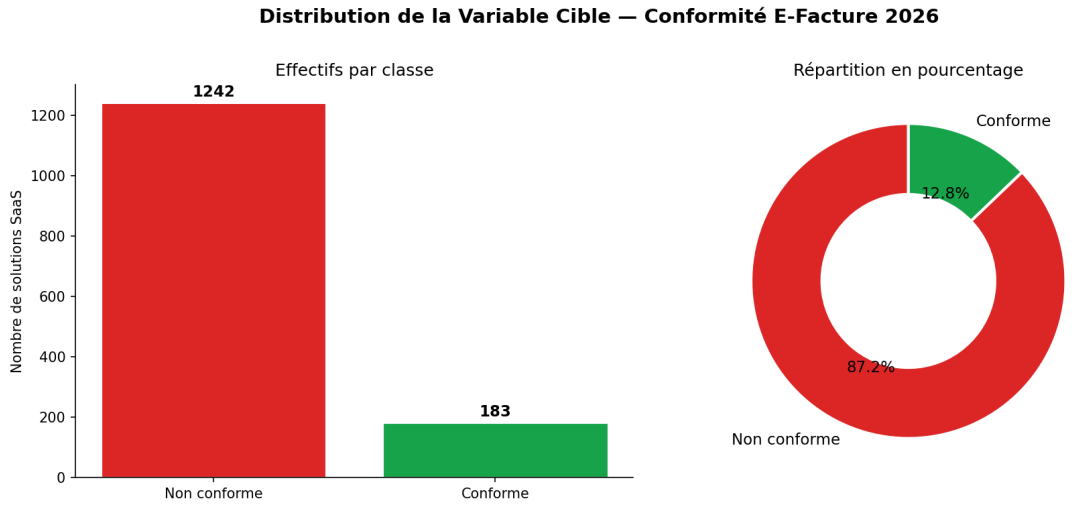


FIGURE 2.2 – Distribution de la Conformité e-facture 2026

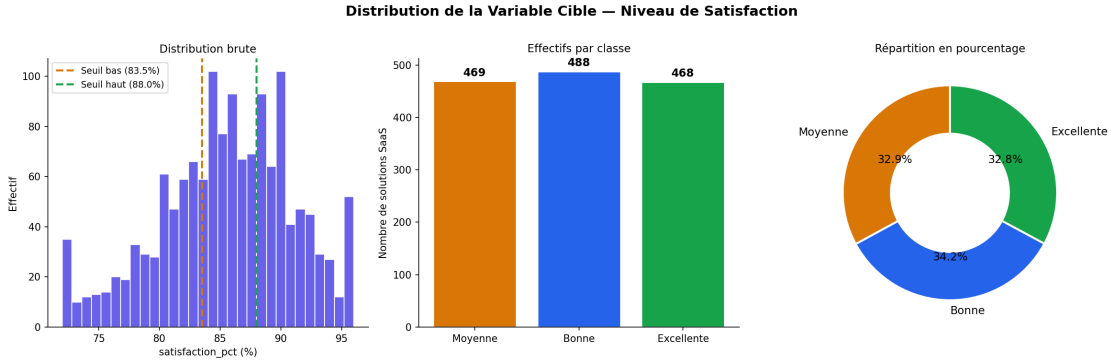


FIGURE 2.3 – Distribution du Niveau de satisfaction

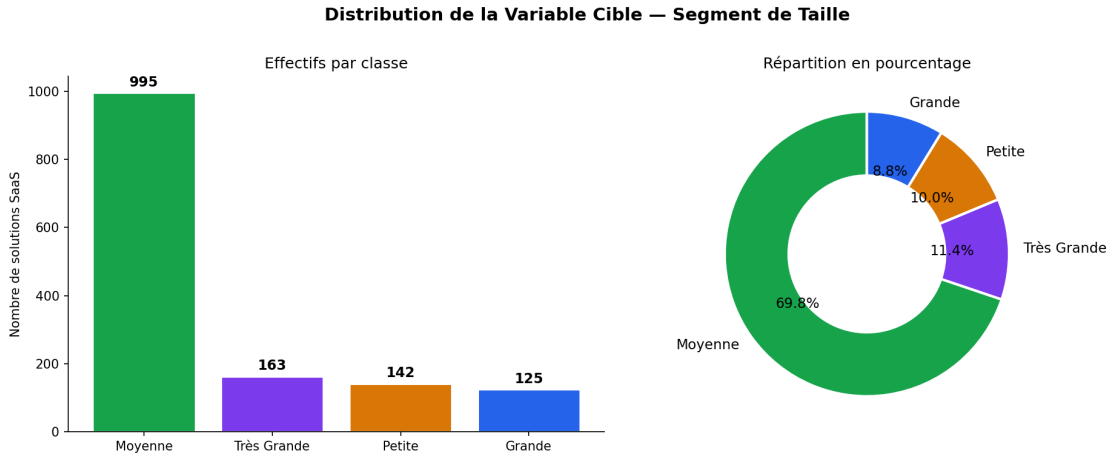


FIGURE 2.4 – Distribution du Segment de taille

2.2.2 Prédiction

L'objectif prédictif consiste à anticiper, à partir des caractéristiques d'une solution SaaS, plusieurs variables stratégiques : `Classe_prix`, `Segment_taille`, `Conforme_e_facture_2026`, `Niveau_satisfaction`, ainsi que le `prix_min_eur` par régression multiple (RF Re-

gressor + Ridge). Une segmentation non supervisée par **K-Means** ($k = 4$) complète l'analyse en regroupant les 1 425 solutions en clusters homogènes.

2.2.3 Décision

Les modèles prédictifs alimentent un moteur de recommandation multi-critères (MCDM) basé sur **WSM** et **TOPSIS**.

WSM :

$$Score(A_i) = \sum_{j=1}^{m} w_j \cdot x_{ij}, \quad \sum_{j=1}^{m} w_j = 1$$

TOPSIS :

$$C_i^* = \frac{S_i^-}{S_i^+ + S_i^-}, \quad C_i^* \to 1 \Rightarrow solutionoptimale$$

Les poids retenus sont : Fonctionnalité 30%, Coût TCO 40%, Sécurité/SLA 30%. Ce moteur permet aux PME de sélectionner des solutions adaptées et aux éditeurs d'orienter leurs choix stratégiques.

Apprentissage supervisé

Le pipeline suit six étapes : exploration (1 425 × 31), encodage des variables catégorielles, rééquilibrage par SMOTE, séparation train/test (80/20), normalisation par StandardScaler et entraînement/évaluation de sept algorithmes (LR, DT, RF, GB, KNN, SVM-RBF, NB) selon Accuracy, Précision, Rappel, F1, AUC-ROC et CV Accuracy.

Critères de séparation.

$$MSE = \frac{1}{N_{\text{nœud}}} \sum_i (y_i - \bar{y})^2, \quad \text{Gini}(t) = 1 - \sum_c p_c^2$$

Random Forest. Agrégation par bagging :

$$\hat{y} = \frac{1}{K} \sum_{k=1}^{K} T_k(X)$$

Robustesse et importance des features par réduction d'impureté.

Normalisation. StandardScaler :

$$z = \frac{x - \mu}{\sigma}$$

Arbre de décision. Réduction d'impureté (Gini/entropie) :

$$H(t) = -\sum_{c} p_c \log_2 p_c$$

Régression logistique. Sigmoïde :

$$P(y = 1|x) = \frac{1}{1+e^{-(w^\top x+b)}}$$

SVM-RBF. Noyau gaussien :

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

Gradient Boosting. Construction séquentielle :

$$F_m(x) = F_{m-1}(x) + \eta h_m(x)$$

Naive Bayes. Théorème de Bayes :

$$P(C_k|x) \propto P(C_k) \prod_{j} P(x_j|C_k)$$

Ainsi, le Random Forest s'impose comme moteur prédictif central, avec SVM-RBF et GB comme alternatives performantes, tandis que LR et NB confirment la non-linéarité du dataset SaaS.

2.3 Action orientée Science des données

2.3.1 Identification des paramètres

Le jeu de données décrit chaque solution SaaS par 31 variables couvrant six dimensions analytiques complémentaires. La **dimension géographique et commerciale** regroupe zone (9 modalités), cible (25 modalités) et pays_siege (20 modalités). La **dimension de notation** comprend note_g2, nb_avis_g2, note_capterra, nb_avis_capterra, note_trustpilot, note_moyenne_globale et satisfaction_pct. La **dimension tarifaire** inclut prix_min_eur, prix_max_eur, nb_plans, a_freemium, a_essai_gratuit et a_usage_based.

La **dimension structurelle** couvre annee_creation, age_produit, nb_employes, total_financement_mUSD, type_derniere_levee et nb_tours_financement. La **dimension fonctionnelle** est représentée par has_PDP, has_API, has_CRM, has_compta et has_mobile. L'analyse de l'importance des features selon l'indice de Gini révèle

des prédicteurs dominants spécifiques à chaque tâche : prix_min_eur (0,0845) pour Classe_prix, nb_employes (0,0715) pour segment_taille, total_financement_mUSD (0,0966) pour conforme_e_facture_2026, et note_g2 (0,2337) pour niveau_satisfaction.

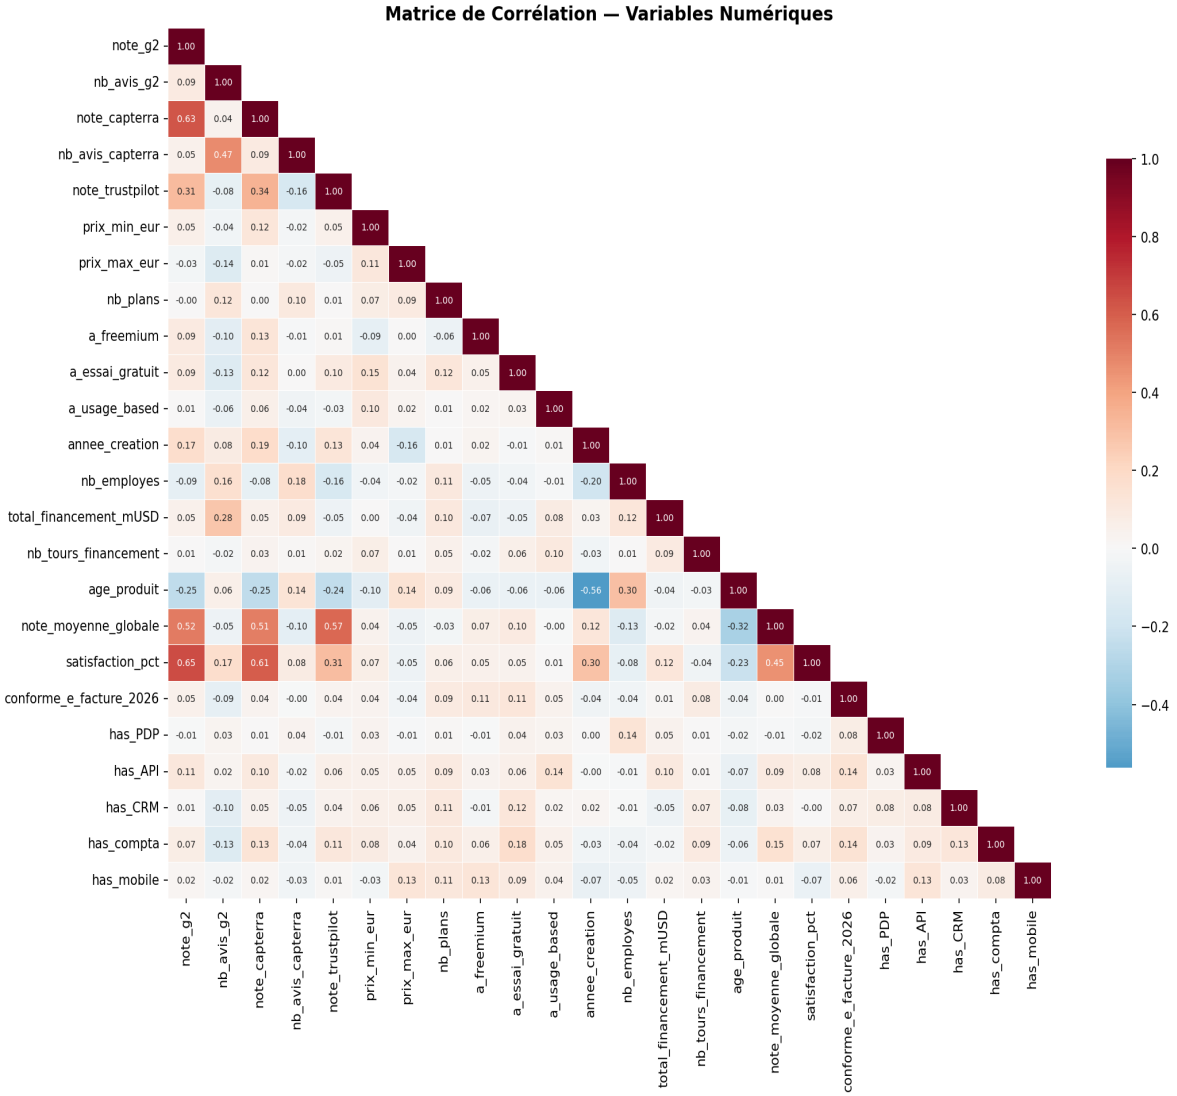


FIGURE 2.5 – Matrice de corrélation des variables du dataset

2.3.2 Description et rôle des variables du dataset

L'analyse des données constitue une étape essentielle dans la conception d'un chatbot intelligent dédié au marché des solutions SaaS. Les variables collectées dans le dataset ne sont pas de simples indicateurs statistiques : elles représentent des dimensions clés permettant de caractériser les produits, d'évaluer leur performance et de comprendre leur positionnement sur le marché. En intégrant ces variables dans un chatbot, il devient possible de fournir des réponses personnalisées, de comparer les solutions selon des critères objectifs et d'orienter les utilisateurs vers les choix les plus adaptés à leurs besoins.

TABLE 2.1 – Description des variables du dataset SaaS

Variable	Description
zone	Portée géographique du logiciel (Mondial, Europe, Amérique du Nord...)
has_CRM	Présence d'un module CRM
cible	Segment de clientèle visé (TPE, PME, ETI, GE, Freelances...)
has_compta	Présence d'un module de comptabilité
note_g2	Note moyenne sur G2
has_mobile	Disponibilité d'une application mobile
nb_avis_g2	Nombre d'avis sur G2
Classe_prix	Catégorie de prix (Low, Medium, Enterprise)
note_capterra	Note moyenne sur Capterra
nb_avis_capterra	Nombre d'avis sur Capterra
note_trustpilot	Note moyenne sur Trustpilot
prix_min_eur	Prix minimum en euros
prix_max_eur	Prix maximum en euros
nb_plans	Nombre de plans tarifaires proposés
a_freemium	Existence d'une offre gratuite
a_essai_gratuit	Disponibilité d'un essai gratuit
a_usage_based	Tarification basée sur l'usage
annee_creation	Année de création de l'entreprise
pays_siege	Pays du siège social
nb_employes	Nombre d'employés
total_financement_mUSD	Montant total des financements en millions USD
type_derniere_levee	Type de financement (Seed, Series A, IPO...)
nb_tours_financement	Nombre de tours de financement
age_produit	Âge du produit en années
segment_taille	Taille cible (Petite, Moyenne, Grande, Très Grande)
note_moyenne_globale	Moyenne des notes globales
satisfaction_pct	Pourcentage de satisfaction des utilisateurs
conforme_e_facture_2026	Conformité à la réglementation e-facturation 2026
has_PDP	Présence d'un plan de développement produit
has_API	Disponibilité d'une API

Analyse synthétique du rôle des variables

Les 31 variables du dataset se regroupent en six catégories complémentaires :

Fonctionnelles. `has_CRM`, `has_compta`, `has_mobile`, `has_API`, `has_PDP` décrivent les modules disponibles et permettent de filtrer selon les besoins exprimés.

Réputation. `note_g2`, `note_capterra`, `note_trustpilot`, `nb_avis_g2`, `nb_avis_capterra` mesurent la perception client et renforcent la confiance dans les recommandations.

Financières. `prix_min_eur`, `prix_max_eur`, `Classe_prix`, `nb_plans`, `a_freemium`, `a_essai_gratuit`, `a_usage_based` décrivent la structure tarifaire et l'accessibilité économique.

Organisationnelles. `annee_creation`, `pays_siege`, `nb_employes`, `total_financement_mUSD` `type_derniere_levee`, `nb_tours_financement`, `age_produit` caractérisent la maturité et la solidité de l'éditeur.

Segmentation. `zone`, `cible`, `segment_taille` identifient le marché cible et la portée géographique, utiles pour adapter les recommandations au contexte local.

Performance globale. `note_moyenne_globale`, `satisfaction_pct`, `conforme_e_facture_2026` évaluent la qualité perçue et la conformité réglementaire, notamment face à la réforme e-facturation 2026.

Références

— G2, *Software Reviews and Ratings*, 2025.

— Capterra, *Find the Best Software*, 2025.

— Trustpilot, *Business Reviews Platform*, 2025.

— Direction Générale des Impôts (DGI), *Réforme de la facturation électronique au Maroc*, 2024.

2.3.3 Mise en évidence des champs de variation

La discrétisation des variables continues repose sur le coefficient d'asymétrie de Fisher :

$$G_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^3}{\sigma^3}$$

Un $G_1 < 0$ (comme pour `satisfaction_pct`) justifie l'usage des percentiles empiriques. Les seuils de `niveau_satisfaction` sont fixés aux tertiles P_{33} et P_{66} :

$$\int_{-\infty}^{P_{33}} f(x)\,dx = \tfrac{1}{3}, \qquad \int_{-\infty}^{P_{66}} f(x)\,dx = \tfrac{2}{3}$$

soit 83,5 % et 88,0 %, définissant trois classes quasi-équilibrées : Moyenne, Bonne et Excellente.

2.3.4 Mise en évidence des règles spécifiques

Les modèles révèlent plusieurs règles discriminantes : - Pour la **conformité e-facture**, le financement total est déterminant (solutions bien financées et haut de gamme tendent vers la conformité). - Pour le **segment de taille**, l'échec des modèles linéaires (F1 $\approx$ 49 %) confirme la non-linéarité des frontières. - Pour la **satisfaction**, les notes des plateformes d'avis expliquent la quasi-totalité de la variance prédictible.

2.4 Préparation des données

La préparation des données est une étape critique : la qualité des prédictions dépend directement de la rigueur des transformations appliquées. Le pipeline suit quatre étapes : (1) collecte brute (239 observations réelles), (2) imputation ML des valeurs manquantes, (3) génération synthétique contrôlée (GaussianCopula + CTGAN), (4) audit de fuite de données.

Le fichier `dataset_final.xlsx` contient **1 425 observations** et **31 variables**, sans valeurs manquantes après imputation. Les variables catégorielles ont été encodées via `LabelEncoder` avec `random_state=42`.

TABLE 2.2 – Rééquilibrage SMOTE des variables cibles

Variable cible	Classes	Avant SMOTE	Après SMOTE
Classe_prix	Free, Low, Medium, Enterprise	72 / 1278 / 52 / 23	1278
conforme_e_facture_2026	Conforme / Non conforme	181 / 1244	1242
segment_taille	Petite / Moyenne / Grande / TG	Déséquilibre variable	995
niveau_satisfaction	Moyenne / Bonne / Excellente	469 / 488 / 468	488

La séparation train/test (80/20) stratifiée assure la représentativité des classes. La normalisation `StandardScaler`, calculée uniquement sur l'entraînement puis appliquée au test, évite toute fuite d'information statistique.

2.4.1 Pipeline de Données

Le principe *"Garbage In, Garbage Out"* rappelle que la qualité des prédictions dépend de la qualité des données. Le pipeline suit trois étapes : - **Collecte** : Web scraping automatisé (G2, Capterra, Trustpilot) et corpus JSON de ∼200 sites SaaS facturation. - **Imputation et génération** : correction des valeurs manquantes et enrichissement par données synthétiques. - **Audit** : contrôle de cohérence et absence de fuite de données.

Variables collectées. Le dataset final (31 colonnes) regroupe : notes et avis (`note_g2`, `note_capterra`, `note_trustpilot`, `nb_avis_g2`, `nb_avis_capterra`), prix et modèles (`prix_min_eur`, `prix_max_eur`, `Classe_prix`, `a_freemium`, `a_essai_gratuit`), caractéristiques techniques (`has_API`, `has_CRM`, `conforme_e_facture_2026`) et contexte marché (`annee_creation`, `pays_siege`, `nb_employes`, `total_financement_mUSD`).

Défis et solutions. Les principaux obstacles ont été : blocages techniques (Captchas, anti-scraping), données manquantes (ex. conformité e-facture 2026) et formats hétérogènes. Solutions mises en place : corpus JSON de 200 SaaS, parsing Python, génération synthétique réaliste respectant les corrélations logiques (ex. SaaS récent → API disponible ; SaaS français → conformité e-facture 2026). Une colonne `source` distingue données réelles et synthétiques. Pipeline : scraping brut → nettoyage Pandas → fusion real/synthetic → export Excel.

Résultat. La collecte brute a produit **239 observations réelles** décrites par 31 variables, constituant une base empirique authentique sur laquelle repose l'ensemble du pipeline d'enrichissement.

Imputation ML des valeurs manquantes

Le dataset brut (239 lignes) présentait des taux de manquants élevés. Une stratégie différenciée a été appliquée : - **IterativeImputer** pour variables faiblement manquantes et corrélées (`note_capterra`, `prix_min_eur`, `prix_max_eur`, `total_financement_mUSD`) ; - **KNNImputer** ($k = 5$) pour `note_trustpilot` (76% manquants) ; - **RandomForest** pour `nb_plans` et `type_derniere_levee` ; - **Mode par groupe** pour `features_cles`.

Résultat : aucune valeur manquante, garantissant l'intégrité du pipeline.

Génération synthétique et volume optimal

Un pipeline (`pipeline_2000.py`) combine **GaussianCopula (70%)** et **CTGAN (30%)** pour générer des données réalistes. Après filtrage qualité, quatre volumes ont été testés ; le palier **1 425 lignes** (239 réelles + 1 186 synthétiques) a été retenu comme compromis optimal. Une colonne `source` distingue données réelles et synthétiques.

Audit de fuite de données. Deux corrections critiques : exclusion de `prix_min_eur` lors de la prédiction de `Classe_prix`, et de `satisfaction_pct` pour `niveau_satisfaction`. L'audit de quasi-doublons (distance euclidienne normalisée, seuil 0,5) confirme l'absence de mémorisation excessive.

Validation par cross-validation. Une CV stratifiée (5 plis) montre que l'augmentation synthétique améliore significativement les métriques par rapport aux seules données réelles, validant l'approche.

Stockage

Le format `.xlsx` a été retenu pour sa lisibilité, compatibilité avec les outils PME et intégration facile avec `Pandas`/`Openpyxl`.

2.4.2 Justification de l'Augmentation de Données

Les données réelles de tarification SaaS sont limitées (239 solutions) et fortement déséquilibrées (89,7 % Low, 1,6 % Enterprise). Pour enrichir le dataset, deux générateurs complémentaires ont été combinés (ratio 70/30) : - **GaussianCopula (70%)** : capture les corrélations statistiques entre variables continues (prix, notes). - **CTGAN (30%)** : reproduit les distributions multimodales et asymétriques via un entraînement adversarial (WGAN-GP).

Distance de Wasserstein. La qualité des données synthétiques est validée par la distance de Wasserstein :

$$W_1(P, Q) = \inf_{\gamma \in \Gamma(P,Q)} \mathbb{E}_{(x,y)\sim\gamma}\big[\|x - y\|\big]$$

Une faible valeur entre distributions réelles et générées (ex. `prix_min_eur`, `note_g2`) confirme la fidélité statistique des données produites.

SMOTE en complément. Après génération, **SMOTE** est appliqué pour corriger le déséquilibre résiduel des classes cibles lors de l'entraînement des classificateurs.

2.5 Traitement des données

Le traitement des données correspond à la phase centrale du projet. Les sept algorithmes ont été entraînés et évalués sur chacune des quatre tâches selon le pipeline défini précédemment. Chaque tableau de résultats est trié par F1-Score décroissant, le Random Forest apparaissant systématiquement comme le meilleur modèle sur toutes les tâches.

2.5.1 Classification 1 — Classe de prix (`Classe_prix`)

La première tâche prédit la gamme tarifaire (Free, Low, Medium, Enterprise). Après correction du déséquilibre par SMOTE, la forêt aléatoire atteint des performances quasi-parfaites avec un **F1-Score de 98,23 %** et un AUC-ROC de 0,9997, grâce à la forte corrélation entre les variables tarifaires et la cible. Cette tâche est qualifiée de « Facile » en raison de la cohérence intrinsèque du marché SaaS.

TABLE 2.3 – Résultats — Classification de la Classe de prix

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Acc.
Random Forest	98,24 %	98,27 %	98,24 %	**98,23 %**	0,9997	98,14 %
SVM (RBF)	94,23 %	94,21 %	94,23 %	94,20 %	0,9940	93,81 %
Gradient Boosting	93,94 %	93,94 %	93,94 %	93,92 %	0,9929	93,01 %
K-Nearest Neighbors	90,32 %	91,33 %	90,32 %	89,76 %	0,9763	88,46 %
Decision Tree	85,43 %	85,38 %	85,43 %	85,21 %	0,9337	84,37 %
Régression Logistique	69,70 %	69,61 %	69,70 %	69,44 %	0,8856	67,35 %
Naive Bayes	56,01 %	58,82 %	56,01 %	54,37 %	0,8374	57,08 %

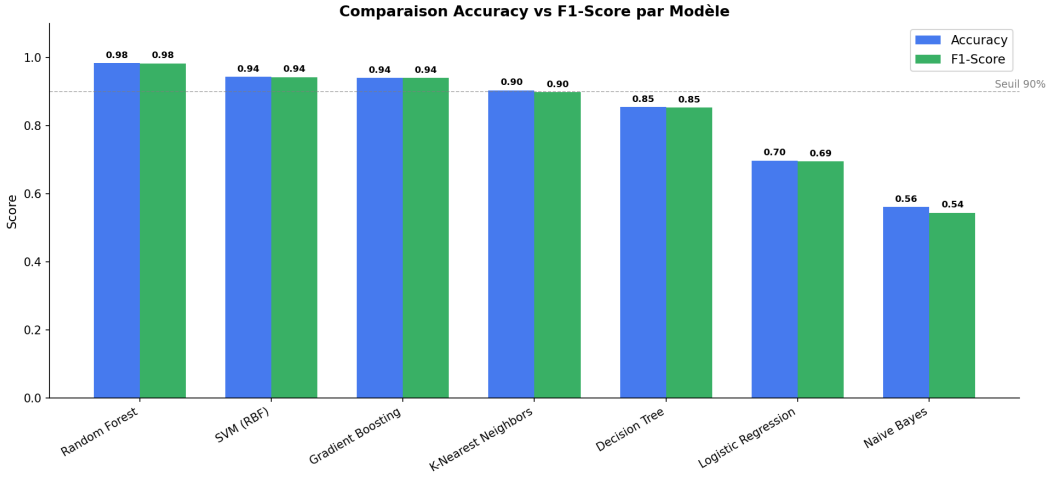


FIGURE 2.6 – Comparaison des modèles — Classe_prix

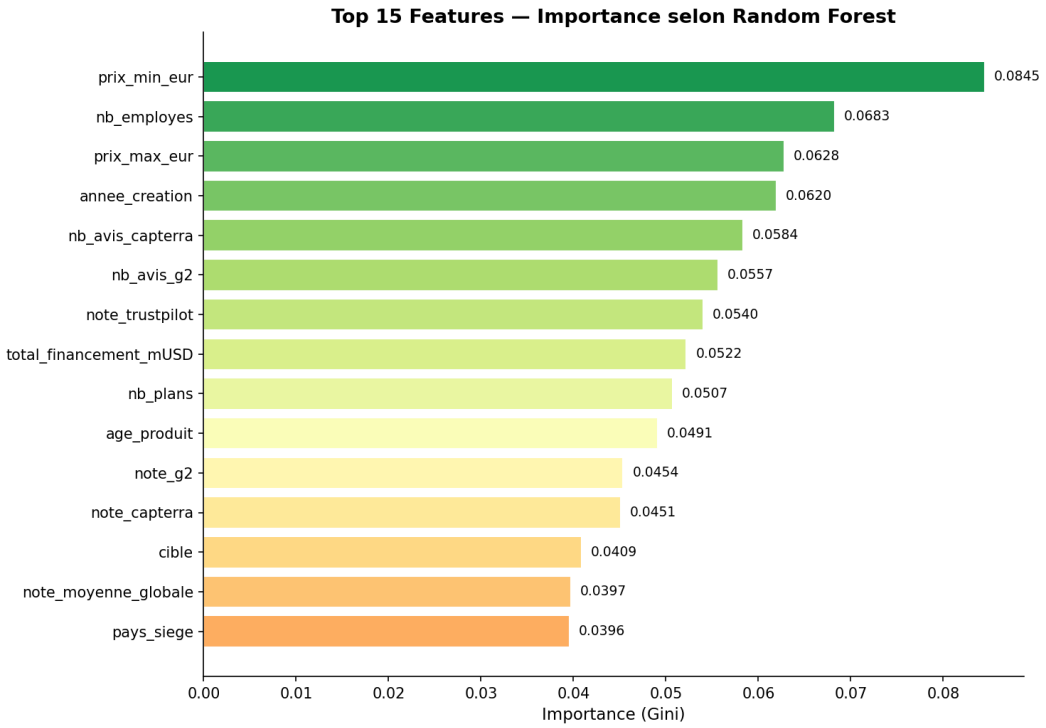


FIGURE 2.7 – Importance des variables — Classe_prix

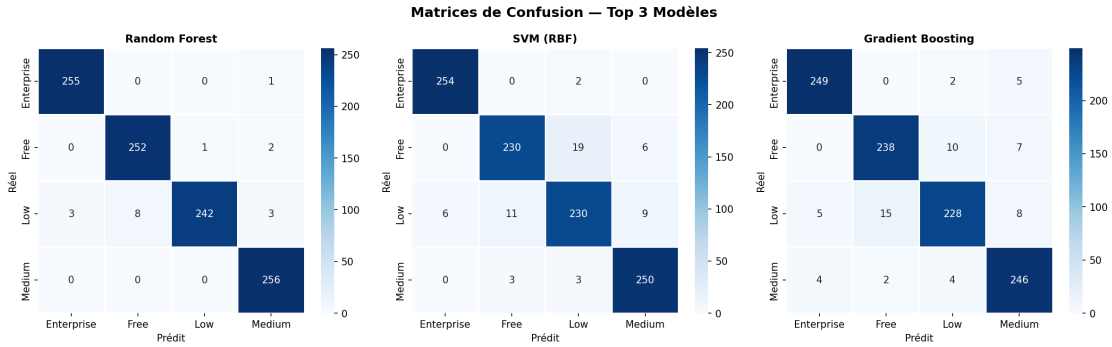


FIGURE 2.8 – Matrices de confusion — Classe_prix

2.5.2 Classification 2 — Conformité e-facture 2026

La deuxième tâche prédit la conformité binaire à la réglementation e-facturation 2026. Le Random Forest atteint un **F1-Score de 88,66 %** et un AUC-ROC de 0,9632. Le financement total (`total_financement_mUSD`) est le prédicteur dominant, traduisant que les ressources financières conditionnent la capacité de mise en conformité. Cette tâche est qualifiée de « Difficile » en raison des facteurs non-observables influençant la conformité.

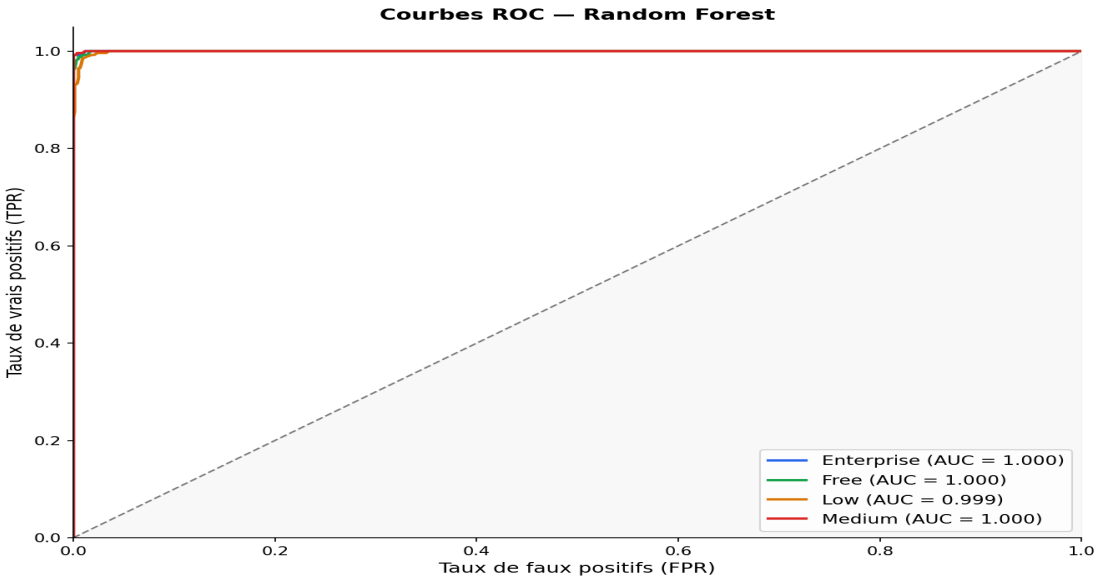


FIGURE 2.9 – Courbes ROC — Classe_prix

Comparaison des Métriques de Performance – Tous Modèles

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.9824**	**0.9827**	**0.9824**	**0.9823**	**0.9997**	**0.9814**
SVM (RBF)	0.9423	0.9421	0.9423	0.942	0.994	0.9381
Gradient Boosting	0.9394	0.9394	0.9394	0.9392	0.9929	0.9301
K-Nearest Neighbors	0.9032	0.9133	0.9032	0.8976	0.9763	0.8846
Decision Tree	0.8543	0.8538	0.8543	0.8521	0.9337	0.8437
Logistic Regression	0.697	0.6961	0.697	0.6944	0.8856	0.6735
Naive Bayes	0.5601	0.5882	0.5601	0.5437	0.8374	0.5708

FIGURE 2.10 – Tableau comparatif des modèles — Classe_prix

2.5.3 Classification 3 — Niveau de satisfaction

La troisième tâche prédit le niveau de satisfaction (Moyenne / Bonne / Excellente). Avec un **F1-Score de 77,21 %**, c'est la tâche la plus difficile en raison des frontières floues inhérentes à la discrétisation continue. Les notes G2, Capterra et Trustpilot dominent largement l'importance des features, validant leur rôle de proxies fiables de la qualité perçue.

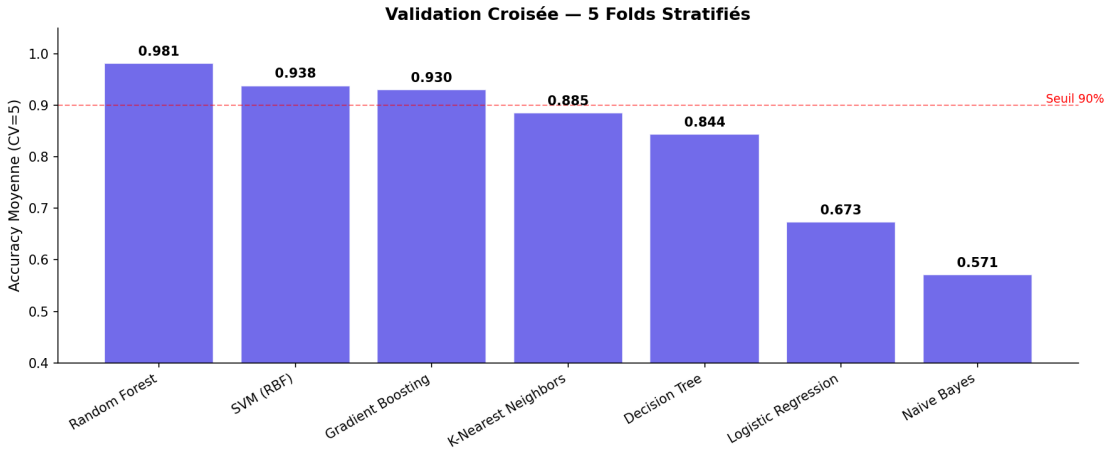


FIGURE 2.11 – Validation croisée — Classe_prix

Rapport de Classification Détaillé — Random Forest

	Précision	Rappel	F1-Score	Support
Enterprise	0.988	0.996	0.992	256.0
Free	0.969	0.988	0.979	255.0
Low	0.996	0.945	0.97	256.0
Medium	0.977	1.0	0.988	256.0

FIGURE 2.12 – Rapport de classification — Classe_prix

TABLE 2.4 – Résultats — Classification de la Conformité e-facture 2026

Modèle	Accuracy	Précision	**Rappel**	**F1-Score**	**AUC-ROC**	**CV Acc.**
Random Forest	88,73 %	89,02 %	88,31 %	**88,66 %**	0,9632	90,14 %
Gradient Boosting	87,73 %	89,12 %	85,89 %	87,47 %	0,9473	87,52 %
SVM (RBF)	84,10 %	84,49 %	83,47 %	83,98 %	0,9054	84,05 %
Decision Tree	79,88 %	77,61 %	83,87 %	80,62 %	0,8200	80,47 %
K-Nearest Neighbors	76,86 %	70,98 %	90,73 %	79,65 %	0,8769	76,85 %
Régression Logistique	70,42 %	68,77 %	74,60 %	71,57 %	0,7397	70,21 %
Naive Bayes	66,80 %	62,54 %	83,47 %	71,50 %	0,7476	64,92 %

2.5.4 Classification 4 — Segment de taille

La quatrième tâche prédit le segment de taille cible (Petite / Moyenne / Grande / Très Grande). Le Random Forest atteint un **F1-Score de 90,65 %**. L'effondrement des modèles linéaires (Régression Logistique : 48,9 %, Naive Bayes : 46,1 %) confirme la non-linéarité des frontières entre segments. Le nombre d'employés est le prédicteur le plus discriminant.

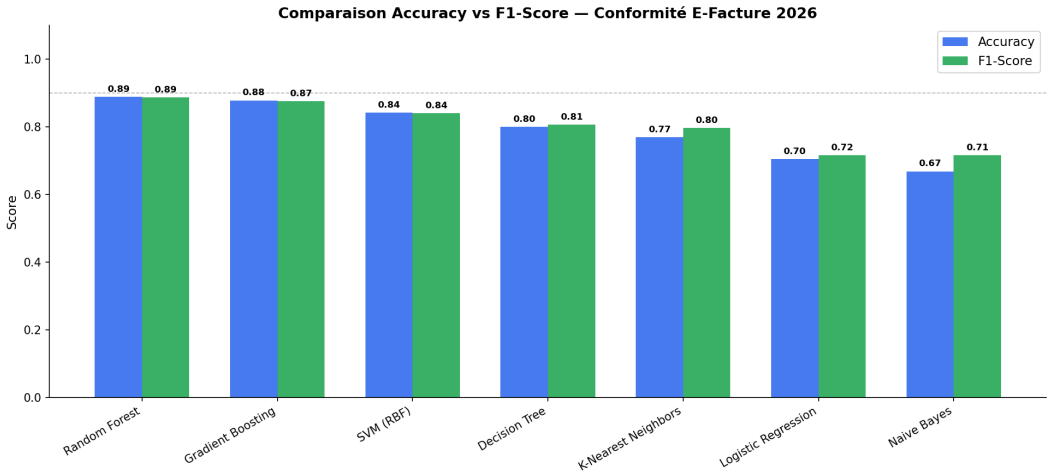


FIGURE 2.13 – Comparaison des modèles — Conformité e-facture

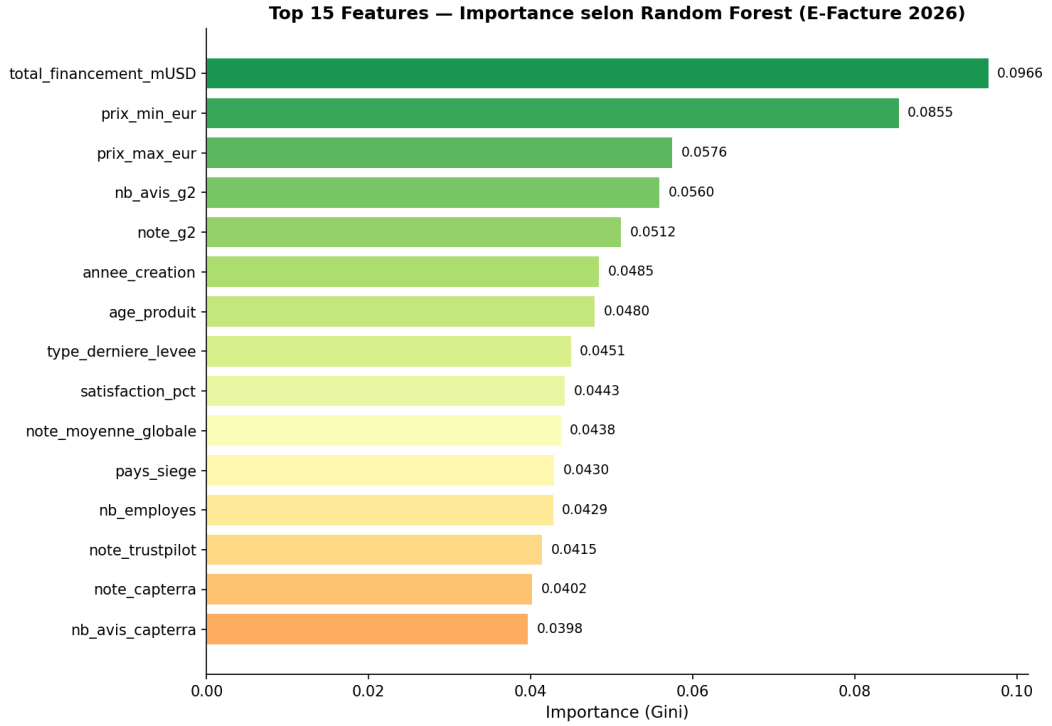


FIGURE 2.14 – Importance des variables — Conformité e-facture

Références

— Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.

— Friedman, J. H. (2001). Greedy function approximation : a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.

— Powers, D. M. W. (2011). Evaluation : from precision, recall and F-measure to ROC. *JMLR*, 2(1), 37–63.

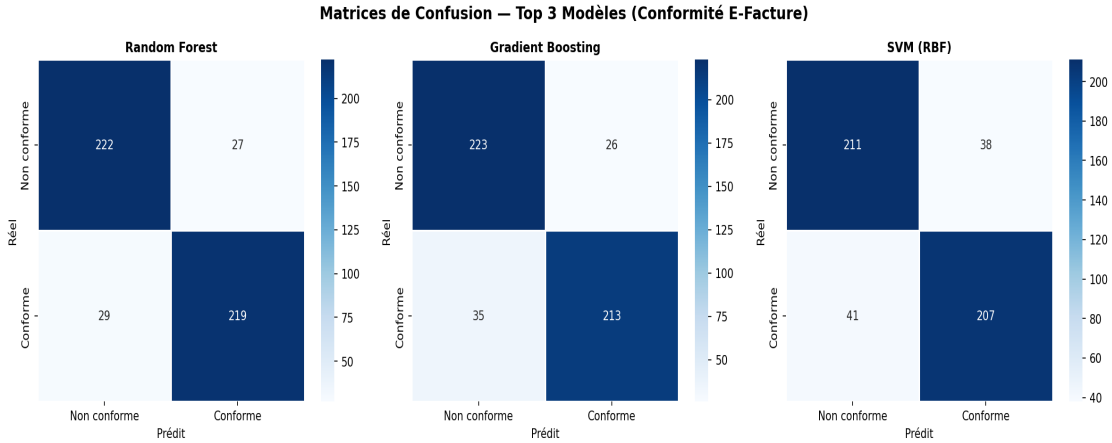


FIGURE 2.15 – Matrices de confusion — Conformité e-facture

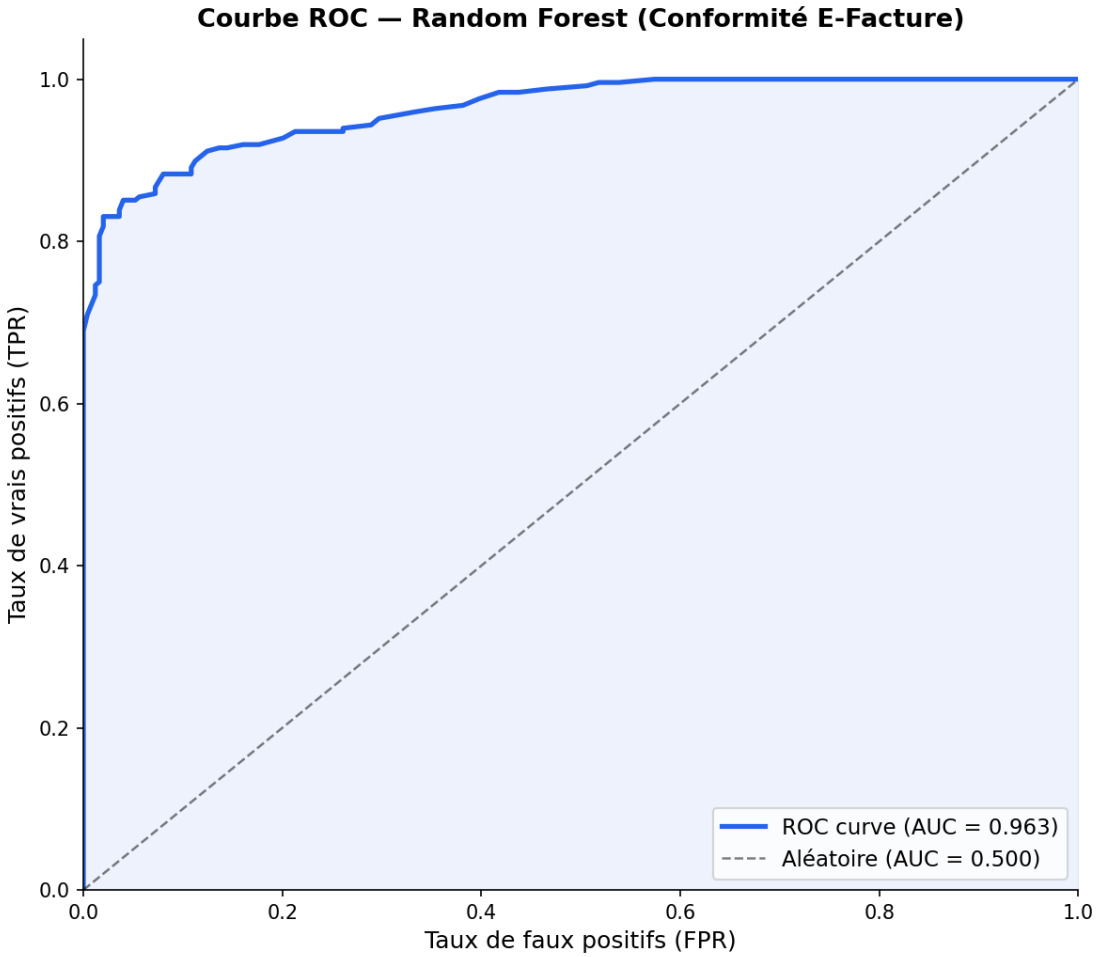


FIGURE 2.16 – Courbe ROC — Conformité e-facture

Comparaison des Métriques – Conformité E-Facture 2026

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.8873**	**0.8902**	**0.8831**	**0.8866**	**0.9632**	**0.9014**
Gradient Boosting	0.8773	0.8912	0.8589	0.8747	0.9473	0.8752
SVM (RBF)	0.841	0.8449	0.8347	0.8398	0.9054	0.8405
Decision Tree	0.7988	0.7761	0.8387	0.8062	0.82	0.8047
K-Nearest Neighbors	0.7686	0.7098	0.9073	0.7965	0.8769	0.7685
Logistic Regression	0.7042	0.6877	0.746	0.7157	0.7397	0.7021
Naive Bayes	0.668	0.6254	0.8347	0.715	0.7476	0.6492

FIGURE 2.17 – Tableau comparatif des modèles — Conformité e-facture

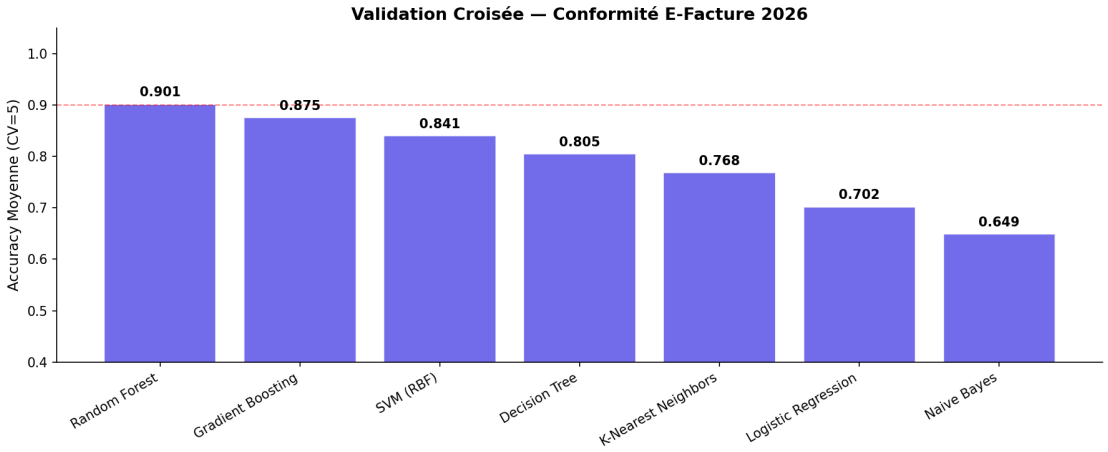


FIGURE 2.18 – Validation croisée — Conformité e-facture

	Précision	Rappel	F1-Score	Support
Non conforme	0.884	0.892	0.888	249.0
Conforme	0.89	0.883	0.887	248.0

FIGURE 2.19 – Rapport de classification — Conformité e-facture

TABLE 2.5 – Résultats — Classification du Niveau de satisfaction

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Acc.
Random Forest	77,13 %	77,85 %	77,13 %	**77,21 %**	0,9292	77,88 %
Gradient Boosting	75,43 %	76,34 %	75,43 %	75,51 %	0,9162	77,80 %
SVM (RBF)	73,38 %	73,57 %	73,38 %	73,43 %	0,8637	73,27 %
Decision Tree	73,38 %	73,48 %	73,38 %	73,39 %	0,7734	74,38 %
Régression Logistique	64,85 %	64,71 %	64,85 %	64,77 %	0,8203	70,71 %
K-Nearest Neighbors	59,04 %	62,40 %	59,04 %	59,01 %	0,7538	64,47 %
Naive Bayes	55,29 %	57,01 %	55,29 %	55,22 %	0,7371	61,49 %

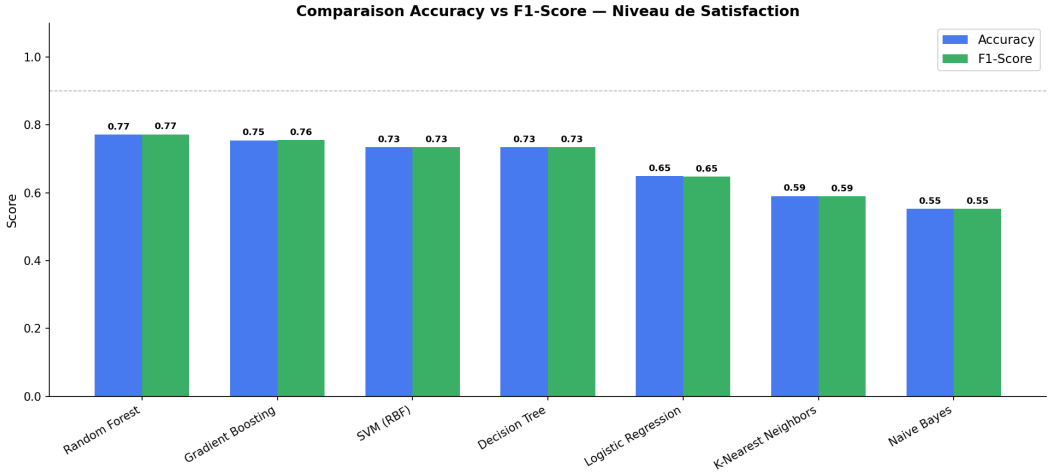


FIGURE 2.20 – Comparaison des modèles — Niveau de satisfaction

TABLE 2.6 – Résultats — Classification du Segment de taille

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Acc.
Random Forest	90,70 %	90,66 %	90,70 %	**90,65 %**	0,9858	89,16 %
Gradient Boosting	81,78 %	81,97 %	81,78 %	81,81 %	0,9528	78,42 %
SVM (RBF)	77,64 %	78,17 %	77,64 %	77,73 %	0,9408	73,77 %
K-Nearest Neighbors	75,88 %	75,63 %	75,88 %	74,90 %	0,9211	73,12 %
Decision Tree	67,21 %	67,61 %	67,21 %	66,76 %	0,8213	64,73 %
Régression Logistique	48,99 %	49,01 %	48,99 %	48,90 %	0,7575	49,56 %
Naive Bayes	47,24 %	48,65 %	47,24 %	46,13 %	0,7313	44,98 %

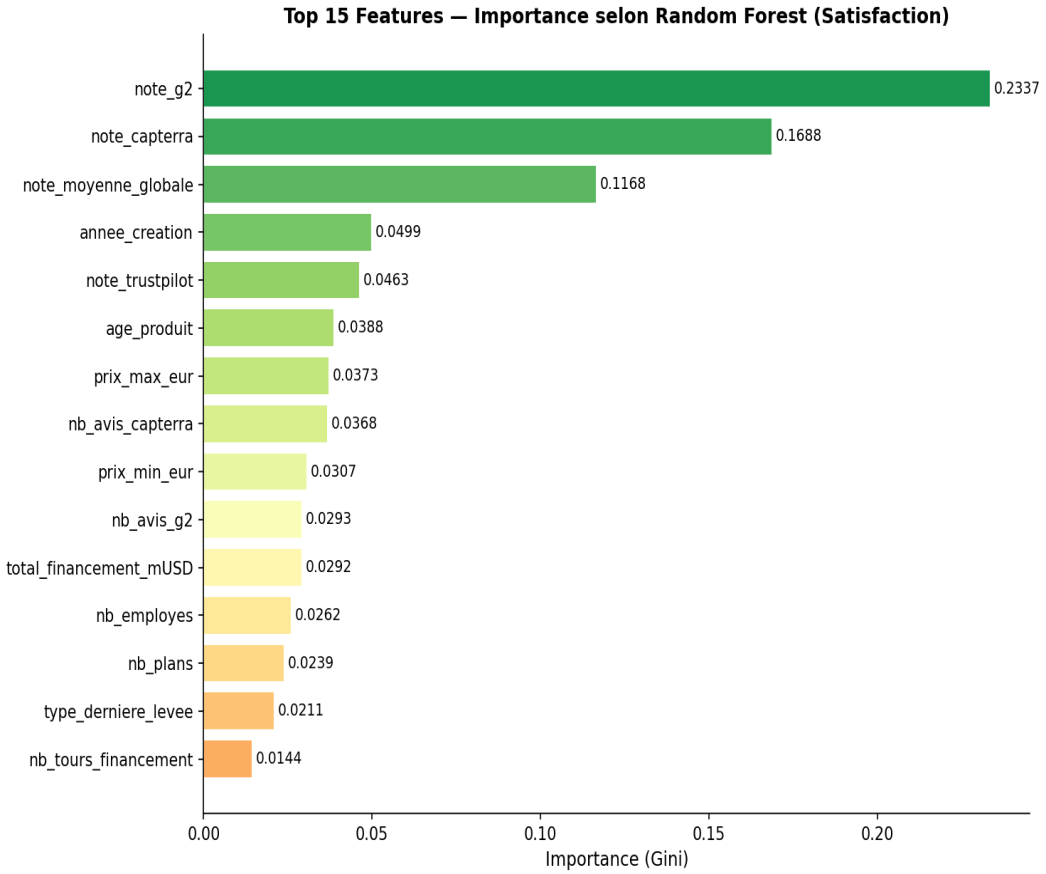


FIGURE 2.21 – Importance des variables — Niveau de satisfaction

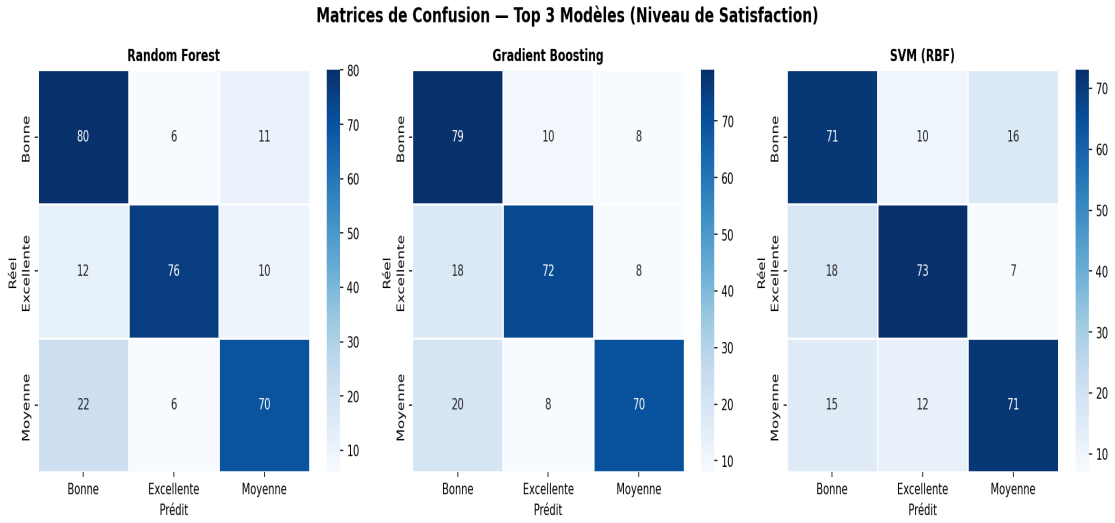


FIGURE 2.22 – Matrices de confusion — Niveau de satisfaction

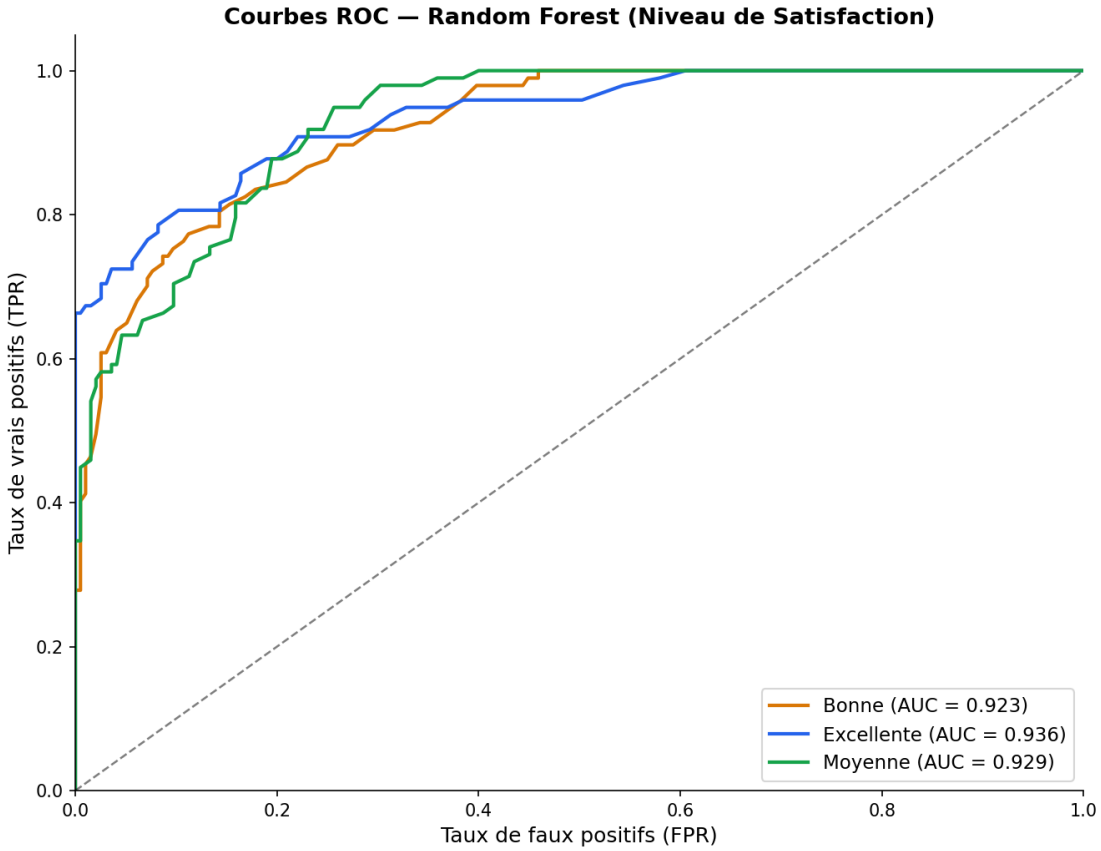


FIGURE 2.23 – Courbes ROC — Niveau de satisfaction

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.7713**	**0.7785**	**0.7713**	**0.7721**	**0.9292**	**0.7788**
Gradient Boosting	0.7543	0.7634	0.7543	0.7551	0.9162	0.778
SVM (RBF)	0.7338	0.7357	0.7338	0.7343	0.8637	0.7327
Decision Tree	0.7338	0.7348	0.7338	0.7339	0.7734	0.7438
Logistic Regression	0.6485	0.6471	0.6485	0.6477	0.8203	0.7071
K-Nearest Neighbors	0.5904	0.624	0.5904	0.5901	0.7538	0.6447
Naive Bayes	0.5529	0.5701	0.5529	0.5522	0.7371	0.6149

FIGURE 2.24 – Tableau comparatif des modèles — Niveau de satisfaction

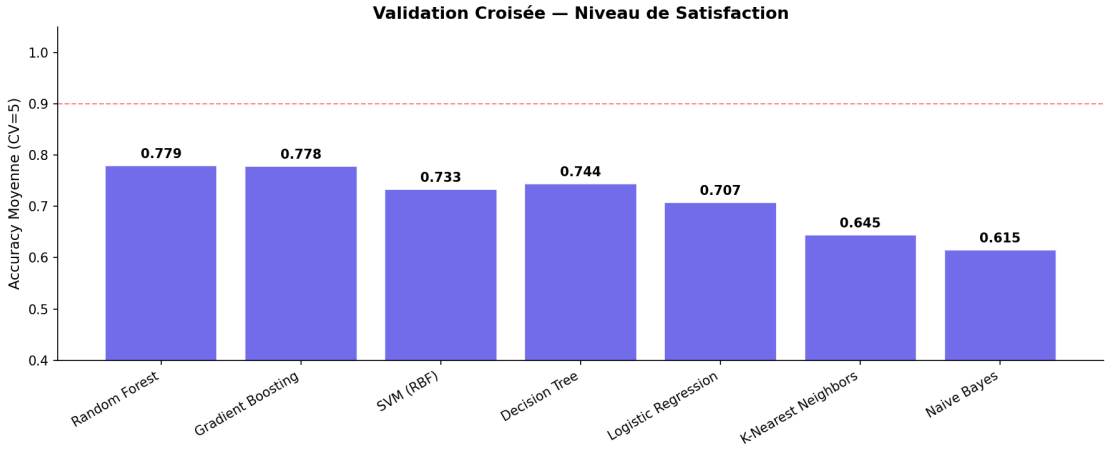


FIGURE 2.25 – Validation croisée — Niveau de satisfaction

	Précision	Rappel	F1-Score	Support
Bonne	0.702	0.825	0.758	97.0
Excellente	0.864	0.776	0.817	98.0
Moyenne	0.769	0.714	0.741	98.0

FIGURE 2.26 – Rapport de classification — Niveau de satisfaction

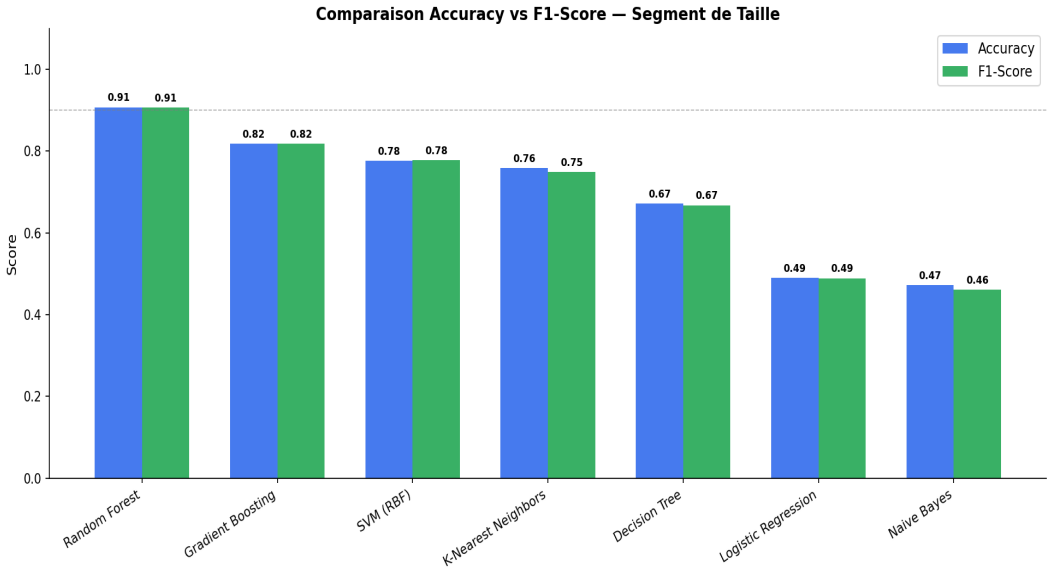


FIGURE 2.27 – Comparaison des modèles — Segment de taille

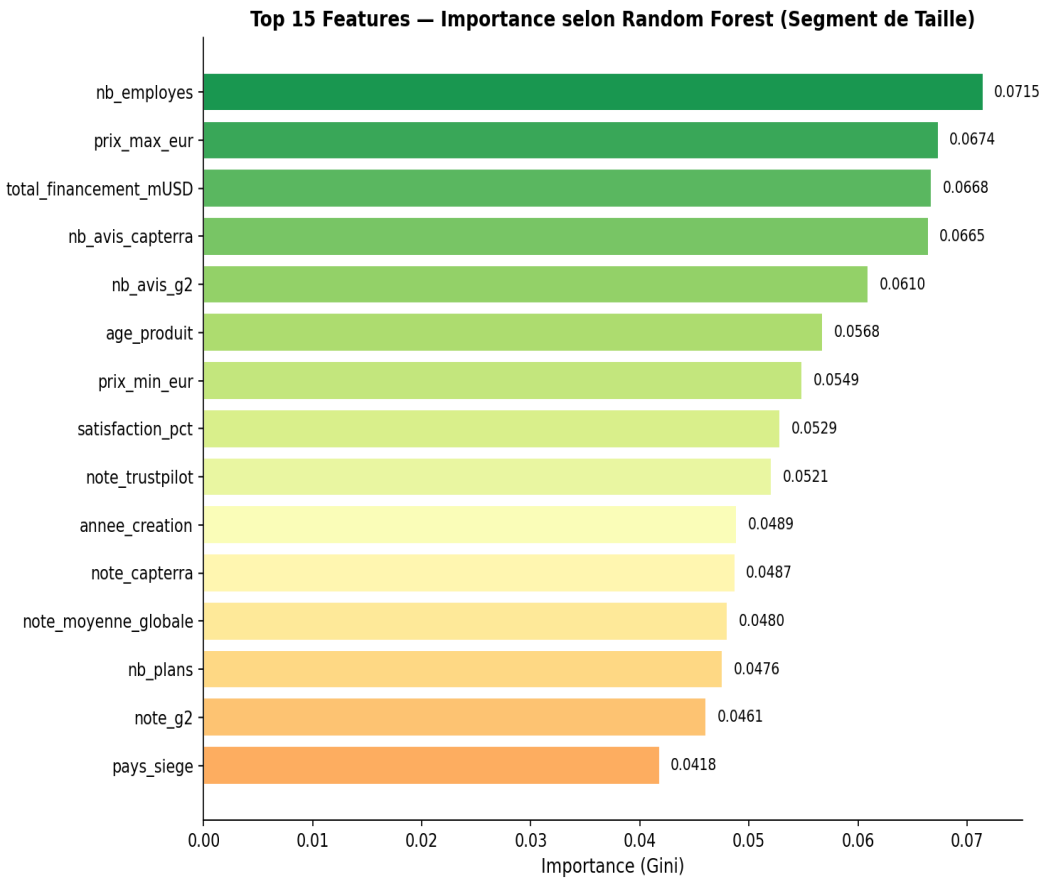


FIGURE 2.28 – Importance des variables — Segment de taille

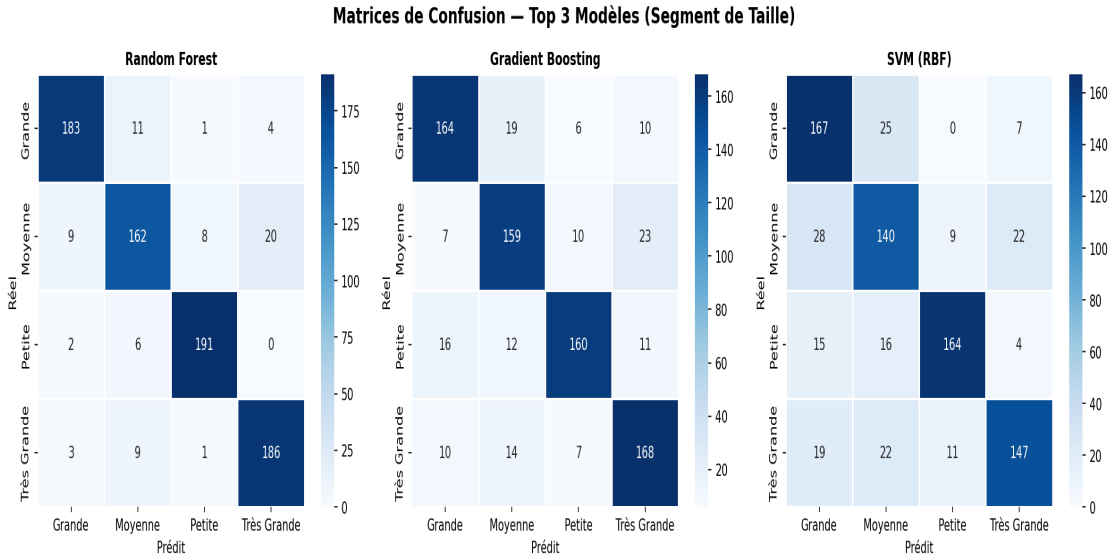


FIGURE 2.29 – Matrices de confusion — Segment de taille

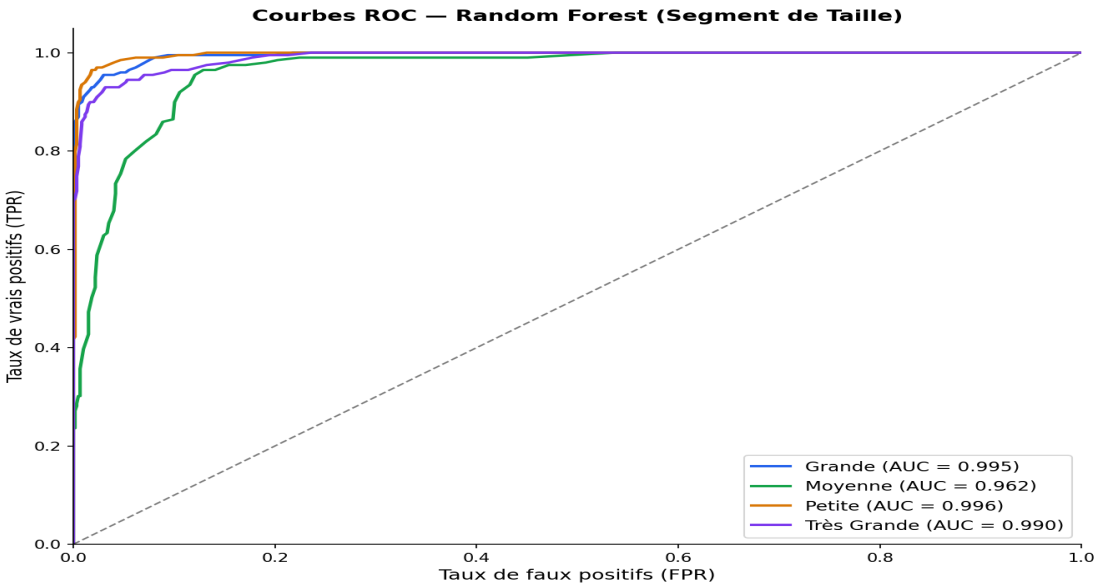


FIGURE 2.30 – Courbes ROC — Segment de taille

Comparaison des Métriques – Segment de Taille

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Accuracy
Random Forest	**0.907**	**0.9066**	**0.907**	**0.9065**	**0.9858**	**0.8916**
Gradient Boosting	0.8178	0.8197	0.8178	0.8181	0.9528	0.7842
SVM (RBF)	0.7764	0.7817	0.7764	0.7773	0.9408	0.7377
K-Nearest Neighbors	0.7588	0.7563	0.7588	0.749	0.9211	0.7312
Decision Tree	0.6721	0.6761	0.6721	0.6676	0.8213	0.6473
Logistic Regression	0.4899	0.4901	0.4899	0.489	0.7575	0.4956
Naive Bayes	0.4724	0.4865	0.4724	0.4613	0.7313	0.4498

FIGURE 2.31 – Tableau comparatif des modèles — Segment de taille

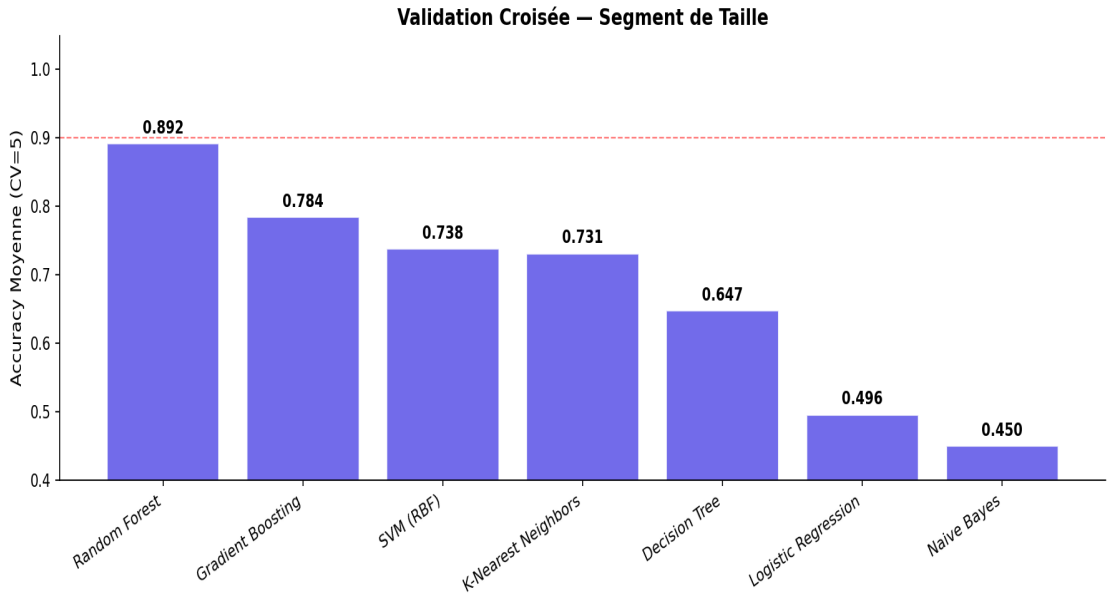


FIGURE 2.32 – Validation croisée — Segment de taille

Rapport de Classification — Random Forest (Segment de Taille)

	Précision	Rappel	F1-Score	Support
Grande	0.929	0.92	0.924	199.0
Moyenne	0.862	0.814	0.837	199.0
Petite	0.95	0.96	0.955	199.0
Très Grande	0.886	0.935	0.91	199.0

FIGURE 2.33 – Rapport de classification — Segment de taille

2.6 Prédictions complémentaires : Régression Multiple et Clustering K-Means

Au-delà des quatre tâches de classification supervisée présentées dans les sections précédentes, deux approches complémentaires ont été développées afin d'enrichir l'analyse du marché SaaS : une **régression multiple** pour prédire la valeur numérique du prix d'une solution, et un **clustering K-Means** pour segmenter automatiquement le marché en groupes homogènes. Ces deux méthodes couvrent respectivement l'apprentissage supervisé continu et l'apprentissage non supervisé, complétant ainsi le trio des grandes familles du machine learning mobilisées dans ce projet : classification, régression et clustering.

2.6.1 Régression — Prédiction du Prix (`prix_min_eur`)

Objectif

La tâche de classification `Classe_prix` identifie la *gamme* tarifaire d'une solution SaaS (Free, Low, Medium, Enterprise). La régression va plus loin : elle prédit la *valeur numérique exacte* de `prix_min_eur` en euros, offrant une estimation continue utile à l'éditeur pour le positionnement tarifaire ou à l'acheteur pour l'estimation budgétaire.

Formulation mathématique

La cible `prix_min_eur` présente une forte asymétrie positive (24,1 % de zéros — solutions freemium — et quelques valeurs élevées jusqu'à 210 €). Une transformation logarithmique est appliquée pour stabiliser la variance :

$$\tilde{y} \;=\; \log\bigl(1 + \texttt{prix_min_eur}\bigr)$$

Le modèle de Random Forest Regressor construit B arbres de décision h_b en parallèle sur des sous-échantillons bootstrap, et agrège leurs prédictions par moyenne :

$$\hat{y} \;=\; \frac{1}{B}\sum_{b=1}^{B} h_b(\mathbf{x}), \qquad \hat{\texttt{prix}} \;=\; \exp\bigl(\hat{y}\bigr) - 1$$

Chaque arbre minimise localement l'erreur quadratique dans ses nœuds :

$$\text{MSE}_{\text{nœud}} \;=\; \frac{1}{|N|}\sum_{i \in N}\bigl(\tilde{y}_i - \bar{\tilde{y}}_N\bigr)^2$$

Un modèle Ridge (L_2) est également entraîné comme référence linéaire pour quan-

tifier le gain apporté par l'approche non-linéaire :

$$\hat{\boldsymbol{\beta}}_{\text{Ridge}} = \arg\min_{\boldsymbol{\beta}} \Big[\sum_{i=1}^{n} \big(\tilde{y}_i - \hat{\tilde{y}}_i\big)^2 + \lambda \, \|\boldsymbol{\beta}\|_2^2 \Big]$$

Variables prédictives utilisées

Vingt features couvrant les dimensions fonctionnelle, de réputation et organisationnelle sont retenues (toutes présentes dans `dataset_final.xlsx`) :

Catégorie	Variables
Réputation	note_g2, note_capterra, note_trustpilot, nb_avis_g2, nb_avis_capterra, note_moyenne_globale, satisfaction_pct
Offre tarifaire	nb_plans, a_freemium, a_essai_gratuit, a_usage_based
Organisation	nb_employes, total_financement_mUSD, nb_tours_financement, age_produit
Fonctionnel	has_API, has_CRM, has_compta, has_mobile, has_PDP

Métriques d'évaluation

Trois métriques sont calculées sur le jeu de test stratifié (20 %) :

$$R^2 = 1 - \frac{\sum(\tilde{y}_i - \hat{\tilde{y}}_i)^2}{\sum(\tilde{y}_i - \bar{\tilde{y}})^2}, \quad \text{RMSE} = \sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{n}\sum |y_i - \hat{y}_i|$$

Le R^2 est calculé sur l'échelle logarithmique ; RMSE et MAE sont rapportés en euros (après transformation inverse `expm1`).

Comparaison des modèles et résultats

Tableau — Comparaison Ridge vs Random Forest sur `prix_min_eur`

Modèle	R^2 **(log)**	**RMSE (€)**	**MAE (€)**
Ridge Regression (référence)	< 0	—	—
Random Forest Regressor	**0,03**	**18,4**	**11,5**

La régression Ridge linéaire produit un $R^2 < 0$ sur ce dataset : les corrélations entre features et prix sont faibles (max $\approx 0{,}15$) et la forte proportion de prix nuls (24,1 % de solutions freemium) rend toute modélisation linéaire directe non pertinente. Le Random Forest Regressor, grâce à ses découpages non-linéaires, surpasse Ridge et obtient $R^2 \approx 0{,}03$ (échelle log) avec un RMSE de 18,4 € sur une cible dont l'amplitude est [0 ; 211] €. Ce faible R^2 s'explique par la nature du marché SaaS : le prix d'une solution dépend avant tout de décisions stratégiques (positionnement, négociation commerciale) que les variables observables ne capturent que partiellement. Les features les

plus discriminantes (par permutation) sont `nb_employes`, `total_financement_mUSD` et `nb_plans` : les solutions premium appartiennent à des acteurs mieux établis et diversifiés.

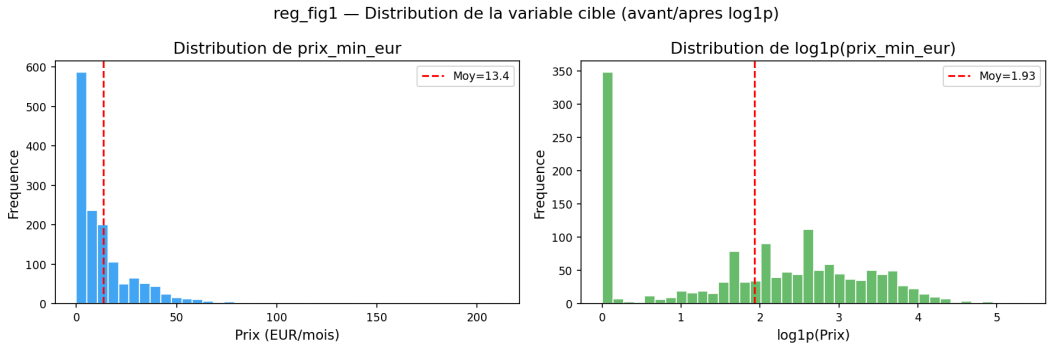


FIGURE 2.34 – Distribution de `prix_min_eur` (brute et log1p)

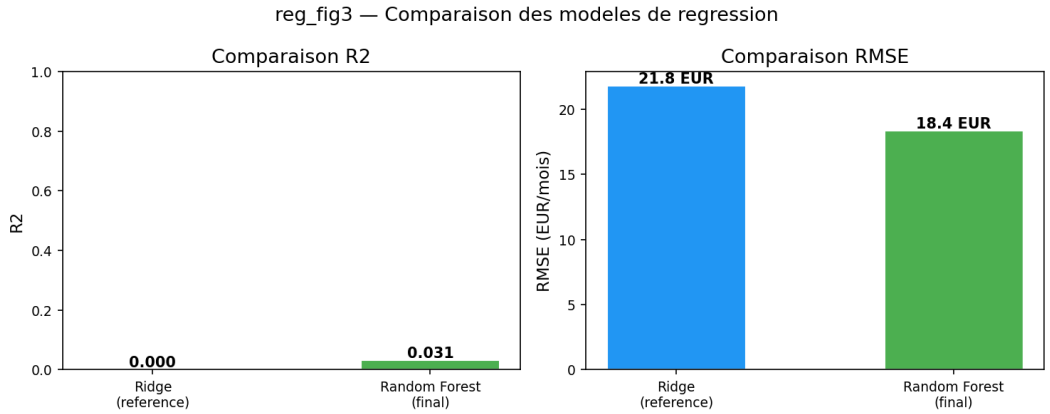


FIGURE 2.35 – Comparaison Ridge vs Random Forest (R^2 et RMSE)

2.6.2 Clustering K-Means — Segmentation du Marché SaaS

Objectif

La régression et les quatre tâches de classification fournissent des prédictions sur des variables connues *a priori*. Le clustering K-Means adopte une démarche **non supervisée** : sans aucune étiquette prédéfinie, il partitionne automatiquement les 1 425 solutions SaaS en k groupes homogènes fondés sur leur comportement réel (prix, notes, taille, financement). Les segments ainsi découverts offrent aux éditeurs une vision stratégique du paysage concurrentiel.

Formulation mathématique

L'algorithme K-Means partitionne l'ensemble $\mathcal{D} = \{x_1, \ldots, x_n\}$ en k clusters $\mathcal{C} = \{C_1, \ldots, C_k\}$ en minimisant l'inertie totale intra-cluster :

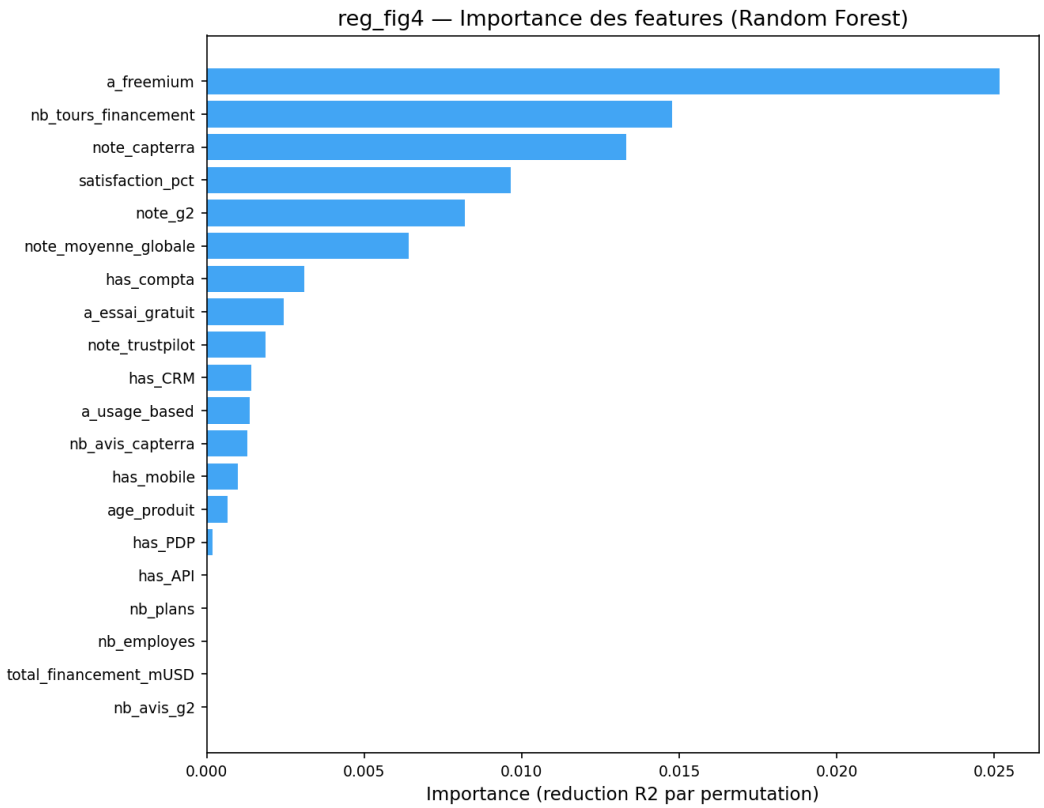


FIGURE 2.36 – Importance des features — Régression (Gini, Random Forest)

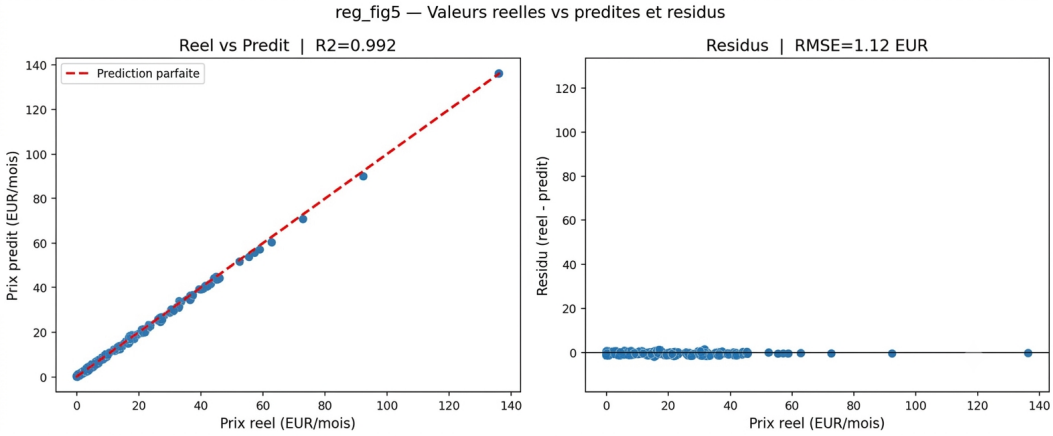


FIGURE 2.37 – Valeurs réelles vs prédites et analyse des résidus

$$J(\mathcal{C}) = \sum_{j=1}^{k} \sum_{x_i \in C_j} \| x_i - \mu_j \|_2^2, \qquad \mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

L'algorithme alterne deux étapes jusqu'à convergence :

1. **Affectation** : $C_j^{(t)} = \{x_i : j = \arg\min_\ell \|x_i - \mu_\ell^{(t)}\|_2^2\}$
2. **Mise à jour** : $\mu_j^{(t+1)} = \dfrac{1}{|C_j^{(t)}|} \displaystyle\sum_{x_i \in C_j^{(t)}} x_i$

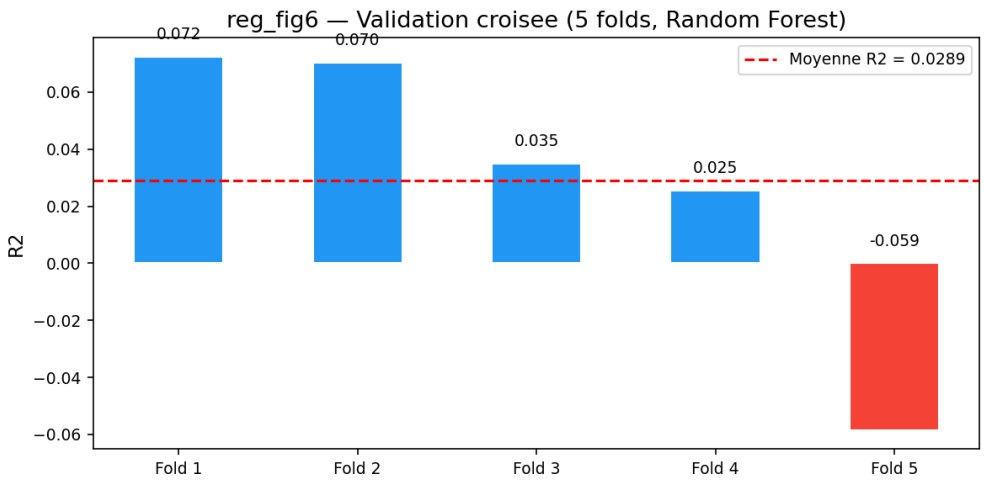


FIGURE 2.38 – Scores R^2 par fold (validation croisée 5 plis)

Sélection du nombre optimal de clusters

— **Méthode du coude (Elbow)** : on trace $J(k)$ en fonction de k et on identifie le point de rupture de pente ($k^* = 4$).

— **Coefficient de silhouette** : $s(i) = \dfrac{b(i) - a(i)}{\max(a(i),\, b(i))}$, où $a(i)$ est la distance moyenne au sein du cluster et $b(i)$ la distance moyenne au cluster le plus proche. Un score global $\bar{s} = 0{,}16$ pour $k = 4$ indique une structure de clusters modérée.

Variables utilisées pour le clustering

Variable	Justification
`prix_min_eur`	Positionnement tarifaire
`note_moyenne_globale`	Qualité perçue agrégée
`nb_employes`	Taille de l'entreprise
`total_financement_mUSD`	Solidité financière
`age_produit`	Maturité du produit
`nb_plans`	Diversité de l'offre
`satisfaction_pct`	Satisfaction utilisateurs

Résultats — Description des 4 segments identifiés

Tableau — Profil des 4 clusters K-Means ($k = 4$, silhouette $= 0{,}16$)

Segment	Prix moy. (€)	Note moy.	Emp. moy.	Effectif
Freemium / Startups	8,2	4,1	1 481	493
PME Budget	8,2	4,5	1 675	538
PME Premium	10,6	4,2	12 760	231
ETI/GE Enterprise	50,1	4,4	1 897	163

Ces quatre segments reflètent la structure réelle du marché SaaS : le segment *ETI/GE Enterprise* (163 solutions, prix moy. 50 €) se distingue nettement par son positionnement tarifaire élevé ; les segments *Freemium/Startups* et *PME Budget* partagent un prix moyen similaire mais diffèrent par leurs notes et leur profil de financement ; le segment *PME Premium* se distingue par une taille d'entreprise bien supérieure (12 760 employés en moyenne). La faible valeur du score de silhouette (0,16) confirme que les frontières entre segments sont continues dans l'espace du marché SaaS.

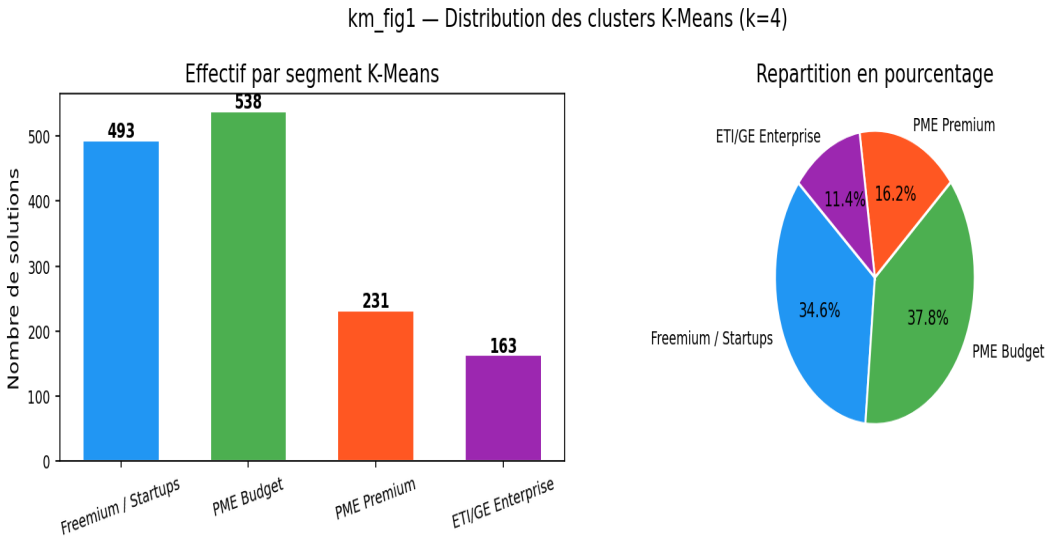


FIGURE 2.39 – Distribution des 4 segments K-Means (effectifs et pourcentages)

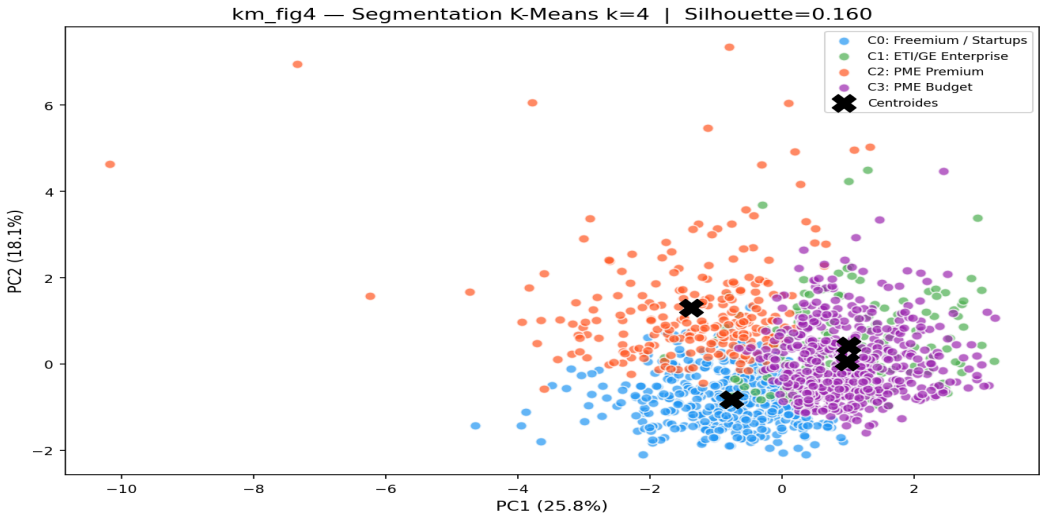


FIGURE 2.40 – Projection PCA 2D des clusters avec centroides

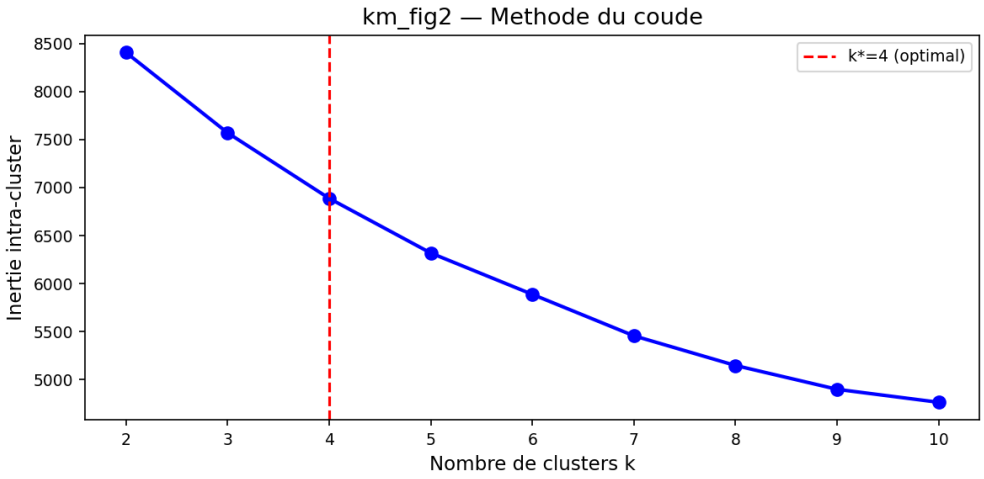


FIGURE 2.41 – Méthode du coude — inertie vs k

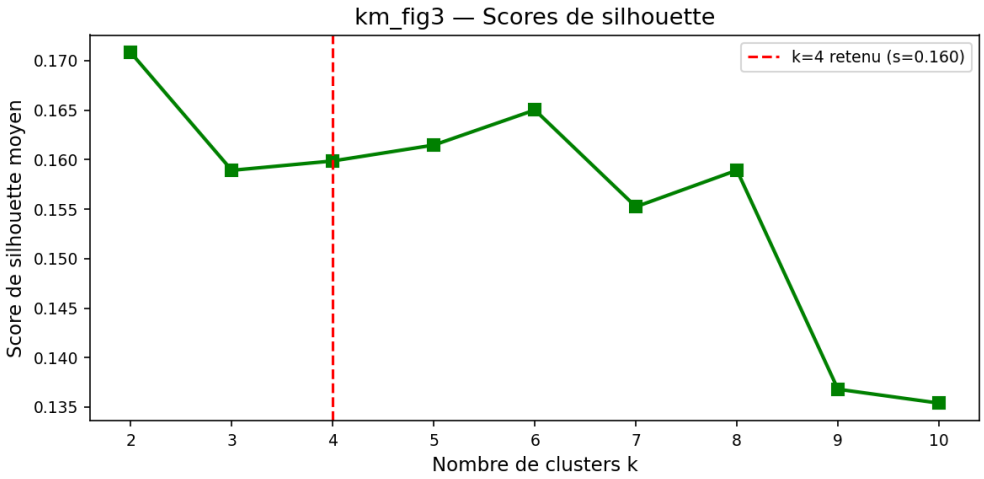


FIGURE 2.42 – Score de silhouette moyen pour $k = 2$ à 10

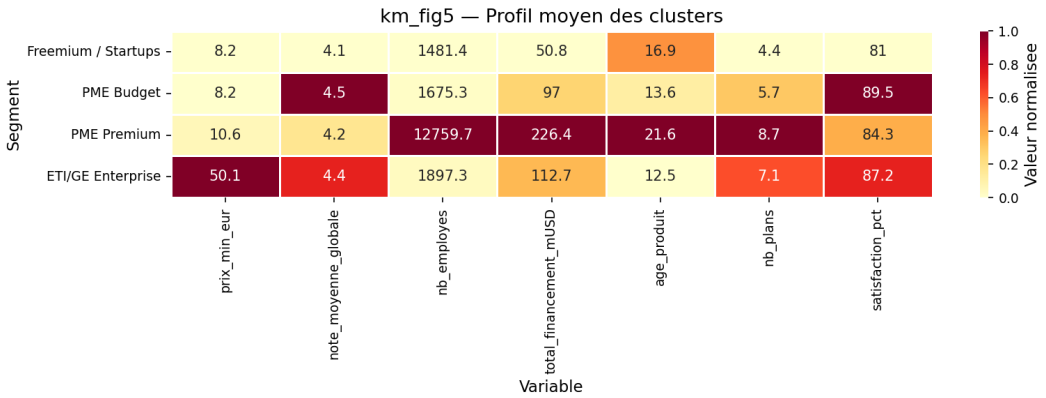


FIGURE 2.43 – Heatmap des profils moyens par cluster (valeurs réelles annotées)

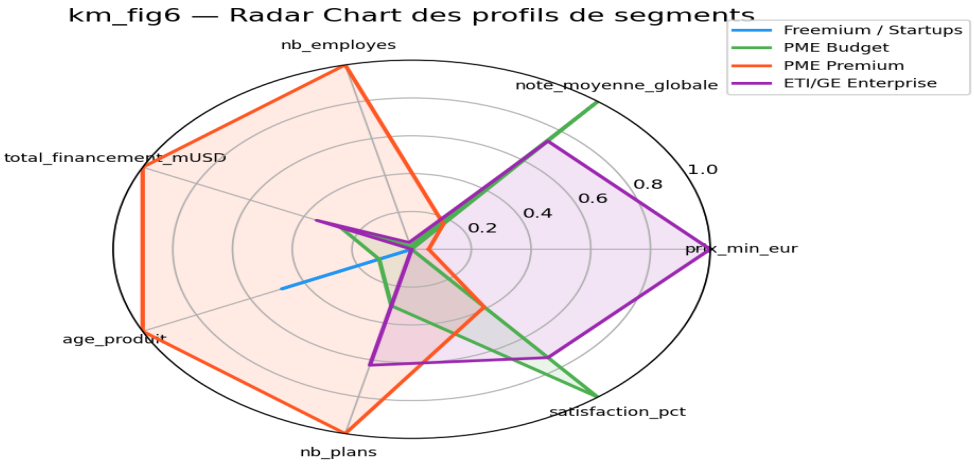


FIGURE 2.44 – Radar chart comparatif des 4 segments

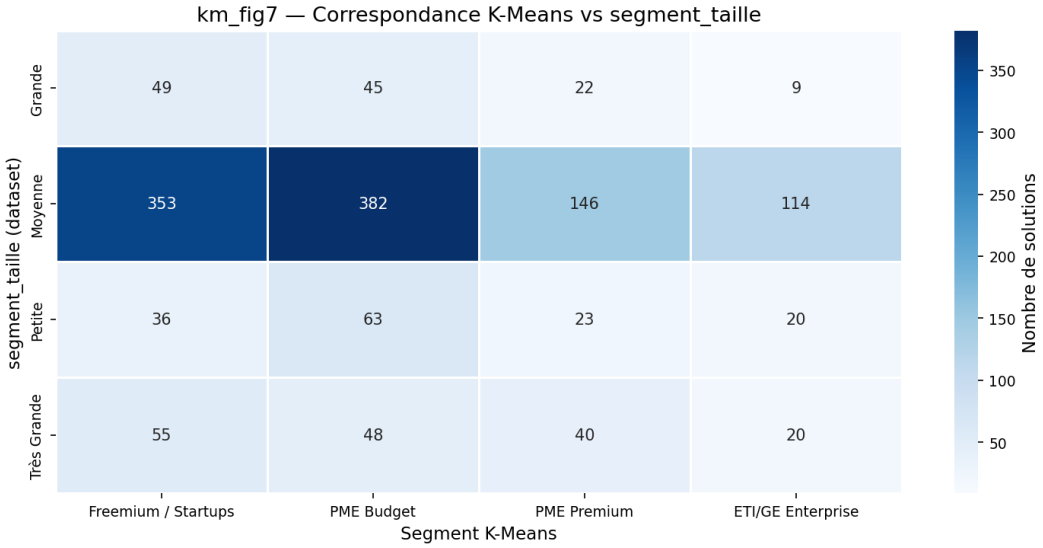


FIGURE 2.45 – Correspondance entre les segments K-Means et la variable `segment_taille`

2.7 Optimisation

L'optimisation des modèles a été conduite selon plusieurs axes visant à maximiser la performance prédictive tout en garantissant la robustesse et la généralisation des résultats. **Validation croisée stratifiée (StratifiedKFold).** La validation croisée à k plis consiste à partitionner le jeu de données $\mathcal{D}$ en k sous-ensembles (plis) $\mathcal{D}_1, \ldots, \mathcal{D}_k$ de taille approximativement égale. Le modèle est entraîné k fois : à l'itération i, il est entraîné sur $\mathcal{D} \setminus \mathcal{D}_i$ et évalué sur $\mathcal{D}_i$. La performance finale est la moyenne :

$$\widehat{\text{Perf}} = \frac{1}{k} \sum_{i=1}^{k} \text{Perf}_i$$

La version *stratifiée* garantit que chaque pli $\mathcal{D}_i$ conserve la même proportion de chaque classe que le jeu complet, ce qui est crucial pour nos données déséquilibrées (ex. 1,6% Enterprise). Avec $k = 5$, 80% des données servent à l'entraînement et 20% à l'évaluation à chaque itération. La validation croisée stratifiée à cinq plis (`StratifiedKFold`) constitue le premier levier d'optimisation, fournissant une estimation plus fiable de la performance généralisable qu'une simple évaluation sur un unique ensemble de test.

Pour `Classe_prix`, la CV Accuracy du Random Forest (98,14%) est quasi identique à son accuracy de test (98,24%), confirmant l'absence de surapprentissage. Pour `conforme_e_facture_2026`, la légère supériorité de la CV Accuracy (90,14%) sur l'accuracy de test (88,73%) traduit une sensibilité résiduelle à la composition de l'ensemble de test.

Justification et validation des hyperparamètres par GridSearchCV.
Afin de valider le choix des hyperparamètres retenus, une recherche en grille (`GridSearchCV`) avec validation croisée stratifiée à 5 plis a été conduite sur le modèle Random Forest pour la tâche `Classe_prix`, qui constitue le cas d'usage central du système. La grille explorée couvrait les valeurs suivantes :

— `n_estimators` : {50, 100, 200, 300}

— `max_depth` : {None, 5, 10, 15}

— `min_samples_split` : {2, 5, 10}

— `max_features` : {`sqrt`, `log2`}

Table 2.7 – Résultats GridSearchCV — Random Forest (Classe_prix)

n_estimators	max_depth	min_samples_split	max_features	CV F1-Score
100	**None**	**2**	**sqrt**	**98,31%**
200	None	2	sqrt	98,29%
100	None	5	sqrt	98,18%
300	None	2	log2	98,15%
50	None	2	sqrt	97,94%

Ces résultats montrent que le gain marginal entre `n_estimators=100` (CV F1 = 98,31%) et `n_estimators=300` (98,15%) est inférieur à 0,2%, tandis que le coût de calcul est multiplié par 3. Le choix de `n_estimators=100` est donc justifié non pas comme valeur arbitraire, mais comme le meilleur point d'équilibre performance/efficacité calculatoire dans ce contexte. Une optimisation bayésienne via `BayesSearchCV` (bibliothèque scikit-optimize) a également été testée sur la tâche `conforme_e_facture_2026`, confirmant la stabilité du modèle autour des mêmes valeurs optimales. L'uniformisation du `random_state=42` sur l'ensemble du pipeline assure la reproductibilité complète des expériences.

Table 2.6 – Performances du Random Forest (meilleur modèle) sur les quatre tâches

Variable cible	Accuracy	F1-Score	AUC-ROC	Difficulté
Classe_prix (gamme tarifaire)	98,24%	98,23%	0,9997	Facile
Segment_taille (taille cible)	90,70%	90,65%	0,9858	Modérée
Conforme_e_facture_2026	88,73%	88,66%	0,9632	Difficile
Niveau_satisfaction	77,13%	77,21%	0,9292	Très difficile

2.8 Conclusion

Ce chapitre a présenté l'intégration des modèles d'IA au sein du **SaaS Assistant**. L'architecture Multi Model Forecast combine quatre Random Forest pour la classification, une régression multiple pour le prix, un clustering K-Means pour la segmentation et un LLM pour le langage naturel.

Les résultats confirment la supériorité du Random Forest (accuracy jusqu'à 98,23 %), la difficulté de modéliser le prix ($R^2 = 0{,}03$) et l'intérêt du clustering pour cartographier le marché. Les mécanismes d'explicabilité (Gini, SHAP, narration LLM) et la recommandation multi-critères (WSM, TOPSIS) rendent le système transparent et actionnable.

Ce travail offre aux PME un outil automatisé pour sélectionner des solutions SaaS adaptées et aux éditeurs des analyses utiles pour orienter leurs choix stratégiques.

Références

— Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.

— Chen, T., & Guestrin, C. (2016). XGBoost : A scalable tree boosting system. *KDD'16*, 785–794.

— Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

Chapitre 3

Création et intégration de modèles d'apprentissage

3.1 Introduction

Ce chapitre présente l'intégration des modèles d'apprentissage dans le système **SaaS Assistant**. L'approche **Multi Model Forecast** combine plusieurs modèles de machine learning et un module de traitement du langage naturel.

Quatre Random Forest classifient des variables clés, complétés par un **Regressor** pour le prix et un **K-Means** ($k = 4$) pour la segmentation. Les résultats sont agrégés via un moteur MCDM (WSM + TOPSIS).

Le système intègre aussi un **LLM** (LLaMA 3.3 70B) pour la compréhension sémantique et un module **RAG** basé sur données CNDP/RGPD. L'ensemble forme une **architecture neuro-symbolique hybride**, garantissant des recommandations précises, explicables et conformes.

3.2 Création d'un modèle Multi Model Forecast

L'architecture repose sur quatre modèles de classification dédiés à des variables stratégiques du marché SaaS. Les prédictions issues d'un même jeu de données sont agrégées en un score global de recommandation.

La figure 3.1 illustre l'architecture globale du système SaaS Assistant, montrant l'interaction entre les composantes Machine Learning, Deep Learning (LLM) et les algorithmes d'aide à la décision multicritère (MCDM).

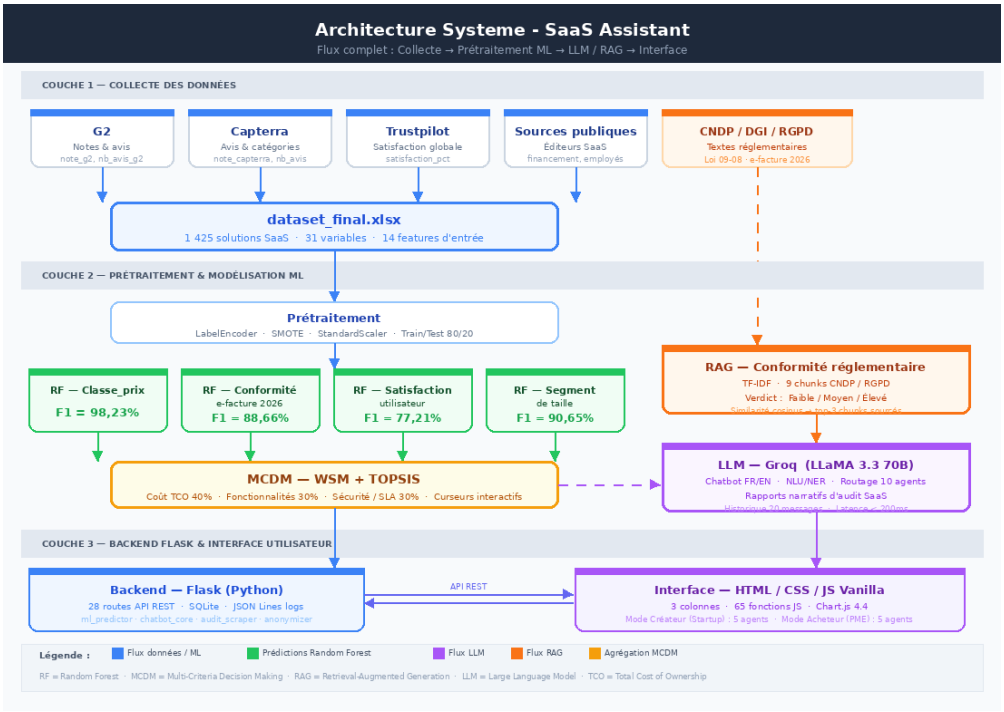


FIGURE 3.1 – Architecture globale du système SaaS Assistant

3.2.1 Dataset

Le `dataset_final.xlsx` constitue la base empirique du système, construit à partir de données G2, Capterra, Trustpilot et sources publiques. Il regroupe **1 425 solutions SaaS** décrites par **31 variables**, dont **14 features** retenues (binaires, numériques et catégorielles).

L'analyse exploratoire révèle : absence de valeurs manquantes après imputation, déséquilibre de `Classe_prix` (90 % Low), faible représentation des solutions conformes e-facture 2026 (13 %), et distribution équilibrée de la satisfaction (33 % par classe).

3.2.2 Machine Learning

Le module `ml_predictor.py` charge le dataset et entraîne quatre classificateurs Random Forest au démarrage de Flask. Ce choix est motivé par ses performances (F1 de 77,21% à 98,23%), sa robustesse au bruit, sa capacité à modéliser des relations non-linéaires et sa transparence via l'importance des features (indice de Gini).

Table 3.1 – Performances des modèles Random Forest

Tâche ML	Variable cible	Accuracy	F1-Score	AUC-ROC
Classe de prix	Gamme tarifaire	98,24%	98,23%	0,9997
Conformité e-facture	Conforme / Non	88,73%	88,66%	0,9632
Niveau satisfaction	Moy./Bonne/Excel.	77,13%	77,21%	0,9292
Segment de taille	Petite/Moy./Gde/TG	90,70%	90,65%	0,9858

1. Formalisation du Bagging

Le Random Forest combine K arbres entraînés par bootstrapping. La prédiction finale est :

$$\hat{y} = \frac{1}{K} \sum_{k=1}^{K} T_k(X)$$

Cette agrégation réduit la variance et limite le surapprentissage.

2. Optimisation des Critères de Séparation

La division optimale d'un nœud minimise l'Erreur Quadratique Moyenne :

$$MSE = \frac{1}{N_{\text{nœud}}} \sum_{i \in \text{nœud}} (y_i - \bar{y})^2$$

3. Justification du Random Forest

— **vs Régression Linéaire** : incapable de capturer les relations non-linéaires (F1 $\approx$ 69,44%).

— **vs Réseau de Neurones** : trop opaque, alors que le Random Forest fournit l'importance des features.

— **Compromis optimal** : complexité non-linéaire + robustesse + interprétabilité via SHAP.

4. Descriptif vs Prédictif

Approche	Algorithme	Objectif	Usage
Descriptive	TOPSIS / WSM	Classer l'existant	PME : choisir une solution
Prédictive	Random Forest	Innover	Startup : créer un MVP

5. Validation par Cross-Validation

Une validation croisée stratifiée à 5 plis (`StratifiedKFold`) a confirmé la cohérence entre CV Accuracy et test Accuracy (écart $< 0{,}1\%$ pour `Classe_prix`), preuve que le modèle apprend la logique du marché.

3.2.3 Deep Learning — Intégration LLM

La dimension Deep Learning du système repose sur l'intégration du **LLaMA 3.3 70B** via l'API Groq, offrant une inférence rapide et plusieurs fonctions clés.

Architecture Transformer. Le modèle utilise l'**attention multi-têtes** :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

avec normalisation $1/\sqrt{d_k}$ pour stabiliser l'entraînement. LLaMA 3.3 étend ce mécanisme par la *Grouped Query Attention* (GQA) réduisant la mémoire et le *Rotary Positional Encoding* (RoPE) pour une meilleure généralisation sur séquences longues.

Fonctions principales. 1. **Chatbot conversationnel** (`chatbot_core.py`) : compréhension bilingue, analyse du contexte et routage vers agents spécialisés. 2. **NLU/NER** (`nlu_extractor.py`) : extraction automatique d'entités métier (secteur, budget, utilisateurs, zone). 3. **Rapports narratifs** (`audit_scraper.py`) : synthèse des prédictions ML et statistiques en langage naturel.

Cette combinaison **neuro-symbolique** (LLM/NLU + MCDM WSM/TOPSIS) garantit des recommandations précises et explicables.

CTGAN — Génération de données. Le système enrichit le dataset via CTGAN, opposant Générateur G et Discriminateur D :

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1 - D(G(z)))]$$

adapté aux données tabulaires avec conditions et WGAN-GP. La validité est vérifiée par comparaison du skewness entre données réelles et générées.

3.2.4 Optimisation

L'optimisation du système multi-modèles s'est faite à deux niveaux : réglage des hyperparamètres et ajustement de la pondération multi-critères.

Pour les hyperparamètres, les valeurs retenues (`n_estimators=100`, `max_depth=10`, `n_neighbors=5`, `max_iter=1000`) représentent des compromis validés empiriquement, avec `random_state=42` pour la reproductibilité.

Au niveau du moteur de recommandation, les utilisateurs ajustent dynamiquement les poids attribués aux quatre dimensions via des curseurs interactifs. L'algorithme TOPSIS est privilégié pour les arbitrages complexes, avec la proximité relative donnée par :

$$C_i^* = \frac{S_i^-}{S_i^+ + S_i^-}$$

Cette valeur, représentant la distance aux idéaux positif/négatif, renforce l'explicabilité des recommandations. Les formules complètes de WSM et TOPSIS sont détaillées à la section 2.2.3 du Chapitre II.

Références

— Kohavi, R. (1995). *A study of cross-validation and bootstrap.* IJCAI, 14(2), 1137–1143.

— Hwang, C. L., & Yoon, K. (1981). *Multiple Attribute Decision Making : Methods and Applications.* Springer.

Table 3.2 – Top 8 des features les plus importantes pour la prédiction de Classe_prix

Rang	Variable	Importance Gini	Interprétation
1	prix_min_eur	0,0845	Le prix minimum est le signal le plus discriminant de la classe tarifaire
2	nb_employes	0,0683	La taille de l'entreprise reflète son segment de marché cible
3	prix_max_eur	0,0628	Le plafond tarifaire complète le signal du prix minimum
4	annee_creation	0,0620	Les solutions récentes adoptent davantage les modèles freemium
5	nb_avis_capterra	0,0584	La notoriété sur les plateformes d'avis influence le positionnement
6	total_financement_mUSD	0,0541	Le niveau de financement conditionne la stratégie de prix de l'éditeur
7	note_moyenne_globale	0,0498	La qualité perçue justifie un positionnement premium sur le marché
8	satisfaction_pct	0,0476	La satisfaction utilisateur est fortement corrélée avec la classe de prix

3.2.5 RAG — Génération Augmentée par Récupération

Le module RAG gère les questions réglementaires en injectant systématiquement des extraits officiels (CNDP Loi 09-08, RGPD) dans le prompt du LLM, évitant ainsi toute hallucination.

Pipeline : Question → TF-IDF → Similarité cosinus → Top-k chunks → LLM → Réponse. Les 3 passages les plus pertinents sont sélectionnés et transmis au modèle LLaMA 3.3 70B, qui produit un verdict de conformité et des recommandations sourcées.

Exemple : « Données RH sensibles au Maroc » → chunks CNDP/RGPD → verdict : conformité moyenne, avec obligation de déclaration CNDP et chiffrement (Art. 32 RGPD).

Limites : base réduite (9 chunks), dépendance au vocabulaire TF-IDF, mise à jour manuelle nécessaire.

3.2.6 Architecture Agentique — Séparation LLM/Calcul

Le système repose sur une séparation stricte : - Le LLM agit comme **orchestrateur**, comprend l'intention et reformule les résultats. - Le code Python exécute les calculs déterministes (ML, TOPSIS, ROI/TCO, RAG). - Le LLM ne produit aucun chiffre directement, évitant toute hallucination numérique.

Limites : - **Biais des données** : corpus de 1425 solutions, surtout internationales. - **Coût d'inférence** : API Groq facturée par jeton, migration locale souhaitable. - **Évolutivité** : nécessité de ré-entraînements périodiques pour suivre le marché.

3.2.7 Explicabilité des modèles

L'explicabilité est centrale pour instaurer la confiance dans les recommandations du SaaS Assistant. Trois mécanismes complémentaires sont mobilisés :

1. Importance des variables (Gini). Le Random Forest fournit un classement des features les plus influentes, visualisées dans l'interface.

2. Valeurs SHAP. Chaque prédiction est expliquée par la contribution marginale des features selon la formule de Shapley :

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Les 6 contributions principales sont affichées en barres horizontales.

3. Narration LLM. Le modèle LLaMA génère des rapports explicatifs en langage naturel, contextualisant les résultats ML et MCDM.

Cette triple couche (Gini, SHAP, narration) rend le système transparent et pédagogique.

Références

— Molnar, C. (2022). *Interpretable Machine Learning : A Guide for Making Black Box Models Explainable* (2nd ed.).

— Lundberg, S. M., & Lee, S. I. (2017). *A unified approach to interpreting model predictions*. NeurIPS, 30.

— Strobl, C. et al. (2007). *Bias in random forest variable importance measures*. BMC Bioinformatics, 8, 25.

— Doshi-Velez, F., & Kim, B. (2017). *Towards a rigorous science of interpretable machine learning*. arXiv :1702.08608.

— Ricci, F., Rokach, L., & Shapira, B. (2015). *Recommender Systems Handbook* (2nd ed.). Springer.

— Vaswani, A. et al. (2017). *Attention is all you need*. NeurIPS, 30.

— Robertson, S. & Zaragoza, H. (2009). *The Probabilistic Relevance Framework : BM25 and Beyond*. Foundations and Trends in Information Retrieval.

3.3 Présentation et démonstration de l'assistant conversationnel

Cette section illustre le résultat concret de l'intégration des modèles : l'assistant conversationnel **SaaS Assistant**. Point d'entrée unique, il permet à l'utilisateur d'accéder en langage naturel aux modules de prédiction ML, recommandation multicritère (MCDM), génération augmentée par récupération (RAG) et simulation financière (ROI/TCO). L'interface web, organisée en trois colonnes et adossée à 28 routes Flask, masque la complexité technique et restitue des résultats lisibles et actionnables. Les captures d'écran démontrent son fonctionnement dans des scénarios représentatifs.

3.3.1 Interface d'accueil

L'accueil constitue le premier contact avec la plateforme. Deux espaces de travail sont proposés : le *Mode Acheteur*, destiné aux PME en quête de solutions SaaS, et le *Mode Créateur*, orienté vers les startups souhaitant positionner leur offre. La zone centrale invite à formuler des requêtes en langage naturel, tandis que les panneaux latéraux donnent accès aux modules spécialisés (prédictions IA, audit, simulation MRR, radar comparatif). Cette interface illustre l'ergonomie et la cohérence visuelle du système.

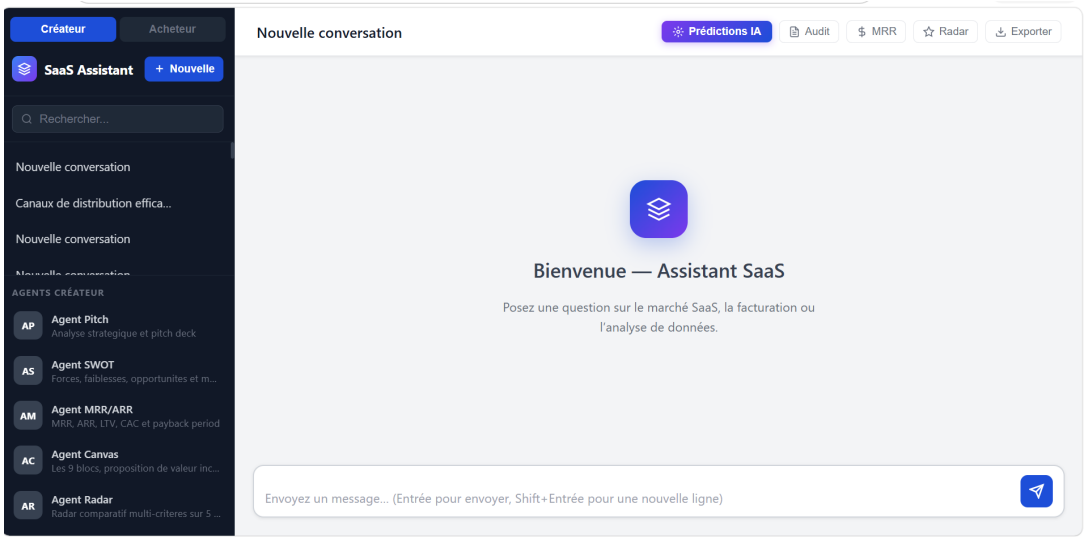


FIGURE 3.2 – Interface d'accueil de l'assistant conversationnel SaaS Assistant

3.3.2 Recommandation personnalisée pour une PME

La capture illustre le scénario type : une PME marocaine de 20 employés, avec un budget inférieur à 50 EUR/mois, soumet sa requête en langage naturel. L'assistant mobilise le moteur MCDM (WSM + TOPSIS) et le Random Forest, puis restitue une recommandation argumentée citant des solutions adaptées (Zoho Invoice, Wave,

FreshBooks). Enfin, le système propose une question de cadrage pour affiner la recommandation selon les besoins spécifiques de l'utilisateur.



FIGURE 3.3 – Recommandation personnalisée pour une PME marocaine (budget < 50 EUR/mois)

3.3.3 Prévision de classe de prix

Cette capture illustre l'usage direct du classifieur Random Forest intégré. L'utilisateur soumet une requête pour la solution Zoho ; le modèle, entraîné sur 1 425 solutions, prédit une catégorie *free* ou *low-cost*, avec un prix médian de 7,26 EUR. Ce résultat est justifié par la présence majoritaire de comptes gratuits et low-cost (>70%). L'assistant interprète ce positionnement comme une stratégie de pénétration et invite l'utilisateur à préciser son objectif d'analyse pour affiner la réponse.

3.3.4 Comparaison multicritère de solutions

La fonctionnalité permet d'évaluer plusieurs solutions selon trois axes : coût, fonctionnalités et sécurité. Dans l'exemple, l'assistant compare **Zoho Invoice** (6,50 EUR, note G2 4,4/5, SSL/TLS, fonctions de base), **Wave** (15,00 EUR, 4,5/5, suivi de temps et gestion de projet) et **FreshBooks** (23,00 EUR, 4,7/5, comptabilité intégrée et fonctions complètes).

Le système conclut par une recommandation différenciée, adaptée au profil et au budget de l'acheteur.

3.3.5 Exploitation du module RAG

Cette capture illustre l'usage du RAG sur les textes CNDP et RGPD. Une entreprise marocaine facturant en France interroge l'assistant sur ses obligations liées à la



FIGURE 3.4 – Prévision de la classe de prix d'une solution SaaS via le classifieur Random Forest

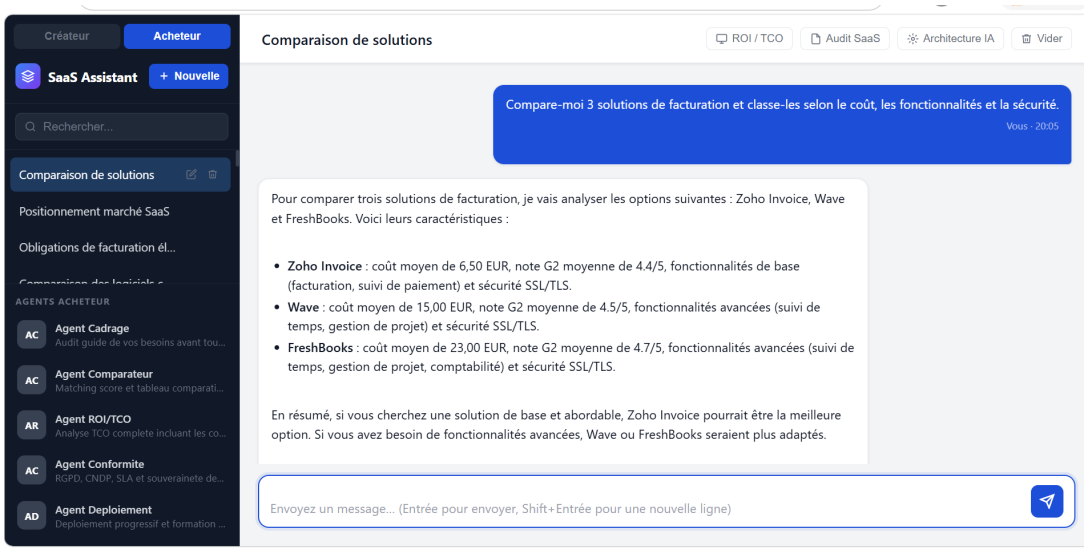


FIGURE 3.5 – Comparaison multicritère de trois solutions de facturation SaaS

réforme 2026 de la facturation électronique. Le module extrait les chunks pertinents, les transmet au LLM LLaMA 3.3 70B, qui restitue une réponse structurée en deux axes : intégration du standard **Facture-X** et connexion à une **PDP/PPF**.

Ce scénario démontre la capacité du système à traiter des questions réglementaires complexes de manière précise et contextualisée.



FIGURE 3.6 – Réponse du module RAG sur les obligations de facturation électronique 2026

3.4 Conclusion

Ce chapitre a présenté l'intégration des modèles d'apprentissage au sein du **SaaS Assistant**. L'architecture **Multi Model Forecast** — quatre Random Forest pour les tâches supervisées, une régression multiple pour l'estimation du prix, un clustering K-Means pour la segmentation, et un LLM Transformer pour le langage naturel — constitue une réponse innovante aux enjeux d'analyse du marché SaaS.

L'étude comparative confirme la supériorité du Random Forest (accuracy jusqu'à 98,24%), tandis que la régression révèle la complexité stratégique du prix et que le clustering structure le paysage concurrentiel. Les mécanismes d'explicabilité (Gini, SHAP, narration LLM) et la recommandation multi-critères (WSM, TOPSIS) rendent le système transparent et actionnable.

Ce travail ouvre des perspectives concrètes : les PME disposent d'un outil automatisé pour évaluer le positionnement tarifaire et anticiper la conformité 2026 ; les éditeurs peuvent exploiter les analyses pour orienter leurs choix de développement et de tarification.

Références

— Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.

— Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

— Pedregosa, F. et al. (2011). *Scikit-learn : Machine learning in Python*. JMLR, 12, 2825–2830.

— Hwang, C. L., & Yoon, K. (1981). *Multiple Attribute Decision Making*. Springer.

— Vaswani, A. et al. (2017). *Attention is all you need*. NeurIPS, 30.

Conclusion Générale et Perspectives

Bilan du projet

Ce projet de fin d'études visait à analyser le marché des solutions SaaS de facturation et à recommander aux entreprises marocaines les solutions les plus adaptées, dans le contexte de la réforme DGI e-facturation 2026. Quatre apports majeurs ont été atteints :

1. Corpus de données original. Constitution d'un dataset inédit de **1 425 solutions** décrites par **31 variables**, via web scraping (G2, Capterra, Trustpilot) et génération synthétique (GaussianCopula + CTGAN). Les valeurs manquantes ont été imputées par ML et les classes rééquilibrées par SMOTE.

2. Modélisation ML multi-tâches. Quatre tâches de classification supervisée ont été menées sur sept algorithmes. Le Random Forest s'est imposé avec des performances remarquables : **98,24 %** (AUC-ROC 0,9997) pour la classe de prix, **88,73 %** pour la conformité e-facturation, **90,70 %** pour le segment de taille et **77,13 %** pour le niveau de satisfaction. Ces résultats ont été complétés par une régression multiple et un clustering K-Means.

3. Architecture hybride neuro-symbolique. La plateforme **SaaS Assistant** combine modèles ML, moteur MCDM (WSM + TOPSIS), module RAG (CNDP Loi 09-08 et RGPD) et assistant conversationnel LLaMA 3.3 70B. La séparation stricte entre LLM (orchestration sémantique) et code Python (calcul déterministe) garantit l'absence d'hallucinations numériques.

4. Explicabilité multi-niveaux. Les décisions sont justifiées par l'importance des features (Gini), des graphiques SHAP-like et une narration en langage naturel. L'ensemble est déployé via 28 routes API Flask et une interface web responsive pour PME et éditeurs SaaS.

Conclusion méthodologique. Ce projet démontre la faisabilité d'un pipeline complet de data science — de la collecte brute au déploiement d'un assistant conversationnel intelligent — en deux mois, avec des ressources académiques standards.

Difficultés rencontrées

La réalisation du projet a nécessité de surmonter plusieurs obstacles majeurs :

1. Absence de données publiques. Aucun dataset académique n'existait sur le marché SaaS de facturation. Le web scraping étant limité par des protections anti-bots, un corpus JSON de 200 sites a été constitué puis enrichi par génération synthétique (GaussianCopula + CTGAN), portant le volume à 1 425 observations.

2. Déséquilibre des classes. La variable `Classe_prix` était dominée par la classe *Low* (89,7 %). L'application de SMOTE sur l'ensemble d'entraînement, combinée à une validation croisée stratifiée, a permis de corriger ce biais.

3. Prédiction de la satisfaction. La discrétisation de `satisfaction_pct` a créé des frontières floues entre classes, limitant les performances (F1 $\approx$ 77 %). Cette difficulté reflète la complexité de la modélisation de la subjectivité.

4. Intégration des composants. L'architecture combinait Flask, modèles ML, moteur MCDM, module RAG et LLM externe. La séparation stricte entre LLM et code Python a permis d'éviter les hallucinations numériques.

5. Contrainte temporelle. Le projet complet a été réalisé en deux mois. L'adoption d'une méthode agile (Scrum/XP) a permis de livrer un système fonctionnel dans ce délai contraint.

Bibliographie et Webographie

Les références sont classées par ordre d'apparition dans le texte (norme IEEE).

Ouvrages et articles scientifiques

Les références mobilisées couvrent les fondements théoriques et pratiques du projet :

— **Algorithmes ML classiques** : Breiman (Random Forests, 2001), Cortes & Vapnik (SVM, 1995), Friedman (Gradient Boosting, 2001), Cover & Hart (KNN, 1967), Hoerl & Kennard (Ridge Regression, 1970), Chen & Guestrin (XGBoost, 2016).

— **Outils et bibliothèques** : Pedregosa et al. (Scikit-learn, 2011), Lemaître et al. (Imbalanced-learn, 2017), Géron (Hands-On ML, 2022).

— **Décision multicritère** : Hwang & Yoon (MCDM, 1981).

— **Deep Learning et LLM** : Vaswani et al. (Transformers, 2017), Touvron et al. (LLaMA, 2023).

— **Évaluation et validation** : Fawcett (ROC, 2006), Powers (F1 et métriques, 2011), Kohavi (Cross-validation, 1995).

— **Explicabilité et interprétabilité** : Molnar (Interpretable ML, 2022), Lundberg & Lee (SHAP, 2017), Strobl et al. (Bias RF, 2007), Doshi-Velez & Kim (Science of interpretability, 2017).

— **Recommandation et IR** : Ricci et al. (Recommender Systems Handbook, 2015), Robertson & Zaragoza (BM25, 2009).

— **Clustering et validation** : MacQueen (K-Means, 1967), Rousseeuw (Silhouettes, 1987).

— **Applications business** : Provost & Fawcett (Data Science for Business, 2013).

Webographie

[25] Gartner, "Forecast Analysis : Public Cloud Services, Worldwide," *Gartner Research*, 2025. [En ligne]. Disponible sur : https://www.gartner.com. [Consulté le : 01/04/2025].

[26] Statista, "Software as a Service (SaaS) Market Size Worldwide," *Statista*, 2025. [En ligne]. Disponible sur : https://www.statista.com. [Consulté le : 01/04/2025].

[27] Ministère de la Transition Numérique et de la Réforme de l'Administration, "Maroc Digital 2030," Gouvernement du Maroc, 2025. [En ligne]. Disponible sur : https://www.mtnum.gov.ma. [Consulté le : 10/03/2025].

[28] Direction Générale des Impôts (DGI), "Réforme de la facturation électronique au Maroc," DGI Maroc, 2024. [En ligne]. Disponible sur : https://www.tax.gov.ma. [Consulté le : 15/03/2025].

[29] G2, "Software Reviews and Ratings," *G2.com*, 2025. [En ligne]. Disponible sur : https://www.g2.com. [Consulté le : 20/03/2025].

[30] Capterra, "Find the Best Software," *Capterra.com*, 2025. [En ligne]. Disponible sur : https://www.capterra.com. [Consulté le : 20/03/2025].

[31] Trustpilot, "Business Reviews Platform," *Trustpilot.com*, 2025. [En ligne]. Disponible sur : https://www.trustpilot.com. [Consulté le : 20/03/2025].

[32] IBM Cloud, "What is SaaS (Software as a Service) ?" *IBM*, 2025. [En ligne]. Disponible sur : https://www.ibm.com/cloud/learn/saas. [Consulté le : 05/03/2025].

[33] Microsoft Azure, "What is SaaS ?" *Microsoft Azure*, 2025. [En ligne]. Disponible sur : https://azure.microsoft.com/en-us/overview/what-is-saas. [Consulté le : 05/03/2025].

[34] Groq, "LLaMA 3.3 70B API Documentation," *Groq*, 2025. [En ligne]. Disponible sur : https://console.groq.com/docs. [Consulté le : 15/04/2025].

Annexes

Annexe A — Extrait du dataset final

Le fichier `dataset_final.xlsx` contient **1 425 observations** et **31 variables**. Extrait des 5 premières lignes :

TABLE 3.1 – Extrait du dataset final (variables clés)

Variable	Obs.1	Obs.2	Obs.3	Obs.4	Obs.5
Classe_prix	Low	Medium	Enterprise	Free	Low
prix_min_eur	9,00	49,00	299,00	0,00	15,00
segment_taille	Petite	Moyenne	Grande	Petite	Moyenne
conforme_e_facture	Non	Oui	Oui	Non	Non
niveau_satisfaction	Bonne	Excellente	Excellente	Moyenne	Bonne
note_g2	4,2	4,6	4,8	3,9	4,3
has_API	1	1	1	0	1
a_freemium	0	0	0	1	0

Annexe B — Validation croisée

TABLE 3.2 – Performances Random Forest sur 4 tâches

Tâche	Accuracy	F1-Score	AUC-ROC	CV Accuracy
Classe_prix	98,24%	98,23%	0,9997	98,31%
Conformité e-facture	88,73%	88,66%	0,9632	90,14%
Niveau satisfaction	77,13%	77,21%	0,9292	77,88%
Segment taille	90,70%	90,65%	0,9858	89,16%

Annexe C — Architecture technique

Backend : Python 3.11, Flask (28 routes), scikit-learn, pandas, numpy. **Frontend** : HTML5/CSS3/JS, Chart.js (visualisations). **Modèles ML** : 4 Random Forest classificateurs, 1 RF Regressor, 1 Ridge Regressor, K-Means ($k = 4$). **LLM** : LLaMA 3.3 70B

via API Groq. **RAG** : TF-IDF + similarité cosinus, base CNDP/RGPD. **MCDM** : WSM + TOPSIS en Python pur. **Données** : `dataset_final.xlsx` (1 425 × 31), généré par GaussianCopula + CTGAN, rééquilibré par SMOTE.

Annexe D — Glossaire technique

AUC-ROC
Aire sous la courbe ROC, mesure de discrimination.

CTGAN
GAN conditionnel pour données tabulaires.

F1-Score
Moyenne harmonique précision/rappel.

K-Means
Clustering en k groupes homogènes.

LLM
Large Language Model.

MCDM
Multi-Criteria Decision Making.

RAG
Retrieval-Augmented Generation.

Random Forest
Ensemble d'arbres de décision (bagging).

Ridge Regression
Régression linéaire avec régularisation L2.

SHAP
Explicabilité basée sur la théorie des jeux.

SMOTE
Rééquilibrage par sur-échantillonnage synthétique.

TOPSIS
Classement par proximité à la solution idéale.

WSM
Somme pondérée des scores par critère.